

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

Thái Thị Kim Huyền - Trần Thị Mỹ Ý

ĐỀ XUẤT KHUNG PHÂN TÍCH HỖ TRỢ
SINH VIÊN PHÂN TÍCH DỮ LIỆU
TUYỂN DỤNG

KHÓA LUẬN TỐT NGHIỆP CỬ NHÂN CNTT
CHƯƠNG TRÌNH CHUẨN

Tp. Hồ Chí Minh, tháng 08/2026

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

Thái Thị Kim Huyền - 22127169
Trần Thị Mỹ Ý - 22127468

ĐỀ XUẤT KHUNG PHÂN TÍCH HỖ TRỢ
SINH VIÊN PHÂN TÍCH DỮ LIỆU
TUYỂN DỤNG

KHÓA LUẬN TỐT NGHIỆP CỬ NHÂN CNTT
CHƯƠNG TRÌNH CHUẨN

GIẢNG VIÊN HƯỚNG DẪN
TS. Vũ Thị Mỹ Hằng

Tp. Hồ Chí Minh, tháng 08/2026

Lời cam đoan

Nhóm xin cam đoan rằng khóa luận tốt nghiệp với đề tài "**Đề xuất khung phân tích hỗ trợ sinh viên phân tích dữ liệu tuyển dụng**" là công trình nghiên cứu và phát triển độc lập của tập thể nhóm tác giả, được thực hiện dưới sự hướng dẫn chuyên môn trực tiếp của TS. Vũ Thị Mỹ Hằng.

Toàn bộ mã nguồn hệ thống, quy trình thực nghiệm, dữ liệu thu thập, kết quả nghiên cứu và các nhận định được trình bày trong khóa luận là trung thực, khách quan và do nhóm tự thực hiện. Khóa luận này chưa từng được nộp hoặc công bố tại bất kỳ học viện hay trường đại học nào khác để nhận học vị cử nhân hoặc các văn bằng tương đương.

Mọi nguồn tài liệu, thông tin tham khảo, ý kiến và kết quả từ các tác giả khác được trích dẫn trong khóa luận đều được chỉ rõ nguồn gốc và ghi nhận đầy đủ trong danh mục tài liệu tham khảo, tuân thủ đúng các quy định về trung thực học thuật.

Nhóm hoàn toàn chịu trách nhiệm trước Hội đồng khoa học và trước pháp luật về tính trung thực và các cam đoan trên.

Tp. Hồ Chí Minh, ngày 3 tháng 6 năm 2026

Tác giả khóa luận

Thái Thị Kim Huyền Trần Thị Mỹ Ý

Thuyết minh chỉnh sửa đề tài

Bản thuyết minh chỉnh sửa đề tài (nếu có thay đổi tên đề tài, nội dung báo cáo, ... trong cuốn báo cáo sau bảo vệ)

Nhận xét hướng dẫn

Bản nhận xét của giảng viên hướng dẫn (có chữ ký) do giáo vụ cung cấp.

Nhận xét phản biện

Bản nhận xét của giảng viên phản biện (có chữ ký) do giáo vụ cung cấp.

Lời cảm ơn

Đề tài "**Đề xuất khung phân tích hỗ trợ sinh viên phân tích dữ liệu tuyến dụng**" là công trình nghiên cứu và hiện thực hóa khóa luận tốt nghiệp của nhóm sau một quãng thời gian học tập và rèn luyện tại Khoa Công nghệ Thông tin, Trường Đại học Khoa học Tự Nhiên — Đại học Quốc gia Thành phố Hồ Chí Minh. Trong suốt hành trình thực hiện đề tài, nhóm đã nhận được rất nhiều sự quan tâm, định hướng, động viên và hỗ trợ tận tình từ quý Thầy Cô, gia đình và bạn bè. Nhờ đó, nhóm mới có thể hoàn thành tốt khóa luận theo đúng mục tiêu đã đề ra. Nhóm xin trân trọng gửi lời cảm ơn chân thành đến tất cả mọi người.

Đầu tiên, nhóm xin gửi lời cảm ơn sâu sắc đến Ban Giám hiệu Nhà trường cùng toàn thể quý Thầy Cô của Trường Đại học Khoa học Tự Nhiên — Đại học Quốc gia Thành phố Hồ Chí Minh, đặc biệt là quý Thầy Cô trong Khoa Công nghệ Thông tin. Trong bốn năm học tập và rèn luyện, nhóm đã được truyền đạt một nền tảng kiến thức chuyên môn vững chắc, cùng phương pháp tư duy khoa học cần thiết để làm hành trang trên con đường sự nghiệp.

Đặc biệt, nhóm xin bày tỏ lòng biết ơn chân thành và sâu sắc nhất đến **TS. Vũ Thị Mỹ Hằng**, giảng viên hướng dẫn trực tiếp của đề tài. Trong suốt quá trình thực hiện khóa luận, Cô đã tận tình định hướng về mặt học thuật và chuyên môn, theo sát tiến độ nghiên cứu, chỉ ra những điểm cần cải thiện và luôn sẵn lòng giải đáp mọi thắc mắc của nhóm. Những lời nhận xét thẳng thắn và những góp ý chi tiết của Cô chính là kim chỉ nam giúp nhóm hoàn thiện từng trang khóa luận.

Nhóm cũng xin gửi lời cảm ơn đến quý Thầy, Cô trong Bộ môn **Hệ thống thông tin** và quý Thầy, Cô trong Hội đồng phản biện đã dành thời gian đọc và đóng góp những ý kiến quý báu, giúp đề tài được hoàn thiện hơn về cả chiều sâu kỹ thuật lẫn cách trình bày.

Nhóm xin gửi lời tri ân sâu sắc đến gia đình, đặc biệt là cha mẹ — những người đã âm thầm hy sinh, luôn là chỗ dựa tinh thần vững chắc nhất và không ngừng tạo mọi điều kiện tốt nhất để chúng em có thể học tập và phát triển. Những lời động viên và niềm tin của gia đình chính là nguồn sức mạnh lớn nhất giúp nhóm vượt qua những giai đoạn khó khăn nhất của quá trình nghiên cứu.

Cuối cùng, nhóm xin cảm ơn tập thể bạn bè, những người đã luôn sẵn sàng hỗ trợ, cùng thảo luận và chia sẻ kinh nghiệm, tạo nên một môi trường học tập tích cực và đầy cảm hứng suốt những năm tháng đại học.

Mặc dù nhóm đã cố gắng thực hiện với tất cả sự nghiêm túc và nỗ lực, song khóa luận chắc chắn không tránh khỏi những thiếu sót. Nhóm rất mong nhận được những ý kiến đóng góp từ quý Thầy Cô và các bạn đọc để đề tài ngày càng hoàn thiện hơn.

Xin trân trọng cảm ơn!

Tp. Hồ Chí Minh, ngày 3 tháng 6 năm 2026

Nhóm sinh viên thực hiện

Thái Thị Kim Huyền Trần Thị Mỹ Ý

Đề cương chi tiết

Bản đề cương đã thực hiện và nộp cho giáo vụ trước đó (*phải có chữ ký của giảng viên hướng dẫn*).

Danh mục các chữ viết tắt

- **AI** – Artificial Intelligence (Trí tuệ nhân tạo)
- **API** – Application Programming Interface (Giao diện lập trình ứng dụng)
- **CV** – Curriculum Vitae (Hồ sơ xin việc)
- **ERD** – Entity Relationship Diagram (Sơ đồ thực thể mối quan hệ)
- **ETL** – Extract, Transform, Load (Trích xuất, biến đổi, lưu trữ)
- **F1-Score** – Điểm F1 (độ đo hài hòa giữa Precision và Recall)
- **GTS** – Ground Truth Set (Tập dữ liệu kiểm thử chuẩn)
- **LLM** – Large Language Model (Mô hình ngôn ngữ lớn)
- **NER** – Named Entity Recognition (Nhận diện thực thể có tên)
- **NLP** – Natural Language Processing (Xử lý ngôn ngữ tự nhiên)
- **Precision** – Độ chính xác (tỷ lệ dự đoán đúng trong tất cả dự đoán dương)
- **Recall** – Độ nhớ lại (tỷ lệ dự đoán đúng trong tất cả mẫu dương thực tế)
- **UI** – User Interface (Giao diện người dùng)

- **UML** – Unified Modeling Language (Ngôn ngữ mô hình hóa thống nhất)
- **URL** – Uniform Resource Locator (Địa chỉ tài nguyên thống nhất)

Mục lục

Lời cảm ơn	i
Đề cương	iii
Danh mục các chữ viết tắt	iv
Mục lục	vi
Danh sách hình	xi
Danh sách bảng	xiii
Tóm tắt	xiv
1 Giới thiệu	1
1.1 Bối cảnh và Lý do chọn đề tài	1
1.2 Phát biểu bài toán	2
1.2.1 Vấn đề chuẩn hóa thực thể và đánh giá khoảng cách năng lực ứng viên	2
1.3 Khảo sát các giải pháp hiện tại và Hạn chế	3
1.4 Giải pháp đề xuất và Cách tiếp cận	4
1.5 Mục tiêu và Đối tượng nghiên cứu	5
1.5.1 Mục tiêu đề tài	5
1.5.2 Phạm vi của đề tài	5
1.6 Ý nghĩa khoa học và thực tiễn (Đóng góp của đề tài) . . .	6

1.7	Cấu trúc cuốn luận văn	7
2	Cơ sở lý thuyết và công nghệ	9
2.1	Các nghiên cứu và hệ thống liên quan	9
2.1.1	Tổng quan về các nền tảng tuyển dụng và hệ thống gợi ý hiện tại	9
2.1.2	Khoảng trống nghiên cứu và Giải pháp đề xuất . .	10
2.2	Giải pháp phân tích thị trường lao động	11
2.2.1	Xác định yêu cầu nghiệp vụ thu thập dữ liệu tuyển dụng	11
2.2.2	Xác định yêu cầu xử lý và tổ chức dữ liệu thu thập	14
2.2.3	Quy trình trích xuất, biến đổi và lưu trữ dữ liệu trong phân tích dữ liệu lớn	15
2.2.4	Yêu cầu trực quan hóa thông tin hỗ trợ ra quyết định	18
2.2.5	Nguyên lý trực quan hóa thông tin hỗ trợ ra quyết định	18
2.3	Giải pháp so khớp hồ sơ	21
2.3.1	Xác định yêu cầu nghiệp vụ của bài toán so khớp hồ sơ	21
2.3.2	Lý thuyết không gian vector và kỹ thuật tạo vector nhúng	22
2.3.3	Phương pháp định lượng hóa độ tương đồng ngữ nghĩa bằng độ đo Cosine và Trọng số TF-IDF từ thị trường	25
2.3.4	Khảo sát các công cụ và thuật toán so khớp hồ sơ hiện có	28
2.4	Trích xuất thực thể trong quản lý thị trường việc làm . . .	31
2.4.1	Bài toán bóc tách thông tin kỹ năng, vị trí công việc từ văn bản	31
2.4.2	Ứng dụng mô hình ngôn ngữ lớn (LLM) và câu lệnh để chuẩn hóa dữ liệu	32

3	Phân tích và thiết kế hệ thống	35
3.1	Phân tích yêu cầu hệ thống	35
3.1.1	Yêu cầu nghiệp vụ	35
3.1.2	Yêu cầu chức năng	36
3.1.3	Yêu cầu phi chức năng	39
3.2	Thiết kế hệ thống	42
3.2.1	Sơ đồ kiến trúc tổng thể	42
3.2.2	Sơ đồ Use Case tổng quát	43
3.2.3	Sơ đồ tuần tự cho các chức năng chính	49
3.3	Thiết kế cơ sở dữ liệu	52
3.3.1	Sơ đồ mối quan hệ thực thể (ERD)	52
3.3.2	Đặc tả các bảng dữ liệu thực tế	53
3.4	Thiết kế giao diện	69
3.4.1	Trang chủ và Dashboard thống kê thị trường việc làm	69
3.4.2	Trang quản lý CV và kết quả so khớp năng lực . .	74
3.5	Thiết kế thuật toán phân tích khoảng cách năng lực	79
3.5.1	Luồng xử lý từ lúc người dùng upload CV đến khi nhận kết quả so khớp	79
3.5.2	Thuật toán so sánh tập kỹ năng trong CV với yêu cầu của Job để tính tỷ lệ tương thích	83
4	Xây dựng hệ thống	87
4.1	Lựa chọn công nghệ	87
4.1.1	Công nghệ Frontend	87
4.1.2	Công nghệ Backend và Cơ sở dữ liệu	88
4.1.3	Công nghệ Thu thập và Xử lý AI	89
4.1.4	Hạ tầng và công cụ triển khai	90
4.2	Kiến trúc tích hợp và xử lý luồng dữ liệu	90
4.2.1	Cài đặt các module thu thập dữ liệu tin tuyển dụng tự động	90

4.2.2	Quy trình làm sạch dữ liệu, xử lý trùng lặp và lưu trữ vào PostgreSQL	91
4.3	Xây dựng chức năng cho các phân hệ người dùng	92
4.3.1	Hiện thực hóa các tính năng Quản lý tài khoản, Đăng ký/Đăng nhập (Auth)	92
4.3.2	Hiện thực hóa giao diện Dashboard trực quan hóa dữ liệu thị trường việc làm	93
4.3.3	Hiện thực hóa chức năng Tìm kiếm job, Lưu job và Quản lý danh sách CV	95
4.4	Xây dựng thuật toán phân tích kỹ năng năng lực	95
4.4.1	Xây dựng cấu trúc Structured Output để trích xuất thông tin CV và JD	95
4.4.2	Cài đặt Matching Engine tính độ phù hợp và liệt kê các kỹ năng còn thiếu	96
5	Kiểm thử và Đánh giá	99
5.1	Môi trường triển khai thử nghiệm hệ thống	99
5.2	Kiểm thử chức năng	100
5.2.1	Kịch bản kiểm thử cho các tính năng	100
5.2.2	Kết quả thực thi kiểm thử	101
5.3	Đánh giá hiệu năng và dữ liệu thực tế	101
5.3.1	Thống kê số lượng dữ liệu bài đăng tuyển dụng đã thu thập và xử lý thành công	101
5.3.2	Đánh giá thời gian phản hồi khi gọi API trích xuất và đối soát CV	102
5.4	Kiểm thử độ chính xác và Đánh giá kết quả đầu ra thuật toán (Algorithm Accuracy Evaluation)	104
5.4.1	Đánh giá độ chính xác của định dạng dữ liệu trả về từ mô hình và các thuật toán tiền xử lý	105
5.4.2	Phân tích thực tế một số trường hợp đối soát để chứng minh tính hợp lý của kết quả gợi ý kỹ năng .	114

6	Kết luận	125
6.1	Các kết quả đã đạt được của hệ thống ứng dụng	125
6.2	Hạn chế còn tồn tại của đề tài	126
6.3	Hướng nghiên cứu và phát triển tương lai	127
	Tài liệu tham khảo	129
A	Ngữ pháp tiếng Việt	134
B	Ngữ pháp tiếng Nôm	135

Danh sách hình

2.1	Phân biệt cơ chế hoạt động của kỹ thuật thu thập dữ liệu tĩnh (Static Scraping) và thu thập dữ liệu động (Dynamic Scraping).	12
2.2	Quy trình tổng quát của tiến trình trích xuất, biến đổi và nạp dữ liệu (ETL Pipeline) theo phương pháp luận Kimball.	16
2.3	Luồng dữ liệu từ cơ sở dữ liệu đến các thành phần trực quan hóa trong hệ thống CareerNova.	20
2.4	Kiến trúc SBERT được sử dụng trong suy luận để tính điểm tương đồng ngữ nghĩa.	23
3.1	Sơ đồ kiến trúc tổng thể hệ thống CareerNova.	42
3.2	Sơ đồ Use Case tổng quát của hệ thống CareerNova.	44
3.3	Sơ đồ tuần tự luồng tải lên CV và so khớp kỹ năng.	49
3.4	Sơ đồ tuần tự luồng xem Dashboard thống kê thị trường việc làm.	51
3.5	Sơ đồ mối quan hệ thực thể (ERD) của hệ thống.	52
3.6	Giao diện trang chủ (Landing Page) của hệ thống CareerNova.	70
3.7	Sơ đồ hoạt động mô tả luồng tương tác người dùng với Dashboard thị trường.	72
3.8	Giao diện Dashboard thống kê thị trường việc làm IT, thể hiện thẻ chỉ số tổng quan, AreaChart xu hướng tuyển dụng, Treemap phân bố thị trường, Top 5 vị trí và hai lưới kỹ năng.	73

3.9	Giao diện trang CV Matching: cột trái quản lý CV, cột phải vùng tải lên, kết quả so khớp với Match Score và phân loại kỹ năng.	75
3.10	Sơ đồ hoạt động mô tả luồng tương tác từ tải lên CV đến xem kết quả Skill Gap Analysis.	77
3.11	Giao diện trang Skill Gap Analysis: biểu đồ Radar so khớp kỹ năng và Gap Report phân loại kỹ năng theo danh mục.	78
3.12	Sơ đồ luồng xử lý từ khi người dùng tải CV lên đến khi nhận kết quả so khớp.	80
3.13	Quy tắc phân loại kỹ năng phục vụ báo cáo khoảng cách năng lực.	85

Danh sách bảng

2.1	So sánh các thể hệ hệ thống ATS theo công nghệ cốt lõi, ưu nhược điểm và chi phí vận hành.	28
3.1	Danh sách yêu cầu chức năng của hệ thống CareerNova. .	36
3.2	Danh sách yêu cầu phi chức năng của hệ thống CareerNova.	39
3.3	Đặc tả Use Case UC-09: Tải lên CV và So khớp kỹ năng. .	45
3.4	Đặc tả Use Case UC-11: Xem Gap Report và báo cáo khoảng cách kỹ năng.	46
3.5	Đặc tả Use Case UC-16: Xem Dashboard thống kê thị trường việc làm.	47
3.6	Cấu trúc bảng <code>users</code>	53
3.7	Cấu trúc bảng <code>user_auth_providers</code>	54
3.8	Cấu trúc bảng <code>user_cvs</code>	55
3.9	Cấu trúc bảng <code>skills</code>	56
3.10	Cấu trúc bảng <code>user_cv_skills</code>	58
3.11	Cấu trúc bảng <code>companies</code>	58
3.12	Cấu trúc bảng <code>jobs</code>	59
3.13	Cấu trúc bảng <code>job_skills</code>	61
3.14	Cấu trúc bảng <code>cv_job_matches</code>	63
3.15	Cấu trúc bảng <code>job_group_skill_weights</code>	64
3.16	Cấu trúc bảng <code>salaries</code>	65
3.17	Cấu trúc bảng <code>saved_jobs</code>	66

5.6	Bảng đối soát thống kê kết quả thực nghiệm trích xuất thực thể kỹ năng (NER) theo tập dữ liệu	106
5.7	Bảng chỉ số đánh giá độ chính xác định dạng dữ liệu và NER từ mô hình	107
5.8	Biểu mẫu đối soát kết quả chuẩn hóa kỹ năng và khớp mờ doanh nghiệp	109
5.9	Bảng đánh giá chất lượng chuẩn hóa kỹ năng và gộp nhóm doanh nghiệp	110
5.10	Biểu mẫu đối soát kết quả phát hiện trùng lặp sâu tin đăng	112
5.11	Bảng đánh giá chất lượng thuật toán khử trùng lặp bài đăng	113
5.12	Bảng đánh giá độ chính xác thuật toán so khớp năng lực Matching Engine	115
5.13	Bảng phân tích đối soát chi tiết Case Study ứng viên Backend Developer	118
5.1	Kịch bản kiểm thử chức năng hệ thống	121
5.2	Kết quả thực thi kiểm thử chức năng	122
5.3	Snapshot dữ liệu tuyển dụng tại thời điểm kiểm thử (13/07/2026)	123
5.4	Thời gian phản hồi thực đo của sáu API Dashboard thị trường (đo ngày 13/07/2026)	124
5.5	Bảng tổng hợp thời gian phản hồi theo thao tác người dùng (đo ngày 13/07/2026)	124

Tóm tắt Khóa luận

Tiếng Việt

Đề tài "**Đề xuất khung phân tích hỗ trợ sinh viên phân tích dữ liệu tuyển dụng**" được thực hiện nhằm giải quyết bài toán thiếu hụt công cụ hỗ trợ sinh viên đánh giá định lượng khoảng cách năng lực của bản thân so với yêu cầu thực tế của thị trường lao động. Trong bối cảnh dữ liệu tuyển dụng trực tuyến ngày càng phong phú nhưng thiếu tính chuẩn hóa, các hệ thống đối soát hồ sơ truyền thống chủ yếu dựa trên so khớp từ khóa chính xác (Exact Keyword Matching) dẫn đến nhiều hạn chế về tính chính xác và tính linh hoạt ngữ nghĩa. Luận văn đề xuất và hiện thực hóa hệ thống *CareerNova* — một nền tảng thông minh tích hợp Pipeline Dữ liệu lớn (ETL), Mô hình ngôn ngữ lớn (LLM) và Xử lý ngôn ngữ tự nhiên (NLP) nhằm trực quan hóa xu hướng thị trường và tự động hóa quy trình đối soát hồ sơ (CV Matching).

Hệ thống được thiết kế với ba phân hệ cốt lõi: (1) Phân hệ thu thập và chuẩn hóa dữ liệu tự động từ các nền tảng tuyển dụng lớn, áp dụng kỹ thuật *Structured Outputs* từ LLM kết hợp thuật toán chống ảo giác để đảm bảo chất lượng dữ liệu đầu vào; (2) Phân hệ trực quan hóa dữ liệu thị trường với các Dashboard tương tác giúp người dùng nắm bắt xu hướng kỹ năng, quyền lợi và nhu cầu tuyển dụng theo thời gian; và (3) Phân hệ đối soát ngữ nghĩa dựa trên vector nhúng SBERT (Sentence-BERT) và trọng số TF-IDF được tính toán động từ thị trường, vượt trội hơn so với các phương pháp so khớp từ khóa truyền thống.

Kết quả thực nghiệm trên môi trường kiểm thử cho thấy hệ thống hoạt động ổn định và chính xác. Pipeline ETL đã thu thập và làm sạch thành công 42.520 tin tuyển dụng, đạt tỷ lệ dữ liệu sạch 74,66%. Trong bài toán trích xuất kỹ năng bằng LLM, hệ thống đạt độ chính xác (Precision) 87,5%, độ phủ (Recall) 84,2% và F1-Score 85,8%. Toàn bộ 15/15 kịch bản kiểm thử tích hợp (Integration Test) đều vượt qua thành công, với thời gian phản hồi trung bình của API đối soát đạt 1,45 giây. Luận văn đóng góp một giải pháp có tính ứng dụng thực tiễn cao, cân bằng giữa chất lượng mô hình LLM và hiệu năng của hệ thống vector cục bộ, tạo ra một công cụ hỗ trợ ra quyết định nghề nghiệp đặc lực cho sinh viên trong thời đại số.

Abstract (English)

This thesis, titled "**Proposal of an Analytical Framework to Assist Students in Analyzing Recruitment Data**", addresses a critical gap in career development support: the absence of a quantitative tool helping students accurately assess their skill gaps against the real-world demands of the IT labor market. As online recruitment data grows increasingly abundant yet unstructured, conventional profile-matching systems that rely on Exact Keyword Matching suffer from significant limitations in semantic flexibility and precision. To overcome these challenges, this thesis proposes and implements the *CareerNova* system — an intelligent platform integrating Big Data ETL Pipelines, Large Language Models (LLMs), and Natural Language Processing (NLP) to visualize market trends and automate the CV Matching process.

The system is designed with three core subsystems: (1) An automated data collection and normalization pipeline from major recruitment platforms, applying *Structured Output* techniques from LLMs combined with an anti-hallucination validation mechanism to ensure high-quality input data; (2) An interactive data visualization module with dynamic dash-

boards enabling users to explore trends in skills, benefits, and hiring demands over time; and (3) A semantic matching engine based on SBERT (Sentence-BERT) embeddings and dynamically computed TF-IDF market weights, significantly outperforming traditional keyword-based approaches.

Experimental results demonstrate stable and highly accurate system performance. The ETL pipeline successfully collected and cleaned 42,520 job postings, achieving a clean data rate of 74.66%. In the LLM-based skill extraction task, the system achieved a Precision of 87.5%, Recall of 84.2%, and F1-Score of 85.8%. All 15/15 integration test cases passed successfully, with an average API response time of 1.45 seconds. This thesis contributes a highly practical solution that balances the expressiveness of LLM-based extraction with the performance of local vector search, ultimately creating a data-driven career decision support tool for students in the digital era.

Chương 1

Giới thiệu

1.1 Bối cảnh và Lý do chọn đề tài

Trong kỷ nguyên số hóa, dữ liệu tuyển dụng trực tuyến ngày càng phong phú nhưng thường tồn tại dưới dạng rời rạc và không nhất quán, gây khó khăn cho sinh viên trong việc theo dõi và phân tích thực trạng thị trường lao động. Các nền tảng tuyển dụng hiện nay chủ yếu tập trung vào việc đăng tin và tìm kiếm ứng viên, trong khi khả năng tổng hợp và phân tích dữ liệu nhằm hỗ trợ người học đối chiếu năng lực cá nhân với yêu cầu thị trường vẫn còn nhiều hạn chế.

- Sự phát triển nhanh chóng của các nền tảng tuyển dụng trực tuyến (LinkedIn, Vietnamworks, CareerViet, Itviec, v.v.) tạo ra khối lượng dữ liệu lớn chưa từng có.
- Nhu cầu cấp thiết về việc chuẩn hóa và phân tích dữ liệu việc làm từ nhiều nguồn khác nhau.
- Khó khăn trong việc kết nối hiệu quả giữa các nhu cầu nhân sự của doanh nghiệp và những kỹ năng thực tế của ứng viên.

Do đó, việc xây dựng một hệ thống thông minh có khả năng khai phá, chuẩn hóa và phân tích dữ liệu tuyển dụng từ nhiều nguồn trở thành một

nhu cầu cấp thiết, giúp sinh viên ngành Công nghệ Thông tin (IT) năm cuối định hình và bù đắp khoảng cách năng lực trước khi bước vào thị trường lao động.

1.2 Phát biểu bài toán

Bài toán cốt lõi mà luận văn giải quyết là sự thiếu hụt một công cụ đánh giá năng lực định lượng và chuẩn hóa ngữ nghĩa chuyên sâu cho thị trường lao động CNTT tại Việt Nam. Cụ thể, các thách thức kỹ thuật bao gồm:

- **Tính không đồng nhất:** Các nền tảng khác nhau sử dụng các định dạng, cấu trúc dữ liệu khác nhau để lưu trữ thông tin công việc.
- **Dữ liệu trùng lặp:** Một công việc có thể được đăng trên nhiều nền tảng tuyển dụng khác nhau, dẫn đến sự trùng lặp dữ liệu thô.
- **Dữ liệu bất đầy đủ:** Thông tin công việc trên các trang Web có thể thiếu những trường quan trọng hoặc không được chuẩn hóa.
- **Khó khăn trong trích xuất thông tin:** Thông tin kỹ năng, yêu cầu công việc thường nhúng trong mô tả công việc (Job Description — JD) dạng văn bản tự do, gây khó khăn cho việc trích xuất tự động.

1.2.1 Vấn đề chuẩn hóa thực thể và đánh giá khoảng cách năng lực ứng viên

Ngay cả khi dữ liệu được thu thập, vấn đề tiếp theo là chuẩn hóa các thực thể (như kỹ năng, vị trí công việc, công ty, v.v.) và so sánh chúng một cách có ý nghĩa:

- **Chuẩn hóa kỹ năng:** Cùng một kỹ năng có thể được gọi bằng nhiều tên hoặc biến thể viết tắt khác nhau (ví dụ: “Python Programming”, “Python Development”, “Python Coding”).

- **Hiểu biết ngữ nghĩa:** Cần hiểu được các mối quan hệ tương đồng hoặc tương đương ngữ nghĩa (ví dụ: “Machine Learning” có liên quan mật thiết đến “Data Science” hoặc “Artificial Intelligence”).
- **Đánh giá khoảng cách:** Cần một phương pháp tính toán định lượng khách quan để so sánh tập kỹ năng yêu cầu của công việc với tập kỹ năng hiện có trên hồ sơ ứng viên (CV), từ đó đưa ra báo cáo chi tiết.

1.3 Khảo sát các giải pháp hiện tại và Hạn chế

Trong các nghiên cứu và ứng dụng thực tiễn, bài toán kết nối hồ sơ năng lực với yêu cầu tuyển dụng đã được giải quyết qua một số thể hệ công nghệ chính:

- **Hệ thống ATS truyền thống (Rule-based & Keyword Matching):** Hoạt động dựa trên việc so khớp từ khóa chính xác thông qua các biểu thức chính quy (Regex).
Hạn chế: Hoàn toàn bỏ sót các từ đồng nghĩa hoặc các kỹ năng tương đương ngữ nghĩa (như không nhận diện được "Git" liên quan đến "Version Control"), đồng thời dễ bị gian lận bằng kỹ thuật nhồi từ khóa (keyword stuffing) trong CV.
- **Giải pháp học máy truyền thống:** Sử dụng mô hình túi từ (Bag of Words) hoặc các biểu diễn vector thưa như TF-IDF tính từ từ vựng để tính toán độ tương đồng.
Hạn chế: Bỏ qua trật tự từ và ngữ cảnh câu văn, dẫn đến hiệu quả so khớp thấp đối với các cụm từ kỹ năng phức tạp.
- **Giải pháp sử dụng mô hình ngôn ngữ lớn (LLM API) thuần túy:** Sử dụng các API thương mại của các mô hình ngôn ngữ lớn để

đọc hiểu và đánh giá trực tiếp hồ sơ ứng viên.

Hạn chế: Chi phí gọi API rất cao khi xử lý hàng loạt, độ trễ phản hồi (latency) lớn (vài giây), không thể đáp ứng nhu cầu tìm kiếm, phân tích dữ liệu lớn và trực quan hóa thời gian thực trên giao diện người dùng.

1.4 Giải pháp đề xuất và Cách tiếp cận

Để giải quyết triệt để các hạn chế nêu trên, đề tài đề xuất hệ thống *CareerNova* — một nền tảng thông minh áp dụng mô hình lai kết hợp giữa sức mạnh hiểu ngữ cảnh của Generative AI và tốc độ của mô hình biểu diễn ngữ nghĩa cục bộ:

- **Khâu tiền xử lý và cấu trúc hóa dữ liệu (ETL Pipeline):** Hệ thống tích hợp thư viện cào dữ liệu để thu thập tin tuyển dụng. Ở tầng biến đổi, hệ thống gọi mô hình ngôn ngữ lớn Gemini API thông qua cấu hình Pydantic Schema (Structured Outputs) để bóc tách thông tin thô thành các trường dữ liệu JSON cấu trúc. Để loại bỏ hiện tượng ảo giác (hallucination) của LLM, cơ chế hậu kiểm dựa trên bằng chứng (evidence-based validation) được triển khai để kiểm chứng thực thể kỹ năng.
- **Khâu so khớp và phân tích khoảng cách năng lực (Matching Engine):** Sử dụng mô hình Sentence-BERT cục bộ (all-MiniLM-L6-v2) để chuyển đổi các thực thể kỹ năng chuẩn hóa thành vector nhúng 384 chiều, kết hợp thư viện FAISS của Meta để lập chỉ mục ngữ nghĩa và tìm kiếm siêu tốc. Thuật toán so khớp áp dụng công thức tính điểm tương đồng Cosine có trọng số TF-IDF động (Inverse Document Frequency được tính toán thực tế từ cơ sở dữ liệu thị trường Việt Nam) để đảm bảo các kỹ năng khan hiếm có tiếng nói quyết định hơn các kỹ năng đại trà.

1.5 Mục tiêu và Đối tượng nghiên cứu

1.5.1 Mục tiêu đề tài

Để hỗ trợ sinh viên trong việc phân tích dữ liệu tuyển dụng và định hướng nghề nghiệp, đề tài tập trung vào ba mục tiêu chính:

1. **Thu thập và chuẩn hóa dữ liệu:** Xây dựng khung công tác (framework) tự động thu thập dữ liệu tuyển dụng từ nhiều nền tảng Web, phát hiện và loại bỏ dữ liệu trùng lặp, chuẩn hóa các trường dữ liệu theo quy chuẩn chung.
2. **So khớp hồ sơ thông minh:** Sử dụng công nghệ Xử lý ngôn ngữ tự nhiên (NLP) và Mô hình ngôn ngữ lớn (LLM) để phân tích hồ sơ ứng viên (CV) và thực hiện Phân tích khoảng cách kỹ năng (Skill Gap Analysis) tương ứng với các công việc phù hợp.
3. **Trực quan hóa dữ liệu:** Xây dựng giao diện người dùng cung cấp các dashboard, biểu đồ trực quan giúp các bên liên quan (nhà tuyển dụng, ứng viên, nhà hoạch định chính sách) hiểu rõ hơn về thị trường lao động.

1.5.2 Phạm vi của đề tài

Đề tài ứng dụng tập trung trực quan hóa nhu cầu tuyển dụng và tự đánh giá kỹ năng. Phạm vi được cụ thể hóa như sau:

- Dữ liệu bài đăng tuyển dụng từ 4 nền tảng Web: LinkedIn, Vietnamworks, CareerViet, Itviec.
- Hồ sơ xin việc (CV) của ứng viên là sinh viên ngành IT năm cuối.
- Thông tin yêu cầu kỹ năng của các tin tuyển dụng.

Phạm vi nghiên cứu:

- Tập trung vào các bài đăng tuyển dụng lĩnh vực Công nghệ Thông tin (IT).
- Khoảng thời gian dữ liệu: Năm 2025–2026.
- Địa chỉ địa lý: Chủ yếu tập trung vào thị trường Việt Nam.

1.6 Ý nghĩa khoa học và thực tiễn (Đóng góp của đề tài)

Ý nghĩa khoa học (Đóng góp về phương pháp & dữ liệu):

- Thiết lập một quy trình ETL lai tối ưu: Kết hợp trích xuất thực thể bằng Generative AI (chống ảo giác bằng hậu kiểm) và so khớp ngữ nghĩa bằng SBERT cục bộ cùng chỉ mục FAISS, giải quyết đồng thời ba yếu tố: độ chính xác ngữ nghĩa, chi phí vận hành và tốc độ phản hồi thời gian thực.
- Xây dựng tập dữ liệu thị trường việc làm ngành IT tại Việt Nam với quy mô 6.729 tin tuyển dụng sạch được xử lý và lưu trữ trong cơ sở dữ liệu hệ thống, chủ yếu thu thập trong năm 2026.
- Xây dựng bộ dữ liệu đối soát chuẩn (Ground Truth) gồm 100 tài liệu ngẫu nhiên (50 CV, 50 JD) được gán nhãn thực tế bởi nhóm thực hiện đề tài để phục vụ kiểm chứng thực tế.

Ý nghĩa thực tiễn (Đóng góp ứng dụng):

- **Cho sinh viên IT năm cuối (Ứng viên):** Giúp sinh viên tự đánh giá mức độ tương thích của bản thân với nhu cầu tuyển dụng thực tế của thị trường năm 2026. Biểu đồ trực quan (Radar chart) và Báo cáo khoảng cách kỹ năng (Gap report) giúp sinh viên nhận diện rõ các kỹ năng còn thiếu, định hướng học tập và bổ sung kịp thời

để đáp ứng tiêu chuẩn tuyển dụng. Đồng thời hỗ trợ sinh viên định hình bức tranh toàn cảnh về thị trường việc làm IT thông qua các bảng thống kê trực quan (dashboard).

- **Cho nhà tuyển dụng:** Cung cấp cái nhìn sâu sắc về nhu cầu kỹ năng thực tế, hỗ trợ quá trình sàng lọc hồ sơ ứng viên dựa trên độ đo tương đồng ngữ nghĩa chính xác hơn.
- **Cho cơ sở đào tạo:** Dữ liệu phân tích từ hệ thống có thể giúp các khoa chuyên ngành tham khảo để điều chỉnh chương trình đào tạo sát hơn với nhu cầu thực tiễn của doanh nghiệp.

1.7 Cấu trúc cuốn luận văn

Ngoài chương Giới thiệu này, luận văn gồm 5 chương chính:

- **Chương 2 - Cơ sở lý thuyết và Công nghệ:** Trình bày các khái niệm cơ bản về quy trình khai phá dữ liệu, nguyên lý trực quan hóa, và nền tảng các mô hình AI (LLM, SBERT) ứng dụng trong chuẩn hóa và đối soát.
- **Chương 3 - Phân tích và Thiết kế hệ thống:** Trình bày chi tiết phân tích yêu cầu, thiết kế kiến trúc, sơ đồ cơ sở dữ liệu, và quy trình xử lý luồng dữ liệu (ETL pipeline).
- **Chương 4 - Xây dựng hệ thống:** Đặc tả các khía cạnh kỹ thuật trong quá trình hiện thực hóa hệ thống, bao gồm thuật toán làm sạch, kỹ thuật Prompting, và logic tính toán độ tương đồng (Cosine Similarity).
- **Chương 5 - Kiểm thử và Đánh giá:** Đánh giá định lượng hiệu suất hệ thống, chất lượng dữ liệu, và kết quả kiểm thử trên các kịch bản sử dụng (Test Matrix).

- **Chương 6 - Kết luận:** Tổng kết kết quả, bài học kinh nghiệm và định hướng phát triển tương lai.

Các phần phụ trợ bao gồm: Danh mục chữ viết tắt, Danh sách hình vẽ, Danh sách bảng biểu, Tóm tắt khóa luận (Abstract), Danh sách tài liệu tham khảo, và Phụ lục chứa các hình vẽ, bảng biểu chi tiết.

Chương 2

Cơ sở lý thuyết và công nghệ

2.1 Các nghiên cứu và hệ thống liên quan

2.1.1 Tổng quan về các nền tảng tuyển dụng và hệ thống gợi ý hiện tại

Trên thị trường hiện nay, có nhiều nền tảng tuyển dụng lớn đang hoạt động như LinkedIn, TopCV, VietnamWorks, hay Indeed. Hầu hết các hệ thống này tập trung vào chức năng đăng tải thông tin việc làm và cung cấp bộ lọc tìm kiếm cơ bản dựa trên chức danh, địa điểm và một số kỹ năng cốt lõi. Trong những năm gần đây, một số hệ thống đã bắt đầu tích hợp các thuật toán học máy cơ bản để gợi ý công việc cho ứng viên dựa trên từ khóa có trong hồ sơ (Resume/CV Matching) [1].

Tuy nhiên, phần lớn các thuật toán đối soát trên các nền tảng này vẫn vận hành dựa trên cơ chế So khớp từ khóa chính xác (Exact Keyword Matching) hoặc các mô hình Boolean truyền thống. Phương pháp này yêu cầu CV của ứng viên phải chứa chính xác các chuỗi ký tự được định nghĩa trong mô tả công việc (Job Description - JD). Điều này bộc lộ nhiều hạn chế nghiêm trọng trong thực tế:

- **Thiếu tính linh hoạt ngôn ngữ:** Một kỹ năng có thể được diễn đạt bằng nhiều cách khác nhau (ví dụ: “JS” và “JavaScript”, “Kỹ

năng lãnh đạo” và “Leadership”). Các hệ thống dựa trên từ khóa sẽ chấm điểm thấp những hồ sơ sử dụng từ đồng nghĩa hoặc biến thể ngôn ngữ.

- **Không đánh giá được mức độ thành thạo:** Các hệ thống thường chỉ đếm số lượng từ khóa xuất hiện mà không thể hiện được mức độ sâu sắc về chuyên môn hay số năm kinh nghiệm gắn liền với kỹ năng đó.
- **Không hiểu ngữ cảnh (Contextual Ignorance):** Hệ thống không thể phân biệt được một kỹ năng xuất hiện với tư cách là yêu cầu chính yếu của công việc hay chỉ là một kỹ năng phụ trợ mang tính chất “nice-to-have”.

2.1.2 Khoảng trống nghiên cứu và Giải pháp đề xuất

Qua phân tích các nghiên cứu và hệ thống hiện có, luận văn nhận thấy tồn tại một **khoảng trống nghiên cứu (Research Gap)** rõ rệt: Chưa có một giải pháp toàn diện nào kết hợp khả năng thu thập dữ liệu thị trường tự động, chuẩn hóa dữ liệu bằng trí tuệ nhân tạo tạo sinh, và đánh giá định lượng khoảng cách năng lực dựa trên ngữ nghĩa chuyên sâu dành riêng cho sinh viên ngành CNTT tại Việt Nam.

Để lấp đầy khoảng trống này, hệ thống *CareerNova* được đề xuất với một cách tiếp cận hoàn toàn mới:

1. **Thay thế Exact Matching bằng Semantic Matching:** Sử dụng các mô hình ngôn ngữ lớn (LLM) như Google Gemini để trích xuất và chuẩn hóa thực thể kỹ năng, loại bỏ hoàn toàn rào cản về biến thể ngôn ngữ và chữ viết tắt.
2. **Mô hình hóa không gian vector:** Áp dụng Sentence-BERT (SBERT) kết hợp với trọng số TF-IDF được tính toán động từ dữ liệu thị trường để đánh giá độ tương đồng ngữ nghĩa giữa hồ sơ ứng viên và yêu cầu công việc một cách khách quan, chính xác hơn.


2.2 Giải pháp phân tích thị trường lao động

2.2.1 Xác định yêu cầu nghiệp vụ thu thập dữ liệu tuyển dụng

Kỹ thuật khai thác thông tin tự động từ môi trường Internet là một trong những phân nhánh quan trọng của khoa học dữ liệu, hỗ trợ đắc lực cho việc thu thập thông tin thị trường lao động theo thời gian thực [2]. Trong nghiên cứu học thuật và ứng dụng thực tiễn, cần phân biệt rõ ràng hai khái niệm thường bị nhầm lẫn: Thu thập liên kết ứng dụng Web (Web Crawling) và Trích xuất dữ liệu Web (Web Scraping) [3].

Quá trình Web Crawling được định nghĩa là việc duyệt mạng Internet một cách hệ thống và tự động bởi các tác nhân phần mềm nhằm mục đích lập chỉ mục nội dung trang web phục vụ cho các công cụ tìm kiếm [3]. Cơ chế hoạt động của một bộ thu thập liên kết (crawler) dựa trên việc bắt đầu từ một danh sách các địa chỉ mạng gốc (seed URLs), liên tục phân tích các siêu liên kết (hyperlinks) xuất hiện trong tài liệu HTML thu về, rồi đưa chúng vào một danh sách hàng đợi các liên kết cần truy cập tiếp theo (gọi là Crawl Frontier) theo các chính sách quản lý nghiêm ngặt [3].

Ngược lại, Web Scraping tập trung vào một phạm vi hẹp và chuyên sâu hơn, đó là quá trình giả lập hành vi duyệt web của con người để tự động trích xuất các trường thông tin cụ thể, có mục tiêu từ cấu trúc tài liệu của một trang web đích và lưu trữ chúng vào hệ thống tệp tin hoặc cơ sở dữ liệu để phục vụ cho các phân tích chuyên sâu [2].



Hình 2.1: Phân biệt cơ chế hoạt động của kỹ thuật thu thập dữ liệu tĩnh (Static Scraping) và thu thập dữ liệu động (Dynamic Scraping).

Khi triển khai hệ thống thu thập thông tin tuyển dụng, việc lựa chọn phương pháp cào dữ liệu tĩnh dựa trên giao thức truyền tải siêu văn bản (HTTP Requests) hay cào dữ liệu động bằng trình duyệt không giao diện (Headless Browser) quyết định trực tiếp đến hiệu năng và độ ổn định của toàn hệ thống [4].

Phương pháp cào dữ liệu tĩnh sử dụng các thư viện như Python Requests để gửi các yêu cầu GET hoặc POST trực tiếp đến máy chủ của trang tuyển dụng nhằm tải về mã nguồn HTML thô [5]. Phương pháp này sở hữu ưu điểm vượt trội về tốc độ phản hồi nhanh, tiêu thụ băng thông thấp và không yêu cầu năng lực tính toán lớn của CPU [6].

Tuy nhiên, HTTP Requests tĩnh hoàn toàn bất lực trước thế hệ ứng dụng web hiện đại sử dụng cơ chế kết xuất phía máy khách (Client-Side Rendering) thông qua JavaScript hoặc các ứng dụng đơn trang (Single Page Applications) [7]. Đối với các trang tin tuyển dụng có cơ chế tải dữ liệu động thông qua các hành vi cuộn chuột hoặc chuyển trang bất tuần tự, hệ thống bắt buộc phải chuyển sang sử dụng Headless Browser như Selenium [4].

Selenium hoạt động bằng cách khởi tạo một trình duyệt thực thụ chạy ngầm không có giao diện hiển thị, thiết lập kết nối thông qua giao thức chuẩn hóa của tổ chức World Wide Web (W3C WebDriver) để thực thi toàn bộ các đoạn mã JavaScript trên trang, tự động hóa các thao tác click

chuột, điền biểu mẫu, giải quyết phân trang và kết xuất ra cây phân cấp đối tượng tài liệu (Document Object Model — DOM) hoàn chỉnh trước khi tiến hành bóc tách dữ liệu [7]. Điểm hạn chế lớn nhất của Selenium là tiêu tốn bộ nhớ RAM lớn, tốc độ chậm và đòi hỏi tài nguyên hệ thống cao hơn gấp nhiều lần so với các yêu cầu HTTP truyền thống [6].

Bên cạnh vấn đề về mặt công nghệ kết xuất, các rào cản bảo mật từ các nền tảng tuyển dụng lớn như ITViec, VietnamWorks, CareerViet hay LinkedIn tạo ra thách thức không nhỏ cho quá trình thu thập thông tin tự động [8]. Các nền tảng này thường thiết lập các hệ thống tường lửa ứng dụng Web (Web Application Firewall — WAF) như Cloudflare nhằm phát hiện và ngăn chặn bot. Các cơ chế phòng thủ tiêu biểu bao gồm kiểm tra thử thách JavaScript (JS Challenges), hệ thống xác thực Turnstile, phân tích hành vi bất thường, giới hạn tần suất yêu cầu từ một địa chỉ IP (Rate Limiting) và phản hồi mã lỗi 403 Forbidden. Để giải quyết triệt để rào cản này, hệ thống tích hợp thư viện chuyên dụng cloudscraper [9].

Thư viện này hoạt động bằng cách tích hợp các công cụ thực thi JavaScript ngay trong tiến trình Python để giải quyết tự động các thuật toán thử thách của Cloudflare mà không cần khởi chạy một trình duyệt hoàn chỉnh [9]. Đồng thời, cloudscraper thực hiện giả lập chữ ký mã hóa TLS (TLS Fingerprinting) kết hợp với việc thay đổi linh hoạt các tiêu đề HTTP (HTTP Headers) bao gồm chuỗi nhận diện trình duyệt (User-Agent) khớp với các thiết bị di động hoặc máy tính thực tế nhằm vượt qua cơ chế nhận diện bot của WAF [10].

Đánh giá và lý giải lựa chọn: Đối với bài toán cụ thể của hệ thống CareerNova, việc chỉ dùng một trong hai phương pháp đều không tối ưu: cào tĩnh nhanh nhưng bị chặn bởi WAF Cloudflare; cào động vượt WAF nhưng chậm và tốn tài nguyên nếu dùng cho toàn bộ hàng nghìn tin tuyển dụng. Yêu cầu nghiệp vụ về *tính bền vững và hiệu năng* dẫn đến quyết định thiết kế một **cơ chế dự phòng hai tầng (Two-tier Fallback Mechanism)**: hệ thống ưu tiên cào tĩnh để đạt tốc độ tối đa; khi gặp tường lửa WAF chặn, hệ thống tự động kích hoạt luồng dự phòng chuyển sang

Headless Browser với plugin chống phát hiện (Undetected ChromeDriver) và cơ chế xoay vòng proxy, đồng thời áp dụng giãn cách thời gian truy cập ngẫu nhiên để tiếp tục duy trì hoạt động thu thập dữ liệu [11].

Vì vậy, trong hệ thống đề xuất, sự kết hợp giữa cào tĩnh (qua Requests và cloudscraper) và cào động dự phòng (qua Selenium Headless Browser) được lựa chọn nhằm tối ưu hóa đồng thời tốc độ thu thập và tỷ lệ thành công đối với các nền tảng tuyển dụng có cơ chế chống bot nghiêm ngặt.

2.2.2 Xác định yêu cầu xử lý và tổ chức dữ liệu thu thập

Sau khi dữ liệu tuyển dụng được thu thập về, một thách thức nghiệp vụ tiếp theo được đặt ra: dữ liệu thô từ nhiều nguồn khác nhau (ITViec, VietnamWorks, LinkedIn...) có định dạng HTML và cấu trúc nội dung hoàn toàn không đồng nhất. Dữ liệu này cần được chuẩn hóa và tổ chức vào một cấu trúc nhất quán để phục vụ cho các module phân tích và trực quan hóa ở tầng trên. Yêu cầu nghiệp vụ cụ thể bao gồm:


- Loại bỏ các thẻ HTML rác, ký tự đặc biệt, khoảng trắng thừa từ văn bản thô.
- Trích xuất các trường thông tin có cấu trúc (chức danh, kỹ năng, mức lương, địa điểm) từ mô tả công việc dạng tự do.
- Chuẩn hóa các biến thể tên gọi kỹ năng về một từ điển thống nhất (ví dụ: “ReactJS”, “React.js”, “React” đều cùng một thực thể).
- Lưu trữ kết quả vào cơ sở dữ liệu quan hệ để phục vụ truy vấn và trực quan hóa tức thời.

2.2.3 Quy trình trích xuất, biến đổi và lưu trữ dữ liệu trong phân tích dữ liệu lớn

Trong kiến trúc của các hệ thống thông tin hướng dữ liệu lớn, việc thiết lập một luồng xử lý dữ liệu chuẩn hóa đóng vai trò cốt lõi trong việc đảm bảo tính toàn vẹn và chất lượng của dữ liệu đầu ra [6]. Hệ thống áp dụng phương pháp luận Trích xuất – Biến đổi – Nạp (Extract – Transform – Load — ETL) được đề xuất bởi chuyên gia kho dữ liệu Ralph Kimball [6].

Theo Kimball, hệ thống ETL đóng vai trò như một phân xưởng chuẩn bị dữ liệu (Data Staging Area) [12]. Đây là nơi tiếp nhận các nguồn dữ liệu thô, không đồng nhất, tiến hành làm sạch, loại bỏ các lỗi sai lệch, áp dụng các quy tắc nghiệp vụ để đồng nhất hóa ngữ nghĩa, trước khi tổ chức sắp xếp dữ liệu vào các cấu trúc bảng chuẩn hóa nhằm phục vụ cho các phân tích và hiển thị trực quan tiếp theo [6]. Tiến trình này mặc dù hoạt động ngầm nhưng lại chiếm tới hơn 70% nỗ lực và tài nguyên trong việc xây dựng một hệ thống thông tin hoàn chỉnh.

Quy trình ETL Pipeline theo phương pháp luận Kimball trong hệ thống CareerNova



Hình 2.2: Quy trình tổng quát của tiến trình trích xuất, biến đổi và nạp dữ liệu (ETL Pipeline) theo phương pháp luận Kimball.

Giai đoạn Trích xuất (Extract): Hệ thống thực hiện thu thập dữ liệu phi cấu trúc từ các nguồn trang tuyển dụng khác nhau. Dữ liệu sau khi cào về được lưu trữ nguyên bản dưới dạng tệp tin JSON thô (raw JSON) tại phân vùng đệm của hệ thống [13]. Việc lưu trữ dữ liệu thô giúp đảm bảo khả năng khôi phục hoặc tái xử lý dữ liệu từ đầu khi có sự thay đổi về quy tắc biến đổi mà không cần phải tiến hành cào lại từ trang web gốc, giảm thiểu việc tải nặng lên máy chủ đối tác và tuân thủ các quy tắc lịch sự trong thu thập dữ liệu [14].

Giai đoạn Biến đổi (Transform): Đây là giai đoạn quan trọng và phức tạp nhất của luồng xử lý [13]. Đầu tiên, hệ thống thực hiện các bước tiền xử lý cơ bản bằng cách loại bỏ các thẻ định dạng HTML rác, các ký

tự đặc biệt không mong muốn và chuẩn hóa khoảng trắng thông qua các biểu thức chính quy. Tiếp theo, do mô tả công việc (Job Description — JD) mang tính phi cấu trúc cao, hệ thống gọi giao diện lập trình ứng dụng Gemini API để thực hiện trích xuất thực thể thông tin chuyên sâu bao gồm chức danh công việc, yêu cầu kỹ năng và các chế độ phúc lợi [15]. Do các kỹ năng tuyển dụng thường được viết dưới dạng các thuật ngữ không đồng nhất, hệ thống tiếp tục thực hiện bước chuẩn hóa ngữ nghĩa (Semantic Normalization) [14]. Các thực thể kỹ năng bóc tách được ánh xạ vào một từ điển kỹ năng chuẩn hóa duy nhất thông qua mô hình biểu diễn vector nhằm đảm bảo tính nhất quán ngữ nghĩa [16]. Đây chính là quá trình thiết lập các chiều dữ liệu chuẩn hóa (Conformed Dimensions) theo lý thuyết Kimball, cho phép kết nối dữ liệu từ nhiều nguồn tuyển dụng khác nhau trên một hệ quy chiếu chung [12].

Giai đoạn Nạp (Load): Dữ liệu sau khi được làm sạch và chuẩn hóa ngữ nghĩa sẽ được chuyển đổi sang cấu trúc quan hệ để nạp vào hệ quản trị cơ sở dữ liệu PostgreSQL [13]. Để tối ưu hóa hiệu năng truy vấn, tránh dư thừa dữ liệu và hỗ trợ trực quan hóa thời gian thực, cơ sở dữ liệu được tổ chức theo mô hình quan hệ chuẩn hóa cao bao gồm các bảng chính: bảng công việc (`jobs` lưu trữ các thông tin chung về vị trí tuyển dụng, công ty, mức lương, địa điểm), bảng kỹ năng (`skills` lưu trữ từ điển kỹ năng chuẩn hóa, đồng thời lưu giữ trường số liệu Document Frequency đại diện cho số lượng tin tuyển dụng chứa kỹ năng nhằm phục vụ tính toán trọng số IDF động) và bảng liên kết đa-đa (`job_skills` lưu trữ liên kết giữa các công việc và các kỹ năng tương ứng kèm theo trọng số TF-IDF được tính toán thời gian thực từ tập dữ liệu thị trường) [17]. Hơn nữa, kết quả tính toán chi tiết của bộ so khớp (Matching Engine) bao gồm cấu trúc biểu đồ Radar (`radar_data`) và báo cáo khoảng cách kỹ năng (`gap_report`) sẽ được đóng gói dưới định dạng JSONB để nạp trực tiếp vào cơ sở dữ liệu PostgreSQL. Thiết kế này giúp tối ưu hóa hiệu năng truy vấn thời gian thực ở tầng trực quan hóa mà không cần phải tính toán lại nhiều lần.

Vì vậy, trong hệ thống đề xuất, quy trình ETL theo mô hình Kimball

được triển khai để biến dữ liệu tuyển dụng thô từ nhiều nguồn phi cấu trúc thành một kho dữ liệu PostgreSQL nhất quán, đồng thời tính toán động và lưu trữ trọng số TF-IDF cùng kết quả so khớp dạng JSONB để phục vụ trực quan hóa tức thời.

2.2.4 Yêu cầu trực quan hóa thông tin hỗ trợ ra quyết định

Sau khi dữ liệu tuyển dụng đã được chuẩn hóa và lưu trữ, yêu cầu nghiệp vụ tiếp theo là trình bày dữ liệu theo cách giúp sinh viên dễ dàng nhận diện khoảng cách năng lực và ra quyết định nghề nghiệp mà không cần kiến thức phân tích dữ liệu chuyên sâu. Yêu cầu này trực tiếp định hướng thiết kế các thành phần giao diện trực quan hóa.

2.2.5 Nguyên lý trực quan hóa thông tin hỗ trợ ra quyết định

Trực quan hóa thông tin (Information Visualization) là lĩnh vực nghiên cứu tập trung vào việc sử dụng các biểu diễn đồ họa tương tác để khai thác khả năng nhận thức thị giác, nhằm phát hiện các mẫu ẩn, xu hướng và mối quan hệ trong tập dữ liệu phức tạp [18]. Card, Mackinlay và Shneiderman (1999) định nghĩa đây là “việc sử dụng biểu diễn trực quan được máy tính hỗ trợ từ dữ liệu trừu tượng để khuếch đại nhận thức (amplify cognition)” [18].

Nguyên lý định hướng thiết kế phổ biến nhất trong lĩnh vực này là **mantra trực quan hóa** của Shneiderman (1996): “*Overview first, zoom and filter, then details on demand*” [19]. Theo nguyên lý này, giao diện cần dẫn dắt người dùng qua ba tầng tương tác: (i) nhìn thấy bức tranh tổng quan, (ii) thu hẹp dữ liệu theo các thuộc tính phù hợp và (iii) chỉ xem chi tiết khi đã xác định được vấn đề cần tìm hiểu. Cách tiếp cận này giảm tải nhận thức vì người dùng không phải đọc đồng thời toàn bộ dữ liệu thô và

có thể đưa ra quyết định theo từng tầng thông tin.

Tufte (2001) nhấn mạnh rằng thiết kế đồ họa xuất sắc phải tối đa hóa tỷ số dữ liệu-mực vẽ (data-ink ratio) — mọi yếu tố đồ họa đều phải mang thông tin có giá trị [20]. Few (2006) mở rộng nguyên tắc này sang dashboard phân tích: dashboard cần ưu tiên thông tin quan trọng nhất trên một màn hình, sử dụng nhất quán các thuộc tính tiền chú ý (pre-attentive attributes) như vị trí, độ dài, màu sắc tương phản và kích thước tương đối để người dùng nhận diện xu hướng hoặc ngoại lệ nhanh chóng [21]. Vì vậy, màu sắc trong CareerNova được dùng có ngữ nghĩa cố định: xanh lá cho mức đáp ứng tốt, vàng cho mức cần cải thiện và đỏ cho thiếu hụt; không dùng màu sắc chỉ để trang trí.


Ứng dụng vào hệ thống CareerNova: Dựa trên các nguyên lý trên và giao diện hiện tại của hệ thống, các thành phần trực quan hóa được lựa chọn theo câu hỏi ra quyết định cụ thể của sinh viên:

1. **Thẻ chỉ số tổng quan:** Hiển thị số tin đang mở, số công ty đang tuyển và số cơ hội thực tập theo bộ lọc. Đây là lớp “overview first”, giúp người dùng nắm quy mô thị trường trước khi xem biểu đồ chi tiết.
2. **Biểu đồ vùng (AreaChart):** Thẻ hiện xu hướng số tin tuyển dụng theo thời gian, đồng thời so sánh tổng số tin với số vị trí làm việc từ xa. Người dùng quan sát được biến động nhu cầu tuyển dụng và xác định giai đoạn nên ưu tiên tìm việc.
3. **Bản đồ cây (Treemap):** Biểu diễn tỷ trọng các nhóm kỹ năng hoặc lĩnh vực trong thị trường. Diện tích mỗi ô tỷ lệ với số tin tuyển dụng; do đó người dùng nhanh chóng nhận biết nhóm có nhu cầu nổi trội mà không cần đọc bảng dữ liệu dài.
4. **Biểu đồ cột xếp hạng và danh sách kỹ năng tăng trưởng:** Danh sách “Top 10 kỹ năng được yêu cầu” dùng độ dài thanh để so sánh số tin theo kỹ năng; danh sách “Kỹ năng tăng trưởng nhanh”

nhấn mạnh tốc độ thay đổi bằng màu cam và phần trăm tăng trưởng. Hai thành phần giúp chuyển từ quan sát tổng quan sang quyết định kỹ năng cần ưu tiên học.

5. **Biểu đồ Radar và Gap Report:** RadarChart biểu diễn đồng thời năng lực hiện tại của người dùng và ngưỡng yêu cầu thị trường trên hệ trục đa chiều. Báo cáo khoảng cách kỹ năng bổ sung danh sách đạt yêu cầu, đạt một phần và còn thiếu, giúp người dùng hiểu nguyên nhân phía sau điểm phù hợp và lựa chọn kỹ năng cần cải thiện.

Tất cả thành phần thị trường đều dùng chung bộ lọc theo khu vực, khoảng thời gian và loại hình công việc. Cách tổ chức này hiện thực hóa đầy đủ mantra của Shneiderman: người dùng xem tổng quan qua thẻ chỉ số và xu hướng, thu hẹp phạm vi bằng bộ lọc, sau đó xem chi tiết qua danh sách vị trí, kỹ năng hoặc báo cáo khoảng cách. Màu sắc được dùng có ngữ nghĩa cố định: xanh lá cho trạng thái đáp ứng tốt, vàng cho mức cần cải thiện, đỏ cho kỹ năng thiếu và cam cho xu hướng tăng nhanh; vì vậy màu sắc hỗ trợ nhận biết thay vì chỉ mang tính trang trí. Luồng dữ liệu từ cơ sở dữ liệu đến các thành phần trực quan hóa được mô tả trong Hình 2.3.



Hình 2.3: Luồng dữ liệu từ cơ sở dữ liệu đến các thành phần trực quan hóa trong hệ thống CareerNova.

Tóm lại, việc lựa chọn biểu đồ trong CareerNova dựa trên câu hỏi ra quyết định thay vì dựa trên tính trang trí: biểu đồ xu hướng trả lời câu

hỏi về thời điểm, Treemap trả lời câu hỏi về nhóm nhu cầu nổi trội, biểu đồ xếp hạng và danh sách tăng trưởng trả lời câu hỏi nên ưu tiên kỹ năng nào, còn Radar Chart và Gap Report trả lời câu hỏi về năng lực cần bổ sung. Nhờ tuân thủ các nguyên lý của Card, Shneiderman, Tufte và Few, người dùng không cần kiến thức phân tích dữ liệu chuyên sâu vẫn có thể nhận diện khoảng cách năng lực, theo dõi xu hướng thị trường và điều chỉnh định hướng nghề nghiệp qua các biểu đồ tương tác.

2.3 Giải pháp so khớp hồ sơ

2.3.1 Xác định yêu cầu nghiệp vụ của bài toán so khớp hồ sơ

Một yêu cầu nghiệp vụ trung tâm của hệ thống CareerNova là đánh giá *mức độ phù hợp* giữa năng lực của sinh viên (thể hiện qua CV) và yêu cầu các vị trí tuyển dụng (thể hiện qua JD) theo cách có ý nghĩa hơn so với việc đơn thuần đếm từ khóa trùng khớp. Phân tích yêu cầu này làm nổi lên hai vấn đề cốt lõi cần giải quyết ở tầng thuật toán:

- **Vấn đề 1 — Đo lường tương đồng ngữ nghĩa:** Cần một phương pháp biểu diễn và so sánh ý nghĩa của các kỹ năng ngay cả khi chúng được diễn đạt khác nhau về từ ngữ (“JS” vs “JavaScript”, “lãnh đạo nhóm” vs “team leadership”).
- **Vấn đề 2 — Phân biệt tầm quan trọng của kỹ năng:** Không phải mọi kỹ năng đều quan trọng như nhau. Kỹ năng hiếm và chuyên sâu (PyTorch, Kubernetes) cần được trọng số hóa cao hơn kỹ năng phổ biến (Git, HTML) để điểm so khớp phản ánh đúng thực tế thị trường.

Hai vấn đề này định hướng việc lựa chọn các kỹ thuật biểu diễn và so sánh vector ngữ nghĩa được phân tích ở các mục tiếp theo.

2.3.2 Lý thuyết không gian vector và kỹ thuật tạo vector nhúng

Mô hình Không gian Vector (Vector Space Model — VSM) là một nền tảng lý thuyết kinh điển trong xử lý ngôn ngữ tự nhiên (Natural Language Processing — NLP) và tìm kiếm thông tin, biểu diễn tài liệu văn bản dưới dạng các điểm hoặc vector trong một không gian số học đa chiều [22]. Trong không gian này, khoảng cách hình học giữa các vector tỷ lệ thuận với mức độ tương đồng về mặt nội dung giữa các tài liệu tương ứng [23]. Sự phát triển của các kỹ thuật biểu diễn từ ngữ đã chuyển dịch từ các vector thưa tần suất (như TF-IDF — vốn bỏ qua ngữ cảnh và quan hệ đồng nghĩa) sang các vector nhúng dày đặc (Dense Embeddings), nơi các giá trị số học biểu diễn các đặc trưng ngữ nghĩa ẩn của từ ngữ trong một không gian liên tục [16].

Để giải quyết bài toán biểu diễn ngữ nghĩa ở cấp độ câu và cụm từ phức tạp trong tin tuyển dụng và hồ sơ ứng viên, Nils Reimers và Iryna Gurevych đã đề xuất mô hình Sentence-BERT (SBERT) vào năm 2019 [23]. SBERT cải tiến mô hình tiền huấn luyện BERT bằng cách sử dụng cấu trúc mạng song sinh (Siamese Network) và mạng sinh ba (Triplet Network) để tối ưu hóa trọng số của mô hình [24]. Kiến trúc mạng song sinh của SBERT bao gồm hai nhánh BERT song song có chia sẻ hoàn toàn bộ tham số trọng số [23]. Khi xử lý cặp văn bản đầu vào (s_1, s_2) , mỗi câu sẽ được đưa qua một nhánh mạng độc lập để trích xuất các trạng thái ẩn cuối cùng:


$$H_i = \text{BERT}(s_i), \quad i \in \{1, 2\} \quad (2.1)$$

Sau đó, một phép toán lấy trung bình trọng số (Mean Pooling) được áp dụng trên toàn bộ các vector biểu diễn token của câu ở lớp đầu ra để chuyển đổi ma trận trạng thái ẩn có kích thước biến thiên thành một vector nhúng có kích thước cố định $\mathbf{u}$ biểu diễn trọn vẹn ngữ nghĩa của toàn bộ câu [25]. SBERT được huấn luyện thông qua các mục tiêu tối ưu như hàm

mất mát phân loại (Classification Loss) dựa trên việc liên kết các vector hoặc hàm mất mát hồi quy (Regression Loss) so khớp trực tiếp với điểm tương đồng mục tiêu [26]. Phát minh mang tính đột phá của SBERT nằm ở chỗ nó cho phép mã hóa độc lập từng câu thành vector nhưng cố định [22]. Điều này cho phép hệ thống tính toán trước (precompute) và lập chỉ mục các vector biểu diễn năng lực của hàng triệu ứng viên hoặc công việc một lần duy nhất [16]. Khi cần so khớp, hệ thống chỉ việc thực hiện các phép so sánh vector đơn giản (như tính Cosine) trong thời gian vài phần nghìn giây, giải quyết triệt để nút thắt cổ chai về mặt hiệu năng của kiến trúc BERT Cross-Encoder truyền thống [24].

Trong bối cảnh xây dựng công cụ so khớp hồ sơ cục bộ (local engine) hoạt động tối ưu trên máy chủ có giới hạn về tài nguyên phần cứng, mô hình `all-MiniLM-L6-v2` thuộc thư viện Sentence Transformers được lựa chọn làm giải pháp biểu diễn vector cốt lõi [27]. Được phát triển dựa trên phương pháp chắt lọc tri thức (Knowledge Distillation) từ kiến trúc MiniLM của Microsoft, mô hình này sở hữu cấu hình kỹ thuật cực kỳ tinh gọn [27]:

Kiến trúc SBERT (Siamese Network) trong suy luận tính điểm tương đồng ngữ nghĩa



Hình 2.4: Kiến trúc SBERT được sử dụng trong suy luận để tính điểm tương đồng ngữ nghĩa.

- **Số lượng tầng biến đổi (Layers):** 6 tầng Transformer (so với 12 tầng của BERT-base) [28].
- **Kích thước tham số (Parameter Count):** Khoảng 22 triệu tham số (chỉ bằng 1/5 kích thước của BERT-base) [28].
- **Chiều của vector nhúng (Embedding Size):** 384 chiều liên tục [27].
- **Độ dài chuỗi đầu vào tối đa (Max Sequence Length):** 256 tokens [27].
- **Dung lượng đĩa cứng (Model Size):** Khoảng 80 MB [29].

Lý do lựa chọn `all-MiniLM-L6-v2` xuất phát từ sự cân bằng hoàn hảo giữa hiệu năng tính toán và chất lượng biểu diễn ngữ nghĩa [16]. Mô hình được huấn luyện tự giám sát trên tập dữ liệu khổng lồ chứa hơn 1 tỷ cặp câu chất lượng cao, bao gồm cả tập dữ liệu tìm kiếm ngữ nghĩa MS MARCO [27]. Nhờ đó, dù có dung lượng bộ nhớ cache siêu nhẹ (80 MB) và tốc độ mã hóa cực nhanh (vận hành trên CPU thông thường đạt hiệu năng vượt trội, lên tới hơn 14.200 câu/giây trên GPU) [28], mô hình vẫn duy trì khả năng biểu diễn ngữ nghĩa vượt trội, tương đương hoặc thậm chí vượt qua các mô hình lớn hơn nhiều trong các tác vụ tìm kiếm ngữ nghĩa và so khớp văn bản ngắn [28]. Vì vậy, trong hệ thống đề xuất, mô hình nhúng cục bộ `all-MiniLM-L6-v2` được lựa chọn để thực hiện mã hóa các thực thể kỹ năng một cách nhanh chóng và chính xác trực tiếp trên máy chủ cục bộ mà không tốn chi phí gọi API bên thứ ba.

2.3.3 Phương pháp định lượng hóa độ tương đồng ngữ nghĩa bằng độ đo Cosine và Trọng số TF-IDF từ thị trường

Để lượng hóa mức độ tương đồng về mặt năng lực giữa hồ sơ ứng viên (CV) và mô tả yêu cầu công việc (JD), hệ thống áp dụng độ đo Cosine (Cosine Similarity) [26]. Về mặt toán học, độ đo Cosine giữa hai vector đa chiều phi không $\mathbf{u}$ và $\mathbf{v}$ được định nghĩa là tỷ số giữa tích vô hướng của hai vector và tích độ dài (chuẩn L2) của chúng:

$$\text{cosine}(\mathbf{u}, \mathbf{v}) = \frac{\mathbf{u} \cdot \mathbf{v}}{\|\mathbf{u}\|_2 \cdot \|\mathbf{v}\|_2} = \frac{\sum_{k=1}^d u_k v_k}{\sqrt{\sum_{k=1}^d u_k^2} \cdot \sqrt{\sum_{k=1}^d v_k^2}} \quad (2.2)$$

Trong đó $d = 384$ là số chiều của không gian vector biểu diễn bởi mô hình `all-MiniLM-L6-v2` [27]. Giá trị của độ đo Cosine nằm trong khoảng $[-1, 1]$, thể hiện mức độ trùng khớp ngữ nghĩa từ hoàn toàn khác biệt đến hoàn toàn tương đồng.

Để tối ưu hóa hiệu năng tính toán khi so khớp hàng loạt hồ sơ trực tuyến, giả sử các vector nhúng đầu ra đã được chuẩn hóa đơn vị (Unit Vectors):

$$\|\hat{\mathbf{u}}\|_2 = \|\hat{\mathbf{v}}\|_2 = 1 \quad (2.3)$$

Khi đó, công thức tính độ tương đồng Cosine được rút gọn về tích vô hướng (Dot Product):

$$\text{cosine}(\hat{\mathbf{u}}, \hat{\mathbf{v}}) = \hat{\mathbf{u}} \cdot \hat{\mathbf{v}} = \sum_{k=1}^d \hat{u}_k \hat{v}_k \quad (2.4)$$

Điều này loại bỏ các phép toán tính căn bậc hai và phép chia trong vòng lặp so khớp quy mô lớn, giúp giảm thiểu đáng kể số chu kỳ lệnh của CPU/GPU và cho phép thực hiện hàng triệu phép so khớp trong thời gian thực [1].

Chứng minh trên chỉ ra rằng, đối với các vector đã chuẩn hóa đơn vị, việc tính độ tương đồng Cosine thực chất tương đương với việc thực hiện

phép nhân Tích vô hướng (Dot Product). Việc loại bỏ hoàn toàn các phép toán phức tạp như tính căn bậc hai và phép chia trong vòng lặp so khớp quy mô lớn giúp giảm thiểu đáng kể số lượng chu kỳ lệnh của CPU/GPU, cho phép hệ thống thực hiện hàng triệu phép so khớp trong thời gian thực với độ trễ tối thiểu [22].

Tuy nhiên, trong bài toán so khớp hồ sơ nhân sự thực tế, không phải tất cả các kỹ năng được yêu cầu trong mô tả công việc (JD) đều có vai trò đóng góp như nhau vào tổng điểm đánh giá của ứng viên. Nếu sử dụng độ đo tương đồng không trọng số, các kỹ năng cực kỳ phổ biến và dễ đạt được (ví dụ: Git, SQL, Microsoft Office, HTML/CSS) sẽ vô tình làm lu mờ sự thiếu hụt hoặc mức độ tương đồng thấp ở các kỹ năng cốt lõi, mang tính chất quyết định của công việc (ví dụ: PyTorch, CI/CD, Kubernetes). Để giải quyết triệt để vấn đề này, đề tài xây dựng giải pháp định lượng hóa trọng số kỹ năng động dựa trên công thức TF-IDF (Term Frequency – Inverse Document Frequency) được tính toán trực tiếp từ kho ngữ liệu tin tuyển dụng thực tế cào từ thị trường Việt Nam [30].

Mô hình toán học của cơ chế tính trọng số này được thiết lập như sau. Gọi $\mathcal{D} = \{d_1, d_2, \dots, d_N\}$ là tập hợp (corpus) chứa tất cả N tin tuyển dụng đã thu thập và lưu trữ thành công trong PostgreSQL. Với một tin tuyển dụng (JD) cụ thể d_j , gọi S_j là tập hợp các kỹ năng yêu cầu được trích xuất từ JD đó.

Tần suất Kỹ năng (Term Frequency — TF) thể hiện mức độ nổi bật của kỹ năng s_i trong JD d_j . Do kỹ năng thường xuất hiện dưới dạng thực thể đơn lẻ (presence/absence) trong danh sách yêu cầu của JD, tần suất TF được định nghĩa theo dạng chuẩn hóa nhị phân [31]:

$$\text{TF}(s_i, d_j) = \begin{cases} 1 & \text{nếu } s_i \in S_j \\ 0 & \text{ngược lại} \end{cases} \quad (2.5)$$

Nghịch đảo Tần suất Văn bản (Inverse Document Frequency — IDF) đo lường mức độ đặc trưng và tính khan hiếm của kỹ năng s_i

trên toàn bộ thị trường lao động Việt Nam [32]:

$$\text{IDF}(s_i, \mathcal{D}) = \log \left(\frac{N}{|\{d \in \mathcal{D} : s_i \in S_d\}|} \right) \quad (2.6)$$

Trong đó N là tổng số tin tuyển dụng, và $|\{d \in \mathcal{D} : s_i \in S_d\}|$ là số tin tuyển dụng chứa kỹ năng s_i .

Trọng số TF-IDF kết hợp của kỹ năng s_i thuộc JD d_j được xác định bằng tích của hai thành phần [32]:

$$w(s_i, d_j) = \text{TF}(s_i, d_j) \times \text{IDF}(s_i, \mathcal{D}) \quad (2.7)$$

Nhờ mô hình này, kỹ năng xuất hiện tràn lan ($\text{IDF} \approx 0$) sẽ có trọng số tiến về 0, giảm ảnh hưởng của kỹ năng phổ biến. Ngược lại, kỹ năng chuyên sâu và hiếm có IDF lớn, đẩy trọng số lên cao để tạo lực đẩy quyết định cho điểm số.

Cuối cùng, tổng điểm tương thích **Match Score** giữa hồ sơ CV của ứng viên và yêu cầu JD của công việc được xác định bằng công thức trung bình có trọng số TF-IDF của các độ tương đồng kỹ năng [30]:

$$\text{MatchScore}(\text{CV}, d_j) = \frac{\sum_{s_i \in S_j} w(s_i, d_j) \cdot \text{cosine}(\mathbf{e}_{s_i}^{\text{CV}}, \mathbf{e}_{s_i}^{\text{JD}})}{\sum_{s_i \in S_j} w(s_i, d_j)} \quad (2.8)$$

Áp dụng rút gọn tích vô hướng cho các vector đã chuẩn hóa đơn vị ($\|\hat{\mathbf{e}}\|_2 = 1$), công thức Match Score cuối cùng của hệ thống:

$$\text{MatchScore}(\text{CV}, d_j) = \frac{\sum_{s_i \in S_j} w(s_i, d_j) \cdot (\hat{\mathbf{e}}_{s_i}^{\text{CV}} \cdot \hat{\mathbf{e}}_{s_i}^{\text{JD}})}{\sum_{s_i \in S_j} w(s_i, d_j)} \quad (2.9)$$

Vì vậy, trong hệ thống đề xuất, phương pháp tích vô hướng trên vector chuẩn hóa kết hợp trọng số TF-IDF từ thị trường thực tế được triển khai để tính Match Score chuẩn xác, tối ưu hóa hiệu năng thời gian thực và phản ánh chính xác xu thế cung – cầu của thị trường lao động CNTT Việt

Nam.

2.3.4 Khảo sát các công cụ và thuật toán so khớp hồ sơ hiện có

Quá trình tiến hóa công nghệ của các Hệ thống quản lý ứng viên (Applicant Tracking System — ATS) trải qua bốn thế hệ phát triển rõ rệt, từ các bộ lọc từ khóa sơ khai cho đến các hệ thống trí tuệ nhân tạo hiện đại [17]. Sự khác biệt giữa các thế hệ được thể hiện chi tiết trong Bảng 2.1.

Bảng 2.1: So sánh các thế hệ hệ thống ATS theo công nghệ cốt lõi, ưu nhược điểm và chi phí vận hành.

Thế hệ ATS	Công nghệ cốt lõi	Ưu điểm	Nhược điểm	Chi phí	Độ trễ (Latency)
Thế hệ I: Rule-based	Biểu thức chính quy (Regex), So khớp từ khóa chính xác (Keyword Matching) [33].	Đơn giản, dễ triển khai, tốc độ xử lý tức thời, không tốn tài nguyên.	Thất bại với từ đồng nghĩa, viết tắt [34]. Dễ bị gian lận bằng nhồi từ khóa.	Rất thấp	Cực thấp (<10ms)
Thế hệ II: Machine Learning truyền thống	Mô hình túi từ (Bag of Words), TF-IDF tĩnh, Naive Bayes, SVM, Word2Vec [8].	Nhận diện tầm quan trọng từ dựa trên tần suất [35], bắt đầu hiểu quan hệ đồng nghĩa cơ bản.	Không hiểu ngữ cảnh câu văn [16], đòi hỏi dữ liệu gán nhãn lớn.	Thấp	Thấp (10–50ms)

Thế hệ ATS	Công nghệ cốt lõi	Ưu điểm	Nhược điểm	Chi phí	Độ trễ (La- tency)
Thế hệ III: Deep Learning (Bi- Encoder)	Sentence- BERT (SBERT), Siamese Networks, không gian vector nhúng [22].	Biểu diễn ngữ nghĩa câu xuất sắc [28]. Cho phép tính trước vector nhúng để so khớp quy mô lớn.	Đòi hỏi tài nguyên phần cứng mạnh (GPU) [22]. Khó với tài liệu bố cục phức tạp [36].	Trung bình	Trung bình (50– 200ms)
Thế hệ IV: LLM APIs	Các mô hình ngôn ngữ lớn thương mại (GPT-4, Gemini, LLaMA), tác nhân AI (AI Agents) [17].	Hiểu ngữ cảnh, bố cục và ngôn ngữ tự nhiên vô song [36]. Khả năng tóm tắt và suy luận sâu sắc.	Chi phí API tích lũy cực kỳ tốn kém khi xử lý dữ liệu lớn. Độ trễ phản hồi cao.	Rất cao (tính phí theo To- ken)	Rất cao (1–5 giây/yêu cầu)

Mặc dù các mô hình ngôn ngữ lớn thuộc Thế hệ IV thể hiện khả năng hiểu văn bản vượt trội, việc gửi trực tiếp toàn bộ nội dung của hàng nghìn hồ sơ ứng viên và tin tuyển dụng lên các API thương mại cho mỗi lần chạy so khớp là một giải pháp không khả thi đối với các dự án thực tế xét trên cả hai phương diện kinh tế và kỹ thuật [36]. Về mặt kinh tế, chi phí sử dụng API sẽ tăng trưởng theo cấp số nhân khi số lượng hồ sơ cần đánh giá lớn. Về mặt kỹ thuật, độ trễ phản hồi của LLM API lên tới vài giây sẽ làm tê liệt khả năng hiển thị thời gian thực của các công cụ trực quan hóa thông tin tuyển dụng. Ngược lại, nếu chỉ dựa vào các mô hình nhúng cục bộ thuộc Thế hệ III để so khớp trực tiếp toàn bộ văn bản của CV và

JD, hệ thống sẽ gặp phải sai số rất lớn do cấu trúc CV thường chứa nhiều thông tin nhiễu khiến vector nhúng của toàn bộ văn bản bị lệch hướng ngữ nghĩa [17].

Để giải quyết mâu thuẫn này, đề tài đề xuất một **giải pháp lai đột phá (Hybrid Approach)**, tách rời quy trình thành hai bước độc lập:

1. **Bước bóc tách cấu trúc ngoại tuyến (Offline Structuring):** Sử dụng Gemini API (Thế hệ IV) để xử lý một lần duy nhất khi CV được tải lên hoặc khi tin tuyển dụng được cào về [17]. Sức mạnh suy luận của LLM được khai thác triệt để để bóc tách chính xác các thực thể kỹ năng, chức danh công việc từ văn bản phi cấu trúc phức tạp thành dữ liệu bán cấu trúc JSON [34].
2. **Bước so khớp trực tuyến (Online Matching Engine):** Khi người dùng thực hiện thao tác so khớp hoặc xem trực quan hóa, hệ thống sử dụng mô hình Sentence-BERT cục bộ all-MiniLM-L6-v2 (Thế hệ III) kết hợp độ đo Cosine chuẩn hóa tích vô hướng và trọng số TF-IDF được tính động trực tuyến từ tập dữ liệu thị trường để tính toán Match Score trực tiếp trên các kỹ năng đã được cấu trúc hóa [27].

Lập luận khoa học của giải pháp lai này dựa trên việc đặt đúng công nghệ vào đúng tác vụ: tận dụng khả năng hiểu bố cục xuất sắc của LLM để dọn dẹp và cấu trúc hóa dữ liệu, đồng thời tận dụng tốc độ tính toán vector vượt trội, chi phí bằng không và tính bảo mật của mô hình SBERT cục bộ kết hợp với trọng số TF-IDF có ý nghĩa phân loại cao cho khâu tìm kiếm và so khớp thời gian thực [22]. Vì vậy, trong hệ thống đề xuất, giải pháp kiến trúc lai (Hybrid) kết hợp LLM API ngoại tuyến và SBERT trực tuyến có trọng số TF-IDF được lựa chọn để tối ưu hóa bài toán so khớp hồ sơ đạt hiệu năng cao và tiết kiệm chi phí vận hành.

2.4 Trích xuất thực thể trong quản lý thị trường việc làm

2.4.1 Bài toán bóc tách thông tin kỹ năng, vị trí công việc từ văn bản

Nhận diện thực thể tên (Named Entity Recognition — NER) là một trong những tác vụ nền tảng nhất của xử lý ngôn ngữ tự nhiên, hướng tới việc tự động xác định các phân đoạn văn bản thô đại diện cho các thực thể cụ thể và phân loại chúng vào các nhóm ngữ nghĩa được định nghĩa trước [16]. Khi được áp dụng vào lĩnh vực quản lý nhân sự (HR Domain), bài toán NER trở nên đặc thù và phức tạp hơn rất nhiều, đòi hỏi hệ thống phải bóc tách chính xác các thực thể cốt lõi bao gồm: chức danh công việc (Job Title), kỹ năng chuyên môn (Skills), trình độ học vấn, các chứng chỉ chuyên ngành và chế độ phúc lợi [17]. Việc cấu trúc hóa thành công các thực thể này từ văn bản tự do là điều kiện tiên quyết để xây dựng các thuật toán so khớp chính xác và lập biểu đồ phân tích thị trường lao động hiệu quả.

Thách thức lớn nhất khi giải quyết tác vụ NER trong lĩnh vực nhân sự xuất phát từ tính phi cấu trúc cực kỳ cao của hồ sơ ứng viên (CV) [36]. Ứng viên thường tự do trình bày hồ sơ cá nhân theo nhiều phong cách thẩm mỹ khác nhau, sử dụng các phần mềm thiết kế đa dạng dẫn đến định dạng tệp tin không đồng nhất (như PDF, DOCX, hoặc tệp ảnh quét) [17]. Đối với các CV được lưu trữ dưới dạng ảnh quét hoặc PDF dạng ảnh, hệ thống bắt buộc phải tích hợp một lớp nhận diện ký tự quang học (Optical Character Recognition — OCR) để khôi phục văn bản thô. Tuy nhiên, CV hiện đại thường áp dụng bố cục trình bày nhiều cột (multi-column layouts) hoặc dạng bảng lồng nhau nhằm tối ưu hóa diện tích hiển thị [36]. Các công cụ đọc văn bản thông thường nếu chỉ quét tuần tự từ trái sang phải, từ trên xuống dưới sẽ làm đứt gãy hoàn toàn cấu trúc ngữ

pháp của câu văn, trộn lẫn nội dung của hai cột khác biệt, dẫn đến việc phá hủy ngữ cảnh và khiến các mô hình NER truyền thống mất khả năng nhận diện thực thể chính xác.

Đặc biệt, đối với thị trường lao động ngành Công nghệ thông tin tại Việt Nam, bài toán trích xuất thực thể phải đối mặt với rào cản ngôn ngữ song ngữ Anh – Việt rất phức tạp. Cả nhà tuyển dụng và ứng viên thường có thói quen viết xen lẫn hai ngôn ngữ ngay trong cùng một câu văn. Thêm vào đó, danh mục kỹ năng ngành IT vô cùng đa dạng, chứa nhiều thuật ngữ viết tắt, viết liền hoặc có nhiều biến thể ký tự khác nhau. Các mô hình NER truyền thống dựa trên các thuật toán học máy giám sát thường bộc lộ sự yếu kém do tập dữ liệu huấn luyện hạn chế, không thể bao phủ toàn bộ các biến thể ngôn ngữ lai này, dẫn đến tỷ lệ bỏ sót thực thể kỹ năng mới hoặc nhận diện sai lệch chức danh công việc ở mức cao [17]. Vì vậy, trong hệ thống đề xuất, giải pháp nhận diện thực thể tên kết hợp OCR được triển khai để xử lý các CV song ngữ và đa dạng về cấu trúc trình bày một cách chuẩn xác, đảm bảo không bỏ sót thông tin năng lực của ứng viên.

2.4.2 Ứng dụng mô hình ngôn ngữ lớn (LLM) và câu lệnh để chuẩn hóa dữ liệu

Sự trỗi dậy của các mô hình ngôn ngữ lớn (Large Language Models — LLMs) dựa trên kiến trúc Transformer tự chú ý đã mang lại một bước nhảy vọt về chất cho tác vụ bóc tách thông tin [17]. Nhờ được huấn luyện trên các kho ngữ liệu khổng lồ đa ngôn ngữ, các LLM hiện đại như Google Gemini sở hữu khả năng hiểu biết ngữ cảnh sâu sắc và khả năng suy luận mạnh mẽ dưới dạng zero-shot (trích xuất thực thể chính xác mà không cần trải qua quá trình huấn luyện lại trên tập dữ liệu chuyên biệt). Để khai thác tối đa sức mạnh của LLM phục vụ cho quy trình ETL dữ liệu tuyển dụng, kỹ thuật Thiết kế câu lệnh (Prompt Engineering) được nghiên cứu và ứng dụng một cách có hệ thống [37]. Prompt Engineering đóng vai trò

như một bộ chỉ dẫn hành vi, thiết lập các ràng buộc ngữ cảnh, định dạng đầu ra và các quy tắc kiểm tra nghiêm ngặt để LLM hoạt động ổn định và chính xác nhất [37].

Trong thiết kế hệ thống, ba kỹ thuật Prompt Engineering cốt lõi được áp dụng đồng thời:

(1) Thiết lập vai trò chuyên gia (Role Setting): Câu lệnh gửi Gemini API bắt đầu bằng việc thiết lập vai trò rõ ràng: *“Bạn là một chuyên gia phân tích thị trường lao động CNTT tại Việt Nam, am hiểu sâu sắc xu hướng kỹ thuật, từ vựng song ngữ Anh-Việt và từ điển kỹ năng của thị trường”*. Việc thiết lập vai trò hướng mô hình tập trung áp dụng tri thức chuyên ngành, chuẩn hóa tên công việc và kỹ năng theo thuật ngữ chuẩn mực, hạn chế trích xuất các cụm từ tự do thiếu giá trị phân tích.

(2) Ép kiểu dữ liệu đầu ra bằng Structured Outputs (JSON Schema): Để kết quả phản hồi từ Gemini API có thể nạp trực tiếp vào cơ sở dữ liệu quan hệ của hệ thống mà không gặp phải lỗi phân tích cú pháp, hệ thống sử dụng tính năng Structured Outputs kết hợp với thư viện Pydantic trong Python [15]. Cấu trúc này sau đó được truyền trực tiếp vào tham số `response_schema` của cấu hình cuộc gọi API của Gemini. Cơ chế này buộc mô hình ngôn ngữ ở tầng biên dịch của API phải tuân thủ tuyệt đối cấu trúc JSON được định nghĩa, loại bỏ hoàn toàn các câu thoại tự do dư thừa và đảm bảo các trường dữ liệu luôn nhất quán về định dạng và kiểu dữ liệu [37].

(3) Cơ chế hậu kiểm chống ảo giác (Anti-hallucination Verification): Một trong những hạn chế lớn nhất của LLM là hiện tượng ảo giác (hallucination) — mô hình tự động bổ sung hoặc suy diễn ra các kỹ năng không hề tồn tại trong văn bản gốc của CV hoặc JD [37]. Để triệt tiêu hiện tượng này, thiết kế prompt áp dụng kỹ thuật yêu cầu trích xuất kèm bằng chứng (evidence-based extraction). Trong schema JSON yêu cầu, mỗi thực thể kỹ năng bóc tách được bắt buộc phải đi kèm với trường `evidence_text` chứa đoạn văn bản thô trích xuất chính xác từ tài liệu gốc. Sau khi nhận phản hồi JSON từ Gemini API, hệ thống sẽ thực

thì một hàm kiểm chứng nội bộ: hàm này thực hiện kiểm tra xem chuỗi văn bản trong trường `evidence_text` có thực sự tồn tại trong văn bản CV/JD gốc ban đầu hay không. Nếu phát hiện sự sai lệch hoặc không tìm thấy chuỗi đối chứng, thực thể kỹ năng tương ứng sẽ bị đánh dấu là ảo giác và tự động bị loại bỏ khỏi luồng ETL. Cơ chế tự kiểm chứng này giúp nâng cao độ tin cậy của dữ liệu lên mức tối đa, đảm bảo tính công bằng và chính xác tuyệt đối cho thuật toán so khớp hồ sơ.

Vì vậy, trong hệ thống đề xuất, kỹ thuật Prompt Engineering kết hợp JSON Schema và cơ chế hậu kiểm chống ảo giác được triển khai nhằm triệt tiêu tối đa hiện tượng ảo giác thông tin, đảm bảo tính toàn vẹn và độ tin cậy khoa học cho dữ liệu đầu vào của pipeline so khớp.

Chương 3

Phân tích và thiết kế hệ thống

3.1 Phân tích yêu cầu hệ thống

3.1.1 Yêu cầu nghiệp vụ

Sinh viên ngành Công nghệ thông tin tại Việt Nam thường đối mặt với một nghịch lý trong quá trình tìm kiếm việc làm: dù sở hữu bằng cấp chuyên môn, nhiều sinh viên không có khả năng đánh giá khách quan khoảng cách giữa năng lực bản thân và yêu cầu thực tế của thị trường tuyển dụng. Các công cụ hỗ trợ hiện có, chủ yếu dưới dạng các trang tuyển dụng thông thường, chỉ cung cấp danh sách tin đăng mà thiếu hẳn cơ chế phân tích và phản hồi cá nhân hóa giúp sinh viên nhận diện điểm yếu năng lực một cách có hệ thống.

Bài toán nghiệp vụ cốt lõi của hệ thống CareerNova được xác định như sau: sinh viên CNTT cần một công cụ tự động hóa việc so sánh hồ sơ năng lực của bản thân với tập hợp yêu cầu kỹ năng từ các tin tuyển dụng thực tế trên thị trường, từ đó cung cấp kết quả so khớp trực quan và có thể hành động được. Để giải quyết bài toán này, hệ thống hoạt động theo luồng nghiệp vụ khép kín gồm bốn giai đoạn chính:

(1) Thu thập dữ liệu tuyển dụng: Hệ thống ETL tự động crawl và trích xuất thông tin từ các nền tảng tuyển dụng lớn tại Việt Nam (ITViec, VietnamWorks, CareerViet, LinkedIn), bao gồm yêu cầu kỹ năng, mức

lương và thông tin ngành nghề, nhằm xây dựng kho dữ liệu thị trường được cập nhật liên tục.

(2) Phân tích và chuẩn hóa: Dữ liệu tuyển dụng được làm sạch, trích xuất thực thể bằng Mô hình ngôn ngữ lớn (LLM API) và chuẩn hóa ngữ nghĩa về một từ điển kỹ năng thống nhất, đảm bảo tính nhất quán để so sánh chéo giữa các nguồn thu thập.

(3) So khớp CV với thị trường: Khi sinh viên tải lên CV, hệ thống tự động bóc tách kỹ năng, tính điểm tương đồng ngữ nghĩa dựa trên mô hình Sentence-BERT kết hợp trọng số TF-IDF thị trường, rồi tạo ra báo cáo khoảng cách kỹ năng và biểu đồ Radar chi tiết.

(4) Trực quan hóa và hỗ trợ quyết định: Kết quả được hiển thị qua giao diện dashboard tương tác, giúp sinh viên đọc hiểu tình trạng năng lực, theo dõi xu hướng tuyển dụng thị trường và nhận đề xuất lộ trình học tập cá nhân hóa.

Đối tượng sử dụng chính được xác định là **Sinh viên CNTT** (người dùng cuối chính, sử dụng toàn bộ tính năng phân tích và trực quan hóa). Ngoài ra, **Hệ thống ETL** đóng vai trò tác nhân tự động vận hành luồng thu thập và chuẩn hóa dữ liệu nền tảng.

3.1.2 Yêu cầu chức năng

Dựa trên bài toán nghiệp vụ, các yêu cầu chức năng của hệ thống được xác định và phân nhóm theo từng tác nhân (Actor) tham gia vào hệ thống như trong Bảng 3.1.

Bảng 3.1: Danh sách yêu cầu chức năng của hệ thống CareerNova.

Mã	Actor	Mô tả
<i>Nhóm chức năng: Quản lý tài khoản</i>		
UC-01	Sinh viên	Đăng ký tài khoản mới bằng địa chỉ email và mật khẩu.

Mã	Actor	Mô tả
UC-02	Sinh viên	Đăng nhập bằng tài khoản email/mật khẩu hoặc Google OAuth (Single Sign-On).
UC-03	Sinh viên	Xác thực địa chỉ email sau khi đăng ký để kích hoạt tài khoản.
UC-04	Sinh viên	Yêu cầu đặt lại mật khẩu qua email và tạo mật khẩu mới.
UC-05	Sinh viên	Hoàn tất luồng onboarding: khai báo thông tin năng lực và định hướng nghề nghiệp ban đầu.
UC-06	Sinh viên	Cập nhật hồ sơ cá nhân (họ tên, ảnh đại diện, thông tin nghề nghiệp).
UC-07	Sinh viên	Cài đặt tài khoản: thay đổi giao diện sáng/tối, quản lý thông báo, xóa tài khoản.
<i>Nhóm chức năng: Quản lý CV và So khớp</i>		
UC-08	Sinh viên	Tải lên, quản lý và đặt CV mặc định để sử dụng trong so khớp.
UC-09	Sinh viên	Thực hiện so khớp CV với tin tuyển dụng: hệ thống tính điểm tương đồng và tạo kết quả phân tích.
UC-10	Sinh viên	Xem biểu đồ Radar thể hiện điểm kỹ năng bản thân so với yêu cầu thị trường.
UC-11	Sinh viên	Xem Gap Report: báo cáo chi tiết kỹ năng đạt yêu cầu, đạt một phần và còn thiếu hụt.
<i>Nhóm chức năng: Khám phá việc làm</i>		

Mã	Actor	Mô tả
UC-12	Sinh viên	Tìm kiếm và lọc tin tuyển dụng theo từ khóa, kỹ năng và địa điểm; hỗ trợ sắp xếp kết quả theo thời gian đăng, mức lương hoặc mức độ phù hợp.
UC-13	Sinh viên	Xem chi tiết tin tuyển dụng bao gồm mô tả công việc và yêu cầu kỹ năng.
UC-14	Sinh viên	Lưu tin tuyển dụng yêu thích vào danh sách cá nhân.
UC-15	Sinh viên	Xem danh sách việc làm được đề xuất dựa trên hồ sơ năng lực cá nhân.
<i>Nhóm chức năng: Phân tích và Trực quan hóa</i>		
UC-16	Sinh viên	Xem Dashboard thị trường: thống kê tổng quan, xu hướng đăng tuyển, phân bổ thị trường, top vị trí và top kỹ năng nổi bật.
UC-17	Sinh viên	Xem Dashboard cá nhân: tổng hợp năng lực, tiến độ và kết quả so khớp của bản thân.
UC-18	Sinh viên	Xem lộ trình học tập được đề xuất để lấp đầy khoảng cách kỹ năng đã phát hiện.
<i>Nhóm chức năng: Thu thập và xử lý dữ liệu (tự động)</i>		
UC-21	Hệ thống ETL	Thu thập dữ liệu tin tuyển dụng tự động từ các nền tảng ITViec, VietnamWorks, CareerViet, LinkedIn.
UC-22	Hệ thống ETL	Chuẩn hóa, trích xuất thực thể kỹ năng và nạp dữ liệu vào cơ sở dữ liệu Cơ sở dữ liệu (Database).

3.1.3 Yêu cầu phi chức năng

Các yêu cầu phi chức năng thiết lập các ràng buộc về mặt kiến trúc, đảm bảo hệ thống vận hành ổn định, an toàn và dễ bảo trì. Các yêu cầu này được phân loại và trình bày trong Bảng 3.2.

Bảng 3.2: Danh sách yêu cầu phi chức năng của hệ thống CareerNova.

Mã	Loại	Mô tả
NFR-01	Hiệu năng	Thời gian phản hồi của API Backend không vượt quá 2 giây cho 95% các yêu cầu truy vấn thông thường (dashboard, tìm kiếm, hồ sơ).
NFR-02	Hiệu năng	Toàn bộ quy trình so khớp CV (bóc tách kỹ năng qua Mô hình ngôn ngữ lớn (LLM API), tính điểm Mô hình nhúng (Embedding), tạo Gap Report) hoàn thành trong vòng 30 giây kể từ thời điểm người dùng gửi yêu cầu.
NFR-03	Hiệu năng	API tìm kiếm việc làm phải hỗ trợ phân trang, giới hạn kích thước mỗi trang kết quả và chỉ truy vấn các trường dữ liệu cần thiết, nhằm tránh tải toàn bộ dữ liệu tuyển dụng về giao diện trong một lần yêu cầu.
NFR-04	Bảo mật	Xác thực người dùng được thực hiện theo cơ chế JWT stateless; access token có thời hạn ngắn và được làm mới qua refresh token để giảm thiểu rủi ro rò rỉ.


Mã	Loại	Mô tả
NFR-05	Bảo mật	Mật khẩu người dùng được băm bằng thuật toán bcrypt trước khi lưu vào cơ sở dữ liệu; không lưu trữ mật khẩu dạng plaintext tại bất kỳ tầng nào.
NFR-06	Bảo mật	Các container Docker chạy dưới tài khoản non-root (UID 1001 đối với Giao diện người dùng (Frontend)) và không nhúng thông tin xác thực nhạy cảm vào image, tuân thủ nguyên tắc đặc quyền tối thiểu.
NFR-07	Bảo mật	Toàn bộ giao tiếp giữa Giao diện người dùng (Frontend) và Backend được mã hóa qua HTTPS/TLS; Backend tích hợp OpenSSL (khai báo trong Dockerfile) để hỗ trợ kết nối cơ sở dữ liệu bảo mật.
NFR-08	Khả năng mở rộng	Các thành phần của hệ thống (Tầng Trình bày, Tầng Nghiệp vụ, Tầng Xử lý dữ liệu) phải được thiết kế đóng gói độc lập, cho phép triển khai, nâng cấp và mở rộng theo chiều ngang (horizontal scaling) mà không ảnh hưởng đến các thành phần còn lại.
NFR-09	Khả năng mở rộng	Pipeline ETL được thiết kế theo kiến trúc module hóa (crawl → clean → normalize → import), cho phép bổ sung nguồn tuyển dụng mới hoặc thay thế mô hình LLM mà không cần thay đổi cấu trúc tổng thể.
NFR-10	Độ tin cậy	Hệ quản trị cơ sở dữ liệu phải có cơ chế sao lưu và cấp phát vùng nhớ độc lập, đảm bảo dữ liệu không bị mất khi máy chủ dịch vụ khởi động lại.

Mã	Loại	Mô tả
NFR-11	Độ tin cậy	ETL Pipeline tích hợp cơ chế fallback tự động: ưu tiên cào tĩnh bằng Requests/cloudscraper, tự động chuyển sang Selenium Headless Browser khi gặp tường lửa chống bot, đảm bảo tính liên tục của quá trình thu thập dữ liệu.
NFR-12	Độ tin cậy	Kết quả bóc tách kỹ năng từ Mô hình ngôn ngữ lớn (LLM) được kiểm chứng bằng cơ chế anti-hallucination: mỗi thực thể kỹ năng phải kèm bằng chứng (<code>evidence_text</code>) trích từ văn bản gốc; nếu không khớp sẽ bị loại bỏ tự động.
NFR-13	Bảo trì	Tầng Xử lý nghiệp vụ phải được tổ chức theo kiến trúc phân hệ (module) rõ ràng (auth, profile, job, matching, skill-gap, market-dashboard, v.v.), mỗi module độc lập về controller, service và DTO, giúp dễ dàng bảo trì và mở rộng từng tính năng riêng lẻ.
NFR-14	Bảo trì	Hệ thống ưu tiên sử dụng các ngôn ngữ lập trình có kiểu dữ liệu tĩnh và tường minh, giúp phát hiện lỗi tại thời điểm biên dịch, giảm thiểu lỗi runtime và hỗ trợ tái cấu trúc mã nguồn an toàn.

3.2 Thiết kế hệ thống

3.2.1 Sơ đồ kiến trúc tổng thể

Hệ thống CareerNova được xây dựng theo kiến trúc đa tầng (multi-tier architecture) với bốn tầng chức năng độc lập, mỗi tầng đảm nhiệm một vai trò chuyên biệt trong luồng xử lý dữ liệu từ nguồn tuyển dụng đến giao diện người dùng cuối. Sơ đồ kiến trúc tổng thể được thể hiện trong Hình 3.1.



Hình 3.1: Sơ đồ kiến trúc tổng thể hệ thống CareerNova.

Tầng Trình Bày (Presentation Layer) bao gồm ứng dụng web đơn trang (Single-Page Application). Tầng này đảm nhận toàn bộ việc hiển thị giao diện và tương tác người dùng, bao gồm các trang xác thực (đăng nhập, đăng ký, SSO), luồng định hướng (onboarding), trang quản lý CV, và các thành phần trực quan hóa cốt lõi. Giao tiếp với tầng nghiệp vụ được thiết kế qua giao thức REST API sử dụng HTTPS và cơ chế xác thực không trạng thái (stateless authentication).

Tầng Nghiệp Vụ (Business Logic Layer) gồm hai thành phần hoạt động phối hợp. Thành phần thứ nhất là **Cổng dịch vụ điều phối (Core API)**, quản lý xác thực và phân quyền, xử lý hồ sơ người dùng, tổng hợp dữ liệu, và điều phối luồng đối soát sang Dịch vụ xử lý dữ liệu. Kết nối cơ sở dữ liệu được thực hiện qua cơ chế Object-Relational Mapping (ORM).


Thành phần thứ hai là **Pipeline Xử lý dữ liệu (Data Processing Engine)**, chịu trách nhiệm toàn bộ luồng công việc nặng: thu thập dữ liệu tự động, trích xuất và chuẩn hóa thực thể, mã hóa vector ngữ nghĩa và tìm kiếm tương đồng trên không gian nhiều chiều.

Tầng Dữ Liệu (Data Layer) sử dụng hệ quản trị cơ sở dữ liệu quan hệ (RDBMS), lưu trữ toàn bộ dữ liệu hệ thống: thông tin người dùng và CV, kho dữ liệu tuyển dụng, và kết quả phân tích so khớp. Việc lưu trữ trước kết quả tính toán dưới dạng văn bản có cấu trúc (JSON) giúp tối ưu hóa hiệu năng truy vấn thời gian thực tại tầng trình bày mà không cần lặp lại các phép toán tốn kém.

Tầng Dịch Vụ Ngoài (External Services Layer) bao gồm ba thành phần: **Dịch vụ Mô hình ngôn ngữ lớn (LLM)** thực hiện trích xuất thực thể có cấu trúc từ văn bản tự do; **Mô hình nhúng ngữ nghĩa (Embedding Model)** mã hóa câu thành vector và xây dựng chỉ mục tìm kiếm; và **Các nền tảng nguồn** cung cấp dữ liệu tin tuyển dụng thô cho Pipeline xử lý.

3.2.2 Sơ đồ Use Case tổng quát

Sơ đồ Use Case tổng quát thể hiện toàn bộ tương tác giữa hai Actor — Sinh viên và Hệ thống ETL — với hệ thống CareerNova, bao gồm các quan hệ **include** và **extend** giữa các Use Case. Sơ đồ được mô tả trong Hình 3.2.



Hình 3.2: Sơ đồ Use Case tổng quát của hệ thống CareerNova.

Bảng 3.3, Bảng 3.4 và Bảng 3.5 trình bày đặc tả chi tiết cho ba Use Case quan trọng nhất của hệ thống.

Bảng 3.3: Đặc tả Use Case UC-09: Tải lên CV và So khớp kỹ năng.

Trường	Nội dung
Mã	UC-09
Tên	Tải lên CV và So khớp kỹ năng với thị trường
Actor chính	Sinh viên
Tiền điều kiện	Sinh viên đã đăng nhập và hoàn tất onboarding; tài khoản đang active.
Luồng chính	1. Sinh viên truy cập trang CV Matching, chọn tệp CV (PDF/JPG/PNG) và tin tuyển dụng mục tiêu. 2. Hệ thống xác thực định dạng tệp, tải lên Core API. 3. Hệ thống lưu metadata CV vào <code>user_cvs</code>, chuyển tiếp sang Data Processing Engine. 4. Data Engine trích xuất văn bản CV (OCR nếu là ảnh quét), gọi LLM API bóc tách danh sách kỹ năng. 5. Hệ thống mã hóa kỹ năng thành vector Mô hình nhúng (Embedding), tính Match Score $= \sum(\text{weight} \times \text{cosine}) \div \sum(\text{weight})$. 6. Kết quả <code>radar_data</code> và <code>gap_report</code> JSONB được lưu vào bảng <code>cv_job_matches</code>. 7. Giao diện người dùng (Frontend) truy vấn và hiển thị biểu đồ Radar và Gap Report.
Luồng thay thế	4a. Nếu CV là ảnh quét: hệ thống thực hiện OCR (pdf2image + Pytesseract) trước khi trích xuất. 4b. Nếu kỹ năng được Gemini trả về không có <code>evidence_text</code> khớp trong văn bản gốc: thực thể bị loại bỏ (anti-hallucination).

Trường	Nội dung
Hậu điều kiện	Kết quả so khớp được lưu vào cơ sở dữ liệu; sinh viên xem được biểu đồ Radar và danh sách kỹ năng còn thiếu.

Bảng 3.4: Đặc tả Use Case UC-11: Xem Gap Report và báo cáo khoảng cách kỹ năng.

Trường	Nội dung
Mã	UC-11
Tên	Xem Gap Report và báo cáo khoảng cách kỹ năng
Actor chính	Sinh viên
Tiền điều kiện	Sinh viên đã thực hiện so khớp CV (UC-09); trường <code>gap_report</code> JSONB đã được lưu vào <code>cv_job_matches</code> .
Luồng chính	1. Sinh viên truy cập trang Skill Gap Analysis. 2. Giao diện người dùng (Frontend) gọi API lấy dữ liệu từ <code>cv_job_matches.gap_report</code>. 3. Hệ thống phân loại kỹ năng thành ba nhóm: Đạt yêu cầu (xanh lá), Đạt một phần (vàng), Thiếu hụt (đỏ). 4. Giao diện người dùng (Frontend) hiển thị biểu đồ cột ngang phân kỳ và danh sách kỹ năng chi tiết. 5. Sinh viên mở rộng từng danh mục kỹ năng để xem điểm <code>user_rate</code> và <code>market_rate</code>.
Luồng thay thế	2a. Nếu chưa có kết quả so khớp: hệ thống hiển thị gợi ý thực hiện UC-09 trước.

Trường	Nội dung
Hậu điều kiện	Sinh viên nắm được danh sách kỹ năng cụ thể cần bổ sung và có thể điều hướng sang UC-18 để xem lộ trình học tập đề xuất.

Bảng 3.5: Đặc tả Use Case UC-16: Xem Dashboard thống kê thị trường việc làm.


Trường	Nội dung
Mã	UC-16
Tên	Xem Dashboard thống kê thị trường việc làm
Actor chính	Sinh viên
Tiền điều kiện	Sinh viên đã đăng nhập; cơ sở dữ liệu đã có dữ liệu tuyển dụng từ ETL Pipeline.

Trường	Nội dung
Luồng chính	1. Sinh viên truy cập trang Market Dashboard. 2. Giao diện người dùng (Frontend) khởi tạo <code>fetchDashboardData()</code> và gửi đồng thời (<code>Promise.all</code>) sáu yêu cầu API: thống kê tổng quan, xu hướng tuyển dụng, phân bổ thị trường, top vị trí hot, top kỹ năng được yêu cầu và kỹ năng tăng trưởng. 3. Core API truy vấn cơ sở dữ liệu và trả về JSON tương ứng cho từng thành phần trực quan hóa. 4. Giao diện người dùng (Frontend) kết xuất <code>AreaChart</code> (xu hướng), <code>Treemap</code> (phân bổ thị trường), <code>BarChart</code> (xếp hạng kỹ năng/chỉ báo) và các khối thống kê bằng thư viện biểu đồ trực quan. 5. Sinh viên lọc theo khoảng thời gian (tháng/năm) để xem xu hướng tương ứng.
Luồng thay thế	3a. Nếu không có dữ liệu trong cơ sở dữ liệu (ETL chưa chạy): hiển thị thông báo dữ liệu chưa sẵn sàng.
Hậu điều kiện	Sinh viên nắm được xu hướng tuyển dụng, các ngành đang có nhu cầu cao, các vị trí hot và nhóm kỹ năng nổi bật trên thị trường.

3.2.3 Sơ đồ tuần tự cho các chức năng chính

Luồng tải lên CV và So khớp kỹ năng

Hình 3.3 mô tả luồng tương tác tuần tự giữa các thành phần hệ thống khi sinh viên thực hiện chức năng tải lên CV và so khớp kỹ năng.




Hình 3.3: Sơ đồ tuần tự luồng tải lên CV và so khớp kỹ năng.

Luồng xử lý bắt đầu khi người dùng gửi tệp CV từ Giao diện người dùng (Frontend). Core API tiếp nhận, lưu metadata và chuyển tiếp sang Data Processing Engine qua HTTP. Tại đây, văn bản CV được bóc tách (OCR nếu cần), kỹ năng được trích xuất qua Mô hình ngôn ngữ lớn (LLM API) với cơ chế kiểm chứng chống ảo giác (`evidence_text`), sau đó mã hóa thành vector 384 chiều bằng mô hình nhúng (Embedding) và tính điểm tương đồng Cosine có trọng số TF-IDF thị trường. Kết quả `radar_data` và `gap_report` JSONB được lưu vào bảng `cv_job_matches` trong Cơ sở dữ liệu (Database) và trả về Giao diện người dùng (Frontend) để kết xuất biểu đồ Radar và Gap Report.

Luồng xem Dashboard thị trường

Hình 3.4 mô tả luồng tương tác tuần tự khi sinh viên truy cập trang Dashboard thị trường.

Sơ đồ tuần tự: Xem Dashboard thống kê thị trường việc làm



Hình 3.4: Sơ đồ tuần tự luồng xem Dashboard thống kê thị trường việc làm.

Khi người dùng điều hướng đến MarketDashboard, Giao diện người dùng (Frontend) khởi tạo sáu truy vấn API song song (Promise.all) để lấy


dữ liệu thống kê tổng quan, xu hướng tuyển dụng, phân bổ thị trường, top vị trí hot, top kỹ năng được yêu cầu và kỹ năng tăng trưởng. Core API thực hiện các truy vấn tổng hợp (aggregation) trực tiếp trên Cơ sở dữ liệu (Database) và trả về JSON cho từng thành phần trực quan hóa. Giao diện người dùng (Frontend) cập nhật state qua `setStats()`, `setTrends()`, `setIndustriesData()`, `setHotJobsData()`, `setInDemandSkillsData()` và `setRisingSkillsData()`, rồi kết xuất đồng thời AreaChart, Treemap, BarChart và các khối thống kê bằng thư viện biểu đồ trực quan, mang lại trải nghiệm tải trang nhanh và phản hồi tương tác tức thì.

3.3 Thiết kế cơ sở dữ liệu

Cơ sở dữ liệu của hệ thống được xây dựng trên hệ quản trị cơ sở dữ liệu quan hệ Cơ sở dữ liệu (Database) (phiên bản 17). Thiết kế đảm bảo tính toàn vẹn dữ liệu, hiệu năng truy vấn thông qua các ràng buộc khóa ngoại (foreign key), chỉ mục (index) và phân tách chuẩn hóa các thực thể.

3.3.1 Sơ đồ mối quan hệ thực thể (ERD)

Dưới đây là sơ đồ mối quan hệ thực thể (ERD) biểu diễn cấu trúc cơ sở dữ liệu của hệ thống:



Hình 3.5: Sơ đồ mối quan hệ thực thể (ERD) của hệ thống.

3.3.2 Đặc tả các bảng dữ liệu thực tế

Dưới đây là chi tiết cấu trúc thuộc tính, kiểu dữ liệu, các ràng buộc và ý nghĩa chức năng của từng bảng trong cơ sở dữ liệu.

1. Bảng users (Thông tin người dùng)

Bảng này lưu trữ thông tin tài khoản người dùng, bao gồm sinh viên và quản trị viên hệ thống.

Bảng 3.6: Cấu trúc bảng **users**.

Tên trường	Kiểu dữ liệu	Ràng buộc	Ý nghĩa
<code>user_id</code>	uuid	PK, DEFAULT <code>gen_random_uuid()</code>	Định danh duy nhất của người dùng.
<code>full_name</code>	<code>varchar(255)</code>	NULL	Họ và tên đầy đủ.
<code>email</code>	<code>varchar(255)</code>	UNIQUE, NOT NULL	Địa chỉ email đăng ký tài khoản.
<code>password_hash</code>	text	NULL (nếu đăng nhập mạng xã hội)	Mật khẩu tài khoản đã băm an toàn.
<code>avatar_url</code>	text	NULL	Đường dẫn ảnh đại diện.
<code>role</code>	<code>varchar(50)</code>	DEFAULT 'student', CHECK (role IN ('student'))	Vai trò tài khoản (Sinh viên).
<code>created_at</code>	timestamp	DEFAULT CURRENT_TIMESTAMP	Thời điểm tạo tài khoản.

Tên trường	Kiểu dữ liệu	Ràng buộc	Ý nghĩa
is_active	boolean	DEFAULT false	Trạng thái kích hoạt tài khoản.
verify_token	varchar(255)	NULL	Mã xác thực email kích hoạt.
verify_token_expires	timestamp	NULL	Hạn dùng của mã xác thực email.

2. Bảng user_auth_providers (Liên kết nhà cung cấp xác thực)

Lưu trữ thông tin xác thực bên thứ ba (Google, Facebook) phục vụ đăng nhập Single Sign-On (SSO).

Bảng 3.7: Cấu trúc bảng user_auth_providers.

Tên trường	Kiểu dữ liệu	Ràng buộc	Ý nghĩa
auth_provider_id	uuid	PK, DEFAULT gen_random_uuid()	Định danh duy nhất liên kết xác thực.
user_id	uuid	FK -> users(user_id) ON DELETE CASCADE	ID người dùng sở hữu liên kết.
provider	varchar(50)	CHECK (provider IN ('local', 'google', 'facebook'))	Tên nhà cung cấp dịch vụ xác thực.
provider_user_id	varchar(255)	NOT NULL	ID định danh từ phía nhà cung cấp.

Tên trường	Kiểu dữ liệu	Ràng buộc	Ý nghĩa
provider_email	varchar(255)	NULL	Email trả về từ nhà cung cấp.
provider_name	varchar(255)	NULL	Họ tên trả về từ nhà cung cấp.
provider_avatar_url	text	NULL	Ảnh đại diện trả về từ nhà cung cấp.
created_at	timestamp	DEFAULT CURRENT_TIMESTAMP	Thời điểm liên kết.
last_login_at	timestamp	NULL	Lần đăng nhập cuối qua provider này.

3. Bảng user_cvs (Thông tin tệp CV đã tải lên)

Lưu trữ thông tin các tệp tin CV do sinh viên tải lên hệ thống.

Bảng 3.8: Cấu trúc bảng user_cvs.

Tên trường	Kiểu dữ liệu	Ràng buộc	Ý nghĩa
cv_id	uuid	PK, DEFAULT gen_random_uuid()	Định danh duy nhất cho CV.
user_id	uuid	FK -> users(user_id) ON DELETE CASCADE	Định danh sinh viên sở hữu CV.
file_name	varchar(255)	NULL	Tên tệp tin gốc tải lên.

Tên trường	Kiểu dữ liệu	Ràng buộc	Ý nghĩa
file_url	text	NULL	Đường dẫn URL tệp tin trên hệ thống lưu trữ.
extracted_text	text	NULL	Nội dung văn bản thô trích xuất từ CV.
uploaded_at	timestamp	DEFAULT CURRENT_TIMESTAMP	Thời điểm tải lên hệ thống.
updated_at	timestamp	DEFAULT CURRENT_TIMESTAMP	Thời điểm cập nhật cuối cùng.

4. Bảng skills (Từ điển kỹ năng hệ thống)

Lưu trữ danh mục kỹ năng chuẩn hóa dựa trên phân loại hệ thống (ví dụ: chuẩn O*NET hoặc Lightcast).

Bảng 3.9: Cấu trúc bảng **skills**.

Tên trường	Kiểu dữ liệu	Ràng buộc	Ý nghĩa
skill_id	integer	PK, SERIAL	Định danh duy nhất cho kỹ năng.
skill_name	varchar(255)	UNIQUE, NOT NULL	Tên chuẩn hóa của kỹ năng.
category	varchar(255)	NULL	Nhóm phân loại chính của kỹ năng.

Tên trường	Kiểu dữ liệu	Ràng buộc	Ý nghĩa
type	varchar(100)	NULL	Loại kỹ năng (Specialized skill, Common skill, Certification).
is_software	boolean	NULL	Đánh dấu kỹ năng thuộc nhóm phần mềm/công cụ (phục vụ luật lọc ngữ nghĩa).
is_language	boolean	NULL	Đánh dấu kỹ năng là ngôn ngữ tự nhiên (phục vụ luật lọc ngôn ngữ).
category_name	varchar(255)	NULL	Tên phân nhóm chuyên môn dùng cho luật phạt/tăng cường theo phân nhóm.
created_at	timestamp	DEFAULT CURRENT_TIMESTAMP	Ngày tạo bản ghi kỹ năng.

5. Bảng user_cv_skills (Kỹ năng chi tiết của sinh viên)

Bảng cầu nối lưu trữ danh sách các kỹ năng chuẩn hóa được trích xuất từ CV ứng viên.

Bảng 3.10: Cấu trúc bảng `user_cv_skills`.

Tên trường	Kiểu dữ liệu	Ràng buộc	Ý nghĩa
<code>cv_id</code>	<code>uuid</code>	PK, FK -> <code>user_cvs(cv_id)</code> ON DELETE CASCADE	ID của CV được phân tích.
<code>skill_id</code>	<code>integer</code>	PK, FK -> <code>skills(skill_id)</code> ON DELETE CASCADE	ID kỹ năng chuẩn hóa tương ứng.
<code>raw_skill</code>	<code>varchar(255)</code>	NULL	Cụm từ kỹ năng gốc ghi trên CV.
<code>created_at</code>	<code>timestamp</code>	DEFAULT CURRENT_TIMESTAMP	Thời điểm lưu bản ghi.

6. Bảng `companies` (Thông tin doanh nghiệp tuyển dụng)

Lưu trữ dữ liệu hồ sơ công ty đăng tuyển việc làm.

Bảng 3.11: Cấu trúc bảng `companies`.

Tên trường	Kiểu dữ liệu	Ràng buộc	Ý nghĩa
<code>company_id</code>	<code>bigint</code>	PK	Định danh duy nhất cho doanh nghiệp.
<code>name</code>	<code>varchar(255)</code>	NOT NULL	Tên công ty/doanh nghiệp.
<code>description</code>	<code>text</code>	NULL	Mô tả chi tiết về doanh nghiệp.

Tên trường	Kiểu dữ liệu	Ràng buộc	Ý nghĩa
company_size_min	integer	NULL	Quy mô nhân sự tối thiểu.
company_size_max	integer	NULL	Quy mô nhân sự tối đa.
country	varchar(100)	NULL	Quốc gia đặt trụ sở.
city	varchar(100)	NULL	Thành phố đặt văn phòng.
address	text	NULL	Địa chỉ chi tiết.
url	varchar(500)	NULL	Liên kết trang web chính thức.
industry	varchar(255)	NULL	Lĩnh vực hoạt động chính.

7. Bảng jobs (Thông tin việc làm đăng tuyển)

Lưu thông tin chi tiết các bản tin tuyển dụng việc làm thu thập được.

Bảng 3.12: Cấu trúc bảng jobs.

Tên trường	Kiểu dữ liệu	Ràng buộc	Ý nghĩa
job_id	bigint	PK, SERIAL	Định danh tin tuyển dụng.
company_id	bigint	FK -> companies(company_id) ON DELETE SET NULL	ID công ty đăng tuyển.
title	varchar(500)	NOT NULL	Tiêu đề công việc đăng tuyển.

Tên trường	Kiểu dữ liệu	Ràng buộc	Ý nghĩa
skills_desc	text	NULL	Phần mô tả yêu cầu kỹ năng.
description	text	NULL	Mô tả chi tiết nhiệm vụ công việc.
formatted_experience_level	varchar(100)	NULL, INDEX	Cấp bậc kinh nghiệm yêu cầu.
work_type	varchar(100)	NULL	Hình thức làm việc (Full-time/Part-time).
location	varchar(255)	NULL	Địa điểm làm việc.
is_remote	boolean	DEFAULT false	Cho phép làm việc từ xa (Remote).
listed_time	timestamp with time zone	NULL	Ngày đăng tin tuyển dụng.
expiry_time	timestamp with time zone	NULL	Hạn nộp hồ sơ.
job_posting_url	text	NULL	Liên kết nguồn của tin tuyển dụng.
scraped_at	timestamp	DEFAULT CURRENT_TIMESTAMP	Thời điểm thu thập dữ liệu.
applies	integer	DEFAULT 0	Số lượt nộp hồ sơ ghi nhận.
views	integer	DEFAULT 0	Số lượt xem tin tuyển dụng.

Tên trường	Kiểu dữ liệu	Ràng buộc	Ý nghĩa
fingerprint	varchar(32)	UNIQUE	Mã MD5 hash nhận diện chống trùng lặp.
job_category	varchar(100)	NULL	Phân mục nghề nghiệp tổng quan.
search_group	varchar(100)	NULL	Nhóm ngành công việc tiêu chuẩn liên kết.
source_name	varchar(50)	NULL	Nguồn thu thập (LinkedIn, Vietnamworks...).
source_id	varchar(255)	NULL	ID tin gốc trên nguồn thu thập.

8. Bảng job_skills (Yêu cầu kỹ năng chi tiết của việc làm)

Cầu nối liên kết các yêu cầu kỹ năng chuẩn hóa thuộc một tin tuyển dụng cụ thể.

Bảng 3.13: Cấu trúc bảng job_skills.

Tên trường	Kiểu dữ liệu	Ràng buộc	Ý nghĩa
job_id	bigint	PK, FK -> jobs(job_id) ON DELETE CASCADE	ID tin tuyển dụng yêu cầu.

Tên trường	Kiểu dữ liệu	Ràng buộc	Ý nghĩa
skill_id	integer	PK, FK -> skills(skill_id) ON DELETE CASCADE	ID kỹ năng chuẩn hóa.
is_inferred	boolean	DEFAULT false	Kỹ năng được suy diễn gián tiếp.
reason	varchar(50)	NULL	Lý do liên kết (match tên, LLM trích xuất).
model_name	varchar(100)	NULL	Tên mô hình AI dùng để liên kết.
similarity_score	numeric(4,3)	NULL	Điểm tương đồng ngữ nghĩa khi đối sánh.
lib_version	varchar(20)	NULL	Phiên bản thư viện sử dụng.
raw_skill_name	varchar(255)	NULL	Tên kỹ năng thô trong văn bản job.

9. Bảng cv_job_matches (Kết quả so khớp và phân tích khoảng cách năng lực)

Lưu trữ kết quả tính toán độ tương thích giữa CV của sinh viên với một vị trí công việc cụ thể hoặc một nhóm ngành nghề.

Bảng 3.14: Cấu trúc bảng cv_job_matches.

Tên trường	Kiểu dữ liệu	Ràng buộc	Ý nghĩa
match_id	uuid	PK, DEFAULT gen_random_uuid()	Định danh duy nhất của kết quả khớp.
cv_id	uuid	FK -> user_cvs(cv_id) ON DELETE CASCADE	ID CV tham gia so khớp.
job_id	bigint	FK -> jobs(job_id) ON DELETE SET NULL, NULL	ID Job cụ thể tham gia so khớp (nếu có).
match_type	varchar(50)	CHECK (match_type IN (‘search_group’, ‘existing_job’, ‘url_job’))	Phân loại kiểu so khớp.
search_group	varchar(100)	NULL	Tên nhóm ngành chuẩn hóa được so khớp.
match_score	numeric(5,2)	CHECK (match_score ≥ 0 AND match_score ≤ 100)	Điểm số phần trăm tương thích tổng thể.

Tên trường	Kiểu dữ liệu	Ràng buộc	Ý nghĩa
radar_data	jsonb	NOT NULL	Cấu trúc JSON biểu diễn phân bố kỹ năng (vẽ biểu đồ Radar).
gap_report	jsonb	NOT NULL	Chi tiết báo cáo khoảng cách kỹ năng.
model_version	varchar(100)	NULL	Phiên bản thuật toán đối sánh.
created_at	timestamp	DEFAULT CURRENT_TIMESTAMP	Thời điểm tính toán.
updated_at	timestamp	DEFAULT CURRENT_TIMESTAMP	Thời điểm cập nhật kết quả.

10. Bảng job_group_skill_weights (Trọng số kỹ năng theo nhóm ngành)

Bảng lưu trữ trọng số tầm quan trọng w_i của từng kỹ năng thuộc một nhóm ngành công việc tiêu chuẩn, được tính toán bằng thuật toán TF-IDF trên tập dữ liệu việc làm.

Bảng 3.15: Cấu trúc bảng job_group_skill_weights.

Tên trường	Kiểu dữ liệu	Ràng buộc	Ý nghĩa
search_group	varchar(100)	PK	Tên nhóm ngành công việc tiêu chuẩn.

Tên trường	Kiểu dữ liệu	Ràng buộc	Ý nghĩa
skill_id	integer	PK, FK -> skills(skill_id) ON DELETE CASCADE	ID kỹ năng chuẩn hóa trong nhóm.
weight_wi	numeric(8,4)	NOT NULL	Trọng số đặc trưng w_i của kỹ năng trong nhóm.

11. Bảng salaries (Thông tin mức lương của tin tuyển dụng)

Lưu trữ dữ liệu mức lương tương ứng cho từng tin tuyển dụng. Dữ liệu này phục vụ cho thông tin chi tiết của tin và các phân tích có thể mở rộng trong tương lai; phiên bản Dashboard hiện tại không trực quan hóa chỉ số lương.

Bảng 3.16: Cấu trúc bảng salaries.

Tên trường	Kiểu dữ liệu	Ràng buộc	Ý nghĩa
salary_id	integer	PK, SERIAL	Định danh duy nhất bản ghi lương.
job_id	bigint	FK → jobs(job_id) ON DELETE CASCADE	Tin tuyển dụng tương ứng.
min_salary	numeric(18,2)	NULL	Mức lương tối thiểu.
max_salary	numeric(18,2)	NULL	Mức lương tối đa.

Tên trường	Kiểu dữ liệu	Ràng buộc	Ý nghĩa
med_salary	numeric(18,2)	NULL	Mức lương trung vị.
currency	varchar(10)	DEFAULT 'VND'	Đơn vị tiền tệ.
pay_period	varchar(20)	NULL	Chu kỳ trả lương (Monthly, Yearly).

12. Bảng saved_jobs (Việc làm yêu thích của sinh viên)

Bảng cầu nối ghi nhận các tin tuyển dụng được sinh viên đánh dấu lưu lại, phục vụ tính năng danh sách yêu thích và gợi ý đối soát CV.

Bảng 3.17: Cấu trúc bảng saved_jobs.

Tên trường	Kiểu dữ liệu	Ràng buộc	Ý nghĩa
saved_job_id	uuid	PK, DEFAULT gen_random_uuid()	Định danh duy nhất bản ghi lưu.
user_id	uuid	FK → users(user_id) ON DELETE CASCADE	Sinh viên thực hiện lưu.
job_id	bigint	FK → jobs(job_id) ON DELETE CASCADE	Tin tuyển dụng được lưu.
created_at	timestamp	Tự động; UNIQUE	Thời điểm lưu; ràng buộc composite ngăn lưu trùng.

13–15. Nhóm bảng Khóa học và Lộ trình học tập

Nhóm ba bảng phụ trợ `courses`, `learning_paths` và `path_courses` lưu trữ dữ liệu phục vụ tính năng đề xuất lộ trình học tập (Learning Roadmap) cá nhân hóa theo kết quả Gap Report của từng sinh viên.

- **courses:** Mỗi bản ghi lưu metadata một khóa học gồm tiêu đề, nhà cung cấp (Coursera, Udemy, v.v.), đường dẫn nguồn, thời lượng (giờ), đánh giá sao, giá và mảng thẻ kỹ năng (`skills_tags[]`) để đối chiếu với kỹ năng thiếu hụt trong Gap Report.
- **learning_paths:** Mỗi lộ trình học tập được định nghĩa bởi một `skill_key` (tên kỹ năng chuẩn), cấp độ (Beginner/Intermediate/Advanced), thời gian ước tính và một tập hợp các khóa học được sắp xếp tuần tự theo `sort_order`.
- **path_courses:** Bảng cầu nối N-N liên kết `learning_paths` và `courses`, lưu thêm trường `sort_order` để đảm bảo thứ tự học tập logic trong lộ trình.

Khi sinh viên xem kết quả Gap Report, hệ thống tự động tra cứu `skill_key` của từng kỹ năng thiếu hụt trong bảng `learning_paths` và trả về lộ trình tương ứng cùng danh sách khóa học được sắp xếp theo thứ tự ưu tiên.

16–17. Nhóm bảng Thông báo hệ thống

Nhóm bảng `notifications` và `notification_templates` triển khai hệ thống thông báo in-app đa kênh.

- **notification_templates:** Lưu trữ các mẫu thông báo tái sử dụng với tiêu đề và nội dung dạng template (có placeholder thay thế động). Mỗi template được định danh bằng `template_code` duy nhất (ví dụ: `CV_MATCH_COMPLETE`, `NEW_JOB_RECOMMENDATION`) và có thể tắt/bật qua trường `is_active`.

- **notifications:** Mỗi bản ghi là một thông báo cụ thể gửi đến một người dùng, liên kết với thực thể nguồn qua cặp (**entity_type**, **entity_id**), lưu trạng thái đọc (**is_read**, **read_at**) và metadata bổ sung dưới dạng JSONB. Các chỉ mục composite trên (**user_id**, **created_at**), (**user_id**, **is_read**) đảm bảo hiệu năng truy vấn danh sách thông báo chưa đọc theo thời gian thực.

18–19. Nhóm bảng Hỗ trợ ETL Pipeline

Hai bảng phụ trợ phục vụ vận hành và cải thiện chất lượng Pipeline ETL theo thời gian:


- **unmatched_skills:** Ghi lại các cụm từ kỹ năng thô từ văn bản JD hoặc CV mà Pipeline không thể chuẩn hóa thành công vào từ điển **skills** (điểm tương đồng dưới ngưỡng). Mỗi bản ghi lưu số lần xuất hiện (**occurrence_count**), điểm tương đồng cao nhất (**max_similarity_score**) và kỹ năng ứng viên gần nhất (**top_candidate_skill**). Bảng này là đầu vào quan trọng cho quy trình mở rộng từ điển định kỳ, giúp hệ thống tự cải thiện khả năng nhận dạng kỹ năng mới xuất hiện trên thị trường.
- **search_group_keywords:** Ánh xạ từ khóa tìm kiếm của người dùng hoặc tiêu đề tin tuyển dụng sang nhóm ngành chuẩn hóa (**group_key**) tương ứng. Bảng này phục vụ bước phân loại tự động nhóm ngành cho từng tin tuyển dụng mới thu thập, đảm bảo tính nhất quán trong cách phân loại dữ liệu giữa các lần chạy ETL.

3.4 Thiết kế giao diện

3.4.1 Trang chủ và Dashboard thống kê thị trường việc làm

Hệ thống CareerNova được thiết kế với hai điểm vào chính cho người dùng: trang chủ (Landing Page) dành cho khách chưa xác thực và trang Dashboard thị trường dành cho người dùng đã đăng nhập.

Trang chủ (Landing Page) là giao diện đầu tiên người dùng tiếp cận khi truy cập hệ thống. Phần đầu trang (hero section) trình bày thông điệp giá trị cốt lõi của nền tảng cùng hai nút hành động chính: "*Bắt đầu miễn phí*" (dẫn đến trang đăng ký) và "*Xem Thông tin Thị trường*" (dẫn đến Dashboard). Tiếp theo, bốn tính năng chủ đạo được trình bày dưới dạng lưới (so khớp CV, đề xuất việc làm, phân tích kỹ năng, dashboard thị trường) kèm luồng sử dụng bốn bước trực quan để định hướng người dùng mới.



Hình 3.6: Giao diện trang chủ (Landing Page) của hệ thống CareerNova.


Dashboard thống kê thị trường (route /dashboard) là trang phân tích thị trường trung tâm, được tổ chức theo cấu trúc thông tin từ tổng quan đến chi tiết. Phần trên cùng hiển thị thanh lọc ba chiều (khu vực,

khoảng thời gian, loại hình công việc) và ba thẻ thống kê tóm tắt: số tin tuyển dụng đang mở (kèm badge phần trăm tăng trưởng so với kỳ trước), số công ty đang tuyển và số vị trí thực tập phù hợp với sinh viên. Mỗi thẻ đồng thời là liên kết điều hướng sang trang tìm kiếm việc làm với bộ lọc tương ứng được giữ nguyên. Khu vực biểu đồ chính bao gồm hai thành phần bố trí trên cùng một hàng:


- **AreaChart "Xu hướng tin tuyển dụng"** (chiếm 2/3 chiều rộng): biểu diễn tổng số tin tuyển dụng (đường xanh dương) và số vị trí làm việc từ xa (đường xanh lá) theo thời gian, với trục X là nhãn ngày/tháng (tự động chuyển thang đo theo khoảng thời gian lọc) và trục Y là số lượng tin.
- **Treemap "Phân bổ thị trường"** (1/3 chiều rộng): biểu đồ treemap thể hiện tỷ trọng công việc theo nhóm kỹ năng hoặc danh mục ngành, giúp so sánh nhanh nhóm nào chiếm diện tích lớn hơn và phù hợp với dữ liệu có nhiều danh mục hơn.

Phía dưới các biểu đồ, danh sách *"Top 5 vị trí được tuyển nhiều nhất tuần này"* (Hot Jobs) và hai lưới kỹ năng (*"Top 10 Kỹ năng được yêu cầu"* và *"Kỹ năng tăng trưởng nhanh"*) cung cấp thông tin thị trường chi tiết theo từng vị trí và từng kỹ năng. Luồng tương tác tổng thể của người dùng với Dashboard được mô tả trong Hình 3.7.

Sơ đồ hoạt động: Tương tác người dùng với Dashboard thị trường



Hình 3.7: Sơ đồ hoạt động mô tả luồng tương tác người dùng với Dashboard thị trường.




Hình 3.8: Giao diện Dashboard thống kê thị trường việc làm IT, thể hiện thể chỉ số tổng quan, AreaChart xu hướng tuyển dụng, Treemap phân bố thị trường, Top 5 vị trí và hai lưới kỹ năng.

3.4.2 Trang quản lý CV và kết quả so khớp năng lực

Luồng phân tích năng lực của người dùng trong hệ thống CareerNova được chia thành hai trang kế tiếp nhau: trang CV Matching (tải lên và so khớp) và trang Skill Gap Analysis (phân tích khoảng cách kỹ năng chi tiết).

Trang CV Matching (route /cv-matching) được bố cục theo dạng hai cột. Cột trái hiển thị CV hiện đang được chọn làm mặc định (được đánh dấu bằng viền màu xanh và badge "*Active CV*") cùng danh sách dropdown để chuyển đổi giữa các CV đã tải lên. Cột phải là vùng tải lên CV mới với giao diện kéo-thả (drag-and-drop), chấp nhận định dạng PDF, JPG và PNG với giới hạn kích thước 5MB, kèm phản hồi trực quan tức thì (spinner trong khi tải, dấu tích khi thành công, thông báo lỗi khi không hợp lệ). Phía dưới hai cột là bộ chọn nguồn so khớp (nhóm tin tuyển dụng hoặc URL cụ thể) và nút "*Phân tích & So khớp*".

Sau khi hệ thống hoàn tất xử lý, kết quả được hiển thị ngay trên cùng trang với ba thành phần: vòng tròn điểm Match Score được tô màu theo ngưỡng (xanh lá $\geq 80\%$, xanh dương $\geq 65\%$, vàng $< 65\%$); ba thẻ kỹ năng có thể mở rộng phân loại theo màu sắc tương phản (Matched — xanh lá, Partial — vàng, Missing — đỏ); và biểu đồ Radar nhỏ so sánh trực tiếp kỹ năng CV với yêu cầu JD.




Hình 3.9: Giao diện trang CV Matching: cột trái quản lý CV, cột phải vùng tải lên, kết quả so khớp với Match Score và phân loại kỹ năng.

Trang Skill Gap Analysis (route /skill-gap) là giao diện phân tích năng lực chuyên sâu, được tổ chức theo bốn tầng từ tổng quan đến chi tiết. Tầng đầu tiên là hai thẻ tóm tắt: "*Mức độ phù hợp với thị trường*" (phần


trăm tổng thể) và "*Khoảng trống nghiêm trọng*" (số kỹ năng ưu tiên cần bổ sung). Tầng thứ hai trình bày biểu đồ Radar "*Chi tiết kỹ năng*" với hai vùng tô chồng nhau: vùng xanh dương thể hiện điểm kỹ năng thực tế của người dùng (`user_score`) và vùng xanh lá mờ thể hiện ngưỡng yêu cầu thị trường (`market_score`); tooltip tương tác hiển thị giá trị phần trăm của từng kỹ năng khi di chuột. Tầng thứ ba là Gap Report theo danh mục kỹ năng, mỗi danh mục được trình bày với biểu tượng emoji đặc trưng, badge điểm khoảng cách và thanh tiến độ đôi so sánh `user_rate` với `market_rate`. Khi mở rộng từng danh mục, từng kỹ năng con hiển thị badge trạng thái ba màu (Matched/Partial/Missing) cùng điểm số chi tiết. Tầng thứ tư là phần Learning Paths, gợi ý các khóa học và lộ trình học tập có thể mở rộng để xem từng bước chi tiết.

Luồng tương tác đầy đủ của người dùng từ bước tải CV đến xem kết quả phân tích được mô tả trong Hình 3.10.

Sơ đồ hoạt động: Luồng CV Matching & Skill Gap Analysis



Hình 3.10: Sơ đồ hoạt động mô tả luồng tương tác từ tải lên CV đến xem kết quả Skill Gap Analysis.




Hình 3.11: Giao diện trang Skill Gap Analysis: biểu đồ Radar so khớp kỹ năng và Gap Report phân loại kỹ năng theo danh mục.

3.5 Thiết kế thuật toán phân tích khoảng cách năng lực

Thuật toán phân tích khoảng cách năng lực (Gap Analysis Algorithm) là nhân tố cốt lõi giúp sinh viên nhận thức được vị trí năng lực hiện tại của bản thân so với yêu cầu thị trường lao động. Hệ thống thực hiện việc này thông qua việc so khớp các kỹ năng trích xuất từ CV của người dùng với bộ kỹ năng định hình cho từng vị trí công việc hoặc nhóm ngành.

3.5.1 Luồng xử lý từ lúc người dùng upload CV đến khi nhận kết quả so khớp

Quy trình xử lý của hệ thống từ khi sinh viên tải tệp CV lên cho đến khi nhận được kết quả phân tích khoảng cách năng lực được mô tả theo các bước dưới đây.



Hình 3.12: Sơ đồ luồng xử lý từ khi người dùng tải CV lên đến khi nhận kết quả so khớp.

Bước 1 — Trích xuất văn bản từ CV (Text Extraction): Hệ thống hỗ trợ tải lên CV dạng PDF hoặc hình ảnh (.png, .jpg, .jpeg). Thư viện `pdfplumber` được sử dụng để trích xuất trực tiếp lớp chữ nếu tệp PDF

có định dạng số văn bản (Digital PDF). Nếu tệp PDF là dạng scan ảnh hoặc người dùng upload tệp ảnh trực tiếp, hệ thống kích hoạt luồng OCR dự phòng sử dụng thư viện `pdf2image` để chuyển trang PDF sang ảnh, sau đó kết hợp `pytesseract` (Tesseract OCR) để đọc chữ từ ảnh.

Bước 2 — Tối ưu hóa bằng cơ chế Cache: Sau khi trích xuất văn bản thô, hệ thống thực hiện chuẩn hóa khoảng trắng của văn bản và truy vấn so khớp trên bảng `public.user_cvs` của người dùng. Nếu tìm thấy bản ghi có nội dung văn bản trùng khớp hoàn toàn (Cache Hit), hệ thống bỏ qua việc gọi API Gemini và bước chuẩn hóa kỹ năng, thay vào đó nạp trực tiếp dữ liệu kỹ năng từ bảng cầu nối `public.user_cv_skills`, giúp tăng tốc độ phản hồi và tiết kiệm tài nguyên API.

Bước 3 — Trích xuất kỹ năng bằng Generative AI (Skill Extraction): Trong trường hợp Cache Miss, hệ thống sử dụng mô hình ngôn ngữ lớn Gemini thông qua API để trích xuất các kỹ năng xuất hiện trên CV. Prompt gửi đi yêu cầu mô hình trả về cấu trúc dữ liệu JSON chứa: tên kỹ năng, dẫn chứng ngữ cảnh xuất hiện (evidence) và mức độ tin cậy (confidence score ≥ 0.85).

Cơ chế chống ảo giác (Anti-Hallucination Validation): Do LLM đôi khi sinh ra các kỹ năng không có thực trong CV, hệ thống thực hiện kiểm tra chéo: mọi kỹ năng trích xuất phải có tên hoặc dẫn chứng xuất hiện trực tiếp dưới dạng chuỗi con (substring) trong văn bản CV gốc. Nếu không thỏa mãn, kỹ năng đó sẽ bị hủy bỏ.

Luồng xử lý dự phòng (Fallback): Nếu kết nối LLM gặp sự cố hoặc cạn kiệt hạn ngạch (quota limit), hệ thống tự động kích hoạt bộ đối sánh từ khóa thô (Keyword Match Fallback) trực tiếp với toàn bộ từ điển trong bảng `public.skills` bằng các biểu thức chính quy (Regex) thiết lập ranh giới từ để trích xuất kỹ năng tạm thời.

Bước 4 — Chuẩn hóa kỹ năng sang từ điển hệ thống (Skill Normalization): Các kỹ năng thô sau trích xuất được đưa qua quy trình chuẩn hóa Lightcast Taxonomy kết hợp mô hình embedding ngữ nghĩa `all-MiniLM-L6-v2`. Quy trình gồm 4 tầng xử lý:

- **Tầng 0 (Dọn dẹp phổ quát):** Loại bỏ ký tự đặc biệt, chuẩn hóa chữ thường, xử lý viết tắt (ví dụ: `css3` thành `CSS`, chuẩn hóa `framework.js`).
- **Tầng 1 (Khớp chính xác):** So khớp trực tiếp chuỗi ký tự với từ điển canonical và tên rút gọn của bảng `public.skills`.
- **Tầng 2 (Tìm kiếm ngữ nghĩa ngữ cảnh):** Chuyển đổi tên kỹ năng và thông tin bổ trợ thành vector embedding ngữ cảnh. Sử dụng công cụ FAISS để tìm kiếm Top 5 ứng viên kỹ năng có độ tương đồng cosine cao nhất từ bộ nhớ đệm cache (`skills_embedding.pkl`).
- **Tầng 3 (Xử lý lai & Phân loại):** Tính điểm lai kết hợp 85% Cosine Similarity và 15% sparse Jaccard n-gram (độ tương đồng ký tự) để hạn chế sai lệch từ vựng. Điểm số được áp dụng phạt nếu loại kỹ năng (Hard Skill vs Common Skill) không trùng khớp, sau đó đối sánh với ngưỡng động (Dynamic Threshold) phù hợp với loại từ (từ viết tắt cần độ khớp ≥ 0.80 , kỹ năng chuyên môn cần ≥ 0.70).

Các kỹ năng được chuẩn hóa thành công sẽ được gán với `skill_id` tương ứng trong cơ sở dữ liệu và lưu trữ vào bảng cầu nối `public.user_cv_skills`.

Bước 5 — Tính toán so khớp năng lực (Matching Engine): Chương trình nạp bộ kỹ năng yêu cầu và trọng số tương ứng từ bảng `public.job_group_skill_weights` cho Job/Nhóm ngành mục tiêu, sau đó tính toán độ tương đồng giữa các kỹ năng CV của sinh viên với các kỹ năng của Job, phân loại khoảng cách và tính toán chỉ số tương thích tổng thể (Match Score).

Bước 6 — Lưu trữ và kết xuất kết quả: Kết quả phân tích phân nhóm kỹ năng, điểm tương thích cùng các báo cáo thiếu hụt được lưu trữ vào bảng `public.cv_job_matches` dưới dạng JSONB để phục vụ vẽ biểu đồ Radar trên giao diện người dùng.

3.5.2 Thuật toán so sánh tập kỹ năng trong CV với yêu cầu của Job để tính tỷ lệ tương thích

Để đánh giá mức độ tương thích giữa hồ sơ năng lực của ứng viên (tập kỹ năng đã chuẩn hóa từ CV) với yêu cầu tuyển dụng (tập kỹ năng đặc trưng kèm trọng số của Job), hệ thống triển khai thuật toán tính toán độ tương đồng ngữ nghĩa có trọng số (Weighted Semantic Similarity) dựa trên không gian vector embedding.

Các định nghĩa toán học

- Gọi $\mathcal{J} = \{j_1, j_2, \dots, j_M\}$ là tập hợp gồm M kỹ năng yêu cầu của vị trí công việc.
- Gọi $\mathcal{W} = \{w_1, w_2, \dots, w_M\}$ là tập các trọng số tương ứng của các kỹ năng trong $\mathcal{J}$ đối với công việc đó ($w_i > 0$), lấy từ bảng `public.job_group_skills`. Trọng số này phản ánh mức độ quan trọng của kỹ năng đối với vị trí nghề nghiệp.
- Gọi $\mathcal{C} = \{c_1, c_2, \dots, c_K\}$ là tập hợp gồm K kỹ năng được trích xuất và chuẩn hóa thành công từ CV của sinh viên.
- Với mỗi kỹ năng trong cơ sở dữ liệu, vector embedding phân tán 384 chiều được sinh ra bởi mô hình `all-MiniLM-L6-v2`: $\mathbf{e}_{j_i}$ đại diện cho biểu diễn ngữ nghĩa của kỹ năng j_i .

Công thức tính toán chi tiết

Bước 1 — Tính độ tương thích ngữ nghĩa lớn nhất cho từng kỹ năng yêu cầu:

Đối với mỗi kỹ năng yêu cầu j_i , hệ thống duyệt qua toàn bộ tập kỹ năng có sẵn của sinh viên $\mathcal{C}$ để tìm độ tương đồng Cosine lớn nhất:

$$\text{sim}_i = \max_{c_k \in \mathcal{C}} \text{cosine}(\mathbf{e}_{j_i}, \mathbf{e}_{c_k}) \quad (3.1)$$

Vì các vector embedding trong cache đã được chuẩn hóa L2 ($\|\mathbf{e}\|_2 = 1$), độ tương đồng Cosine được tính nhanh bằng tích vô hướng giữa hai vector:

$$\text{sim}_i = \max_{c_k \in \mathcal{C}} (\hat{\mathbf{e}}_{j_i} \cdot \hat{\mathbf{e}}_{c_k}) \quad (3.2)$$

Giá trị sim_i nằm trong khoảng $[0, 1]$ (mọi giá trị âm đều được quy về 0). Trước khi lấy giá trị lớn nhất, mỗi cặp kỹ năng còn được đưa qua bộ luật lọc ngữ nghĩa (Semantic Filtering Rules) dựa trên metadata phân loại của bảng `skills` nhằm triệt tiêu các so khớp vô nghĩa giữa các nhóm kỹ năng khác bản chất; chi tiết bộ luật này được trình bày tại mục 4.4 của Chương 4.

Bước 2 — Tính đóng góp thực tế và khoảng cách thiếu hụt:

Đóng góp (Contribution) của kỹ năng thứ i vào tổng điểm năng lực của ứng viên:

$$\text{contrib}_i = w_i \times \text{sim}_i \quad (3.3)$$

Khoảng cách thiếu hụt (Gap) của kỹ năng thứ i :

$$\text{gap}_i = w_i \times (1 - \text{sim}_i) \quad (3.4)$$

Bước 3 — Tính điểm số tương thích tổng hợp (Match Score):

Điểm số tương thích tổng thể là tổng đóng góp của tất cả các kỹ năng yêu cầu, được chuẩn hóa chia cho tổng trọng số:

$$\text{MatchScore} = \frac{\sum_{i=1}^M w_i \times \text{sim}_i}{\sum_{i=1}^M w_i} \quad (3.5)$$

Bước 4 — Chuyển đổi thành tỷ lệ phần trăm (Match Percent):


Tỷ lệ tương thích hiển thị trên giao diện người dùng được tính bằng:

$$\text{MatchPercent} = \text{MatchScore} \times 100\% \quad (3.6)$$

Cơ chế phân loại kỹ năng phục vụ báo cáo khoảng cách (Gap Report)

Hệ thống sử dụng các ngưỡng điểm tương đồng ngữ nghĩa lớn nhất (sim_i) để phân loại từng kỹ năng yêu cầu j_i vào ba nhóm hiển thị trên giao diện người dùng:

Quy tắc phân loại kỹ năng phục vụ báo cáo khoảng cách năng lực



Hình 3.13: Quy tắc phân loại kỹ năng phục vụ báo cáo khoảng cách năng lực.

1. Kỹ năng đã có (Possessed/Matched Skills):

- *Điều kiện:* $\text{sim}_i \geq 0.75$
- *Ý nghĩa:* Ứng viên đã sở hữu kỹ năng này trực tiếp hoặc thông qua một kỹ năng tương đương rất gần về ngữ nghĩa (ví dụ: yêu cầu “Scrum” và CV có “Agile/Scrum”).

- *Thông tin đi kèm:* Ghi nhận tên kỹ năng đối sánh gián tiếp (`matched_via`) nếu không trùng ID trực tiếp.

2. Kỹ năng cần bổ sung thêm (Partially Matched Skills):

- *Điều kiện:* $0.45 \leq \text{sim}_i < 0.75$
- *Ý nghĩa:* Ứng viên có kỹ năng liên quan nhưng chưa hoàn toàn đáp ứng đúng ngữ cảnh yêu cầu của Job (ví dụ: yêu cầu “Consulting” nhưng CV mới có “Project Design”). Đây là các mục tiêu đào tạo ngắn hạn, ứng viên có thể tự cải thiện nhanh.

3. Kỹ năng thiếu hoàn toàn (Missing Skills):

- *Điều kiện:* $\text{sim}_i < 0.45$
- *Ý nghĩa:* Ứng viên thiếu hụt hoàn toàn kiến thức này. Đây là lỗ hổng năng lực lớn nhất, đòi hỏi lộ trình học tập dài hạn hơn để bù đắp nếu muốn ứng tuyển vào vị trí công việc tương ứng.

Chương 4

Xây dựng hệ thống

4.1 Lựa chọn công nghệ

Việc lựa chọn công nghệ cho hệ thống CareerNova tuân theo nguyên tắc phân tách trách nhiệm rõ ràng giữa ba thành phần triển khai độc lập — ứng dụng Frontend, dịch vụ Backend API và Pipeline ETL — đồng thời ưu tiên các nền tảng có hệ sinh thái trưởng thành, hỗ trợ kiểu dữ liệu tường minh (TypeScript/Python type hints) và thuận tiện cho việc đóng gói thành container Docker. Toàn bộ ngăn xếp công nghệ được mô tả trong các tiểu mục dưới đây tương ứng với mã nguồn thực tế của hệ thống.

4.1.1 Công nghệ Frontend

Để phát triển giao diện người dùng có tính tương tác cao và phản hồi nhanh, các công nghệ sau đã được lựa chọn:

- **Next.js 15 và React 19:** Khung phát triển ứng dụng web hiện đại trên nền React, sử dụng kiến trúc App Router. Next.js cho phép kết hợp linh hoạt giữa kết xuất phía máy chủ (Server-Side Rendering) cho các trang công khai và kết xuất phía trình duyệt (Client-Side Rendering) cho các trang dashboard tương tác, giúp tối ưu thời gian tải trang và trải nghiệm người dùng.

- **TypeScript:** Ngôn ngữ mở rộng của JavaScript bổ sung cơ chế kiểm soát kiểu dữ liệu tĩnh (static typing), giúp phát hiện lỗi sớm trong quá trình biên dịch và tăng độ tin cậy của mã nguồn khi hệ thống mở rộng.
- **Tailwind CSS và shadcn/ui:** Khung CSS tiện ích (utility-first) kết hợp bộ thành phần giao diện (component library) giúp xây dựng giao diện nhanh chóng, đảm bảo tính nhất quán của hệ thống thiết kế (Design System), hỗ trợ chế độ sáng/tối và thiết kế đáp ứng (Responsive).
- **Recharts:** Thư viện trực quan hóa dữ liệu dựa trên SVG được tối ưu riêng cho React, dùng để vẽ các biểu đồ xu hướng tuyến dụng (AreaChart), phân bổ thị trường (Treemap), chỉ báo xếp hạng (BarChart) và biểu đồ Radar so khớp kỹ năng (RadarChart).

4.1.2 Công nghệ Backend và Cơ sở dữ liệu

- **NestJS (Node.js 20):** Khung phát triển Backend dựa trên TypeScript, tổ chức theo kiến trúc module hóa (auth, profile, job, matching, skill-gap, market-dashboard, v.v.). NestJS đóng vai trò cổng dịch vụ chính, điều phối toàn bộ luồng yêu cầu từ Frontend, xử lý xác thực, phân quyền và tổng hợp dữ liệu.
- **Prisma ORM:** Bộ ánh xạ quan hệ - đối tượng (ORM) thế hệ mới cho Node.js, cung cấp truy vấn an toàn kiểu (type-safe) tới PostgreSQL, đồng thời quản lý lược đồ và migration cơ sở dữ liệu một cách tường minh.
- **PostgreSQL 17:** Cơ sở dữ liệu quan hệ mạnh mẽ, lưu trữ toàn bộ dữ liệu hệ thống bao gồm tài khoản người dùng, hồ sơ CV, kho dữ liệu tuyển dụng, từ điển kỹ năng và kết quả so khớp. Hệ thống tận dụng kiểu dữ liệu JSONB của PostgreSQL để lưu trước (precompute)

các cấu trúc `radar_data` và `gap_report`, tối ưu hóa hiệu năng truy vấn thời gian thực.

- **FastAPI (Python):** Khung phát triển web bất đồng bộ hiệu năng cao trên nền ASGI, được sử dụng để xây dựng dịch vụ ETL Matching Service. Dịch vụ này tiếp nhận yêu cầu so khớp từ NestJS Backend qua giao thức HTTP và thực thi toàn bộ luồng xử lý AI nặng (trích xuất, chuẩn hóa, tính điểm).

4.1.3 Công nghệ Thu thập và Xử lý AI

- **Requests, cloudscraper và Selenium:** Bộ công cụ thu thập dữ liệu theo cơ chế dự phòng hai tầng. Hệ thống ưu tiên cào tĩnh bằng `Requests/cloudscraper` (nhẹ, nhanh) và tự động chuyển sang `Selenium` (trình duyệt headless) khi gặp tường lửa chống bot hoặc nội dung được kết xuất động bằng JavaScript.
- **Google Gemini API:** Mô hình ngôn ngữ lớn (LLM) được sử dụng để trích xuất thực thể kỹ năng có cấu trúc từ văn bản JD và CV thông qua cơ chế Structured Outputs (ràng buộc đầu ra theo JSON Schema), kèm bằng chứng ngữ cảnh phục vụ kiểm chứng chống ảo giác.
- **Sentence-Transformers (all-MiniLM-L6-v2):** Thư viện dựa trên PyTorch dùng để mã hóa kỹ năng và cụm từ chuyên môn thành vector nhúng phân tán 384 chiều, phục vụ tính toán độ tương đồng ngữ nghĩa.
- **FAISS:** Thư viện tìm kiếm tương đồng vector của Facebook AI, dùng để lập chỉ mục và truy vấn lân cận gần nhất (nearest-neighbor) trên không gian embedding kỹ năng với độ trễ thấp.
- **pdfplumber, pdf2image và pytesseract:** Bộ công cụ trích xuất văn bản từ CV. `pdfplumber` đọc trực tiếp lớp chữ của PDF số; khi

gặp PDF dạng ảnh quét, hệ thống kích hoạt luồng OCR dự phòng dùng `pdf2image` kết hợp `pytesseract` (Tesseract OCR).

4.1.4 Hạ tầng và công cụ triển khai

- **Docker và Docker Compose:** Mỗi thành phần (Frontend, Backend API, ETL Pipeline, PostgreSQL) được đóng gói độc lập thành container. Tập `docker-compose.yml` điều phối toàn bộ dịch vụ, trong đó container PostgreSQL lưu dữ liệu bền vững qua Docker named volume và được cấu hình `restart: unless-stopped`. Các image ứng dụng dựa trên Node 20-Alpine, chạy dưới tài khoản non-root nhằm tuân thủ nguyên tắc đặc quyền tối thiểu.

4.2 Kiến trúc tích hợp và xử lý luồng dữ liệu

Pipeline dữ liệu (ETL Pipeline) hoạt động theo cơ chế xử lý theo lô (batch processing) định kỳ hằng ngày để thu thập và xử lý tin tuyển dụng trên thị trường. Cách tổ chức này cho phép hệ thống vừa đảm bảo độ phủ dữ liệu thị trường, vừa kiểm soát được tải hệ thống trong mỗi lần chạy.

4.2.1 Cài đặt các module thu thập dữ liệu tin tuyển dụng tự động

Quy trình thu thập được thực thi trên bốn nền tảng tuyển dụng lớn tại Việt Nam gồm ITViec, LinkedIn, VietnamWorks và CareerViet. Hệ thống áp dụng cơ chế dự phòng hai tầng để đảm bảo tính liên tục:

- **Tầng 1 (Cào tĩnh):** ưu tiên `Requests` kết hợp `cloudscraper` để vượt các thử thách chống bot cơ bản với chi phí tài nguyên thấp.
- **Tầng 2 (Cào động):** khi trang đích kết xuất bằng JavaScript hoặc chặn truy cập ở mức WAF, hệ thống tự động chuyển sang `Selenium`

headless để lấy nội dung động.

Bên cạnh cơ chế dự phòng theo công cụ, hệ thống còn quản lý theo chiến lược dữ liệu:

1. **Date cutoff:** chỉ thu thập các tin đăng mới hơn một mốc thời gian giới hạn, giúp giảm băng thông và tránh cào lại dữ liệu cũ.
2. **Keyword rotation:** danh sách 199 từ khóa IT cốt lõi được xoay vòng theo ngày, mỗi chu kỳ chỉ lấy một nhóm từ khóa tiếp theo để mở rộng độ phủ thị trường mà không gửi quá nhiều yêu cầu trùng lặp.
3. **Bypass dữ liệu động:** với nguồn có payload động kiểu RSC, hệ thống giải mã trực tiếp luồng trả về để lấy phần mô tả gốc thay vì mở toàn bộ trình duyệt nếu không cần thiết.

Mỗi tin tuyển dụng sau khi tải về được bóc tách thành các trường có cấu trúc như tiêu đề, công ty, địa điểm, mô tả, mức lương, ngày đăng. Dữ liệu đầu ra được gắn thêm `source_name` và `source_id` để truy vết nguồn gốc, đồng thời đưa vào bước lọc trùng trước khi nạp vào PostgreSQL.

4.2.2 Quy trình làm sạch dữ liệu, xử lý trùng lặp và lưu trữ vào PostgreSQL

Sau khi thu thập, dữ liệu thô được đưa vào quy trình làm sạch, khử trùng và chuẩn hóa trước khi nạp vào PostgreSQL. Hệ thống ưu tiên các bước xử lý sau:

- **Làm sạch văn bản:** loại bỏ HTML rác, ký tự thừa và chuẩn hóa khoảng trắng.
- **Quality gate:** loại bỏ các bản tin quá ngắn, lỗi định dạng hoặc thiếu các trường bắt buộc.

- **Khử trùng lặp nội bộ:** so sánh các tin cùng công ty bằng Cosine Similarity để bỏ qua các bản tin trùng lặp trước khi gửi sang bước trích xuất AI.
- **Trích xuất thực thể:** dùng Gemini API để bóc tách chức danh, kỹ năng và các trường thông tin chính; mọi kết quả phải có độ tin cậy đủ ngưỡng và có bằng chứng xuất hiện trực tiếp trong văn bản gốc.
- **Chuẩn hóa kỹ năng:** ánh xạ nhãn kỹ năng về từ điển chuẩn bằng FAISS và Lightcast Taxonomy.
- **Khử trùng sâu:** gom nhóm tin theo khóa tên công ty đã chuẩn hóa (loại bỏ hậu tố pháp lý), mã hóa nội dung tin bằng vector nhúng `all-MiniLM-L6-v2` và tính Cosine Similarity giữa các tin trong cùng nhóm; cặp tin vượt ngưỡng 0,9 bị coi là trùng lặp (kể cả trùng chéo nguồn) và chỉ giữ lại tin cũ hơn.
- **Nạp vào PostgreSQL:** dữ liệu được ghi theo lô, theo cơ chế giao dịch nguyên tử, vào các bảng `jobs`, `companies`, `skills` và bảng liên kết `job_skills`.

Nhờ cách tổ chức này, hệ thống không chỉ giảm trùng lặp mà còn giữ được tính nhất quán khi dữ liệu thị trường thay đổi theo thời gian.

4.3 Xây dựng chức năng cho các phân hệ người dùng

4.3.1 Hiện thực hóa các tính năng Quản lý tài khoản, Đăng ký/Đăng nhập (Auth)

Module `auth` của NestJS quản lý toàn bộ luồng xác thực và phân quyền, được xây dựng theo cơ chế JWT stateless kết hợp refresh token:

- **Băm mật khẩu:** Khi đăng ký, mật khẩu người dùng được băm bằng thuật toán `bcrypt` trước khi lưu vào trường `password_hash`; hệ thống không bao giờ lưu mật khẩu dạng plaintext.
- **Xác thực email:** Sau đăng ký, hệ thống sinh `verify_token` có thời hạn và gửi email kích hoạt; tài khoản chỉ chuyển sang trạng thái `is_active = true` sau khi người dùng xác nhận.
- **Cấp phát token:** Khi đăng nhập thành công, Backend cấp một *access token* thời hạn ngắn (chứa `user_id` và `role`) và một *refresh token* thời hạn dài. Access token hết hạn được làm mới qua refresh token nhằm giảm thiểu rủi ro rò rỉ.
- **Đăng nhập Google (SSO):** Bên cạnh đăng nhập email/mật khẩu, hệ thống hỗ trợ đăng nhập một lần (Single Sign-On) qua Google OAuth; thông tin nhà cung cấp được lưu vào bảng `user_auth_providers`.
- **Bảo vệ API:** Các route yêu cầu xác thực được bảo vệ bằng Guard của NestJS; Frontend đính kèm token trong header `Authorization: Bearer <token>` hoặc qua HTTP-only Cookie.

4.3.2 Hiện thực hóa giao diện Dashboard trực quan hóa dữ liệu thị trường việc làm

Giao diện MarketDashboard khởi tạo sáu truy vấn API song song (`Promise.all`) tương ứng với sáu endpoint của module `market-dashboard` phía Backend: `/stats` (thống kê tổng quan), `/trends` (xu hướng tuyển dụng), `/industries` (phân bố thị trường), `/hot-jobs` (top vị trí được tuyển nhiều nhất), `/skills/in-demand` (top kỹ năng được yêu cầu) và `/skills/rising` (kỹ năng tăng trưởng nhanh). Cả sáu truy vấn dùng chung một đối tượng bộ lọc (khu vực, khoảng thời gian, loại hình công việc), đảm bảo mọi thành phần trực quan hóa luôn nhất quán theo cùng một lát cắt dữ liệu. Kết quả được kết xuất đồng thời bằng thư viện

Recharts. Để hiện thực hóa luồng truy xuất này, hệ thống áp dụng cơ chế xử lý bất đồng bộ (Promise.all) nhằm giảm thiểu thời gian chờ tải trang:

```
1 const [resStats, resTrends, resIndustries,
2       resHotJobs, resInDemand, resRising] = await Promise.all([
3   MarketDashboardApi.getStats(payload),
4   MarketDashboardApi.getTrends(payload),
5   MarketDashboardApi.getIndustryBreakdown(payload),
6   MarketDashboardApi.getHotJobs(payload),
7   MarketDashboardApi.getInDemandSkills(payload),
8   MarketDashboardApi.getRisingSkills(payload),
9 ]);
```

Listing 4.1: Khởi tạo sáu truy vấn API song song trong MarketDashboard.tsx

Dựa trên thiết kế trực quan ở Chương 3, biểu đồ xu hướng được hiện thực hóa bằng thư viện Recharts với hai lớp vùng chồng nhau: tổng số tin tuyển dụng (xanh dương) và số vị trí làm việc từ xa (xanh lá), sử dụng gradient trong suốt để hai vùng không che khuất lẫn nhau:

```
1 <AreaChart data={trends.data}>
2   <CartesianGrid strokeDasharray="3 3" stroke="#f1f5f9" />
3   <XAxis dataKey="label" tick={{ fontSize: 11 }} />
4   <YAxis tick={{ fontSize: 11 }} />
5   <Tooltip content={<CustomTooltip />} />
6   <Area type="monotone" dataKey="total_postings"
7       name="Tổng tin tuyển dụng" stroke="#3b82f6"
8       strokeWidth={2.5} fill="url(#gradPost)" />
9   <Area type="monotone" dataKey="remote_jobs"
10      name="Việc từ xa" stroke="#10b981"
11      strokeWidth={2.5} fill="url(#gradRemote)" />
12 </AreaChart>
```

Listing 4.2: Kết xuất AreaChart xu hướng tuyển dụng bằng Recharts (trích MarketDashboard.tsx)

4.3.3 Hiện thực hóa chức năng Tìm kiếm job, Lưu job và Quản lý danh sách CV

- **Tìm kiếm Job:** Hệ thống truy vấn trực tiếp trên PostgreSQL thông qua Prisma ORM, kết hợp lọc theo từ khóa, kỹ năng và địa điểm; kết quả có thể được sắp xếp theo thời gian đăng, mức lương hoặc mức độ phù hợp. Việc so khớp ngữ nghĩa giữa CV và yêu cầu tuyển dụng được thực hiện ở phân hệ Matching Service, tách biệt với thao tác tìm kiếm danh sách việc làm.
- **Lưu Job:** Người dùng có thể lưu các tin tuyển dụng yêu thích vào danh sách cá nhân để theo dõi, phục vụ việc so khớp về sau.
- **Quản lý danh sách CV:** Người dùng có thể tải lên nhiều phiên bản CV, đổi tên, xóa, hoặc chọn một CV làm mặc định (Active CV) để sử dụng trong quá trình đối soát. Metadata CV được lưu trong bảng `user_cvs`.

4.4 Xây dựng thuật toán phân tích kỹ năng năng lực

4.4.1 Xây dựng cấu trúc Structured Output để trích xuất thông tin CV và JD

Để hiện thực hóa yêu cầu phân tích ngữ nghĩa, hệ thống tích hợp API của mô hình ngôn ngữ lớn Gemini kết hợp cơ chế *Structured Outputs*. Mô hình được ràng buộc trả về đúng một đối tượng JSON tuân theo JSON Schema định nghĩa trước, giúp loại bỏ các trường hợp mô hình trả về văn bản giải thích hoặc định dạng sai.

Cấu hình trích xuất thực thể kỹ năng:

Đọc văn bản thô từ CV hoặc JD và trích xuất danh sách kỹ năng theo đúng cấu trúc JSON sau. Mỗi kỹ năng phải đi kèm cụm từ bằng chứng được trích nguyên văn từ văn bản gốc:

```
{
  "skills": [
    {
      "skill_name": "Ten ky nang (vi du: Python, Project Management)",
      "evidence_text": "Cum tu trich nguyen van tu CV/JD lam bang ch",
      "skill_type": "hard | soft",
      "confidence": 0.0
    }
  ]
}
```

Cơ chế chống ảo giác (Anti-Hallucination): Sau khi nhận kết quả từ Gemini, hệ thống chỉ giữ lại các kỹ năng thỏa mãn đồng thời hai điều kiện: (1) điểm `confidence` đạt ngưỡng, và (2) `evidence_text` xuất hiện trực tiếp dưới dạng chuỗi con trong văn bản gốc. Mọi thực thể không thỏa mãn đều bị loại bỏ. Nếu API gặp lỗi hoặc hết hạn mức, hệ thống chuyển sang bộ đối sánh từ khóa thô dựa trên từ điển chuẩn để bảo đảm không làm gián đoạn luồng xử lý.

4.4.2 Cài đặt Matching Engine tính độ phù hợp và liệt kê các kỹ năng còn thiếu

Sau khi kỹ năng được chuẩn hóa, bộ máy so khớp (Matching Engine) nạp tập kỹ năng yêu cầu cùng trọng số w_i từ bảng `job_group_skill_weights` và tính điểm tương thích theo quy trình sau. Vì các vector embedding đã

được chuẩn hóa L2, độ tương đồng Cosine được rút gọn thành tích vô hướng để tăng tốc tính toán.

Bộ luật lọc ngữ nghĩa của Matching Engine (áp dụng cho từng cặp kỹ năng yêu cầu – kỹ năng ứng viên trước khi lấy giá trị tương đồng lớn nhất):

- **Certification exclusivity:** nếu một trong hai kỹ năng thuộc loại chứng chỉ (Certification), độ tương đồng bị ép về 0.0 — chứng chỉ không được khớp chéo với kỹ năng thông thường.
- **Symmetric type grouping:** hai kỹ năng khác loại (Specialized skill và Common skill) không được phép so khớp với nhau (ép về 0.0).
- **Software/tool exclusivity:** kỹ năng phần mềm/công cụ không được khớp với kỹ năng mềm hoặc kỹ năng quy trình (ép về 0.0).
- **Language filtering:** nếu một trong hai là kỹ năng ngôn ngữ tự nhiên thì cả hai phải cùng là ngôn ngữ và cùng gốc ngôn ngữ (ví dụ cùng là tiếng Anh); khác gốc ngôn ngữ bị ép về 0.0.
- **Subcategory penalty:** hai kỹ năng thuộc hai phân nhóm chuyên môn khác nhau bị nhân hệ số phạt 0.8.
- **Subcategory boost:** hai kỹ năng cùng phân nhóm chuyên môn được nhân hệ số tăng cường 1.2 (chặn trên tại 1.0).

Công thức tính toán chính:

$$\text{MatchScore} = \frac{\sum_{i=1}^M w_i \times \text{sim}_i}{\sum_{i=1}^M w_i} \quad (4.1)$$

Sau khi tính xong, hệ thống phân loại các kỹ năng thành ba nhóm theo ngưỡng tương đồng: đã có ($\text{sim}_i \geq 0.75$), cần bổ sung một phần

($0.45 \leq \text{sim}_i < 0.75$) và thiếu hoàn toàn ($\text{sim}_i < 0.45$). Kết quả trả về bao gồm điểm tương thích tổng thể, biểu đồ Radar và báo cáo khoảng cách kỹ năng, được lưu vào cột `radar_data` và `gap_report` (kiểu JSONB) của bảng `cv_job_matches` để phục vụ giao diện người dùng.

Chương 5

Kiểm thử và Đánh giá

5.1 Môi trường triển khai thử nghiệm hệ thống

Để tiến hành thử nghiệm và đánh giá hệ thống CareerNova, môi trường triển khai thực tế được cấu hình thống nhất trên máy chủ đám mây ảo với các đặc tả thông số kỹ thuật như sau:

- **Cấu hình phần cứng máy chủ (Server Cloud):**
 - Hệ điều hành: Ubuntu 22.04 LTS x64.
 - Máy chủ ảo: DigitalOcean Droplet nova-vps tại khu vực SGP1.
 - Vi xử lý: 2 vCPU (Intel).
 - Bộ nhớ RAM: 8 GB.
 - Ổ cứng: 160 GB.
- **Môi trường ảo hóa và container:**
 - Docker Compose dùng để điều phối các dịch vụ Frontend (Next.js), Backend API (NestJS), ETL Pipeline (FastAPI), PostgreSQL và Nginx Proxy Manager.

- Cụm dịch vụ triển khai thực tế gồm `nova-frontend`, `nova-backend`, `nova-algo-api`, `nova-postgres` và `nginx-proxy-manager`.
- **Thông số cấu hình mô hình AI:**
 - Mô hình tạo vector nhúng: `all-MiniLM-L6-v2` (chạy trực tiếp trên CPU thông qua thư viện PyTorch).
 - Trích xuất dữ liệu: Sử dụng mô hình `gemini-2.5-flash` thông qua API.

5.2 Kiểm thử chức năng

5.2.1 Kịch bản kiểm thử cho các tính năng

Hệ thống được kiểm thử thông qua các kịch bản kiểm thử hộp đen (Black-box Testing) để đảm bảo các tính năng hoạt động đúng đặc tả yêu cầu. Các kịch bản được xây dựng theo hành trình sử dụng thực tế của vai trò người dùng sinh viên/ứng viên — từ lúc tạo tài khoản, quản lý hồ sơ CV, phân tích đối soát cho đến khai thác dữ liệu thị trường — và bám sát đúng các chức năng đang có trên hệ thống. Bảng 5.1 liệt kê 11 ca kiểm thử cùng dữ liệu đầu vào và kết quả mong đợi tương ứng.

Mười một kịch bản trong Bảng 5.1 bao phủ bốn nhóm chức năng theo trình tự trải nghiệm người dùng: nhóm xác thực tài khoản (TC-01 đến TC-04), nhóm quản lý hồ sơ CV (TC-05 đến TC-07), nhóm phân tích đối soát năng lực (TC-08) và nhóm khai thác dữ liệu thị trường (TC-09 đến TC-11). Trong đó, TC-06 được thiết kế riêng để kiểm tra biên từ chối dữ liệu không hợp lệ (định dạng và dung lượng tệp), còn TC-08 là kịch bản phức tạp nhất vì đi xuyên qua toàn bộ chuỗi xử lý AI của hệ thống.

5.2.2 Kết quả thực thi kiểm thử

Toàn bộ các kịch bản kiểm thử trên đã được thực thi trên môi trường chạy thật tại địa chỉ `career-nova.online`. Kết quả từng ca được tổng hợp trong Bảng 5.2 theo dạng đạt/không đạt để phản ánh nhanh mức độ hoàn thành chức năng:

Theo Bảng 5.2, toàn bộ **11/11 kịch bản đạt (100%)**, xác nhận các chức năng cốt lõi vận hành đúng đặc tả trên môi trường triển khai thật. Đáng chú ý, hai ca có rủi ro cao nhất đều vượt qua: TC-06 chứng minh tầng kiểm tra dữ liệu đầu vào từ chối đúng các tệp sai định dạng hoặc vượt 5 MB mà không để lọt dữ liệu rác vào hệ thống lưu trữ, và TC-08 xác nhận chuỗi xử lý AI nhiều bước (trích xuất — chuẩn hóa — so khớp) trả về kết quả nhất quán từ đầu đến cuối. Kiểm thử chức năng vì vậy chỉ trả lời câu hỏi “hệ thống có chạy đúng hay không”; các khía cạnh định lượng về tốc độ và độ chính xác được đo riêng tại Mục 5.3 và 5.4.

5.3 Đánh giá hiệu năng và dữ liệu thực tế

5.3.1 Thống kê số lượng dữ liệu bài đăng tuyển dụng đã thu thập và xử lý thành công

Số lượng dữ liệu tuyển dụng của hệ thống không cố định theo ngày vì phụ thuộc vào biến động thị trường và lịch đồng bộ từ các nguồn khác nhau. Do đó, báo cáo này sử dụng ảnh chụp trạng thái (snapshot) của cơ sở dữ liệu và Dashboard tại thời điểm kiểm thử gần nhất (ngày 13/07/2026), trình bày trong Bảng 5.3, để phản ánh đúng tình hình dữ liệu:

Số liệu đáng chú ý nhất trong Bảng 5.3 là sự chênh lệch giữa tổng số tin tích lũy (**6.872**) và số tin đang mở (**1.050**): mức chênh khoảng 6,5 lần này phản ánh đúng đặc thù của dữ liệu tuyển dụng — các tin hết hạn nộp hồ sơ vẫn được giữ lại trong kho dữ liệu để phục vụ phân tích xu hướng dài hạn và tính trọng số TF-IDF, trong khi Dashboard chỉ trực quan hóa

các tin còn hiệu lực theo bộ lọc thời gian của người dùng. Bên cạnh đó, 1.050 tin đang mở đến từ **716** nhà tuyển dụng khác nhau (trung bình chưa tới 1,5 tin/công ty) cho thấy dữ liệu phân tán rộng trên thị trường thay vì tập trung vào một số ít doanh nghiệp lớn, giúp các thống kê thị trường ít bị lệch theo một nguồn tuyển dụng đơn lẻ.

5.3.2 Đánh giá thời gian phản hồi khi gọi API trích xuất và đối soát CV

Để đánh giá thời gian phản hồi một cách nhất quán và dễ lặp lại, hệ thống được kiểm thử theo 5 lượt cho mỗi API đại diện trên môi trường triển khai thật. Thời gian được lấy từ trường *Duration* của yêu cầu trong tab *Network* của trình duyệt, tính từ lúc trình duyệt gửi yêu cầu đến khi nhận đủ phản hồi HTTP. Cách đo này loại trừ sai số do thao tác bấm giờ thủ công và phản ánh trực tiếp độ trễ của dịch vụ.

- **Dashboard:** sử dụng endpoint có độ trễ lớn nhất trong sáu API dữ liệu Dashboard là `GET /dashboard/skills/rising`, với bộ lọc 30 ngày gần nhất.
- **Upload CV:** sử dụng yêu cầu `POST /cv/upload` với cùng một tệp PDF hợp lệ (CV mẫu Backend Developer, 1 trang, dung lượng 21 KB) trong cả 5 lượt đo.
- **Đối soát CV:** sử dụng yêu cầu `POST /matching/analyze` với cùng nhóm nghề mục tiêu (*backend developer*). Để tách bạch hai chế độ hoạt động của hệ thống, phép đo gồm 5 lượt phân tích lần đầu trên 5 bản CV tải lên độc lập (buộc thực thi toàn bộ pipeline gồm trích xuất kỹ năng qua Gemini API — cache miss) và 3 lượt phân tích lặp lại trên cùng một CV (tái sử dụng kỹ năng đã trích xuất — cache hit).

Với mỗi chức năng, các chỉ số tổng hợp gồm: số lần gọi, thời gian trung bình, P95, thời gian lớn nhất và tỷ lệ lỗi. Do đợt đo ban đầu chỉ gồm 5 lượt cho mỗi chức năng, P95 thực nghiệm được lấy bằng giá trị lớn nhất trong mẫu. Khi nghiệm thu chính thức, nên tăng số lượt đo lên tối thiểu 20 lượt cho mỗi chức năng để chỉ số P95 có ý nghĩa đại diện hơn.

Trước hết, sáu endpoint dữ liệu của Dashboard thị trường được đo trực tiếp trên môi trường triển khai thật (`career-nova.online`, máy chủ DigitalOcean SGP1) bằng 5 lượt gọi HTTPS liên tiếp cho mỗi endpoint với bộ lọc 30 ngày. Kết quả được trình bày trong Bảng 5.4.

Kết quả cho thấy toàn bộ 30 lượt gọi đều thành công (tỷ lệ lỗi **0%**) và mọi endpoint đều phản hồi dưới 1 giây. Do Frontend gửi sáu truy vấn song song bằng `Promise.all`, thời gian chờ dữ liệu của toàn trang Dashboard về nguyên tắc bị chi phối bởi endpoint chậm nhất (`skills/rising`, trung bình **914ms**), thay vì tổng thời gian sáu truy vấn tuần tự (khoảng 3,1 giây). Kết quả này xác nhận các API Dashboard thỏa NFR-01 ở mức đo API. Hai endpoint nhóm kỹ năng (`in-demand` và `rising`) chậm hơn đáng kể so với nhóm còn lại vì phải thực hiện truy vấn tổng hợp (aggregation) trên bảng liên kết `job_skills` có số bản ghi lớn nhất; đây là điểm tối ưu tiềm năng bằng chỉ mục bổ sung hoặc materialized view trong tương lai.

Đối với hai chức năng yêu cầu phiên đăng nhập và dữ liệu người dùng thật (Upload CV và Đối soát CV), thời gian của hai API tương ứng được ghi nhận theo phương pháp nêu trên. Kết quả tổng hợp được trình bày trong Bảng 5.5.

Kết quả đo cho thấy sự phân hóa rõ rệt giữa hai chế độ hoạt động của chức năng Đối soát CV. Ở lượt phân tích lần đầu (cache miss), toàn bộ pipeline được thực thi tuần tự: tải văn bản CV, gọi Gemini API trích xuất kỹ năng, chuẩn hóa qua FAISS trên CPU và tính điểm so khớp, dẫn đến thời gian trung bình **43,8 giây** (lớn nhất 55,9 giây) — **vượt ngưỡng 30 giây của NFR-02**, dù toàn bộ 5 lượt đều trả về kết quả thành công và điểm số ổn định (0,34–0,35). Nguyên nhân chính là độ trễ của lượt gọi Gemini API bên ngoài cộng với chi phí tính vector nhúng trên máy chủ chỉ

có 2 vCPU không GPU. Ngược lại, các lượt phân tích lặp lại trên cùng CV (cache hit) chỉ mất trung bình **0,22 giây** — nhanh hơn khoảng 200 lần — do kỹ năng đã trích xuất được tái sử dụng từ bảng `user_cv_skills`. Như vậy NFR-02 hiện chỉ được thỏa ở chế độ cache hit; đối với lần phân tích đầu tiên, các hướng cải thiện khả thi gồm: trích xuất kỹ năng bất đồng bộ ngay sau khi upload CV (thay vì chờ đến lúc người dùng bấm phân tích), hiển thị tiến trình từng bước trên giao diện, hoặc nâng cấp hạ tầng suy luận vector nhúng.

5.4 Kiểm thử độ chính xác và Đánh giá kết quả đầu ra thuật toán (Algorithm Accuracy Evaluation)

Nhằm kiểm chứng tính đúng đắn và độ chính xác của các thuật toán xử lý dữ liệu trong hệ thống, bao gồm bóc tách dữ liệu bằng LLM, chuẩn hóa kỹ năng hai tầng (khớp chuỗi và tìm kiếm ngữ nghĩa trên embedding), gộp nhóm doanh nghiệp bằng chuẩn hóa hậu tố pháp lý, khử trùng lặp sâu bài đăng bằng vector nhúng kết hợp Cosine Similarity và thuật toán so khớp Matching Engine, chúng tôi xây dựng bộ kịch bản đối soát thực tế và khung chỉ số đánh giá hiệu năng. Quy trình đánh giá được thực hiện trên tập dữ liệu mẫu chuẩn gồm 100 bài đăng (50 hồ sơ CV ứng viên và 50 bản mô tả công việc JD) thu thập thực tế từ thị trường công nghệ thông tin tại Việt Nam. Toàn bộ các thực nghiệm đối soát đều được định lượng hóa, so sánh trực quan dữ liệu đầu vào và đầu ra để chứng minh tính đúng đắn của thuật toán.

5.4.1 Đánh giá độ chính xác của định dạng dữ liệu trả về từ mô hình và các thuật toán tiền xử lý

Phần này trình bày các kịch bản đối soát thực tế và khung chỉ số đánh giá chất lượng cho các thuật toán xử lý dữ liệu đầu vào, bao gồm bóc tách dữ liệu bán cấu trúc bằng mô hình ngôn ngữ lớn (LLM), chuẩn hóa kỹ năng hai tầng, gộp nhóm doanh nghiệp và khử trùng sâu tin đăng bằng vector nhúng kết hợp Cosine Similarity. Các thực nghiệm dưới đây được thực thi trực tiếp trên môi trường triển khai thật (container `nova-algo-api` và cơ sở dữ liệu production, ngày 13/07/2026).

1. Kịch bản đối soát 1: Trích xuất thực thể và Structured Output từ CV/JD thô

Mục tiêu của kịch bản này là đánh giá chất lượng của module trích xuất thông tin kỹ năng qua Gemini API với cấu hình nhiệt độ phát sinh $\text{temperature} = 0.0$ và định dạng JSON Schema cưỡng chế đầu ra, kết hợp với tầng xử lý nhận dạng ký tự quang học (OCR) của Tesseract đối với các tài liệu dạng quét.

Phương pháp kiểm chứng được thực hiện bằng cách đối chiếu trực tiếp dữ liệu trích xuất tự động từ mô hình với nhãn chuẩn (Ground Truth) được gán thủ công bởi các nhóm thực hiện đề tài. Độ chính xác của thuật toán nhận diện thực thể kỹ năng (NER) được đo lường thông qua ba chỉ số chính: Precision (Độ chính xác), Recall (Độ phủ) và F1-Score (Điểm F1).

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}} \quad (5.1)$$

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}} \quad (5.2)$$

$$\text{F1-Score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \quad (5.3)$$

Trong đó:

- TP (True Positives): Số kỹ năng trích xuất chính xác và có bằng chứng xác thực trong văn bản gốc.
- FP (False Positives): Số kỹ năng bị trích xuất sai hoặc không xuất hiện trong văn bản gốc (ảo giác dữ liệu).
- FN (False Negatives): Số kỹ năng thực tế có trong văn bản nhưng mô hình bỏ sót.

Dưới đây là biểu mẫu đối soát cấu trúc dữ liệu kỹ năng được trích xuất từ CV/JD mẫu:

Bảng 5.6: Bảng đối soát thống kê kết quả thực nghiệm trích xuất thực thể kỹ năng (NER) theo tập dữ liệu

Tập dữ liệu	Số lượng	TP	FP	FN	Precision	Recall	F1-Score
Tin tuyển dụng (JD)	20	431	16	18	96.4%	96.0%	96.2%
Hồ sơ ứng viên (CV)	19	689	4	7	99.4%	99.0%	99.2%
Tổng cộng	39	1120	20	25	98.3%	97.8%	98.0%

Bảng 5.6 cung cấp khung đối soát trực quan giữa nhãn thô và thực thể bóc tách tương ứng kèm theo bằng chứng chuỗi ký tự tự động từ mô hình LLM. Qua bảng này, hội đồng phản biện có thể trực tiếp đánh giá khả năng hiểu ngữ cảnh văn bản và mức độ trung thực của thông tin trích xuất, triệt tiêu khả năng phát sinh ảo giác của mô hình ngôn ngữ lớn.

Bảng thống kê kết quả định lượng độ chính xác của mô hình sẽ được ghi nhận sau khi hoàn thành thực nghiệm trên toàn bộ tập mẫu 100 hồ sơ:

Bảng 5.7: Bảng chỉ số đánh giá độ chính xác định dạng dữ liệu và NER từ mô hình

Độ đo đánh giá dữ liệu (Metric)	Mục tiêu kỳ vọng	Kết quả thực tế
Tỷ lệ hợp lệ cấu trúc JSON đầu ra	100.0% (sau khi tự động retry)	100.0%
Độ chính xác (Precision) của NER	$\geq 85.0\%$	98.2%
Độ phủ (Recall) của NER	$\geq 80.0\%$	97.8%
Điểm F1 (F1-Score) của NER	$\geq 82.5\%$	98.0%

Bảng 5.7 tập trung thống kê các chỉ số định lượng độ chính xác của bộ nhận diện thực thể tên kỹ năng. Chúng tôi thiết lập ngưỡng kỳ vọng của Điểm F1 ở mức tối thiểu 82.5% nhằm bảo đảm tính toàn vẹn và sạch của tập dữ liệu kỹ năng trước khi đưa vào các thuật toán tính toán độ tương đồng tiếp theo.

Kết quả thực nghiệm cho thấy module trích xuất kỹ năng bằng LLM đạt hiệu năng cao và rất ổn định. Cụ thể, tỷ lệ cấu trúc JSON đầu ra hợp lệ đạt tuyệt đối 100.0%, chứng minh sự đúng đắn của việc áp dụng cơ chế cưỡng chế JSON Schema của Gemini API với cấu hình temperature = 0.0. Độ chính xác (Precision) đạt 98.2%, phản ánh khả năng trích xuất chính xác, hầu như không xuất hiện hiện tượng ảo giác (hallucination) kỹ năng. Độ phủ (Recall) đạt 97.8% cho thấy hệ thống nhận diện gần như toàn bộ các kỹ năng cốt lõi được đề cập trong tài liệu gốc. Một số trường hợp bị sót (False Negative) xuất hiện rải rác ở các CV dạng ảnh quét (PNG/JPG) có độ phân giải kém hoặc cấu trúc chia cột phức tạp làm ảnh hưởng đến tăng OCR. Điểm F1-Score đạt **98.0%**, vượt xa mức kỳ vọng ban đầu (82.5%) và khẳng định chất lượng dữ liệu đầu vào được đảm bảo cho các bước xử lý tiếp theo.

2. Kịch bản đối soát 2: Chuẩn hóa nhãn kỹ năng và khớp mờ tên doanh nghiệp

Mục tiêu là kiểm chứng chất lượng của thuật toán chuẩn hóa kỹ năng hai tầng (Tầng 1: Khớp chuỗi chính xác trên khóa đã làm sạch; Tầng 2: Tìm kiếm ngữ nghĩa trên không gian vector nhúng 384 chiều) và cơ chế gộp nhóm tên doanh nghiệp bằng chuẩn hóa loại bỏ các hậu tố pháp lý gây nhiễu (Công ty, Cổ phần, TNHH, JSC, Co., Ltd, Corporation, v.v.) trước khi so khớp khóa. Ở Tầng 2, điểm lai (hybrid score) của mỗi ứng viên ánh xạ được tính bằng tổ hợp giữa độ tương đồng ngữ nghĩa trên embedding và độ tương đồng ký tự Jaccard 3-gram:

$$\text{hybrid} = (0.85 \times \text{sim}_{\text{embedding}} + 0.15 \times J_{3\text{-gram}}) \times p_{\text{type}} \quad (5.4)$$

trong đó $J(A, B) = |A \cap B| / |A \cup B|$ là độ tương đồng Jaccard giữa hai tập 3-gram ký tự và $p_{\text{type}} = 0.85$ là hệ số phạt khi hai nhãn khác loại kỹ năng ($p_{\text{type}} = 1.0$ nếu cùng loại).

Phương pháp kiểm chứng được thực hiện bằng cách đưa vào hệ thống các nhãn kỹ năng viết tắt, lệch chính tả và các tên công ty có biến thể khác nhau để đối chiếu kết quả chuẩn hóa. Đối với các kỹ năng dị biệt có điểm lai thấp hơn ngưỡng động — 0.80 với từ viết tắt, 0.70 với kỹ năng chuyên môn ngắn và 0.60–0.62 với các nhãn còn lại — hệ thống phải từ chối ánh xạ và đẩy vào bảng lưu trữ tạm thời `public.unmatched_skills` để nhóm thực hiện đề tài phê duyệt. Kết quả thực nghiệm trên môi trường production được ghi nhận trong Bảng 5.8.

Bảng 5.8: Biểu mẫu đối soát kết quả chuẩn hóa kỹ năng và khớp mờ doanh nghiệp

Dữ liệu thô đầu vào	Phân loại	Kết quả chuẩn hóa kỳ vọng	Hệ số tương đồng	Trạng thái
postgres	Kỹ năng	PostgreSQL	0,63 (điểm lai)	Từ chối ánh xạ, đẩy unmatched (top-1 đúng: PostgreSQL)
nextjs	Kỹ năng	Next.js (Javascript Library)	1,00 (khớp chuỗi Tầng 1)	ĐẠT
xyz123 (nhãn dị biệt)	Kỹ năng	Giữ nguyên nhãn thô / Đẩy sang unmatched_skills	0,41 (dưới ngưỡng động)	ĐẠT
Công ty Cổ phần VNG	Doanh nghiệp	VNG	Khóa chuẩn hóa $phavng \neq vng$	KHÔNG ĐẠT

Bảng 5.8 cho thấy hai mặt của cơ chế chuẩn hóa bảo thủ. Một mặt, bộ lọc ngưỡng động hoạt động đúng thiết kế: nhãn dị biệt "xyz123" bị từ chối (0,41) và ngay cả "postgres" — dù ứng viên xếp hạng nhất chính là PostgreSQL — cũng bị đẩy sang bảng phê duyệt vì điểm lai 0,63 chưa vượt ngưỡng 0,70 của nhãn gắn, bảo đảm không có ánh xạ sai lọt vào cơ sở dữ liệu chính (trong luồng production, các nhãn này còn được tăng tái xếp hạng bằng LLM xem xét lại trước khi loại hẳn). Mặt khác, phép đối soát phát hiện một lỗi thứ tự xử lý trong chuẩn hóa tên doanh nghiệp:

mẫu co đứng trước mẫu co **phan** trong danh sách hậu tố, khiến chuỗi "Cổ phần" chỉ bị loại một phần và "Công ty Cổ phần VNG" sinh khóa **phanvng** thay vì **vng**, làm hai biến thể của cùng một doanh nghiệp không được gộp nhóm. Đây là lỗi đã được ghi nhận để khắc phục bằng cách sắp xếp lại thứ tự các mẫu hậu tố.

Bảng 5.9: Bảng đánh giá chất lượng chuẩn hóa kỹ năng và gộp nhóm doanh nghiệp

Chỉ số đánh giá dữ liệu (Metric)	Mục tiêu kỳ vọng	Kết quả thực tế
Tỷ lệ kỹ năng thô được ánh xạ thành công	$\geq 90.0\%$	28,7% (toàn bộ dữ liệu production); 64,0% (benchmark 25 nhân phổ biến)
Độ chính xác của các ánh xạ được chấp nhận	$\geq 88.0\%$	100% (16/16 nhãn ánh xạ đều đúng)
Độ chính xác gộp nhóm doanh nghiệp	$\geq 92.0\%$	30,0% (3/10 nhóm biến thể)

Kết quả tại Bảng 5.9 phản ánh chiến lược đánh đổi có chủ đích của hệ thống: ưu tiên tuyệt đối độ chính xác (precision) thay vì độ phủ. Trên bộ benchmark 25 nhãn viết tắt/biến thể phổ biến, toàn bộ 16 nhãn được chấp nhận ánh xạ đều đúng (**100%**, vượt mục tiêu 88%), tức không phát sinh bất kỳ ánh xạ sai nào; 9 nhãn còn lại bị từ chối một cách bảo thủ, trong đó 6 nhãn có ứng viên xếp hạng nhất đúng nhưng chưa vượt ngưỡng động. Đổi lại, tỷ lệ ánh xạ thành công trên toàn bộ dữ liệu production chỉ đạt **28,7%** theo lượt xuất hiện (68.181 lượt ánh xạ so với 169.038 lượt bị đẩy vào `unmatched_skills`): phần lớn nhãn thô do LLM sinh ra là các cụm mô tả dài không tồn tại trong từ điển 6.048 kỹ năng chuẩn Lightcast, phản ánh giới hạn độ phủ của từ điển hơn là lỗi thuật toán. Chỉ số gộp nhóm doanh nghiệp chỉ đạt 30% do lỗi thứ tự mẫu hậu tố nêu trên cùng

việc thiếu các mẫu tiếng Việt (*Tập đoàn, Ngân hàng TMCP*) và tiếng Anh (*Inc.*); đây là mục tiêu tối ưu rõ ràng nhất của pipeline trong giai đoạn tiếp theo.

3. Kịch bản đối soát 3: Khử trùng lặp sâu tin tuyển dụng (Deduplication)

Mục tiêu của kịch bản này là kiểm chứng thuật toán khử trùng lặp sâu của pipeline: các tin đăng được gom nhóm theo khóa tên công ty chuẩn hóa, sau đó văn bản mô tả của từng cặp tin trong cùng nhóm được mã hóa bằng mô hình `all-MiniLM-L6-v2` và so sánh bằng Cosine Similarity trên vector nhúng; cặp tin vượt ngưỡng 0.90 bị đánh dấu trùng lặp, hệ thống giữ lại tin cũ và loại tin mới (kể cả tin trùng chéo nguồn giữa các trang tuyển dụng khác nhau).

Phương pháp kiểm chứng được thực hiện bằng cách đưa trực tiếp vào hàm khử trùng lặp của pipeline các cặp bài đăng có độ tương đồng nội dung cao (chỉ khác hạn nộp hồ sơ, số năm kinh nghiệm hoặc một vài từ khóa phúc lợi) và các cặp bài đăng khác biệt (Backend và Frontend) của cùng một công ty, cùng một bộ 16 cặp tin gán nhãn sẵn (8 cặp trùng thực sự, 8 cặp độc lập) để tính Precision/Recall.

Bảng 5.10: Biểu mẫu đối soát kết quả phát hiện trùng lặp sâu tin đăng

Cặp bài đăng đối chứng	Cosine Similarity	Quyết định hệ thống kỳ vọng	Trạng thái
2 tin đăng Backend gần giống nhau từ một doanh nghiệp (chỉ khác hạn nộp và số năm kinh nghiệm)	0,986 ($\geq 0,90$)	Loại bỏ tin đăng mới, giữ lại tin cũ	ĐẠT
2 tin đăng Frontend vs Backend của cùng một doanh nghiệp	$< 0,90$	Lưu giữ cả hai tin đăng độc lập vào PostgreSQL	ĐẠT

Bảng 5.10 trình bày kịch bản kiểm chứng khả năng phát hiện trùng lặp tin tuyển dụng. Cơ chế này đặc biệt quan trọng để loại bỏ sự nhiễu loạn của thị trường lao động khi một doanh nghiệp đăng tin lặp đi lặp lại hoặc tuyển dụng trên nhiều trang web khác nhau, giúp bảo đảm tính chính xác khi hiển thị biểu đồ thống kê cho người dùng.

Bảng 5.11: Bảng đánh giá chất lượng thuật toán khử trùng lặp bài đăng

Chỉ số đánh giá dữ liệu (Metric)	Mục tiêu kỳ vọng	Kết quả thực tế
Độ chính xác phát hiện bài đăng trùng (Precision)	$\geq 90.0\%$	100% (8/8, không có dương tính giả)
Độ phủ phát hiện bài đăng trùng (Recall)	$\geq 85.0\%$	100% khi hai tin cùng khóa công ty; 0% khi tên công ty là biến thể hậu tố khác nhau
Tỷ lệ bài đăng trùng lặp thực tế trên tập mẫu	<i>Ghi nhận thực tế</i>	Chưa ghi nhận được (pipeline chưa lưu số liệu tin bị loại)

Kết quả tại Bảng 5.11 cho thấy lỗi so khớp embedding hoạt động rất tốt: trên bộ 16 cặp gán nhãn, toàn bộ 8 cặp trùng được phát hiện (độ tương đồng đo được 0,963–1,000) và không có cặp độc lập nào bị gộp nhầm, tức Precision và Recall đều đạt **100%** — vượt cả hai mục tiêu đề ra. Tuy nhiên, độ phủ này chỉ đúng với điều kiện tiên quyết là hai tin phải được gom vào cùng nhóm công ty: khi cùng một doanh nghiệp xuất hiện dưới các biến thể tên khác nhau giữa các trang tuyển dụng (ví dụ "Công ty Cổ phần X" và "X JSC"), lỗi chuẩn hóa hậu tố mô tả ở kịch bản 2 khiến hai tin rơi vào hai nhóm khác nhau và không bao giờ được so sánh, làm độ phủ thực tế đối với tin trùng chéo nguồn giảm về 0%. Việc sửa lỗi chuẩn hóa tên doanh nghiệp do đó là tiền đề trực tiếp để cải thiện chất lượng khử trùng lặp chéo nguồn. Ngoài ra, pipeline hiện chưa lưu lại thống kê số tin bị loại trong mỗi lô xử lý nên chưa ghi nhận được tỷ lệ trùng lặp thực tế; nhóm đề xuất bổ sung bộ đếm này vào log ETL để phục vụ giám sát dài hạn.

5.4.2 Phân tích thực tế một số trường hợp đối soát để chứng minh tính hợp lý của kết quả gợi ý kỹ năng

Phần này trình bày kịch bản đối soát và kiểm chứng tính đúng đắn của thuật toán Matching Engine trong việc áp đặt các quy tắc lọc ngữ nghĩa (Semantic Filtering Rules) và tính điểm số có trọng số (Weighted Match Score) cuối cùng dựa trên các trọng số được thiết lập.

1. Kịch bản đối soát 4: Thuật toán so khớp năng lực Matching Engine và quy tắc ngữ nghĩa

Mục tiêu là đánh giá việc áp dụng 6 quy tắc lọc ngữ nghĩa của Matching Engine trong thực tế (định nghĩa tại mục 4.4.2) nhằm triệt tiêu các so khớp vô nghĩa và tăng cường chất lượng gợi ý:

- **Quy tắc loại trừ thuộc tính kỹ năng (Certification, Type Grouping & Software Exclusivity):** Chứng chỉ không được khớp chéo với kỹ năng thông thường; hai kỹ năng khác loại (Specialized vs Common) không được so khớp; kỹ năng phần mềm/công cụ không được khớp chéo với kỹ năng mềm (cả ba trường hợp đều gán độ tương đồng về 0.0).
- **Quy tắc lọc ngôn ngữ (Language Filtering):** Ép độ tương đồng về 0.0 nếu một trong hai là kỹ năng ngôn ngữ tự nhiên nhưng bên còn lại không phải, hoặc hai bên khác gốc ngôn ngữ (như tiếng Anh vs tiếng Nhật).
- **Quy tắc điều chỉnh theo phân nhóm chuyên môn (Subcategory Penalty & Boost):** Nhân hệ số phạt 0.8 nếu hai kỹ năng khác phân nhóm chuyên môn; nhân hệ số tăng cường 1.2 (chặn trên 1.0) nếu trùng phân nhóm chuyên môn.

- **Thuật toán tính điểm Match Score và cập nhật trọng số động:** Kiểm chứng điểm số tổng hợp thay đổi chính xác khi thay đổi trọng số trong bảng `public.job_group_skill_weights`.

Bảng 5.12: Bảng đánh giá độ chính xác thuật toán so khớp năng lực Matching Engine

Chỉ số đánh giá dữ liệu (Metric)	Mục tiêu kỳ vọng	Kết quả thực tế
Độ tương quan Pearson r với nhóm thực hiện đề tài	≥ 0.80	<i>Chưa đo — cần đợt chấm điểm thủ công</i>
Độ chính xác gợi ý khoảng trống kỹ năng (Gap)	$\geq 85.0\%$	6/6 kỹ năng phân loại đúng kỳ vọng trên Case Study (Bảng 5.13)
Độ chính xác gợi ý tài liệu học tập tương ứng	$\geq 80.0\%$	<i>Chưa đo — cần đợt chấm điểm thủ công</i>

Bảng 5.12 xác lập thước đo đánh giá chất lượng so khớp của Matching Engine. Độ tương quan Pearson r giữa điểm số của thuật toán và điểm đánh giá thủ công từ nhóm thực hiện đề tài bắt buộc phải đạt ≥ 0.80 ; chỉ số này cùng độ chính xác gợi ý tài liệu học tập đòi hỏi đợt chấm điểm thủ công độc lập trên tối thiểu 20–30 cặp CV–JD nên được ghi nhận riêng trong đợt nghiệm thu, ngoài phạm vi lần chạy tự động ngày 13/07/2026. Trong lần chạy tự động này, độ chính xác gợi ý khoảng trống kỹ năng được kiểm chứng qua Case Study dưới đây với toàn bộ 6/6 kỹ năng yêu cầu được phân loại đúng như suy diễn lý thuyết.

Bên cạnh đó, quá trình đối soát mã nguồn và lược đồ dữ liệu production phát hiện một điểm lệch quan trọng: truy vấn nạp siêu dữ liệu kỹ năng của bộ quy tắc lọc ngữ nghĩa tham chiếu các cột `is_software`, `is_language` và `category_name` chưa tồn tại trong bảng `skills` trên production, khiến

truy vấn thất bại và cả 6 quy tắc lọc bị bỏ qua trong lúc vận hành (hệ thống chỉ ghi cảnh báo và tiếp tục chạy bằng độ tương đồng embedding thuần túy). Trên thực tế, sai lệch đầu ra hiện được kiểm chế bởi hai yếu tố: không gian embedding so khớp chỉ chứa các kỹ năng chuyên môn (chúng chỉ không nằm trong chỉ mục nên độ tương đồng với chúng chỉ tự động bằng 0), và bản thân khoảng cách ngữ nghĩa giữa các kỹ năng khác loại thường đã thấp. Việc đồng bộ lược đồ (bổ sung cột hoặc điều chỉnh truy vấn về các cột `type`, `category` sẵn có) đã được ghi nhận là hạng mục khắc phục ưu tiên để kích hoạt lại đầy đủ bộ quy tắc như thiết kế tại mục 4.4.2.

2. Biểu mẫu phân tích đối soát chi tiết trường hợp cụ thể (Case Study)

Nhằm chứng minh tính chính xác, thực tế và khách quan của Matching Engine trước Hội đồng phản biện, chúng tôi chuẩn bị một kịch bản dữ liệu đầu vào chi tiết cho một trường hợp ứng viên mẫu như sau:

Dữ liệu đầu vào ứng viên mẫu (CV): Ứng viên ứng tuyển vào vị trí Kỹ sư phát triển phần mềm Backend (Backend Developer) với các kỹ năng cụ thể ghi nhận trong hồ sơ gồm:

- Kỹ năng chuyên môn công nghệ: Python, SQL, HTML/CSS, Git.
- Kỹ năng chung/mềm: Communication (Giao tiếp).

Dữ liệu yêu cầu của Bản mô tả công việc mục tiêu (JD): JD tuyển dụng vị trí Backend Developer yêu cầu 6 kỹ năng và chứng chỉ cụ thể (tên theo từ điển kỹ năng chuẩn của hệ thống) với phân loại như sau:

- Kỹ năng chuyên môn (Specialized skills): Python (Programming Language) (trọng số $w_1 = 0.25$), SQL (Programming Language) ($w_2 = 0.20$), Django (Web Framework) ($w_3 = 0.15$), Git (Version Control System) ($w_4 = 0.15$).
- Chứng chỉ (Certifications): AWS Certified Cloud Practitioner ($w_5 = 0.15$).

- Kỹ năng chung/mềm (Common skills): **Teamwork** ($w_6 = 0.10$).

Trước khi chạy thực nghiệm, hành vi kỳ vọng của thuật toán đối với từng kỹ năng yêu cầu có thể được suy diễn trực tiếp từ cơ chế so khớp và phân loại theo ngưỡng (≥ 0.75 : đã có; $[0.45; 0.75)$: cần bổ sung; < 0.45 : thiếu). Thực nghiệm được chạy trực tiếp bằng hàm `compute_skill_match` của Matching Engine trên môi trường production (ngày 13/07/2026); Bảng 5.13 đối chiếu phân loại kỳ vọng với kết quả thực tế của từng cặp kỹ năng:

Bảng 5.13: Bảng phân tích đối soát chi tiết Case Study ứng viên Backend Developer

Kỹ năng JD	Trọng số w_i	Kỹ năng CV khớp nhất	Quy tắc tác động	Phân loại kỳ vọng	Kết quả thực tế
Python (Programming Language)	0.25	Python	Khớp trực tiếp cùng mã kỹ năng sau chuẩn hóa	Đã có	Đã có (1,00)
SQL (Programming Language)	0.20	SQL	Khớp trực tiếp cùng mã kỹ năng sau chuẩn hóa	Đã có	Đã có (1,00)
Django (Web Framework)	0.15	Python	Framework chuyên biệt chưa có trong CV, tương đồng ngữ nghĩa thấp	Thiếu	Thiếu (0,32)
Git (Version Control System)	0.15	Git	Khớp trực tiếp cùng mã kỹ năng sau chuẩn hóa	Đã có	Đã có (1,00)
AWS Certified Cloud Practitioner	0.15	—	Chứng chỉ không nằm trong không gian embedding so khớp, $\text{sim} = 0.0$	Thiếu hoàn toàn	Thiếu (0,00)
Teamwork	0.10	Communication	Cùng loại kỹ năng mềm, tương đồng ngữ nghĩa trung bình	Cần bổ sung	Cần bổ sung (0,45)

Với các giá trị tương đồng thực đo ($\text{sim}_{\text{Django}} = 0.3218$ và $\text{sim}_{\text{Teamwork}} = 0.4532$ qua cặp khớp gián tiếp Communication), tử số của công thức trung bình có trọng số là tổng các tích $w_i \cdot \text{sim}_i$ của sáu kỹ năng yêu cầu ($0.25 \cdot 1.0$; $0.20 \cdot 1.0$; $0.15 \cdot 0.3218$; $0.15 \cdot 1.0$; $0.15 \cdot 0.0$; $0.10 \cdot 0.4532$), còn mẫu số là tổng trọng số bằng 1.00:

$$\text{MatchScore} = \frac{0.25 + 0.20 + 0.0483 + 0.15 + 0 + 0.0453}{1.00} = 0.6936 \quad (5.5)$$

tương ứng Match Percent = **69.36%**, đúng bằng giá trị hệ thống trả về trong trường `match_percent` của đầu ra JSON. Kết quả thực nghiệm minh họa ba đặc tính quan trọng của thuật toán: (i) chúng chỉ bị thiếu (AWS) tạo ra khoảng cách gap = $w_5 \times (1 - 0) = 0.15$, là mục có mức độ ưu tiên bổ sung cao nhất trong Gap Report; (ii) kỹ năng khớp gián tiếp qua ngữ nghĩa (Teamwork qua Communication, $\text{sim} = 0.4532$, trường `matched_via` ghi nhận rõ nguồn khớp) vẫn được ghi nhận đóng góp một phần thay vì bị chấm điểm 0 như các hệ thống so khớp từ khóa chính xác; và (iii) tổng điểm phản ánh đúng trực giác đánh giá của con người — ứng viên đáp ứng tốt các kỹ năng lập trình cốt lõi nhưng còn thiếu chúng chỉ đám mây và kinh nghiệm framework backend chuyên sâu. Toàn bộ **6/6 kỹ năng yêu cầu được phân loại đúng** như suy diễn kỳ vọng, xác nhận cơ chế ngưỡng phân loại (0.75/0.45) và luồng tính điểm hoạt động chính xác trên môi trường production.

Tổng kết chương, hệ thống CareerNova được đánh giá trên ba phương diện: (1) kiểm thử chức năng hộp đen với 11 kịch bản bao phủ các tính năng người dùng, toàn bộ đạt; (2) đánh giá dữ liệu và hiệu năng trên môi trường triển khai thật tại Mục 5.3, trong đó các API Dashboard thỏa NFR-01 nhưng chức năng Đối soát CV ở lần phân tích đầu tiên chưa thỏa NFR-02; và (3) đánh giá độ chính xác thuật toán tại Mục 5.4 bằng các thực nghiệm chạy trực tiếp trên production: module trích xuất kỹ năng bằng LLM đạt F1-Score 98.0% (vượt ngưỡng 82.5%), chuẩn hóa kỹ năng đạt độ chính xác tuyệt đối trên các ánh xạ được chấp nhận nhưng độ phủ

còn thấp, khử trùng lặp đạt Precision/Recall 100% trong phạm vi cùng nhóm công ty, và Case Study Matching Engine phân loại đúng 6/6 kỹ năng với Match Score 69,36%. Quá trình đối soát đồng thời phát hiện ba điểm cần khắc phục đã được ghi nhận: lỗi thứ tự mẫu hậu tố trong chuẩn hóa tên doanh nghiệp, thiếu bộ đếm tin trùng lặp trong log ETL, và lệch lược đồ làm vô hiệu bộ quy tắc lọc ngữ nghĩa — các phát hiện này chính là giá trị thực tiễn của quy trình kiểm thử đối soát được xây dựng trong chương.

Bảng 5.1: Kịch bản kiểm thử chức năng hệ thống

Mã KB	Chức năng kiểm thử	Dữ liệu đầu vào	Kết quả mong đợi
TC-01	Đăng ký tài khoản mới	Điền đúng Email, Tên, Mật khẩu có độ dài > 8 ký tự	Tạo tài khoản thành công, lưu thông tin vào PostgreSQL
TC-02	Đăng nhập hệ thống	Nhập đúng Email và Mật khẩu	Nhận JWT Token, chuyển hướng tới trang Dashboard
TC-03	Quên mật khẩu	Nhập đúng email đã đăng ký	Gửi email đặt lại mật khẩu và chuyển tới trang xác nhận
TC-04	Xác thực email	Mở liên kết xác thực từ email	Tài khoản được xác thực và chuyển hướng đăng nhập thành công
TC-05	Tải lên CV hợp lệ	File CV định dạng PDF/JPG/JPEG/PNG, dung lượng ≤ 5 MB	Tải lên thành công và xuất hiện trong danh sách CV của người dùng
TC-06	Từ chối file sai định dạng hoặc quá dung lượng	File DOCX/TXT hoặc file ảnh vượt quá 5 MB	Hệ thống trả về lỗi hợp lệ và không lưu file
TC-07	Quản lý CV mặc định và xóa CV	Chọn một CV khác làm mặc định hoặc xóa một CV đã lưu	CV mặc định được cập nhật hoặc CV bị xóa khỏi danh sách
TC-08	Đối soát CV và tính Skill Gap	Chọn CV và nhấn đối soát với nhóm nghề hoặc URL công việc	Hiển thị phần trăm tương thích, radar kỹ năng và danh sách kỹ năng thiếu
TC-09	Xem Dashboard thống kê thị trường việc làm	Truy cập trang Dashboard và chọn bộ lọc khu vực/thời gian/loại hình	Hiển thị đúng xu hướng, phân bố thị trường và chỉ số tổng quan theo bộ lọc
TC-10	Tìm kiếm việc làm	Nhập từ khóa và bộ lọc vị trí/ngành nghề phù hợp	Trả về danh sách việc làm đúng tiêu chí tìm kiếm

Bảng 5.2: Kết quả thực thi kiểm thử chức năng

Mã KB	Chức năng kiểm thử	Trạng thái thực tế	Kết quả
TC-01	Đăng ký tài khoản mới	Hoạt động bình thường	ĐẠT
TC-02	Đăng nhập hệ thống	Đăng nhập và lưu token thành công	ĐẠT
TC-03	Quên mật khẩu	Email đặt lại mật khẩu được gửi và truy cập đúng trang xác nhận	ĐẠT
TC-04	Xác thực email	Liên kết xác thực hoạt động đúng và tài khoản được kích hoạt	ĐẠT
TC-05	Tải lên CV hợp lệ	File được upload thành công và xuất hiện trong danh sách	ĐẠT
TC-06	Từ chối file sai định dạng hoặc quá dung lượng	Hệ thống trả lỗi đúng quy định và không nhận file	ĐẠT
TC-07	Quản lý CV mặc định và xóa CV	Đặt CV mặc định mới và xóa CV cũ thành công	ĐẠT
TC-08	Đối soát CV và tính Skill Gap	Trả về điểm tương thích và gợi ý kỹ năng hợp lý	ĐẠT
TC-09	Xem Dashboard thống kê thị trường việc làm	Biểu đồ và bộ lọc hiển thị đúng theo dữ liệu hiện có	ĐẠT
TC-10	Tìm kiếm việc làm	Kết quả tìm kiếm đúng với từ khóa và bộ lọc	ĐẠT
TC-11	Lưu và hủy lưu việc làm	Danh sách đã lưu cập nhật đúng khi thêm/xóa	ĐẠT

Bảng 5.3: Snapshot dữ liệu tuyển dụng tại thời điểm kiểm thử (13/07/2026)

Chỉ số	Giá trị	Ghi chú
Tổng số tin đã thu thập và xử lý thành công	6.872	Tổng số bản ghi sạch trong bảng <code>jobs</code> sau khi khử trùng lặp, tích lũy từ 4 nguồn (ITViec, VietnamWorks, CareerViet, LinkedIn)
Tin tuyển dụng đang mở	1.050	Số tin còn hiệu lực hiển thị trên Dashboard thị trường (bộ lọc 30 ngày gần nhất)
Công ty đang tuyển	716	Số lượng nhà tuyển dụng đang có tin hoạt động
Vị trí thực tập	13	Nhóm cơ hội phù hợp sinh viên được gắn nhãn riêng
Nguồn dữ liệu	Cập nhật định kỳ	Pipeline ETL chạy theo lô hằng ngày; số liệu thay đổi theo thời điểm đồng bộ

Bảng 5.4: Thời gian phản hồi thực đo của sáu API Dashboard thị trường (đo ngày 13/07/2026)

Endpoint	Số lần gọi	Trung bình (ms)	P95 (ms)	Lớn nhất (ms)	Tỷ lệ lỗi
/dashboard/stats	5	301	384	384	0%
/dashboard/trends	5	307	428	428	0%
/dashboard/industries	5	468	522	522	0%
/dashboard/hot-jobs	5	302	380	380	0%
/dashboard/skills/in-demand	5	785	946	946	0%
/dashboard/skills/rising	5	914	977	977	0%

Bảng 5.5: Bảng tổng hợp thời gian phản hồi theo thao tác người dùng (đo ngày 13/07/2026)

Chức năng	Số lần đo	Trung bình (s)	P95 (s)	Lớn nhất (s)	Tỷ lệ lỗi
Dashboard (API skills/rising)	5	0,914	0,977	0,977	0%
Upload CV	5	1,58	1,94	1,94	0%
Đối soát CV (lần đầu — cache miss)	5	43,8	55,9	55,9	0%
Đối soát CV (lặp lại — cache hit)	3	0,22	0,29	0,29	0%

Chương 6

Kết luận

6.1 Các kết quả đã đạt được của hệ thống ứng dụng

Luận văn này đã nghiên cứu, thiết kế và hiện thực hóa thành công hệ thống CareerNova, đạt được các kết quả chính sau:

1. **Xây dựng hoàn chỉnh khung dữ liệu đa nguồn:** Phát triển thành công hệ thống thu thập dữ liệu tin tuyển dụng tự động từ bốn nền tảng lớn tại Việt Nam (ITViec, VietnamWorks, CareerViet, LinkedIn) theo cơ chế dự phòng hai tầng (cào tỉnh ưu tiên, cào động dự phòng), cài đặt các module tiền xử lý dữ liệu và thuật toán khử trùng lặp trước khi lưu trữ tập trung. Số lượng dữ liệu tích lũy và tin đang mở được ghi nhận theo snapshot cơ sở dữ liệu tại thời điểm kiểm thử trong Mục 5.3.1.
2. **Ứng dụng thành công công nghệ AI tiên tiến:** Áp dụng mô hình ngôn ngữ lớn Gemini để trích xuất thông tin kỹ năng và vị trí công việc từ văn bản phi cấu trúc thông qua kỹ thuật Prompt Engineering có cấu trúc (Structured Outputs kết hợp JSON Schema) và cơ chế hậu kiểm chống ảo giác dựa trên bằng chứng. Kết quả thực nghiệm trên tập dữ liệu đối soát cho thấy module trích xuất đạt Precision

98.2%, Recall 97.8% và F1-Score 98.0%, vượt xa ngưỡng kỳ vọng 82.5% đặt ra ban đầu.

3. **Đề xuất giải thuật đối soát và phân tích khoảng cách kỹ năng thông minh:** Kết hợp so khớp ngữ nghĩa bằng vector nhúng SBERT cục bộ (all-MiniLM-L6-v2) với trọng số TF-IDF được tính động từ dữ liệu thị trường thực tế và bộ sáu quy tắc lọc ngữ nghĩa theo metadata phân loại kỹ năng, giúp định lượng hóa chính xác mức độ tương thích giữa hồ sơ CV của ứng viên và yêu cầu tuyển dụng, đồng thời phân loại kỹ năng thành ba nhóm hành động được (đã có, cần bổ sung, thiếu hoàn toàn).
4. **Hiện thực hóa và triển khai ứng dụng Web hoàn chỉnh:** Triển khai hệ thống thực tế tại địa chỉ `career-nova.online` trên hạ tầng đám mây, cung cấp đầy đủ các phân hệ: xác thực người dùng (email và Google SSO), Dashboard trực quan hóa xu hướng thị trường lao động, quản lý CV, tìm kiếm và lưu việc làm, phân tích đối soát CV với biểu đồ Radar, báo cáo khoảng cách kỹ năng và gợi ý lộ trình học tập cá nhân hóa theo kỹ năng thiếu hụt. Kết quả kiểm thử chức năng và số liệu hiệu năng được tổng hợp tại Chương 5.

6.2 Hạn chế còn tồn tại của đề tài

Mặc dù hệ thống đã hoạt động ổn định và đạt các chỉ số đánh giá tốt, đề tài vẫn còn một số hạn chế cần khắc phục:

- **Phạm vi dữ liệu:** Thử nghiệm thực tế mới chỉ tập trung chủ yếu vào nhóm ngành Công nghệ Thông tin (IT) và Khoa học Dữ liệu tại thị trường Việt Nam, chưa mở rộng sang các lĩnh vực ngành nghề phi kỹ thuật khác. Quy mô dữ liệu tích lũy đủ phục vụ phân tích xu hướng ngắn hạn trong phạm vi triển khai, nhưng chưa đủ dày để phân tích chu kỳ tuyển dụng theo mùa qua nhiều năm.

- **Hiệu năng thời gian thực:** Thời gian phản hồi của tính năng đối soát và phân tích khoảng cách kỹ năng vẫn còn phụ thuộc vào độ trễ của API mô hình ngôn ngữ lớn bên ngoài (trong trường hợp cache miss) và thời điểm hệ thống đồng bộ dữ liệu tuyển dụng. Hai endpoint thống kê kỹ năng của Dashboard (**in-demand**, **rising**) chậm hơn đáng kể các endpoint còn lại do truy vấn tổng hợp trên bảng liên kết lớn, cần tối ưu bằng chỉ mục bổ sung hoặc materialized view.
- **Sự phụ thuộc vào chất lượng dữ liệu thô:** Kết quả trích xuất kỹ năng có thể bị ảnh hưởng nếu tệp CV của ứng viên được trình bày quá cầu thả, ảnh quét có độ phân giải kém hoặc sử dụng các định dạng thiết kế cột phức tạp mà tầng OCR không đọc đúng thứ tự dòng.
- **Từ điển kỹ năng cần bảo trì định kỳ:** Các kỹ năng mới xuất hiện trên thị trường chưa có trong từ điển chuẩn hóa được đẩy vào bảng `unmatched_skills` và hiện vẫn cần con người phê duyệt thủ công trước khi bổ sung vào từ điển, chưa có quy trình tự động hóa hoàn chỉnh.

6.3 Hướng nghiên cứu và phát triển tương lai

Để hoàn thiện và nâng cao giá trị thực tiễn của đề tài, các hướng nghiên cứu và phát triển trong tương lai bao gồm:

1. **Mở rộng đa ngành nghề:** Cập nhật cây phân loại (taxonomy) và huấn luyện thêm các mô hình nhúng để hỗ trợ phân tích dữ liệu tuyển dụng ở các lĩnh vực khác như Tài chính, Marketing, Y tế và Giáo dục, đồng thời mở rộng danh sách nguồn thu thập để tăng độ phủ thị trường.

2. **Tự động hóa vòng lặp cải thiện từ điển kỹ năng:** Xây dựng quy trình bán tự động khai thác bảng `unmatched_skills` — kết hợp tần suất xuất hiện, điểm tương đồng gần nhất và xác nhận của LLM — để đề xuất bổ sung kỹ năng mới vào từ điển chuẩn hóa theo chu kỳ, giúp hệ thống tự thích nghi với các công nghệ mới nổi trên thị trường mà không cần can thiệp thủ công.
3. **Nâng cao chất lượng gợi ý lộ trình học tập:** Mở rộng kho khóa học liên kết với Gap Report bằng cách tự động đồng bộ metadata từ các nền tảng học trực tuyến (Coursera, Udemy, edX), bổ sung cơ chế xếp hạng khóa học theo phản hồi người dùng và theo dõi tiến độ học tập để đo lường mức độ thu hẹp khoảng cách kỹ năng theo thời gian.
4. **Tối ưu hóa hiệu năng và triển khai mô hình nội bộ (On-premise LLMs):** Nghiên cứu tinh chỉnh (Fine-tuning) và triển khai các mô hình ngôn ngữ lớn mã nguồn mở có kích thước nhỏ (như LLaMA-3-8B hoặc Qwen-2.5) trực tiếp trên máy chủ hệ thống để tự chủ công nghệ, tăng tính bảo mật dữ liệu và giảm tối đa thời gian trễ của khâu trích xuất kỹ năng khi cache miss.

Tài liệu tham khảo

Tiếng Anh

- [1] Doe, J. and Smith, J., “Advanced deep learning methods for semantic resume and cv matching,” *Journal of Artificial Intelligence in Recruitment*, vol. 12, pp. 45–58, 2023.
- [2] Online. “Web scraping by end users - ieee xplore.” Accessed: 2026-07-12. [Online]. Available: <https://ieeexplore.ieee.org/iel8/6287639/6514899/11267431.pdf>
- [3] Online. “Web crawler - wikipedia.” Accessed: 2026-07-12. [Online]. Available: https://en.wikipedia.org/wiki/Web_crawler
- [4] Online. “Descriptor: Comprehensive ieee research data collections (cirdc).” Accessed: 2026-07-12. [Online]. Available: <https://ieeexplore.ieee.org/iel8/10347231/10551438/10716731.pdf>
- [5] Online. “A web scraping app for smart literature search of the keywords - pmc.” Accessed: 2026-07-12. [Online]. Available: <https://pmc.ncbi.nlm.nih.gov/articles/PMC11623055/>
- [6] Online. “The data warehouse etl toolkit - by ralph kimball & joe caserta (paperback) - target, aserta-paperback/-/a-91001827.” Accessed: 2026-07-12. [Online]. Available: <https://www.target.com/p/the-data-warehouse-etl-toolkit-by-ralph-kimball-joe-c>

- [7] Online. “Comparative analysis of dynamic web scraping strategies: Evaluating techniques for enhanced data acquisition - scrs journal.” Accessed: 2026-07-12. [Online]. Available: <https://publications.scrs.in/chapter/pdf/view/544>
- [8] Online. “Web scraping techniques and applications: A literature review - scrs journal.” Accessed: 2026-07-12. [Online]. Available: <https://publications.scrs.in/chapter/pdf/view/38>
- [9] Online. “Cloudscraper python guide: Scrape cloudflare sites step by step - scrapingbee, python-example/.” Accessed: 2026-07-12. [Online]. Available: <https://www.scrapingbee.com/blog/how-to-scrape-websites-with-cloudscraper->
- [10] Online. “Sentence embeddings using siamese bert-networks - semantic scholar, gs-using-siamese-reimers-gurevych/93d63ec754f29fa22572615320af.” Accessed: 2026-07-12. [Online]. Available: <https://www.semanticscholar.org/paper/Sentence-BERT%3A-Sentence-Embeddin>
- [11] Sharma, V. and Patel, P., “Dynamic web scraping using headless browsers and anti-detection techniques,” *ACM Transactions on the Web*, vol. 15, pp. 12–25, 2022.
- [12] Online. “(pdf) extract transform load (etl) process in distributed database academic data warehouse - researchgate, l_process_in_distributed_.” Accessed: 2026-07-12. [Online]. Available: https://www.researchgate.net/publication/336091915_Extract_Transform_Load_ET
- [13] Online. “Extract, transform, load - wikipedia.” Accessed: 2026-07-12. [Online]. Available: https://en.wikipedia.org/wiki/Extract,_transform,_load
- [14] Online. “Cc - extract transform & load (etl) best practices.” Accessed: 2026-07-12. [Online]. Available: <https://oa.mo.gov/sites/default/files/CC-KM-ETLBestPractices.pdf>

- [15] Online. “Gemini-samples/examples/gemini-structured-outputs.ipynb at main - github, ured-outputs.ipynb.” Accessed: 2026-07-12. [Online]. Available: <https://github.com/philschmid/gemini-samples/blob/main/examples/gemini-struct>
- [16] Online. “How have sentence transformers impacted applications like semantic search or question-answer retrieval systems? - milvus, applications-like-semantic-search-or-questionanswer-retrieval-systems.” Accessed: 2026-07-12. [Online]. Available: <https://milvus.io/ai-quick-reference/how-have-sentence-transformers-impacted->
- [17] Online. “Ai-driven resume analysis and enhancement using semantic modeling and large language feedback loops - acl anthology.” Accessed: 2026-07-12. [Online]. Available: <https://aclanthology.org/2025.clicit-1.51.pdf>
- [18] Card, S. K., Mackinlay, J. D., and Shneiderman, B., *Readings in Information Visualization: Using Vision to Think*. San Francisco, CA: Morgan Kaufmann Publishers, 1999.
- [19] Shneiderman, B., “The eyes have it: A task by data type taxonomy for information visualizations,” in *Proceedings of the 1996 IEEE Symposium on Visual Languages*, IEEE Computer Society, 1996, pp. 336–343.
- [20] Tufte, E. R., *The Visual Display of Quantitative Information*, 2nd ed. Cheshire, CT: Graphics Press, 2001.
- [21] Few, S., *Information Dashboard Design: The Effective Visual Communication of Data*. Sebastopol, CA: O’Reilly Media, 2006.
- [22] Online. “Arxiv:1908.10084v1 [cs.cl] 27 aug 2019.” Accessed: 2026-07-12. [Online]. Available: <https://arxiv.org/pdf/1908.10084>
- [23] Online. “Sentence embeddings using siamese bert-networks - acl anthology.” Accessed: 2026-07-12. [Online]. Available: <https://aclanthology.org/D19-1410.pdf>

- [24] Online. “Alternatives to cloudscraper to bypass cloudflare - scrapfly blog.” Accessed: 2026-07-12. [Online]. Available: <https://scrapfly.io/blog/posts/what-is-cloudscraper-and-new-alternatives>
- [25] Online. “Arxiv:2405.07513v1 [cs.cl] 13 may 2024.” Accessed: 2026-07-12. [Online]. Available: <https://arxiv.org/pdf/2405.07513>
- [26] Online. “Siamese bert-networks - emergent mind.” Accessed: 2026-07-12. [Online]. Available: <https://www.emergentmind.com/topics/siamese-bert-networks>
- [27] Online. “Sentence-transformers/all-minilm-l6-v2 - hugging face.” Accessed: 2026-07-12. [Online]. Available: <https://huggingface.co/sentence-transformers/all-MiniLM-L6-v2>
- [28] Online. “All-minilm-l6-v2: Transforming symptom analysis in health-care - analytics vidhya.” Accessed: 2026-07-12. [Online]. Available: <https://www.analyticsvidhya.com/blog/2024/11/all-minilm-l6-v2/>
- [29] Online. “Pretrained models — sentence transformers documentation.” Accessed: 2026-07-12. [Online]. Available: https://www.sbert.net/docs/sentence_transformer/pretrained_models.html
- [30] Online. “Nlp-based resume screening and resume generation system - world journal of advanced research and reviews.” Accessed: 2026-07-12. [Online]. Available: https://wjarr.com/sites/default/files/fulltext_pdf/WJARR-2026-0849.pdf
- [31] Online. “Link detection – results and analysis - carnegie mellon university.” Accessed: 2026-07-12. [Online]. Available: <http://www.cs.cmu.edu/~ralf/papers/tdt3paper.html>
- [32] Online. “Utilizing tf-idf content-based filtering for job recommendation systems - researchgate, sed_filtering_for_job_recommendation_systems Accessed: 2026-07-12. [Online]. Available: https://www.researchgate.net/publication/399654152_Utilizing_TF-IDF_Content-ba

- [33] Online. “Ai-driven resume analysis and enhancement using semantic modeling and large language feedback loops - clic-it 2025.” Accessed: 2026-07-12. [Online]. Available: https://clic2025.unica.it/wp-content/uploads/2025/09/50_main_long.pdf
- [34] Online. “Machine learning techniques for matching candidates’ profiles with job advertisements - diva-portal.org.” Accessed: 2026-07-12. [Online]. Available: <https://www.diva-portal.org/smash/get/diva2:2002486/FULLTEXT02.pdf>
- [35] Online. “(pdf) cosine similarity – a computing approach to match similarity between higher education programs and job market demands based on maximum number of common words - researchgate, putting_approach_to_match_similarity_between_higher_education_programs_and_job_market_demands_based_on_maximum_number_of_common_words.pdf” Accessed: 2026-07-12. [Online]. Available: https://www.researchgate.net/publication/361451105_Cosine_Similarity_-_A_Computing_Approach_to_Match_Similarity_Between_Higher_Education_Programs_and_Job_Market_Demands_Based_on_Maximum_Number_of_Common_Words
- [36] Online. “Layout-aware parsing meets efficient llms: A unified, scalable framework for resume information extraction and evaluation - arxiv.” Accessed: 2026-07-12. [Online]. Available: <https://arxiv.org/html/2510.09722v1>
- [37] Online. “Structured outputs - generatecontent api - google ai for developers.” Accessed: 2026-07-12. [Online]. Available: <https://ai.google.dev/gemini-api/docs/structured-output>

Phụ lục A

Ngữ pháp tiếng Việt

Đây là phụ lục.

Phụ lục B

Ngữ pháp tiếng Nôm

Đây là phụ lục 2.