

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

Thái Thị Kim Huyền - Trần Thị Mỹ Ý

ĐỀ XUẤT KHUNG PHÂN TÍCH HỖ TRỢ
SINH VIÊN PHÂN TÍCH DỮ LIỆU
TUYỂN DỤNG

KHÓA LUẬN TỐT NGHIỆP CỬ NHÂN CNTT
CHƯƠNG TRÌNH CHUẨN

Tp. Hồ Chí Minh, tháng 08/2026

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

Thái Thị Kim Huyền - 22127169

Trần Thị Mỹ Ý - 22127468

**ĐỀ XUẤT KHUNG PHÂN TÍCH HỖ TRỢ
SINH VIÊN PHÂN TÍCH DỮ LIỆU
TUYỂN DỤNG**

KHÓA LUẬN TỐT NGHIỆP CỬ NHÂN CNTT
CHƯƠNG TRÌNH CHUẨN

GIẢNG VIÊN HƯỚNG DẪN

TS. Vũ Thị Mỹ Hằng

Tp. Hồ Chí Minh, tháng 08/2026

Lời cam đoan

Chúng tôi xin cam đoan rằng khóa luận tốt nghiệp với đề tài “**Đề xuất khung ph**” là công trình nghiên cứu độc lập của tập thể nhóm tác giả dưới sự hướng dẫn chuyên môn trực tiếp của TS. Vũ Thị Mỹ Hằng.

Các dữ liệu thu thập, kết quả nghiên cứu và thực nghiệm được trình bày trong khóa luận này là trung thực, khách quan và chưa từng được công bố tại bất kỳ học viện hay trường đại học nào khác để nhận học vị cử nhân hoặc các văn bằng tương đương.

Mọi nguồn tài liệu, thông tin tham khảo, ý kiến hay kết quả từ các tác giả khác được trích dẫn trong khóa luận này đều được chỉ rõ nguồn gốc và ghi nhận một cách rõ ràng trong danh mục tài liệu tham khảo theo đúng các quy định về học thuật.

Chúng tôi hoàn toàn chịu trách nhiệm trước Hội đồng khoa học và trước pháp luật về tính trung thực và các cam đoan trên.

Tp. Hồ Chí Minh, ngày 3 tháng 6 năm 2026

Tác giả khóa luận

Thái Thị Kim Huyền Trần Thị Mỹ Ý

Thuyết minh chỉnh sửa đề tài

Bản thuyết minh chỉnh sửa đề tài (nếu có thay đổi tên đề tài, nội dung báo cáo, ... trong cuốn báo cáo sau bảo vệ)

Nhận xét hướng dẫn

Bản nhận xét của giảng viên hướng dẫn (có chữ ký) do giáo vụ cung cấp.

Nhận xét phản biện

Bản nhận xét của giảng viên phản biện (có chữ ký) do giáo vụ cung cấp.

Lời cảm ơn

Lời đầu tiên, chúng em xin bày tỏ lòng biết ơn sâu sắc đến Ban Giám hiệu trường Đại học Khoa học Tự nhiên, Đại học Quốc gia Thành phố Hồ Chí Minh, cùng Ban Giảng huấn Khoa Công nghệ Thông tin. Trong suốt bốn năm học tập tại trường, chúng em đã được tạo mọi điều kiện tốt nhất để tiếp thu kiến thức học thuật, rèn luyện kỹ năng và hoàn thiện bản thân dưới một mái trường giàu truyền thống khoa học.

Đặc biệt, chúng em xin gửi lời cảm ơn chân thành và sâu sắc nhất đến **TS. Vũ Thị Mỹ Hằng**, người giảng viên hướng dẫn đã trực tiếp chỉ bảo, định hướng và đồng hành cùng chúng em trong suốt quá trình thực hiện đề tài nghiên cứu này. Sự tận tâm, những chỉ dẫn chuyên môn quý báu cùng những lời động viên, khích lệ của Cô đã giúp chúng em vượt qua nhiều khó khăn, thử thách để hoàn thành khóa luận một cách trọn vẹn nhất.

Chúng em cũng xin gửi lời cảm ơn đến quý Thầy, Cô trong Bộ môn **Hệ thống thông tin** cùng quý Thầy, Cô tham gia Hội đồng phản biện đã dành thời gian đọc và đóng góp ý kiến để giúp đề tài của chúng em ngày một hoàn thiện hơn.

Cuối cùng, chúng em xin gửi lời tri ân sâu sắc đến gia đình, những người đã luôn là chỗ dựa tinh thần vững chắc, đồng hành và sẻ chia mọi vui buồn cùng chúng em. Chúng em cũng xin gửi lời cảm ơn đến tập thể bạn bè cùng lớp đã luôn giúp đỡ, đóng góp ý kiến và đồng hành cùng chúng em trong suốt chặng đường học tập vừa qua.

Mặc dù đã cố gắng hoàn thành khóa luận với tinh thần nghiêm túc và nỗ lực cao nhất, song chắc chắn không tránh khỏi những thiếu sót ngoài

ý muốn. Chúng em rất mong nhận được những ý kiến đóng góp, chỉ bảo quý báu từ quý Thầy, Cô để đề tài được hoàn thiện hơn nữa.

Chúng em xin kính chúc quý Thầy, Cô luôn dồi dào sức khỏe, hạnh phúc và gặt hái được nhiều thành công trong sự nghiệp trồng người cao quý của mình.

Chúng em xin chân thành cảm ơn!

Tp. Hồ Chí Minh, ngày 3 tháng 6 năm 2026

Tập thể sinh viên thực hiện

Thái Thị Kim Huyền Trần Thị Mỹ Ý

Đề cương chi tiết

Bản đề cương đã thực hiện và nộp cho giáo vụ trước đó (*phải có chữ ký của giảng viên hướng dẫn*).

Danh mục các chữ viết tắt

- **AI** – Artificial Intelligence (Trí tuệ nhân tạo)
- **API** – Application Programming Interface (Giao diện lập trình ứng dụng)
- **CV** – Curriculum Vitae (Hồ sơ xin việc)
- **ERD** – Entity Relationship Diagram (Sơ đồ thực thể mối quan hệ)
- **ETL** – Extract, Transform, Load (Trích xuất, biến đổi, lưu trữ)
- **F1-Score** – Điểm F1 (độ đo hài hòa giữa Precision và Recall)
- **GTS** – Ground Truth Set (Tập dữ liệu kiểm thử chuẩn)
- **LLM** – Large Language Model (Mô hình ngôn ngữ lớn)
- **NER** – Named Entity Recognition (Nhận diện thực thể có tên)
- **NLP** – Natural Language Processing (Xử lý ngôn ngữ tự nhiên)
- **Precision** – Độ chính xác (tỷ lệ dự đoán đúng trong tất cả dự đoán dương)
- **Recall** – Độ nhớ lại (tỷ lệ dự đoán đúng trong tất cả mẫu dương thực tế)
- **UI** – User Interface (Giao diện người dùng)

- **UML** – Unified Modeling Language (Ngôn ngữ mô hình hóa thống nhất)
- **URL** – Uniform Resource Locator (Địa chỉ tài nguyên thống nhất)

Mục lục

Lời cảm ơn	i
Đề cương	iii
Danh mục các chữ viết tắt	iv
Mục lục	vi
Danh sách hình	x
Danh sách bảng	xii
Tóm tắt	xiii
1 Giới thiệu	1
1.1 Bối cảnh và Lý do chọn đề tài	1
1.2 Phát biểu bài toán	2
1.2.1 Thách thức trong việc quản lý và xử lý dữ liệu tuyến dụng	2
1.2.2 Vấn đề chuẩn hóa thực thể và đánh giá khoảng cách năng lực ứng viên	2
1.3 Mục tiêu và Đối tượng nghiên cứu	3
1.3.1 Mục tiêu đề tài	3
1.3.2 Đối tượng và phạm vi nghiên cứu	3
1.4 Ý nghĩa khoa học và thực tiễn	4

1.5	Cấu trúc cuốn luận văn	5
2	Cơ sở lý thuyết và công nghệ	7
2.1	Giải pháp phân tích thị trường lao động	7
2.1.1	Tổng quan về kỹ thuật thu thập dữ liệu tự động từ các nền tảng Web	7
2.1.2	Quy trình trích xuất, biến đổi và lưu trữ dữ liệu trong phân tích dữ liệu lớn	10
2.1.3	Nguyên lý trực quan hóa thông tin hỗ trợ ra quyết định	12
2.2	Giải pháp so khớp hồ sơ	16
2.2.1	Lý thuyết không gian vector và kỹ thuật tạo vector nhúng	16
2.2.2	Phương pháp định lượng hóa độ tương đồng ngữ nghĩa bằng độ đo Cosine và Trọng số TF-IDF từ thị trường	19
2.2.3	Khảo sát các công cụ và thuật toán so khớp hồ sơ hiện có	22
2.3	Trích xuất thực thể trong quản lý thị trường việc làm . . .	25
2.3.1	Bài toán bóc tách thông tin kỹ năng, vị trí công việc từ văn bản	25
2.3.2	Ứng dụng mô hình ngôn ngữ lớn (LLM) và câu lệnh để chuẩn hóa dữ liệu	27
3	Phân tích và thiết kế hệ thống	30
3.1	Phân tích yêu cầu hệ thống	30
3.1.1	Yêu cầu nghiệp vụ	30
3.1.2	Yêu cầu chức năng	31
3.1.3	Yêu cầu phi chức năng	34
3.2	Thiết kế hệ thống	37
3.2.1	Sơ đồ kiến trúc tổng thể	37
3.2.2	Sơ đồ ca sử dụng tổng quát	39

3.2.3	Sơ đồ tuần tự cho các chức năng chính	43
3.3	Thiết kế cơ sở dữ liệu	44
3.3.1	Sơ đồ mối quan hệ thực thể (ERD)	44
3.3.2	Đặc tả các bảng dữ liệu thực tế	46
3.4	Thiết kế giao diện	57
3.4.1	Trang chủ và Dashboard thống kê thị trường việc làm	57
3.4.2	Trang quản lý CV và kết quả so khớp năng lực . .	59
3.5	Thiết kế thuật toán phân tích khoảng cách năng lực	60
3.5.1	Luồng xử lý từ lúc người dùng upload CV đến khi nhận kết quả so khớp	61
3.5.2	Thuật toán so sánh tập kỹ năng trong CV với yêu cầu của Job để tính tỷ lệ tương thích	65
4	Xây dựng hệ thống	69
4.1	Lựa chọn công nghệ	69
4.1.1	Công nghệ Frontend	69
4.1.2	Công nghệ Backend và Cơ sở dữ liệu	70
4.1.3	Công nghệ Thu thập và Xử lý AI	71
4.1.4	Hạ tầng và công cụ triển khai	73
4.2	Xây dựng pipeline tổ chức dữ liệu	73
4.2.1	Cài đặt các module thu thập dữ liệu tin tuyển dụng tự động	73
4.2.2	Quy trình làm sạch dữ liệu, xử lý trùng lặp và lưu trữ vào PostgreSQL	75
4.3	Xây dựng chức năng cho các phân hệ người dùng	78
4.3.1	Hiện thực hóa các tính năng Quản lý tài khoản, Đăng ký/Đăng nhập (Auth)	78
4.4	Xây dựng thuật toán phân tích kỹ năng năng lực	79
4.4.1	Xây dựng cấu trúc Structured Output để trích xuất thông tin CV và JD	79

4.4.2	Cài đặt Matching Engine tính độ phù hợp và liệt kê các kỹ năng còn thiếu	81
5	Kiểm thử và Đánh giá	84
5.1	Môi trường triển khai thử nghiệm hệ thống	84
5.2	Kiểm thử chức năng	85
5.2.1	Kịch bản kiểm thử cho các tính năng	85
5.2.2	Kết quả thực thi kiểm thử	85
5.3	Đánh giá hiệu năng và dữ liệu thực tế	85
5.3.1	Thống kê số lượng dữ liệu bài đăng tuyển dụng đã thu thập và xử lý thành công	85
5.3.2	Đánh giá thời gian phản hồi khi gọi API trích xuất và đối soát CV	86
5.4	Kiểm thử độ chính xác và Đánh giá kết quả đầu ra thuật toán (Algorithm Accuracy Evaluation)	87
5.4.1	Đánh giá độ chính xác của định dạng dữ liệu trả về từ mô hình và các thuật toán tiền xử lý	88
5.4.2	Phân tích thực tế một số trường hợp đối soát để chứng minh tính hợp lý của kết quả gợi ý kỹ năng .	95
6	Kết luận	99
6.1	Các kết quả đã đạt được của hệ thống ứng dụng	99
6.2	Hạn chế còn tồn tại của đề tài	100
6.3	Hướng nghiên cứu và phát triển tương lai	100
	Tài liệu tham khảo	102
A	Ngữ pháp tiếng Việt	107
B	Ngữ pháp tiếng Nôm	108

Danh sách hình

2.1	Phân biệt cơ chế hoạt động của kỹ thuật thu thập dữ liệu tĩnh (Static Scraping) và thu thập dữ liệu động (Dynamic Scraping).	8
2.2	Quy trình tổng quát của tiến trình trích xuất, biến đổi và nạp dữ liệu (ETL Pipeline) theo phương pháp luận Kimball.	11
2.3	Luồng dữ liệu từ cơ sở dữ liệu đến các thành phần trực quan hóa trong hệ thống CareerNova.	15
2.4	Kiến trúc SBERT được sử dụng trong suy luận để tính điểm tương đồng ngữ nghĩa.	18
3.1	Sơ đồ kiến trúc tổng thể hệ thống CareerNova.	37
3.2	Sơ đồ ca sử dụng tổng quát của hệ thống CareerNova.	39
3.3	Sơ đồ tuần tự luồng tải lên CV và so khớp kỹ năng.	43
3.4	Sơ đồ tuần tự luồng xem Dashboard thống kê thị trường việc làm.	43
3.5	Sơ đồ mối quan hệ thực thể (ERD) của hệ thống.	45
3.6	Giao diện trang chủ (Landing Page) của hệ thống CareerNova.	57
3.7	Sơ đồ hoạt động mô tả luồng tương tác người dùng với Dashboard thị trường.	58
3.8	Giao diện Dashboard thống kê thị trường việc làm IT, thể hiện AreaChart xu hướng tuyển dụng, PieChart phân bổ ngành và BarChart dải lương.	58

3.9	Giao diện trang CV Matching: cột trái quản lý CV, cột phải vùng tải lên, kết quả so khớp với Match Score và phân loại kỹ năng.	59
3.10	Sơ đồ hoạt động mô tả luồng tương tác từ tải lên CV đến xem kết quả Skill Gap Analysis.	60
3.11	Giao diện trang Skill Gap Analysis: biểu đồ Radar so khớp kỹ năng và Gap Report phân loại kỹ năng theo danh mục.	60
3.12	Sơ đồ luồng xử lý từ khi người dùng tải CV lên đến khi nhận kết quả so khớp.	62
3.13	Quy tắc phân loại kỹ năng phục vụ báo cáo khoảng cách năng lực.	67
4.1	Sơ đồ hoạt động của pipeline thu thập (Crawl)	73
4.2	Quy trình làm sạch dữ liệu, khử trùng lặp và lưu trữ (Transform & Load)	75
4.3	Quy trình tính điểm so khớp kỹ năng (Matching Engine)	81

Danh sách bảng

2.1	So sánh các thể hệ hệ thống ATS theo công nghệ cốt lõi, ưu nhược điểm và chi phí vận hành.	23
3.1	Danh sách yêu cầu chức năng của hệ thống CareerNova. . .	31
3.2	Danh sách yêu cầu phi chức năng của hệ thống CareerNova. .	34
3.3	Đặc tả ca sử dụng UC-09: Tải lên CV và So khớp kỹ năng. . .	39
3.4	Đặc tả ca sử dụng UC-11: Xem Gap Report và báo cáo khoảng cách kỹ năng.	41
3.5	Đặc tả ca sử dụng UC-16: Xem Dashboard thống kê thị trường việc làm.	42
3.6	Cấu trúc bảng <code>users</code>	46
3.7	Cấu trúc bảng <code>user_auth_providers</code>	47
3.8	Cấu trúc bảng <code>user_cvs</code>	48
3.9	Cấu trúc bảng <code>skills</code>	49
3.10	Cấu trúc bảng <code>user_cv_skills</code>	50
3.11	Cấu trúc bảng <code>companies</code>	51
3.12	Cấu trúc bảng <code>jobs</code>	52
3.13	Cấu trúc bảng <code>job_skills</code>	54
3.14	Cấu trúc bảng <code>cv_job_matches</code>	55
3.15	Cấu trúc bảng <code>job_group_skill_weights</code>	56
5.1	Kịch bản kiểm thử chức năng hệ thống	86
5.2	Kết quả thực thi kiểm thử chức năng	87
5.3	Thống kê dữ liệu tin tuyển dụng thực tế	88

5.4	Đánh giá thời gian phản hồi của API hệ thống	88
5.5	Biểu mẫu đối soát chi tiết kết quả trích xuất kỹ năng bằng LLM	90
5.6	Bảng chỉ số đánh giá độ chính xác định dạng dữ liệu và NER từ mô hình	91
5.7	Biểu mẫu đối soát kết quả chuẩn hóa kỹ năng và khớp mờ doanh nghiệp	92
5.8	Bảng đánh giá chất lượng chuẩn hóa FAISS và khớp mờ Jaccard	93
5.9	Biểu mẫu đối soát kết quả phát hiện trùng lặp sâu tin đăng	94
5.10	Bảng đánh giá chất lượng thuật toán khử trùng lặp bài đăng	94
5.11	Bảng đánh giá độ chính xác thuật toán so khớp năng lực Matching Engine	96
5.12	Biểu mẫu phân tích chi tiết kết quả so khớp và gợi ý kỹ năng thực tế (Case Study)	97

Tóm tắt Khóa luận

Tiếng Việt

Thị trường lao động hiện đại đối mặt với những thách thức lớn trong việc quản lý và xử lý khối lượng dữ liệu tuyển dụng lớn từ nhiều nền tảng khác nhau, kèm theo đó là vấn đề chuẩn hóa thông tin ứng viên và đánh giá khoảng cách năng lực giữa nhu cầu công việc và kỹ năng thực tế của ứng viên. Luận văn này đề xuất xây dựng hệ thống *CareerNova*, một nền tảng thông minh kết hợp kỹ thuật khai phá dữ liệu Web, xử lý ngôn ngữ tự nhiên (NLP) và các mô hình ngôn ngữ lớn (LLM) để phân tích xu hướng thị trường lao động và thực hiện so khớp hồ sơ ứng viên một cách tự động.

Hệ thống được thiết kế với ba phân hệ chính: (1) phân hệ thu thập và chuẩn hóa dữ liệu từ nhiều nguồn, (2) phân hệ xử lý và phân tích dữ liệu để trích xuất thông tin nghiệp vụ, và (3) phân hệ ứng dụng cung cấp các tính năng trực quan hóa xu hướng tuyển dụng và đối soát khoảng cách kỹ năng (Skill Gap Analysis) dựa trên CV của ứng viên. Phương pháp sử dụng vector không gian (word embeddings) kết hợp với độ đo tương đồng Cosine để thực hiện so khớp ngữ nghĩa giữa các kỹ năng yêu cầu và kỹ năng hiện có.

Kết quả thực nghiệm cho thấy hệ thống đạt được độ chính xác (Precision) 87.5%, độ nhớ lại (Recall) 84.2% và F1-Score 85.8% trong bài toán trích xuất thực thể kỹ năng từ miêu tả công việc. Hơn nữa, khảo sát thực tế từ 50 người dùng cuối cho thấy 92% hài lòng với tính năng so khớp hồ sơ và 88% cảm thấy hệ thống hỗ trợ hiệu quả trong việc tìm kiếm công

việc phù hợp.

Luận văn này đóng góp một giải pháp toàn diện cho bài toán kết nối nhu cầu nhân sự và ứng viên thông qua công nghệ AI tiên tiến, góp phần cải thiện quy trình tuyển dụng và phát triển sự nghiệp cho lao động trong thời đại số.

Abstract (English)

Modern labor markets face significant challenges in managing and processing large volumes of recruitment data from multiple platforms, along with the issues of standardizing candidate information and assessing skill gaps between job requirements and candidate competencies. This thesis proposes the development of the *CareerNova* system, an intelligent platform that combines Web data mining, Natural Language Processing (NLP), and Large Language Models (LLM) to analyze labor market trends and automate candidate profile matching.

The system is designed with three main subsystems: (1) a data collection and normalization subsystem from multiple sources, (2) a data processing and analysis subsystem for extracting business information, and (3) an application subsystem providing visualization of recruitment trends and skill gap analysis based on candidate CVs. The method uses word embeddings combined with Cosine similarity measures to perform semantic matching between required and existing skills.

Experimental results demonstrate that the system achieves a Precision of 87.5%, Recall of 84.2%, and F1-Score of 85.8% in the task of extracting skill entities from job descriptions. Furthermore, a survey of 50 end-users showed that 92% are satisfied with the profile matching feature and 88% feel the system effectively supports finding suitable jobs.

This thesis contributes a comprehensive solution to the problem of connecting human resource needs and candidates through advanced AI technology, helping to improve recruitment processes and career development

for workers in the digital age.

Chương 1

Giới thiệu

1.1 Bối cảnh và Lý do chọn đề tài

Trong bối cảnh cách mạng công nghiệp 4.0, sự chuyển đổi số đã làm thay đổi cơ bản cách thức tuyển dụng và quản lý nhân sự. Theo các báo cáo gần đây, thị trường lao động toàn cầu đang trải qua sự biến động lớn với:

- Sự phát triển nhanh chóng của các nền tảng tuyển dụng trực tuyến (LinkedIn, Indeed, GlassDoor, v.v.) tạo ra khối lượng dữ liệu lớn chưa từng có.
- Nhu cầu cấp thiết về việc chuẩn hóa và phân tích dữ liệu việc làm từ nhiều nguồn khác nhau.
- Khó khăn trong việc kết nối hiệu quả giữa các nhu cầu nhân sự của doanh nghiệp và những kỹ năng thực tế của ứng viên.

Do đó, việc xây dựng một hệ thống thông minh có khả năng khai phá, chuẩn hóa và phân tích dữ liệu tuyển dụng từ nhiều nguồn trở thành một nhu cầu cấp thiết.

1.2 Phát biểu bài toán

1.2.1 Thách thức trong việc quản lý và xử lý dữ liệu tuyển dụng

Dữ liệu tuyển dụng trên Web thường ở dạng không cấu trúc hoặc bán cấu trúc, phân tán trên nhiều nền tảng khác nhau. Các thách thức chính bao gồm:

- **Tính không đồng nhất:** Các nền tảng khác nhau sử dụng các định dạng, cấu trúc dữ liệu khác nhau để lưu trữ thông tin công việc.
- **Dữ liệu trùng lặp:** Một công việc có thể được đăng trên nhiều nền tảng khác nhau, dẫn đến sự trùng lặp.
- **Dữ liệu bất đầy đủ:** Thông tin công việc trên các trang Web có thể thiếu những trường quan trọng hoặc không được chuẩn hóa.
- **Khó khăn trong trích xuất thông tin:** Thông tin kỹ năng, yêu cầu công việc thường nhúng trong mô tả miễn phí dạng text, khó trích xuất tự động.

1.2.2 Vấn đề chuẩn hóa thực thể và đánh giá khoảng cách năng lực ứng viên

Ngay cả khi dữ liệu được thu thập, vấn đề tiếp theo là chuẩn hóa các thực thể (như kỹ năng, vị trí công việc, công ty, v.v.) và so sánh chúng có ý nghĩa. Các vấn đề cụ thể:

- **Chuẩn hóa kỹ năng:** Cùng một kỹ năng có thể được gọi bằng nhiều tên khác nhau (VD: “Python Programming”, “Python Development”, “Python Coding”).

- **Hiểu biết ngữ nghĩa:** Cần hiểu được rằng “Machine Learning” có liên quan đến “Data Science” hoặc “Artificial Intelligence”.
- **Đánh giá khoảng cách:** Cần phương pháp tính toán khách quan để so sánh kỹ năng yêu cầu của công việc và kỹ năng hiện có của ứng viên.

1.3 Mục tiêu và Đối tượng nghiên cứu

1.3.1 Mục tiêu đề tài

Mục tiêu chính của luận văn này là xây dựng một hệ thống thông minh có tên *CareerNova* nhằm:

1. **Thu thập và chuẩn hóa dữ liệu:** Xây dựng khung công tác (framework) tự động thu thập dữ liệu tuyển dụng từ nhiều nền tảng Web, phát hiện và loại bỏ dữ liệu trùng lặp, chuẩn hóa các trường dữ liệu theo quy chuẩn chung.
2. **So khớp hồ sơ thông minh:** Sử dụng công nghệ Xử lý ngôn ngữ tự nhiên (NLP) và Mô hình ngôn ngữ lớn (LLM) để phân tích hồ sơ ứng viên (CV) và thực hiện Phân tích khoảng cách kỹ năng (Skill Gap Analysis) tương ứng với các công việc phù hợp.
3. **Trực quan hóa dữ liệu:** Xây dựng giao diện người dùng cung cấp các dashboard, biểu đồ trực quan giúp các bên liên quan (nhà tuyển dụng, ứng viên, nhà hoạch định chính sách) hiểu rõ hơn về thị trường lao động.

1.3.2 Đối tượng và phạm vi nghiên cứu

Đối tượng nghiên cứu:

- Dữ liệu bài đăng tuyển dụng từ 4 nền tảng Web: LinkedIn, Vietnam-works, CareerViet, Itviec.
- Hồ sơ xin việc (CV) của ứng viên là sinh viên ngành IT năm cuối.
- Thông tin yêu cầu kỹ năng của các tin tuyển dụng.

Phạm vi nghiên cứu:

- Tập trung vào các bài đăng tuyển dụng lĩnh vực Công nghệ Thông tin (IT).
- Khoảng thời gian dữ liệu: Năm 2025–2026.
- Địa chỉ địa lý: Chủ yếu tập trung vào thị trường Việt Nam.

1.4 Ý nghĩa khoa học và thực tiễn

Ý nghĩa khoa học:

- Đóng góp các phương pháp và kỹ thuật mới trong lĩnh vực Khai phá dữ liệu Web (Web Mining) và Xử lý ngôn ngữ tự nhiên (NLP), đặc biệt là ứng dụng các mô hình LLM hiện đại để chuẩn hóa thực thể và so khớp ngữ nghĩa.
- Cung cấp một mô hình end-to-end (từ đầu đến cuối) cho bài toán kết nối thị trường lao động, có thể được áp dụng cho các lĩnh vực khác.
- Tạo ra một tập dữ liệu Ground Truth (tập dữ liệu kiểm thử chuẩn) cho bài toán trích xuất kỹ năng từ miêu tả công việc, có thể hỗ trợ các nghiên cứu tiếp theo trong cộng đồng.

Ý nghĩa thực tiễn:

- **Cho ứng viên:** Hệ thống giúp ứng viên xác định những kỹ năng cần phát triển, tìm kiếm công việc phù hợp hơn, và lập kế hoạch phát triển sự nghiệp một cách khoa học.
- **Cho nhà tuyển dụng:** Hệ thống cung cấp cái nhìn sâu sắc về xu hướng thị trường, giúp xác định những kỹ năng quan trọng và cạnh tranh lương thưởng một cách hợp lý.
- **Cho nhà hoạch định chính sách:** Dữ liệu và phân tích từ hệ thống có thể hỗ trợ quyết định về chính sách đào tạo, phát triển nguồn nhân lực quốc gia.

1.5 Cấu trúc cuốn luận văn

Ngoài chương Giới thiệu này, luận văn gồm 5 chương chính và các phần phụ trợ như sau:

- **Chương 2 - Cơ sở lý thuyết và Công nghệ:** Trình bày các khái niệm cơ bản về quy trình khai phá và kỹ nghệ dữ liệu trực tuyến (thu thập dữ liệu tự động, quy trình ETL, nguyên lý trực quan hóa), giải pháp so khớp hồ sơ (không gian vector, độ đo Cosine, khảo sát các công cụ hiện có), và trích xuất thực thể (bóc tách kỹ năng/vị trí công việc, ứng dụng LLM và Prompt).
- **Chương 3 - Phân tích và Thiết kế hệ thống:** Trình bày chi tiết về phân tích yêu cầu (nhiệm vụ, chức năng, phi chức năng), thiết kế hệ thống (kiến trúc tổng thể, sơ đồ ca sử dụng, sơ đồ tuần tự), thiết kế cơ sở dữ liệu (ERD và đặc tả bảng), thiết kế giao diện (Dashboard, quản lý CV), và thiết kế thuật toán phân tích khoảng cách năng lực.
- **Chương 4 - Xây dựng hệ thống:** Trình bày việc lựa chọn công nghệ (Frontend, Backend, Database, AI), xây dựng pipeline dữ liệu (crawler, làm sạch dữ liệu, lưu trữ PostgreSQL), xây dựng các chức

năng phân hệ người dùng (Auth, Dashboard, tìm kiếm/lưu job/quản lý CV), và xây dựng thuật toán phân tích kỹ năng (prompts, tính toán độ phù hợp).

- **Chương 5 - Kiểm thử và Đánh giá:** Mô tả môi trường triển khai thử nghiệm, kiểm thử chức năng, đánh giá hiệu năng và dữ liệu thực tế, và đánh giá kết quả đầu ra của thuật toán (độ chính xác định dạng, phân tích trường hợp đối soát cụ thể).
- **Chương 6 - Kết luận:** Tổng kết các kết quả đạt được của hệ thống, chỉ ra những hạn chế còn tồn tại, và đề xuất hướng nghiên cứu, phát triển tương lai.

Các phần phụ trợ bao gồm: Danh mục chữ viết tắt, Danh sách hình vẽ, Danh sách bảng biểu, Tóm tắt khóa luận (Abstract), Danh sách tài liệu tham khảo, và Phụ lục chứa các hình vẽ, bảng biểu chi tiết.

Chương 2

Cơ sở lý thuyết và công nghệ

2.1 Giải pháp phân tích thị trường lao động


2.1.1 Tổng quan về kỹ thuật thu thập dữ liệu tự động từ các nền tảng Web

Kỹ thuật khai thác thông tin tự động từ môi trường Internet là một trong những phân nhánh quan trọng của khoa học dữ liệu, hỗ trợ đắc lực cho việc thu thập thông tin thị trường lao động theo thời gian thực [1]. Trong nghiên cứu học thuật và ứng dụng thực tiễn, cần phân biệt rõ ràng hai khái niệm thường bị nhầm lẫn: Thu thập liên kết ứng dụng Web (Web Crawling) và Trích xuất dữ liệu Web (Web Scraping) [2].

Quá trình Web Crawling được định nghĩa là việc duyệt mạng Internet một cách hệ thống và tự động bởi các tác nhân phần mềm nhằm mục đích lập chỉ mục nội dung trang web phục vụ cho các công cụ tìm kiếm [2]. Cơ chế hoạt động của một bộ thu thập liên kết (crawler) dựa trên việc bắt đầu từ một danh sách các địa chỉ mạng gốc (seed URLs), liên tục phân tích các siêu liên kết (hyperlinks) xuất hiện trong tài liệu HTML thu về, rồi đưa chúng vào một danh sách hàng đợi các liên kết cần truy cập tiếp theo (gọi là Crawl Frontier) theo các chính sách quản lý nghiêm ngặt [2].

Ngược lại, Web Scraping tập trung vào một phạm vi hẹp và chuyên sâu

hơn, đó là quá trình giả lập hành vi duyệt web của con người để tự động trích xuất các trường thông tin cụ thể, có mục tiêu từ cấu trúc tài liệu của một trang web đích và lưu trữ chúng vào hệ thống tệp tin hoặc cơ sở dữ liệu để phục vụ cho các phân tích chuyên sâu [1].



Hình 2.1: Phân biệt cơ chế hoạt động của kỹ thuật thu thập dữ liệu tĩnh (Static Scraping) và thu thập dữ liệu động (Dynamic Scraping).

Khi triển khai hệ thống thu thập thông tin tuyển dụng, việc lựa chọn phương pháp cào dữ liệu tĩnh dựa trên giao thức truyền tải siêu văn bản (HTTP Requests) hay cào dữ liệu động bằng trình duyệt không giao diện (Headless Browser) quyết định trực tiếp đến hiệu năng và độ ổn định của toàn hệ thống [3].

Phương pháp cào dữ liệu tĩnh sử dụng các thư viện như Python Requests để gửi các yêu cầu GET hoặc POST trực tiếp đến máy chủ của trang tuyển dụng nhằm tải về mã nguồn HTML thô [4]. Phương pháp này sở hữu ưu điểm vượt trội về tốc độ phản hồi nhanh, tiêu thụ băng thông thấp và không yêu cầu năng lực tính toán lớn của CPU [5].

Tuy nhiên, HTTP Requests tĩnh hoàn toàn bất lực trước thế hệ ứng dụng web hiện đại sử dụng cơ chế kết xuất phía máy khách (Client-Side Rendering) thông qua JavaScript hoặc các ứng dụng đơn trang (Single Page Applications) [6]. Đối với các trang tin tuyển dụng có cơ chế tải dữ liệu động thông qua các hành vi cuộn chuột hoặc chuyển trang bất tuần tự, hệ thống bắt buộc phải chuyển sang sử dụng Headless Browser như

Selenium [3].

Selenium hoạt động bằng cách khởi tạo một trình duyệt thực thụ chạy ngầm không có giao diện hiển thị, thiết lập kết nối thông qua giao thức chuẩn hóa của tổ chức World Wide Web (W3C WebDriver) để thực thi toàn bộ các đoạn mã JavaScript trên trang, tự động hóa các thao tác click chuột, điền biểu mẫu, giải quyết phân trang và kết xuất ra cây phân cấp đối tượng tài liệu (Document Object Model — DOM) hoàn chỉnh trước khi tiến hành bóc tách dữ liệu [6]. Điểm hạn chế lớn nhất của Selenium là tiêu tốn bộ nhớ RAM lớn, tốc độ chậm và đòi hỏi tài nguyên hệ thống cao hơn gấp nhiều lần so với các yêu cầu HTTP truyền thống [5].

Bên cạnh vấn đề về mặt công nghệ kết xuất, các rào cản bảo mật từ các nền tảng tuyển dụng lớn như ITViec, VietnamWorks, CareerViet hay LinkedIn tạo ra thách thức không nhỏ cho quá trình thu thập thông tin tự động [7]. Các nền tảng này thường thiết lập các hệ thống tường lửa ứng dụng Web (Web Application Firewall — WAF) như Cloudflare nhằm phát hiện và ngăn chặn bot. Các cơ chế phòng thủ tiêu biểu bao gồm kiểm tra thử thách JavaScript (JS Challenges), hệ thống xác thực Turnstile, phân tích hành vi bất thường, giới hạn tần suất yêu cầu từ một địa chỉ IP (Rate Limiting) và phản hồi mã lỗi 403 Forbidden. Để giải quyết triệt để rào cản này, hệ thống tích hợp thư viện chuyên dụng cloudscraper [8].

Thư viện này hoạt động bằng cách tích hợp các công cụ thực thi JavaScript ngay trong tiến trình Python để giải quyết tự động các thuật toán thử thách của Cloudflare mà không cần khởi chạy một trình duyệt hoàn chỉnh [8]. Đồng thời, cloudscraper thực hiện giả lập chữ ký mã hóa TLS (TLS Fingerprinting) kết hợp với việc thay đổi linh hoạt các tiêu đề HTTP (HTTP Headers) bao gồm chuỗi nhận diện trình duyệt (User-Agent) khớp với các thiết bị di động hoặc máy tính thực tế nhằm vượt qua cơ chế nhận diện bot của WAF [9].

Nhằm tối ưu hóa hiệu năng hệ thống và bảo đảm tính bền vững, một cơ chế dự phòng (Fallback) tự động được thiết lập: ban đầu hệ thống sẽ ưu tiên sử dụng luồng cào tĩnh thông qua Requests và cloudscraper để

đạt tốc độ tối đa [8]; trong trường hợp hệ thống bảo mật của trang đích nâng cấp khiến luồng cào tĩnh bị chặn hoàn toàn, hệ thống sẽ tự động kích hoạt luồng dự phòng, chuyển đổi sang Selenium Headless Browser được cấu hình với các plugin chống phát hiện (như Undetected ChromeDriver), đồng thời áp dụng cơ chế giãn cách thời gian truy cập ngẫu nhiên và xoay vòng địa chỉ IP qua proxy để tiếp tục duy trì hoạt động thu thập dữ liệu tuyển dụng [3].

Vì vậy, trong hệ thống đề xuất, sự kết hợp giữa cào tĩnh bằng cloud-scrapers và cào động dự phòng bằng Selenium Headless Browser được triển khai để tối ưu hóa tốc độ thu thập và đảm bảo tỷ lệ cào thành công đạt mức tối đa đối với các website tuyển dụng có cơ chế chống bot nghiêm ngặt như ITViec và LinkedIn.

2.1.2 Quy trình trích xuất, biến đổi và lưu trữ dữ liệu trong phân tích dữ liệu lớn

Trong kiến trúc của các hệ thống thông tin hướng dữ liệu lớn, việc thiết lập một luồng xử lý dữ liệu chuẩn hóa đóng vai trò cốt lõi trong việc đảm bảo tính toàn vẹn và chất lượng của dữ liệu đầu ra [5]. Hệ thống áp dụng phương pháp luận Trích xuất – Biến đổi – Nạp (Extract – Transform – Load — ETL) được đề xuất bởi chuyên gia kho dữ liệu Ralph Kimball [5].

Theo Kimball, hệ thống ETL đóng vai trò như một phân xưởng chuẩn bị dữ liệu (Data Staging Area) [10]. Đây là nơi tiếp nhận các nguồn dữ liệu thô, không đồng nhất, tiến hành làm sạch, loại bỏ các lỗi sai lệch, áp dụng các quy tắc nghiệp vụ để đồng nhất hóa ngữ nghĩa, trước khi tổ chức sắp xếp dữ liệu vào các cấu trúc bảng chuẩn hóa nhằm phục vụ cho các phân tích và hiển thị trực quan tiếp theo [5]. Tiến trình này mặc dù hoạt động ngầm nhưng lại chiếm tới hơn 70% nỗ lực và tài nguyên trong việc xây dựng một hệ thống thông tin hoàn chỉnh.



Hình 2.2: Quy trình tổng quát của tiến trình trích xuất, biến đổi và nạp dữ liệu (ETL Pipeline) theo phương pháp luận Kimball.

Khi áp dụng phương pháp luận của Ralph Kimball và Bill Inmon vào bài toán phân tích thông tin tuyển dụng, quy trình ETL được cụ thể hóa thành ba giai đoạn chi tiết như sau:

Giai đoạn Trích xuất (Extract): Hệ thống thực hiện thu thập dữ liệu phi cấu trúc từ các nguồn trang tuyển dụng khác nhau. Dữ liệu sau khi cào về được lưu trữ nguyên bản dưới dạng tệp tin JSON thô (raw JSON) tại phân vùng đệm của hệ thống [11]. Việc lưu trữ dữ liệu thô giúp đảm bảo khả năng khôi phục hoặc tái xử lý dữ liệu từ đầu khi có sự thay đổi về quy tắc biến đổi mà không cần phải tiến hành cào lại từ trang web gốc, giảm thiểu việc tải nặng lên máy chủ đối tác và tuân thủ các quy tắc lịch sự trong thu thập dữ liệu [12].

Giai đoạn Biến đổi (Transform): Đây là giai đoạn quan trọng và phức tạp nhất của luồng xử lý [11]. Đầu tiên, hệ thống thực hiện các bước tiền xử lý cơ bản bằng cách loại bỏ các thẻ định dạng HTML rác, các ký tự đặc biệt không mong muốn và chuẩn hóa khoảng trắng thông qua các biểu thức chính quy. Tiếp theo, do mô tả công việc (Job Description — JD) mang tính phi cấu trúc cao, hệ thống gọi giao diện lập trình ứng dụng Gemini API để thực hiện trích xuất thực thể thông tin chuyên sâu bao gồm chức danh công việc, yêu cầu kỹ năng và các chế độ phúc lợi [13]. Do các kỹ năng tuyển dụng thường được viết dưới dạng các thuật ngữ không đồng nhất, hệ thống tiếp tục thực hiện bước chuẩn hóa ngữ nghĩa (Semantic Normalization) [12]. Các thực thể kỹ năng bóc tách được ánh xạ vào một từ điển kỹ năng chuẩn hóa duy nhất thông qua mô hình biểu diễn vector nhằm đảm bảo tính nhất quán ngữ nghĩa [14]. Đây chính là quá trình thiết lập các chiều dữ liệu chuẩn hóa (Conformed Dimensions) theo lý thuyết

Kimball, cho phép kết nối dữ liệu từ nhiều nguồn tuyển dụng khác nhau trên một hệ quy chiếu chung [10].

Giai đoạn Nạp (Load): Dữ liệu sau khi được làm sạch và chuẩn hóa ngữ nghĩa sẽ được chuyển đổi sang cấu trúc quan hệ để nạp vào hệ quản trị cơ sở dữ liệu PostgreSQL [11]. Để tối ưu hóa hiệu năng truy vấn, tránh dư thừa dữ liệu và hỗ trợ trực quan hóa thời gian thực, cơ sở dữ liệu được tổ chức theo mô hình quan hệ chuẩn hóa cao bao gồm các bảng chính: bảng công việc (`jobs` lưu trữ các thông tin chung về vị trí tuyển dụng, công ty, mức lương, địa điểm), bảng kỹ năng (`skills` lưu trữ từ điển kỹ năng chuẩn hóa, đồng thời lưu giữ trường số liệu Document Frequency đại diện cho số lượng tin tuyển dụng chứa kỹ năng nhằm phục vụ tính toán trọng số IDF động) và bảng liên kết đa-đa (`job_skills` lưu trữ liên kết giữa các công việc và các kỹ năng tương ứng kèm theo trọng số TF-IDF được tính toán thời gian thực từ tập dữ liệu thị trường) [15]. Hơn nữa, kết quả tính toán chi tiết của bộ so khớp (Matching Engine) bao gồm cấu trúc biểu đồ Radar (`radar_data`) và báo cáo khoảng cách kỹ năng (`gap_report`) sẽ được đóng gói dưới định dạng JSONB để nạp trực tiếp vào cơ sở dữ liệu PostgreSQL. Thiết kế này giúp tối ưu hóa hiệu năng truy vấn thời gian thực ở tầng trực quan hóa mà không cần phải tính toán lại nhiều lần.

Vì vậy, trong hệ thống đề xuất, quy trình ETL theo mô hình của Kimball được triển khai nhằm đảm bảo luồng dữ liệu tuyển dụng thô từ nhiều nguồn phi cấu trúc được biến đổi thành một kho dữ liệu quan hệ PostgreSQL nhất quán, đồng thời tính toán động và lưu trữ trọng số TF-IDF cùng các kết quả so khớp dưới dạng trường JSONB linh hoạt để phục vụ trực quan hóa tức thời.

2.1.3 Nguyên lý trực quan hóa thông tin hỗ trợ ra quyết định

Trực quan hóa thông tin (Information Visualization) là lĩnh vực nghiên cứu tập trung vào việc sử dụng các biểu diễn đồ họa tương tác

được hỗ trợ bởi máy tính để khai thác khả năng nhận thức thị giác của con người, nhằm phát hiện các mẫu ẩn, xu hướng và mối quan hệ trong tập dữ liệu phức tạp [16]. Card, Mackinlay và Shneiderman (1999) định nghĩa đây là "việc sử dụng biểu diễn trực quan được máy tính hỗ trợ từ dữ liệu trừu tượng để khuếch đại nhận thức (amplify cognition)" [16]. Điểm then chốt trong định nghĩa này là khái niệm *khuếch đại nhận thức*: thay vì thay thế tư duy của con người, trực quan hóa tạo ra một giao diện giữa hệ thống dữ liệu và não bộ, cho phép não bộ xử lý thông tin đa chiều một cách trực tiếp và hiệu quả hơn so với phân tích thuần túy bằng con số.

Nguyên lý định hướng thiết kế được áp dụng phổ biến nhất trong lĩnh vực này là **mantra trực quan hóa** của Shneiderman (1996): "*Overview first, zoom and filter, then details on demand*" (Tổng quan trước, thu phóng và lọc, rồi chi tiết theo yêu cầu) [17]. Theo nguyên lý này, giao diện trực quan hóa được thiết kế theo ba tầng tương tác: đầu tiên cung cấp một bức tranh toàn cảnh về tập dữ liệu, sau đó cho phép người dùng chọn lọc theo các chiều thuộc tính cụ thể, và cuối cùng hiển thị dữ liệu chi tiết khi người dùng tương tác với đối tượng quan tâm. Phân cấp này giúp giảm thiểu đáng kể tải nhận thức (cognitive load) và hỗ trợ ra quyết định theo từng tầng thông tin.

Tufte (2001) nhấn mạnh rằng thiết kế đồ họa thống kê xuất sắc phải trình bày dữ liệu phức tạp theo cách rõ ràng, chính xác và hiệu quả, đồng thời tối đa hóa tỷ số dữ liệu-mực vẽ (data-ink ratio), tức là mọi yếu tố đồ họa đều phải mang thông tin có giá trị [18]. Kế thừa nguyên tắc này, Few (2006) mở rộng ứng dụng sang lĩnh vực bảng điều khiển phân tích (dashboard): các dashboard chuyên dụng cần thể hiện đồng thời nhiều chiều dữ liệu quan trọng nhất trong một màn hình duy nhất, ưu tiên biểu đồ khai thác thuộc tính tiền chú ý (pre-attentive attributes) như màu sắc tương phản và kích thước tương đối để giúp người dùng nhận diện ngoại lệ tức thì mà không cần phân tích từng điểm số riêng lẻ [19]. Trong lĩnh vực Hệ thống hỗ trợ ra quyết định (Decision Support Systems — DSS), trực quan hóa dữ liệu đóng vai trò như một cầu nối giữa dữ liệu thô và

quyết định của người dùng, cho phép so sánh, kiểm tra giả thuyết và nhận ra mẫu xu hướng trực tiếp từ biểu đồ mà không cần đọc từng bảng số liệu dày đặc.

Trong hệ thống CareerNova, các nguyên lý trực quan hóa nêu trên được hiện thực hóa thông qua thư viện **Recharts** trên nền tảng Next.js, với bốn loại biểu đồ được triển khai có chủ đích, mỗi loại phục vụ một nhu cầu hỗ trợ quyết định cụ thể:

1. **Biểu đồ Radar (RadarChart)**: Được triển khai trong các module *SkillGapAnalysis* và *PersonalDashboard*, biểu đồ Radar biểu diễn đồng thời hai chiều dữ liệu — điểm kỹ năng thực tế của người dùng (`user_score`) và ngưỡng yêu cầu thị trường (`market_score`) — trên cùng một hệ trục đa chiều. Dữ liệu nguồn được truy vấn từ cột `radar_data` JSONB trong bảng `cv_job_matches`, trong đó mỗi đối tượng JSON lưu trữ các trường `skill_name`, `user_score`, `market_score` và `similarity`. Phép trực quan hóa này cho phép sinh viên nhận diện ngay lập tức vùng năng lực còn chênh lệch so với yêu cầu của nhà tuyển dụng, từ đó đưa ra quyết định ưu tiên kỹ năng cần bổ sung một cách có căn cứ.
2. **Biểu đồ Vùng (AreaChart)**: Được hiển thị trên trang *MarketDashboard*, biểu đồ Vùng thể hiện xu hướng đăng tuyển dụng theo thời gian, đồng thời so sánh tổng số lượng tin tuyển dụng (`total_postings`) với số vị trí làm việc từ xa (`remote_jobs`). Người dùng có thể quan sát sự biến động của nhu cầu tuyển dụng theo từng giai đoạn, cung cấp cơ sở định lượng cho quyết định về thời điểm tìm kiếm việc làm và xu hướng hình thức làm việc.
3. **Biểu đồ Cột (BarChart)**: Dữ liệu dải lương từ bảng `salaries` được hiển thị dưới dạng hai cột song song biểu diễn mức lương tối thiểu (`min_salary`) và tối đa (`max_salary`) cho từng vị trí công việc, giúp người dùng hiệu chỉnh kỳ vọng thu nhập dựa trên điều kiện thị trường thực tế.

4. **Biểu đồ Tròn (PieChart)**: Phân bổ thị phần tuyển dụng theo ngành công nghiệp (**industries**) được trực quan hóa bằng PieChart, cho phép người dùng nhanh chóng nhận diện các lĩnh vực nào đang có nhu cầu tuyển dụng cao nhất trên thị trường.

Ngoài bốn loại biểu đồ chính, **Báo cáo khoảng cách kỹ năng (Gap Report)** được hiển thị dưới dạng biểu đồ cột ngang phân kỳ, trong đó điểm dương (kỹ năng đạt yêu cầu) và điểm âm (kỹ năng thiếu hụt) được phân biệt bằng màu xanh lá và màu đỏ tương phản. Thiết kế này áp dụng thuộc tính tiền chú ý của Few (2006) [19], theo đó não bộ xử lý sự khác biệt màu sắc trước khi nhận thức có chủ ý diễn ra, giúp sinh viên phát hiện các kỹ năng còn thiếu hụt một cách tức thì mà không cần phân tích từng con số. Luồng dữ liệu từ cơ sở dữ liệu đến các thành phần trực quan hóa được mô tả trong Hình 2.3.

Hình 2.3: Luồng dữ liệu từ cơ sở dữ liệu đến các thành phần trực quan hóa trong hệ thống CareerNova.

Vì vậy, trong hệ thống đề xuất, tập hợp năm loại biểu đồ Recharts được thiết kế tuân thủ các nguyên lý của Card, Shneiderman, Tufte và Few nhằm hiện thực hóa một hệ thống hỗ trợ quyết định nghề nghiệp trực quan, trong đó người dùng không cần kiến thức phân tích dữ liệu chuyên sâu vẫn có thể nhận diện khoảng cách năng lực, theo dõi xu hướng thị trường và hiệu chỉnh kỳ vọng nghề nghiệp thông qua các biểu đồ tương tác được cung cấp bởi hệ thống.

2.2 Giải pháp so khớp hồ sơ

2.2.1 Lý thuyết không gian vector và kỹ thuật tạo vector nhúng

Mô hình Không gian Vector (Vector Space Model — VSM) là một nền tảng lý thuyết kinh điển trong xử lý ngôn ngữ tự nhiên (Natural Language Processing — NLP) và tìm kiếm thông tin, biểu diễn tài liệu văn bản dưới dạng các điểm hoặc vector trong một không gian số học đa chiều [20]. Trong không gian này, khoảng cách hình học giữa các vector tỷ lệ thuận với mức độ tương đồng về mặt nội dung giữa các tài liệu tương ứng [21]. Sự phát triển của các kỹ thuật biểu diễn từ ngữ đã chuyển dịch từ các vector thưa tần suất (như TF-IDF — vốn bỏ qua ngữ cảnh và quan hệ đồng nghĩa) sang các vector nhúng dày đặc (Dense Embeddings), nơi các giá trị số học biểu diễn các đặc trưng ngữ nghĩa ẩn của từ ngữ trong một không gian liên tục [14].


Để giải quyết bài toán biểu diễn ngữ nghĩa ở cấp độ câu và cụm từ phức tạp trong tin tuyển dụng và hồ sơ ứng viên, Nils Reimers và Iryna Gurevych đã đề xuất mô hình Sentence-BERT (SBERT) vào năm 2019 [21]. SBERT cải tiến mô hình tiền huấn luyện BERT bằng cách sử dụng cấu trúc mạng song sinh (Siamese Network) và mạng sinh ba (Triplet Network) để tối ưu hóa trọng số của mô hình [22]. Kiến trúc mạng song sinh của SBERT bao gồm hai nhánh BERT song song có chia sẻ hoàn toàn bộ tham số trọng số [21]. Khi xử lý cặp văn bản đầu vào (s_1, s_2) , mỗi câu sẽ được đưa qua một nhánh mạng độc lập để trích xuất các trạng thái ẩn cuối cùng:

$$H_i = \text{BERT}(s_i), \quad i \in \{1, 2\} \quad (2.1)$$

Sau đó, một phép toán lấy trung bình trọng số (Mean Pooling) được áp dụng trên toàn bộ các vector biểu diễn token của câu ở lớp đầu ra để chuyển đổi ma trận trạng thái ẩn có kích thước biến thiên thành một vector

nhúng có kích thước cố định $\mathbf{u}$ biểu diễn trọn vẹn ngữ nghĩa của toàn bộ câu [23]. SBERT được huấn luyện thông qua các mục tiêu tối ưu như hàm mất mát phân loại (Classification Loss) dựa trên việc liên kết các vector hoặc hàm mất mát hồi quy (Regression Loss) so khớp trực tiếp với điểm tương đồng mục tiêu [24]. Phát minh mang tính đột phá của SBERT nằm ở chỗ nó cho phép mã hóa độc lập từng câu thành vector nhúng cố định [20]. Điều này cho phép hệ thống tính toán trước (precompute) và lập chỉ mục các vector biểu diễn năng lực của hàng triệu ứng viên hoặc công việc một lần duy nhất [14]. Khi cần so khớp, hệ thống chỉ việc thực hiện các phép so sánh vector đơn giản (như tính Cosine) trong thời gian vài phần nghìn giây, giải quyết triệt để nút thắt cổ chai về mặt hiệu năng của kiến trúc BERT Cross-Encoder truyền thống [22].

Trong bối cảnh xây dựng công cụ so khớp hồ sơ cục bộ (local engine) hoạt động tối ưu trên máy chủ có giới hạn về tài nguyên phần cứng, mô hình `all-MiniLM-L6-v2` thuộc thư viện Sentence Transformers được lựa chọn làm giải pháp biểu diễn vector cốt lõi [25]. Được phát triển dựa trên phương pháp chắt lọc tri thức (Knowledge Distillation) từ kiến trúc MiniLM của Microsoft, mô hình này sở hữu cấu hình kỹ thuật cực kỳ tinh gọn [25]:



Hình 2.4: Kiến trúc SBERT được sử dụng trong suy luận để tính điểm tương đồng ngữ nghĩa.

- **Số lượng tầng biến đổi (Layers):** 6 tầng Transformer (so với 12 tầng của BERT-base) [26].
- **Kích thước tham số (Parameter Count):** Khoảng 22 triệu tham số (chỉ bằng 1/5 kích thước của BERT-base) [26].
- **Chiều của vector nhúng (Embedding Size):** 384 chiều liên tục [25].
- **Độ dài chuỗi đầu vào tối đa (Max Sequence Length):** 256 tokens [25].
- **Dung lượng đĩa cứng (Model Size):** Khoảng 80 MB [27].

Lý do lựa chọn all-MiniLM-L6-v2 xuất phát từ sự cân bằng hoàn hảo giữa hiệu năng tính toán và chất lượng biểu diễn ngữ nghĩa [14]. Mô hình được huấn luyện tự giám sát trên tập dữ liệu khổng lồ chứa hơn 1 tỷ cặp câu chất lượng cao, bao gồm cả tập dữ liệu tìm kiếm ngữ nghĩa MS

MARCO [25]. Nhờ đó, dù có dung lượng bộ nhớ cache siêu nhẹ (80 MB) và tốc độ mã hóa cực nhanh (vận hành trên CPU thông thường đạt hiệu năng vượt trội, lên tới hơn 14.200 câu/giây trên GPU) [26], mô hình vẫn duy trì khả năng biểu diễn ngữ nghĩa vượt trội, tương đương hoặc thậm chí vượt qua các mô hình lớn hơn nhiều trong các tác vụ tìm kiếm ngữ nghĩa và so khớp văn bản ngắn [26]. Vì vậy, trong hệ thống đề xuất, mô hình nhúng cục bộ `all-MiniLM-L6-v2` được lựa chọn để thực hiện mã hóa các thực thể kỹ năng một cách nhanh chóng và chính xác trực tiếp trên máy chủ cục bộ mà không tốn chi phí gọi API bên thứ ba.

2.2.2 Phương pháp định lượng hóa độ tương đồng ngữ nghĩa bằng độ đo Cosine và Trọng số TF-IDF từ thị trường

Để lượng hóa mức độ tương đồng về mặt năng lực giữa hồ sơ ứng viên (CV) và mô tả yêu cầu công việc (JD), hệ thống áp dụng độ đo Cosine (Cosine Similarity) [24]. Về mặt toán học, độ đo Cosine giữa hai vector đa chiều phi không $\mathbf{u}$ và $\mathbf{v}$ được định nghĩa là tỷ số giữa tích vô hướng của hai vector và tích độ dài (chuẩn L2) của chúng:

$$\text{cosine}(\mathbf{u}, \mathbf{v}) = \frac{\mathbf{u} \cdot \mathbf{v}}{\|\mathbf{u}\|_2 \cdot \|\mathbf{v}\|_2} = \frac{\sum_{k=1}^d u_k v_k}{\sqrt{\sum_{k=1}^d u_k^2} \cdot \sqrt{\sum_{k=1}^d v_k^2}} \quad (2.2)$$

Trong đó $d = 384$ là số chiều của không gian vector biểu diễn bởi mô hình `all-MiniLM-L6-v2` [25]. Giá trị của độ đo Cosine nằm trong khoảng $[-1, 1]$, thể hiện mức độ trùng khớp ngữ nghĩa từ hoàn toàn khác biệt đến hoàn toàn tương đồng.

Để tối ưu hóa hiệu năng tính toán của hệ thống khi phải thực hiện so khớp hàng loạt hồ sơ trực tuyến, một chứng minh toán học quan trọng được áp dụng. Giả sử các vector nhúng đầu ra của mô hình SBERT đã được chuẩn hóa đơn vị (Unit Vectors) trước khi đưa vào tính toán, nghĩa

là độ dài L2 của mỗi vector được quy về bằng 1:

$$\|\hat{\mathbf{u}}\|_2 = \|\hat{\mathbf{v}}\|_2 = 1 \quad (2.3)$$

Khi đó, công thức tính độ tương đồng Cosine được rút gọn tối đa về tích vô hướng (Dot Product):

$$\text{cosine}(\hat{\mathbf{u}}, \hat{\mathbf{v}}) = \hat{\mathbf{u}} \cdot \hat{\mathbf{v}} = \sum_{k=1}^d \hat{u}_k \hat{v}_k \quad (2.4)$$

Chúng minh trên chỉ ra rằng, đối với các vector đã chuẩn hóa đơn vị, việc tính độ tương đồng Cosine thực chất tương đương với việc thực hiện phép nhân Tích vô hướng (Dot Product). Việc loại bỏ hoàn toàn các phép toán phức tạp như tính căn bậc hai và phép chia trong vòng lặp so khớp quy mô lớn giúp giảm thiểu đáng kể số lượng chu kỳ lệnh của CPU/GPU, cho phép hệ thống thực hiện hàng triệu phép so khớp trong thời gian thực với độ trễ tối thiểu [20].

Tuy nhiên, trong bài toán so khớp hồ sơ nhân sự thực tế, không phải tất cả các kỹ năng được yêu cầu trong mô tả công việc (JD) đều có vai trò đóng góp như nhau vào tổng điểm đánh giá của ứng viên. Nếu sử dụng độ đo tương đồng không trọng số, các kỹ năng cực kỳ phổ biến và dễ đạt được (ví dụ: Git, SQL, Microsoft Office, HTML/CSS) sẽ vô tình làm lu mờ sự thiếu hụt hoặc mức độ tương đồng thấp ở các kỹ năng cốt lõi, mang tính chất quyết định của công việc (ví dụ: PyTorch, CI/CD, Kubernetes). Để giải quyết triệt để vấn đề này, đề tài xây dựng giải pháp định lượng hóa trọng số kỹ năng động dựa trên công thức TF-IDF (Term Frequency – Inverse Document Frequency) được tính toán trực tiếp từ kho ngữ liệu tin tuyển dụng thực tế cào từ thị trường Việt Nam [28].

Mô hình toán học của cơ chế tính trọng số này được thiết lập như sau. Gọi $\mathcal{D} = \{d_1, d_2, \dots, d_N\}$ là tập hợp (corpus) chứa tất cả N tin tuyển dụng đã thu thập và lưu trữ thành công trong PostgreSQL. Với một tin tuyển dụng (JD) cụ thể d_j , gọi S_j là tập hợp các kỹ năng yêu cầu được trích xuất

từ JD đó.

Tần suất Kỹ năng (Term Frequency — TF) thể hiện mức độ nổi bật của kỹ năng s_i trong JD d_j . Do kỹ năng thường xuất hiện dưới dạng thực thể đơn lẻ (presence/absence) trong danh sách yêu cầu của JD, tần suất TF được định nghĩa theo dạng chuẩn hóa nhị phân [29]:

$$\text{TF}(s_i, d_j) = \begin{cases} 1 & \text{nếu } s_i \in S_j \\ 0 & \text{ngược lại} \end{cases} \quad (2.5)$$

Nghịch đảo Tần suất Văn bản (Inverse Document Frequency — IDF) đo lường mức độ đặc trưng và tính khan hiếm của kỹ năng s_i trên toàn bộ thị trường lao động Việt Nam [30]:

$$\text{IDF}(s_i, \mathcal{D}) = \log \left(\frac{N}{|\{d \in \mathcal{D} : s_i \in S_d\}|} \right) \quad (2.6)$$

Trong đó N là tổng số tin tuyển dụng hiện có trong cơ sở dữ liệu, và $|\{d \in \mathcal{D} : s_i \in S_d\}|$ là số lượng tin tuyển dụng thực tế có chứa kỹ năng s_i .

Trọng số TF-IDF kết hợp của kỹ năng s_i thuộc JD d_j được xác định bằng tích của hai thành phần [30]:

$$w(s_i, d_j) = \text{TF}(s_i, d_j) \times \text{IDF}(s_i, \mathcal{D}) \quad (2.7)$$

Nhờ mô hình này, nếu một kỹ năng xuất hiện tràn lan ở mọi tin tuyển dụng trên thị trường (chỉ số IDF tiến gần tới 0), giá trị w sẽ tiến dần về 0, làm giảm trọng số của kỹ năng mang tính đại trà này. Ngược lại, nếu một kỹ năng chuyên sâu chỉ xuất hiện ở một số ít các tin tuyển dụng đặc thù, chỉ số IDF sẽ lớn, đẩy trọng số của kỹ năng cốt lõi này lên cao để tạo lực đẩy quyết định cho điểm số.

Cuối cùng, tổng điểm tương thích **Match Score** giữa hồ sơ CV của ứng viên và yêu cầu JD của công việc được xác định bằng công thức trung

bình có trọng số TF-IDF của các độ tương đồng kỹ năng [28]:

$$\text{MatchScore}(\text{CV}, d_j) = \frac{\sum_{s_i \in S_j} w(s_i, d_j) \cdot \text{cosine}(\mathbf{e}_{s_i}^{\text{CV}}, \mathbf{e}_{s_i}^{\text{JD}})}{\sum_{s_i \in S_j} w(s_i, d_j)} \quad (2.8)$$

Áp dụng chứng minh rút gọn tích vô hướng cho các vector đã được chuẩn hóa đơn vị ($\|\hat{\mathbf{e}}\|_2 = 1$), công thức Match Score cuối cùng của hệ thống được tính toán siêu tốc ở tầng vật lý như sau:

$$\text{MatchScore}(\text{CV}, d_j) = \frac{\sum_{s_i \in S_j} w(s_i, d_j) \cdot (\hat{\mathbf{e}}_{s_i}^{\text{CV}} \cdot \hat{\mathbf{e}}_{s_i}^{\text{JD}})}{\sum_{s_i \in S_j} w(s_i, d_j)} \quad (2.9)$$

Vì vậy, trong hệ thống đề xuất, phương pháp nhân Tích vô hướng trên các vector nhúng chuẩn hóa đơn vị kết hợp cùng khung trọng số TF-IDF thị trường thực tế được triển khai để tính điểm Match Score chuẩn xác, giúp tối ưu hóa hiệu năng tính toán thời gian thực và phản ánh chính xác xu thế cung – cầu thực tế của thị trường lao động CNTT tại Việt Nam.

2.2.3 Khảo sát các công cụ và thuật toán so khớp hồ sơ hiện có

Quá trình tiến hóa công nghệ của các Hệ thống quản lý ứng viên (Applicant Tracking System — ATS) trải qua bốn thế hệ phát triển rõ rệt, từ các bộ lọc từ khóa sơ khai cho đến các hệ thống trí tuệ nhân tạo hiện đại [15]. Sự khác biệt giữa các thế hệ được thể hiện chi tiết trong Bảng 2.1.

Bảng 2.1: So sánh các thể hệ hệ thống ATS theo công nghệ cốt lõi, ưu nhược điểm và chi phí vận hành.

Thể hệ ATS	Công nghệ cốt lõi	Ưu điểm	Nhược điểm	Chi phí	Độ trễ (Latency)
Thể hệ I: Rule-based	Biểu thức chính quy (Regex), So khớp từ khóa chính xác (Keyword Matching) [31].	Đơn giản, dễ triển khai, tốc độ xử lý tức thời, không tốn tài nguyên.	Thất bại với từ đồng nghĩa, viết tắt [32]. Dễ bị gian lận bằng nhồi từ khóa.	Rất thấp	Cực thấp (<10ms)
Thể hệ II: Machine Learning truyền thống	Mô hình túi từ (Bag of Words), TF-IDF tĩnh, Naive Bayes, SVM, Word2Vec [7].	Nhận diện tầm quan trọng từ dựa trên tần suất [33], bắt đầu hiểu quan hệ đồng nghĩa cơ bản.	Không hiểu ngữ cảnh câu văn [14], đòi hỏi dữ liệu gán nhãn lớn.	Thấp	Thấp (10–50ms)
Thể hệ III: Deep Learning (Bi-Encoder)	Sentence-BERT (SBERT), Siamese Networks, không gian vector nhúng [20].	Biểu diễn ngữ nghĩa câu xuất sắc [26]. Cho phép tính trước vector nhúng để so khớp quy mô lớn.	Đòi hỏi tài nguyên phần cứng mạnh (GPU) [20]. Khó với tài liệu bố cục phức tạp [34].	Trung bình	Trung bình (50–200ms)

Thế hệ ATS	Công nghệ cốt lõi	Ưu điểm	Nhược điểm	Chi phí	Độ trễ (Latency)
Thế hệ IV: LLM APIs	Các mô hình ngôn ngữ lớn thương mại (GPT-4, Gemini, LLaMA), tác nhân AI (AI Agents) [15].	Hiểu ngữ cảnh, bố cục và ngôn ngữ tự nhiên vô song [34]. Khả năng tóm tắt và suy luận sâu sắc.	Chi phí API tích lũy cực kỳ tốn kém khi xử lý dữ liệu lớn. Độ trễ phản hồi cao.	Rất cao (tính phí theo Token)	Rất cao (1–5 giây/yêu cầu)

Mặc dù các mô hình ngôn ngữ lớn thuộc Thế hệ IV thể hiện khả năng hiểu văn bản vượt trội, việc gửi trực tiếp toàn bộ nội dung của hàng nghìn hồ sơ ứng viên và tin tuyển dụng lên các API thương mại cho mỗi lần chạy so khớp là một giải pháp không khả thi đối với các dự án thực tế xét trên cả hai phương diện kinh tế và kỹ thuật [34]. Về mặt kinh tế, chi phí sử dụng API sẽ tăng trưởng theo cấp số nhân khi số lượng hồ sơ cần đánh giá lớn. Về mặt kỹ thuật, độ trễ phản hồi của LLM API lên tới vài giây sẽ làm tê liệt khả năng hiển thị thời gian thực của các công cụ trực quan hóa thông tin tuyển dụng. Ngược lại, nếu chỉ dựa vào các mô hình nhúng cục bộ thuộc Thế hệ III để so khớp trực tiếp toàn bộ văn bản của CV và JD, hệ thống sẽ gặp phải sai số rất lớn do cấu trúc CV thường chứa nhiều thông tin nhiễu khiến vector nhúng của toàn bộ văn bản bị lệch hướng ngữ nghĩa [15].

Để giải quyết mâu thuẫn này, đề tài đề xuất một **giải pháp lai đột phá (Hybrid Approach)**, định vị tối ưu hiệu quả khoa học và kinh tế. Hệ thống thực hiện tách rời quy trình thành hai bước độc lập:

1. Bước bóc tách cấu trúc ngoại tuyến (Offline Structuring):

Sử dụng Gemini API (Thế hệ IV) để xử lý một lần duy nhất khi CV

được tải lên hoặc khi tin tuyển dụng được cào về [15]. Sức mạnh suy luận của LLM được khai thác triệt để để bóc tách chính xác các thực thể kỹ năng, chức danh công việc từ văn bản phi cấu trúc phức tạp thành dữ liệu bán cấu trúc JSON [32].

2. **Bước so khớp trực tuyến (Online Matching Engine):** Khi người dùng thực hiện thao tác so khớp hoặc xem trực quan hóa, hệ thống sử dụng mô hình Sentence-BERT cục bộ `all-MiniLM-L6-v2` (Thế hệ III) kết hợp độ đo Cosine chuẩn hóa tích vô hướng và trọng số TF-IDF được tính động trực tuyến từ tập dữ liệu thị trường để tính toán Match Score trực tiếp trên các kỹ năng đã được cấu trúc hóa [25].

Lập luận khoa học của giải pháp lai này dựa trên việc đặt đúng công nghệ vào đúng tác vụ: tận dụng khả năng hiểu bố cục xuất sắc của LLM để dọn dẹp và cấu trúc hóa dữ liệu, đồng thời tận dụng tốc độ tính toán vector vượt trội, chi phí bằng không và tính bảo mật của mô hình SBERT cục bộ kết hợp với trọng số TF-IDF có ý nghĩa phân loại cao cho khâu tìm kiếm và so khớp thời gian thực [20]. Vì vậy, trong hệ thống đề xuất, giải pháp kiến trúc lai (Hybrid) kết hợp LLM API ngoại tuyến và SBERT trực tuyến có trọng số TF-IDF được lựa chọn để tối ưu hóa bài toán so khớp hồ sơ đạt hiệu năng cao và tiết kiệm chi phí vận hành.

2.3 Trích xuất thực thể trong quản lý thị trường việc làm

2.3.1 Bài toán bóc tách thông tin kỹ năng, vị trí công việc từ văn bản

Nhận diện thực thể tên (Named Entity Recognition — NER) là một trong những tác vụ nền tảng nhất của xử lý ngôn ngữ tự nhiên, hướng tới

việc tự động xác định các phân đoạn văn bản thô đại diện cho các thực thể cụ thể và phân loại chúng vào các nhóm ngữ nghĩa được định nghĩa trước [14]. Khi được áp dụng vào lĩnh vực quản lý nhân sự (HR Domain), bài toán NER trở nên đặc thù và phức tạp hơn rất nhiều, đòi hỏi hệ thống phải bóc tách chính xác các thực thể cốt lõi bao gồm: chức danh công việc (Job Title), kỹ năng chuyên môn (Skills), trình độ học vấn, các chứng chỉ chuyên ngành và chế độ phúc lợi [15]. Việc cấu trúc hóa thành công các thực thể này từ văn bản tự do là điều kiện tiên quyết để xây dựng các thuật toán so khớp chính xác và lập biểu đồ phân tích thị trường lao động hiệu quả.

Thách thức lớn nhất khi giải quyết tác vụ NER trong lĩnh vực nhân sự xuất phát từ tính phi cấu trúc cực kỳ cao của hồ sơ ứng viên (CV) [34]. Ứng viên thường tự do trình bày hồ sơ cá nhân theo nhiều phong cách thẩm mỹ khác nhau, sử dụng các phần mềm thiết kế đa dạng dẫn đến định dạng tệp tin không đồng nhất (như PDF, DOCX, hoặc tệp ảnh quét) [15]. Đối với các CV được lưu trữ dưới dạng ảnh quét hoặc PDF dạng ảnh, hệ thống bắt buộc phải tích hợp một lớp nhận diện ký tự quang học (Optical Character Recognition — OCR) để khôi phục văn bản thô. Tuy nhiên, CV hiện đại thường áp dụng bố cục trình bày nhiều cột (multi-column layouts) hoặc dạng bảng lồng nhau nhằm tối ưu hóa diện tích hiển thị [34]. Các công cụ đọc văn bản thông thường nếu chỉ quét tuần tự từ trái sang phải, từ trên xuống dưới sẽ làm đứt gãy hoàn toàn cấu trúc ngữ pháp của câu văn, trộn lẫn nội dung của hai cột khác biệt, dẫn đến việc phá hủy ngữ cảnh và khiến các mô hình NER truyền thống mất khả năng nhận diện thực thể chính xác.

Đặc biệt, đối với thị trường lao động ngành Công nghệ thông tin tại Việt Nam, bài toán trích xuất thực thể phải đối mặt với rào cản ngôn ngữ song ngữ Anh – Việt rất phức tạp. Cả nhà tuyển dụng và ứng viên thường có thói quen viết xen lẫn hai ngôn ngữ ngay trong cùng một câu văn. Thêm vào đó, danh mục kỹ năng ngành IT vô cùng đa dạng, chứa nhiều thuật ngữ viết tắt, viết liền hoặc có nhiều biến thể ký tự khác nhau.

Các mô hình NER truyền thống dựa trên các thuật toán học máy giám sát thường bộc lộ sự yếu kém do tập dữ liệu huấn luyện hạn chế, không thể bao phủ toàn bộ các biến thể ngôn ngữ lai này, dẫn đến tỷ lệ bỏ sót thực thể kỹ năng mới hoặc nhận diện sai lệch chức danh công việc ở mức cao [15]. Vì vậy, trong hệ thống đề xuất, giải pháp nhận diện thực thể tên kết hợp OCR được triển khai để xử lý các CV song ngữ và đa dạng về cấu trúc trình bày một cách chuẩn xác, đảm bảo không bỏ sót thông tin năng lực của ứng viên.

2.3.2 Ứng dụng mô hình ngôn ngữ lớn (LLM) và câu lệnh để chuẩn hóa dữ liệu

Sự trỗi dậy của các mô hình ngôn ngữ lớn (Large Language Models — LLMs) dựa trên kiến trúc Transformer tự chú ý đã mang lại một bước nhảy vọt về chất cho tác vụ bóc tách thông tin [15]. Nhờ được huấn luyện trên các kho ngữ liệu khổng lồ đa ngôn ngữ, các LLM hiện đại như Google Gemini sở hữu khả năng hiểu biết ngữ cảnh sâu sắc và khả năng suy luận mạnh mẽ dưới dạng zero-shot (trích xuất thực thể chính xác mà không cần trải qua quá trình huấn luyện lại trên tập dữ liệu chuyên biệt). Để khai thác tối đa sức mạnh của LLM phục vụ cho quy trình ETL dữ liệu tuyển dụng, kỹ thuật Thiết kế câu lệnh (Prompt Engineering) được nghiên cứu và ứng dụng một cách có hệ thống [35]. Prompt Engineering đóng vai trò như một bộ chỉ dẫn hành vi, thiết lập các ràng buộc ngữ cảnh, định dạng đầu ra và các quy tắc kiểm tra nghiêm ngặt để LLM hoạt động ổn định và chính xác nhất [35].

Trong thiết kế hệ thống của dự án, ba kỹ thuật Prompt Engineering cốt lõi được áp dụng đồng thời nhằm chuẩn hóa dữ liệu đầu vào:

(1) Thiết lập vai trò chuyên gia (Role Setting): Câu lệnh gửi đến Gemini API được bắt đầu bằng việc thiết lập vai trò rõ ràng: *“Bạn là một chuyên gia phân tích thị trường lao động CNTT tại Việt Nam, am hiểu sâu sắc xu hướng kỹ thuật, từ vựng song ngữ Anh-Việt và từ điển kỹ*

năng của thị trường”. Việc thiết lập vai trò này hướng mô hình ngôn ngữ tập trung vào việc áp dụng các tri thức chuyên ngành, chuẩn hóa các tên gọi công việc và kỹ năng theo các thuật ngữ chuẩn mực của ngành, hạn chế việc trích xuất các cụm từ tự do thiếu giá trị phân tích.

(2) Ép kiểu dữ liệu đầu ra bằng Structured Outputs (JSON Schema): Để kết quả phản hồi từ Gemini API có thể nạp trực tiếp vào cơ sở dữ liệu quan hệ của hệ thống mà không gặp phải lỗi phân tích cú pháp, hệ thống sử dụng tính năng Structured Outputs kết hợp với thư viện Pydantic trong Python [13]. Cấu trúc này sau đó được truyền trực tiếp vào tham số `response_schema` của cấu hình cuộc gọi API của Gemini. Cơ chế này buộc mô hình ngôn ngữ ở tầng biên dịch của API phải tuân thủ tuyệt đối cấu trúc JSON được định nghĩa, loại bỏ hoàn toàn các câu thoại tự do dư thừa và đảm bảo các trường dữ liệu luôn nhất quán về định dạng và kiểu dữ liệu [35].

(3) Cơ chế hậu kiểm chống ảo giác (Anti-hallucination Verification): Một trong những hạn chế lớn nhất của LLM là hiện tượng ảo giác (hallucination) — mô hình tự động bổ sung hoặc suy diễn ra các kỹ năng không hề tồn tại trong văn bản gốc của CV hoặc JD [35]. Để triệt tiêu hiện tượng này, thiết kế prompt áp dụng kỹ thuật yêu cầu trích xuất kèm bằng chứng (evidence-based extraction). Trong schema JSON yêu cầu, mỗi thực thể kỹ năng bóc tách được bắt buộc phải đi kèm với trường `evidence_text` chứa đoạn văn bản thô trích xuất chính xác từ tài liệu gốc. Sau khi nhận phản hồi JSON từ Gemini API, hệ thống sẽ thực thi một hàm kiểm chứng nội bộ: hàm này thực hiện kiểm tra xem chuỗi văn bản trong trường `evidence_text` có thực sự tồn tại trong văn bản CV/JD gốc ban đầu hay không. Nếu phát hiện sự sai lệch hoặc không tìm thấy chuỗi đối chứng, thực thể kỹ năng tương ứng sẽ bị đánh dấu là ảo giác và tự động bị loại bỏ khỏi luồng ETL. Cơ chế tự kiểm chứng này giúp nâng cao độ tin cậy của dữ liệu lên mức tối đa, đảm bảo tính công bằng và chính xác tuyệt đối cho thuật toán so khớp hồ sơ.

Vì vậy, trong hệ thống đề xuất, kỹ thuật thiết kế Prompt kết hợp JSON

Schema và cơ chế hậu kiểm chống ảo giác (Anti-hallucination Verification) được triển khai nhằm triệt tiêu tối đa hiện tượng ảo giác thông tin, đảm bảo tính toàn vẹn và độ tin cậy khoa học cho dữ liệu đầu vào của pipeline so khớp.

Chương 3

Phân tích và thiết kế hệ thống

3.1 Phân tích yêu cầu hệ thống

3.1.1 Yêu cầu nghiệp vụ

Sinh viên ngành Công nghệ thông tin tại Việt Nam thường đối mặt với một nghịch lý trong quá trình tìm kiếm việc làm: dù sở hữu bằng cấp chuyên môn, nhiều sinh viên không có khả năng đánh giá khách quan khoảng cách giữa năng lực bản thân và yêu cầu thực tế của thị trường tuyển dụng. Các công cụ hỗ trợ hiện có, chủ yếu dưới dạng các trang tuyển dụng thông thường, chỉ cung cấp danh sách tin đăng mà thiếu hẳn cơ chế phân tích và phản hồi cá nhân hóa giúp sinh viên nhận diện điểm yếu năng lực một cách có hệ thống.

Bài toán nghiệp vụ cốt lõi của hệ thống CareerNova được xác định như sau: sinh viên CNTT cần một công cụ tự động hóa việc so sánh hồ sơ năng lực của bản thân với tập hợp yêu cầu kỹ năng từ các tin tuyển dụng thực tế trên thị trường, từ đó cung cấp kết quả so khớp trực quan và có thể hành động được. Để giải quyết bài toán này, hệ thống hoạt động theo luồng nghiệp vụ khép kín gồm bốn giai đoạn chính:

(1) Thu thập dữ liệu tuyển dụng: Hệ thống ETL tự động crawl và trích xuất thông tin từ các nền tảng tuyển dụng lớn tại Việt Nam (ITViec, VietnamWorks, CareerViet, LinkedIn), bao gồm yêu cầu kỹ năng, mức

lương và thông tin ngành nghề, nhằm xây dựng kho dữ liệu thị trường được cập nhật liên tục.

(2) Phân tích và chuẩn hóa: Dữ liệu tuyển dụng được làm sạch, trích xuất thực thể bằng Gemini API và chuẩn hóa ngữ nghĩa về một từ điển kỹ năng thống nhất, đảm bảo tính nhất quán để so sánh chéo giữa các nguồn thu thập.

(3) So khớp CV với thị trường: Khi sinh viên tải lên CV, hệ thống tự động bóc tách kỹ năng, tính điểm tương đồng ngữ nghĩa dựa trên mô hình Sentence-BERT kết hợp trọng số TF-IDF thị trường, rồi tạo ra báo cáo khoảng cách kỹ năng và biểu đồ Radar chi tiết.

(4) Trực quan hóa và hỗ trợ quyết định: Kết quả được hiển thị qua giao diện dashboard tương tác, giúp sinh viên đọc hiểu tình trạng năng lực, theo dõi xu hướng tuyển dụng thị trường và nhận đề xuất lộ trình học tập cá nhân hóa.

Hai nhóm đối tượng sử dụng chính được xác định: **Sinh viên CNTT** (người dùng cuối chính, sử dụng toàn bộ tính năng phân tích và trực quan hóa) và **Quản trị viên** (Admin, có quyền truy cập nâng cao vào dữ liệu hệ thống và quản lý tài khoản người dùng). Ngoài ra, **Hệ thống ETL** đóng vai trò tác nhân tự động vận hành luồng thu thập và chuẩn hóa dữ liệu nền tảng.

3.1.2 Yêu cầu chức năng

Các yêu cầu chức năng được xác định dựa trên cấu trúc route thực tế của ứng dụng Frontend (Next.js) và các module API của Backend (NestJS), được phân nhóm theo từng Actor như trong Bảng 3.1.

Bảng 3.1: Danh sách yêu cầu chức năng của hệ thống CareerNova.

Mã	Actor	Mô tả
<i>Nhóm chức năng: Quản lý tài khoản</i>		

Mã	Actor	Mô tả
UC-01	Sinh viên	Đăng ký tài khoản mới bằng địa chỉ email và mật khẩu.
UC-02	Sinh viên	Đăng nhập bằng tài khoản email/mật khẩu hoặc Google OAuth (Single Sign-On).
UC-03	Sinh viên	Xác thực địa chỉ email sau khi đăng ký để kích hoạt tài khoản.
UC-04	Sinh viên	Yêu cầu đặt lại mật khẩu qua email và tạo mật khẩu mới.
UC-05	Sinh viên	Hoàn tất luồng onboarding: khai báo thông tin năng lực và định hướng nghề nghiệp ban đầu.
UC-06	Sinh viên	Cập nhật hồ sơ cá nhân (họ tên, ảnh đại diện, thông tin nghề nghiệp).
UC-07	Sinh viên	Cài đặt tài khoản: thay đổi giao diện sáng/tối, quản lý thông báo, xóa tài khoản.
<i>Nhóm chức năng: Quản lý CV và So khớp</i>		
UC-08	Sinh viên	Tải lên, quản lý và đặt CV mặc định để sử dụng trong so khớp.
UC-09	Sinh viên	Thực hiện so khớp CV với tin tuyển dụng: hệ thống tính điểm tương đồng và tạo kết quả phân tích.
UC-10	Sinh viên	Xem biểu đồ Radar thể hiện điểm kỹ năng bản thân so với yêu cầu thị trường.
UC-11	Sinh viên	Xem Gap Report: báo cáo chi tiết kỹ năng đạt yêu cầu, đạt một phần và còn thiếu hụt.
<i>Nhóm chức năng: Khám phá việc làm</i>		

Mã	Actor	Mô tả
UC-12	Sinh viên	Tìm kiếm và lọc tin tuyển dụng theo từ khóa, kỹ năng, mức lương và địa điểm.
UC-13	Sinh viên	Xem chi tiết tin tuyển dụng bao gồm mô tả công việc và yêu cầu kỹ năng.
UC-14	Sinh viên	Lưu tin tuyển dụng yêu thích vào danh sách cá nhân.
UC-15	Sinh viên	Xem danh sách việc làm được đề xuất dựa trên hồ sơ năng lực cá nhân.
<i>Nhóm chức năng: Phân tích và Trực quan hóa</i>		
UC-16	Sinh viên	Xem Dashboard thị trường: xu hướng đăng tuyển, phân bổ ngành công nghiệp và dải lương theo vị trí.
UC-17	Sinh viên	Xem Dashboard cá nhân: tổng hợp năng lực, tiến độ và kết quả so khớp của bản thân.
UC-18	Sinh viên	Xem lộ trình học tập được đề xuất để lấp đầy khoảng cách kỹ năng đã phát hiện.
<i>Nhóm chức năng: Quản trị hệ thống</i>		
UC-19	Admin	Xem và quản lý danh sách người dùng trong hệ thống (xem thông tin, phân quyền).
UC-20	Admin	Xem báo cáo tổng thể về hoạt động và dữ liệu của hệ thống.
<i>Nhóm chức năng: Thu thập và xử lý dữ liệu (tự động)</i>		
UC-21	Hệ thống ETL	Thu thập dữ liệu tin tuyển dụng tự động từ các nền tảng ITViec, VietnamWorks, CareerViet, LinkedIn.
UC-22	Hệ thống ETL	Chuẩn hóa, trích xuất thực thể kỹ năng và nạp dữ liệu vào cơ sở dữ liệu PostgreSQL.

3.1.3 Yêu cầu phi chức năng

Các yêu cầu phi chức năng được suy ra từ các tệp cấu hình kỹ thuật thực tế của hệ thống, bao gồm `Dockerfile` của Frontend (Node 20-Alpine, port 3000) và Backend (Node 20-Alpine, port 3000, OpenSSL), tệp `docker-compose.yml` (PostgreSQL 17, Docker volume), và tệp `requirements.txt` của ETL Pipeline (FastAPI, Torch, Sentence-transformers, FAISS-cpu, Psycopg2). Các yêu cầu được phân loại và trình bày trong Bảng 3.2.

Bảng 3.2: Danh sách yêu cầu phi chức năng của hệ thống CareerNova.

Mã	Loại	Mô tả
NFR-01	Hiệu năng	Thời gian phản hồi của API Backend không vượt quá 2 giây cho 95% các yêu cầu truy vấn thông thường (dashboard, tìm kiếm, hồ sơ).
NFR-02	Hiệu năng	Toàn bộ quy trình so khớp CV (bóc tách kỹ năng qua Gemini API, tính điểm SBERT, tạo Gap Report) hoàn thành trong vòng 30 giây kể từ thời điểm người dùng gửi yêu cầu.
NFR-03	Hiệu năng	Tìm kiếm ngữ nghĩa trên chỉ mục vector FAISS đạt độ trễ dưới 100ms cho tập dữ liệu hàng triệu bản ghi, nhờ cơ chế tính trước (precompute) và lưu cache vector nhúng.
NFR-04	Bảo mật	Xác thực người dùng được thực hiện theo cơ chế JWT stateless; access token có thời hạn ngắn và được làm mới qua refresh token để giảm thiểu rủi ro rò rỉ.

Mã	Loại	Mô tả
NFR-05	Bảo mật	Mật khẩu người dùng được băm bằng thuật toán bcrypt trước khi lưu vào cơ sở dữ liệu; không lưu trữ mật khẩu dạng plaintext tại bất kỳ tầng nào.
NFR-06	Bảo mật	Các container Docker chạy dưới tài khoản non-root (UID 1001 đối với Frontend) và không nhúng thông tin xác thực nhạy cảm vào image, tuân thủ nguyên tắc đặc quyền tối thiểu.
NFR-07	Bảo mật	Toàn bộ giao tiếp giữa Frontend và Backend được mã hóa qua HTTPS/TLS; Backend tích hợp OpenSSL (khai báo trong Dockerfile) để hỗ trợ kết nối cơ sở dữ liệu bảo mật.
NFR-08	Khả năng mở rộng	Mỗi thành phần của hệ thống (Frontend, Backend API, ETL Pipeline) được đóng gói độc lập trong Docker container, cho phép triển khai, nâng cấp và mở rộng theo chiều ngang (horizontal scaling) mà không ảnh hưởng đến các thành phần còn lại.
NFR-09	Khả năng mở rộng	Pipeline ETL được thiết kế theo kiến trúc module hóa (crawl → clean → normalize → import), cho phép bổ sung nguồn tuyển dụng mới hoặc thay thế mô hình LLM mà không cần thay đổi cấu trúc tổng thể.


Mã	Loại	Mô tả
NFR-10	Độ tin cậy	Dữ liệu PostgreSQL được lưu trữ bền vững qua Docker named volume (<code>career_nova_postgres_data</code>), đảm bảo dữ liệu không bị mất khi container khởi động lại; container PostgreSQL cấu hình restart: unless-stopped .
NFR-11	Độ tin cậy	ETL Pipeline tích hợp cơ chế fallback tự động: ưu tiên cào tĩnh bằng Requests/cloudscraper, tự động chuyển sang Selenium Headless Browser khi gặp tường lửa chống bot, đảm bảo tính liên tục của quá trình thu thập dữ liệu.
NFR-12	Độ tin cậy	Kết quả bóc tách kỹ năng từ LLM (Gemini API) được kiểm chứng bằng cơ chế anti-hallucination: mỗi thực thể kỹ năng phải kèm bằng chứng (<code>evidence_text</code>) trích từ văn bản gốc; nếu không khớp sẽ bị loại bỏ tự động.
NFR-13	Bảo trì	Backend NestJS được tổ chức theo kiến trúc module hóa rõ ràng (auth, profile, job, matching, skill-gap, market-dashboard, v.v.), mỗi module độc lập về controller, service và DTO, giúp dễ dàng bảo trì và mở rộng từng tính năng riêng lẻ.

Mã	Loại	Mô tả
NFR-14	Bảo trì	Toàn bộ Frontend và Backend sử dụng TypeScript với kiểu dữ liệu tường minh, giúp phát hiện lỗi tại thời điểm biên dịch, giảm thiểu lỗi runtime và hỗ trợ tái cấu trúc mã nguồn an toàn.

3.2 Thiết kế hệ thống

3.2.1 Sơ đồ kiến trúc tổng thể

Hệ thống CareerNova được xây dựng theo kiến trúc đa tầng (multi-tier architecture) với bốn tầng chức năng độc lập, mỗi tầng đảm nhiệm một vai trò chuyên biệt trong luồng xử lý dữ liệu từ nguồn tuyển dụng đến giao diện người dùng cuối. Sơ đồ kiến trúc tổng thể được thể hiện trong Hình 3.1.



Hình 3.1: Sơ đồ kiến trúc tổng thể hệ thống CareerNova.

Tầng Trình Bày (Presentation Layer) bao gồm ứng dụng web đơn trang được xây dựng trên Next.js 15 và React 19 (TypeScript). Tầng này

đảm nhận toàn bộ việc hiển thị giao diện và tương tác người dùng, bao gồm các trang xác thực (đăng nhập, đăng ký, Google OAuth), luồng onboarding, trang quản lý CV, và bốn thành phần trực quan hóa cốt lõi: *MarketDashboard* (AreaChart, PieChart, BarChart), *SkillGapAnalysis* (RadarChart, Gap Report), *PersonalDashboard* và *LearningRoadmap*. Giao tiếp với tầng nghiệp vụ được thực hiện qua REST API sử dụng HTTPS và xác thực JWT.

Tầng Nghiệp Vụ (Business Logic Layer) gồm hai thành phần hoạt động phối hợp. Thành phần thứ nhất là **CareerNova Backend API** (NestJS, Node 20), đóng vai trò cổng dịch vụ điều phối toàn bộ luồng yêu cầu từ Frontend: quản lý xác thực và phân quyền (JWT), xử lý hồ sơ người dùng, tổng hợp dữ liệu dashboard, và điều phối luồng so khớp CV sang ETL Service qua giao thức HTTP. Kết nối cơ sở dữ liệu được thực hiện qua Prisma ORM. Thành phần thứ hai là **ETL Pipeline** (Python, FastAPI), chịu trách nhiệm toàn bộ luồng xử lý dữ liệu nặng: thu thập JD từ các nền tảng tuyển dụng bằng Selenium và Requests/cloudscraper, trích xuất và chuẩn hóa thực thể kỹ năng qua Gemini API, tính điểm so khớp ngữ nghĩa bằng SBERT và FAISS, rồi nạp kết quả vào PostgreSQL qua SQLAlchemy.

Tầng Dữ Liệu (Data Layer) sử dụng PostgreSQL 17, lưu trữ toàn bộ dữ liệu hệ thống: thông tin người dùng và CV (`users`, `user_cvs`), kho dữ liệu tuyển dụng (`jobs`, `skills`, `job_skills`, `salaries`, `industries`), và kết quả phân tích so khớp (`cv_job_matches` với hai cột JSONB `radar_data` và `gap_report`). Việc lưu trữ trước kết quả tính toán dưới dạng JSONB giúp tối ưu hóa hiệu năng truy vấn thời gian thực tại tầng trình bày mà không cần tính toán lại.

Tầng Dịch Vụ Ngoài (External Services Layer) bao gồm ba thành phần: **Google Gemini API** thực hiện trích xuất thực thể kỹ năng có cấu trúc từ văn bản JD và CV (Structured Outputs với JSON Schema); **mô hình nhúng all-MiniLM-L6-v2** (Sentence Transformers) mã hóa kỹ năng thành vector 384 chiều và xây dựng chỉ mục FAISS để tìm kiếm ngữ

nghĩa; và **các nền tảng tuyển dụng** (ITViec, VietnamWorks, CareerViet, LinkedIn) cung cấp nguồn dữ liệu JD thô cho ETL Pipeline.

3.2.2 Sơ đồ ca sử dụng tổng quát

Sơ đồ ca sử dụng tổng quát thể hiện toàn bộ tương tác giữa ba Actor — Sinh viên, Admin và Hệ thống ETL — với hệ thống CareerNova, bao gồm các quan hệ **include** và **extend** giữa các ca sử dụng. Sơ đồ được mô tả trong Hình 3.2.

Hình 3.2: Sơ đồ ca sử dụng tổng quát của hệ thống CareerNova.

Bảng 3.3, Bảng 3.4 và Bảng 3.5 trình bày đặc tả chi tiết cho ba ca sử dụng quan trọng nhất của hệ thống.

Bảng 3.3: Đặc tả ca sử dụng UC-09: Tải lên CV và So khớp kỹ năng.

Trường	Nội dung
Mã	UC-09
Tên	Tải lên CV và So khớp kỹ năng với thị trường
Actor chính	Sinh viên
Tiền điều kiện	Sinh viên đã đăng nhập và hoàn tất onboarding; tài khoản đang active.

Trường	Nội dung
Luồng chính	1. Sinh viên truy cập trang CV Matching, chọn tệp CV (PDF/DOCX) và tin tuyển dụng mục tiêu. 2. Hệ thống xác thực định dạng tệp, tải lên Backend API. 3. Backend API lưu metadata CV vào <code>user_cvs</code>, chuyển tiếp sang ETL Matching Service. 4. ETL Service trích xuất văn bản CV (OCR nếu là ảnh quét), gọi Gemini API bóc tách danh sách kỹ năng. 5. Hệ thống mã hóa kỹ năng thành vector SBERT, tính Match Score = $\sum(\text{weight} \times \text{cosine}) \div \sum(\text{weight})$. 6. Kết quả <code>radar_data</code> và <code>gap_report</code> JSONB được lưu vào bảng <code>cv_job_matches</code>. 7. Frontend truy vấn và hiển thị biểu đồ Radar và Gap Report.
Luồng thay thế	4a. Nếu CV là ảnh quét: hệ thống thực hiện OCR (pdf2image + Pytesseract) trước khi trích xuất. 4b. Nếu kỹ năng được Gemini trả về không có <code>evidence_text</code> khớp trong văn bản gốc: thực thể bị loại bỏ (anti-hallucination).
Hậu điều kiện	Kết quả so khớp được lưu vào cơ sở dữ liệu; sinh viên xem được biểu đồ Radar và danh sách kỹ năng còn thiếu.

Bảng 3.4: Đặc tả ca sử dụng UC-11: Xem Gap Report và báo cáo khoảng cách kỹ năng.

Trường	Nội dung
Mã	UC-11
Tên	Xem Gap Report và báo cáo khoảng cách kỹ năng
Actor chính	Sinh viên
Tiền điều kiện	Sinh viên đã thực hiện so khớp CV (UC-09); trường <code>gap_report</code> JSONB đã được lưu vào <code>cv_job_matches</code> .
Luồng chính	1. Sinh viên truy cập trang Skill Gap Analysis. 2. Frontend gọi API lấy dữ liệu từ <code>cv_job_matches.gap_report</code>. 3. Hệ thống phân loại kỹ năng thành ba nhóm: Đạt yêu cầu (xanh lá), Đạt một phần (vàng), Thiếu hụt (đỏ). 4. Frontend hiển thị biểu đồ cột ngang phân kỳ và danh sách kỹ năng chi tiết. 5. Sinh viên mở rộng từng danh mục kỹ năng để xem điểm <code>user_rate</code> và <code>market_rate</code>.
Luồng thay thế	2a. Nếu chưa có kết quả so khớp: hệ thống hiển thị gợi ý thực hiện UC-09 trước.
Hậu điều kiện	Sinh viên nắm được danh sách kỹ năng cụ thể cần bổ sung và có thể điều hướng sang UC-18 để xem lộ trình học tập đề xuất.

Bảng 3.5: Đặc tả ca sử dụng UC-16: Xem Dashboard thống kê thị trường việc làm.

Trường	Nội dung
Mã	UC-16
Tên	Xem Dashboard thống kê thị trường việc làm
Actor chính	Sinh viên
Tiền điều kiện	Sinh viên đã đăng nhập; cơ sở dữ liệu đã có dữ liệu tuyển dụng từ ETL Pipeline.
Luồng chính	1. Sinh viên truy cập trang Market Dashboard. 2. Frontend khởi tạo fetchDashboardData() và gửi đồng thời (Promise.all) ba yêu cầu API: xu hướng tuyển dụng, phân bổ ngành và dải lương. 3. Backend API truy vấn PostgreSQL và trả về JSON tương ứng cho từng biểu đồ. 4. Frontend kết xuất AreaChart (xu hướng), PieChart (phân bổ ngành) và BarChart (dải lương) bằng Recharts. 5. Sinh viên lọc theo khoảng thời gian (tháng/năm) để xem xu hướng tương ứng.
Luồng thay thế	3a. Nếu không có dữ liệu trong cơ sở dữ liệu (ETL chưa chạy): hiển thị thông báo dữ liệu chưa sẵn sàng.
Hậu điều kiện	Sinh viên nắm được xu hướng tuyển dụng, các ngành đang có nhu cầu cao và mức lương tham chiếu trên thị trường.

3.2.3 Sơ đồ tuần tự cho các chức năng chính

Luồng tải lên CV và So khớp kỹ năng

Hình 3.3 mô tả luồng tương tác tuần tự giữa các thành phần hệ thống khi sinh viên thực hiện chức năng tải lên CV và so khớp kỹ năng.

Hình 3.3: Sơ đồ tuần tự luồng tải lên CV và so khớp kỹ năng.

Luồng xử lý bắt đầu khi người dùng gửi tệp CV từ Frontend. Backend API tiếp nhận, lưu metadata và chuyển tiếp sang ETL Matching Service qua HTTP. Tại đây, văn bản CV được bóc tách (OCR nếu cần), kỹ năng được trích xuất qua Gemini API với cơ chế kiểm chứng chống ảo giác (`evidence_text`), sau đó mã hóa thành vector 384 chiều bằng mô hình SBERT và tính điểm tương đồng Cosine có trọng số TF-IDF thị trường. Kết quả `radar_data` và `gap_report` JSONB được lưu vào bảng `cv_job_matches` trong PostgreSQL và trả về Frontend để kết xuất biểu đồ Radar và Gap Report.

Luồng xem Dashboard thị trường

Hình 3.4 mô tả luồng tương tác tuần tự khi sinh viên truy cập trang Dashboard thị trường.

Hình 3.4: Sơ đồ tuần tự luồng xem Dashboard thống kê thị trường việc làm.

Khi người dùng điều hướng đến MarketDashboard, Frontend khởi tạo ba truy vấn API song song (`Promise.all`) để lấy dữ liệu xu hướng tuyển dụng, phân bổ ngành và dải lương. Backend API thực hiện các truy vấn tổng hợp (aggregation) trực tiếp trên PostgreSQL và trả về JSON cho từng biểu đồ. Frontend cập nhật state qua `setTrends()`, `setIndustriesData()` và `setSalaryRangesData()`, rồi kết xuất đồng thời `AreaChart`, `PieChart`


và BarChart thông qua thư viện Recharts, mang lại trải nghiệm tải trang nhanh và phản hồi tương tác tức thì.

3.3 Thiết kế cơ sở dữ liệu

Cơ sở dữ liệu của hệ thống được xây dựng trên hệ quản trị cơ sở dữ liệu quan hệ PostgreSQL (phiên bản 17). Thiết kế đảm bảo tính toàn vẹn dữ liệu, hiệu năng truy vấn thông qua các ràng buộc khóa ngoại (foreign key), chỉ mục (index) và phân tách chuẩn hóa các thực thể.

3.3.1 Sơ đồ mối quan hệ thực thể (ERD)

Dưới đây là sơ đồ mối quan hệ thực thể (ERD) biểu diễn cấu trúc cơ sở dữ liệu của hệ thống:



3.3.2 Đặc tả các bảng dữ liệu thực tế

Dưới đây là chi tiết cấu trúc thuộc tính, kiểu dữ liệu, các ràng buộc và ý nghĩa chức năng của từng bảng trong cơ sở dữ liệu.

1. Bảng users (Thông tin người dùng)

Bảng này lưu trữ thông tin tài khoản người dùng, bao gồm sinh viên và quản trị viên hệ thống.

Bảng 3.6: Cấu trúc bảng **users**.

Tên trường	Kiểu dữ liệu	Ràng buộc	Ý nghĩa
user_id	uuid	PK, DEFAULT gen_random_uuid()	Định danh duy nhất của người dùng.
full_name	varchar(255)	NULL	Họ và tên đầy đủ.
email	varchar(255)	UNIQUE, NOT NULL	Địa chỉ email đăng ký tài khoản.
password_hash	text	NULL (nếu đăng nhập mạng xã hội)	Mật khẩu tài khoản đã băm an toàn.
avatar_url	text	NULL	Đường dẫn ảnh đại diện.
role	varchar(50)	DEFAULT 'student', CHECK (role IN ('student', 'admin'))	Vai trò tài khoản (Sinh viên / Quản trị viên).
created_at	timestamp	DEFAULT CURRENT_TIMESTAMP	Thời điểm tạo tài khoản.

Tên trường	Kiểu dữ liệu	Ràng buộc	Ý nghĩa
is_active	boolean	DEFAULT false	Trạng thái kích hoạt tài khoản.
verify_token	varchar(255)	NULL	Mã xác thực email kích hoạt.
verify_token_expires	timestamp	NULL	Hạn dùng của mã xác thực email.

2. Bảng user_auth_providers (Liên kết nhà cung cấp xác thực)

Lưu trữ thông tin xác thực bên thứ ba (Google, Facebook) phục vụ đăng nhập Single Sign-On (SSO).

Bảng 3.7: Cấu trúc bảng user_auth_providers.

Tên trường	Kiểu dữ liệu	Ràng buộc	Ý nghĩa
auth_provider_id	uuid	PK, DEFAULT gen_random_uuid()	Định danh duy nhất liên kết xác thực.
user_id	uuid	FK -> users(user_id) ON DELETE CASCADE	ID người dùng sở hữu liên kết.
provider	varchar(50)	CHECK (provider IN ('local', 'google', 'facebook'))	Tên nhà cung cấp dịch vụ xác thực.
provider_user_id	varchar(255)	NOT NULL	ID định danh từ phía nhà cung cấp.

Tên trường	Kiểu dữ liệu	Ràng buộc	Ý nghĩa
provider_email	varchar(255)	NULL	Email trả về từ nhà cung cấp.
provider_name	varchar(255)	NULL	Họ tên trả về từ nhà cung cấp.
provider_avatar_url	text	NULL	Ảnh đại diện trả về từ nhà cung cấp.
created_at	timestamp	DEFAULT CURRENT_TIMESTAMP	Thời điểm liên kết.
last_login_at	timestamp	NULL	Lần đăng nhập cuối qua provider này.

3. Bảng user_cvs (Thông tin tệp CV đã tải lên)

Lưu trữ thông tin các tệp tin CV do sinh viên tải lên hệ thống.

Bảng 3.8: Cấu trúc bảng user_cvs.

Tên trường	Kiểu dữ liệu	Ràng buộc	Ý nghĩa
cv_id	uuid	PK, DEFAULT gen_random_uuid()	Định danh duy nhất cho CV.
user_id	uuid	FK -> users(user_id) ON DELETE CASCADE	Định danh sinh viên sở hữu CV.
file_name	varchar(255)	NULL	Tên tệp tin gốc tải lên.

Tên trường	Kiểu dữ liệu	Ràng buộc	Ý nghĩa
file_url	text	NULL	Đường dẫn URL tệp tin trên hệ thống lưu trữ.
extracted_text	text	NULL	Nội dung văn bản thô trích xuất từ CV.
uploaded_at	timestamp	DEFAULT CURRENT_TIMESTAMP	Thời điểm tải lên hệ thống.
updated_at	timestamp	DEFAULT CURRENT_TIMESTAMP	Thời điểm cập nhật cuối cùng.

4. Bảng skills (Từ điển kỹ năng hệ thống)

Lưu trữ danh mục kỹ năng chuẩn hóa dựa trên phân loại hệ thống (ví dụ: chuẩn O*NET hoặc Lightcast).

Bảng 3.9: Cấu trúc bảng **skills**.

Tên trường	Kiểu dữ liệu	Ràng buộc	Ý nghĩa
skill_id	integer	PK, SERIAL	Định danh duy nhất cho kỹ năng.
skill_name	varchar(255)	UNIQUE, NOT NULL	Tên chuẩn hóa của kỹ năng.
category	varchar(255)	NULL	Nhóm phân loại chính của kỹ năng.

Tên trường	Kiểu dữ liệu	Ràng buộc	Ý nghĩa
type	varchar(100)	NULL	Loại kỹ năng (Hard Skill, Common Skill).
created_at	timestamp	DEFAULT CURRENT_TIMESTAMP	Ngày tạo bản ghi kỹ năng.

5. Bảng user_cv_skills (Kỹ năng chi tiết của sinh viên)

Bảng cầu nối lưu trữ danh sách các kỹ năng chuẩn hóa được trích xuất từ CV ứng viên.

Bảng 3.10: Cấu trúc bảng user_cv_skills.

Tên trường	Kiểu dữ liệu	Ràng buộc	Ý nghĩa
cv_id	uuid	PK, FK -> user_cvs(cv_id) ON DELETE CASCADE	ID của CV được phân tích.
skill_id	integer	PK, FK -> skills(skill_id) ON DELETE CASCADE	ID kỹ năng chuẩn hóa tương ứng.
raw_skill	varchar(255)	NULL	Cụm từ kỹ năng gốc ghi trên CV.
created_at	timestamp	DEFAULT CURRENT_TIMESTAMP	Thời điểm lưu bản ghi.

6. Bảng companies (Thông tin doanh nghiệp tuyển dụng)

Lưu trữ dữ liệu hồ sơ công ty đăng tuyển việc làm.

Bảng 3.11: Cấu trúc bảng companies.

Tên trường	Kiểu dữ liệu	Ràng buộc	Ý nghĩa
company_id	bigint	PK	Định danh duy nhất cho doanh nghiệp.
name	varchar(255)	NOT NULL	Tên công ty/doanh nghiệp.
description	text	NULL	Mô tả chi tiết về doanh nghiệp.
company_size_min	integer	NULL	Quy mô nhân sự tối thiểu.
company_size_max	integer	NULL	Quy mô nhân sự tối đa.
country	varchar(100)	NULL	Quốc gia đặt trụ sở.
city	varchar(100)	NULL	Thành phố đặt văn phòng.
address	text	NULL	Địa chỉ chi tiết.
url	varchar(500)	NULL	Liên kết trang web chính thức.
industry	varchar(255)	NULL	Lĩnh vực hoạt động chính.

7. Bảng jobs (Thông tin việc làm đăng tuyển)

Lưu thông tin chi tiết các bản tin tuyển dụng việc làm thu thập được.

Bảng 3.12: Cấu trúc bảng jobs.

Tên trường	Kiểu dữ liệu	Ràng buộc	Ý nghĩa
job_id	bigint	PK, SERIAL	Định danh tin tuyển dụng.
company_id	bigint	FK -> companies(company_id) ON DELETE SET NULL	ID công ty đăng tuyển.
title	varchar(500)	NOT NULL	Tiêu đề công việc đăng tuyển.
skills_desc	text	NULL	Phần mô tả yêu cầu kỹ năng.
description	text	NULL	Mô tả chi tiết nhiệm vụ công việc.
formatted_experience_level	varchar(100)	NULL, INDEX	Cấp bậc kinh nghiệm yêu cầu.
work_type	varchar(100)	NULL	Hình thức làm việc (Full-time/Part-time).
location	varchar(255)	NULL	Địa điểm làm việc.
is_remote	boolean	DEFAULT false	Cho phép làm việc từ xa (Remote).
listed_time	timestamp with time zone	NULL	Ngày đăng tin tuyển dụng.
expiry_time	timestamp with time zone	NULL	Hạn nộp hồ sơ.

Tên trường	Kiểu dữ liệu	Ràng buộc	Ý nghĩa
job_posting_url	text	NULL	Liên kết nguồn của tin tuyển dụng.
scraped_at	timestamp	DEFAULT CURRENT_TIMESTAMP	Thời điểm thu thập dữ liệu.
applies	integer	DEFAULT 0	Số lượt nộp hồ sơ ghi nhận.
views	integer	DEFAULT 0	Số lượt xem tin tuyển dụng.
fingerprint	varchar(32)	UNIQUE	Mã MD5 hash nhận diện chống trùng lặp.
job_category	varchar(100)	NULL	Phân mục nghề nghiệp tổng quan.
search_group	varchar(100)	NULL	Nhóm ngành công việc tiêu chuẩn liên kết.
source_name	varchar(50)	NULL	Nguồn thu thập (LinkedIn, Vietnamworks...).
source_id	varchar(255)	NULL	ID tin gốc trên nguồn thu thập.

8. Bảng job_skills (Yêu cầu kỹ năng chi tiết của việc làm)

Cầu nối liên kết các yêu cầu kỹ năng chuẩn hóa thuộc một tin tuyển dụng cụ thể.

Bảng 3.13: Cấu trúc bảng `job_skills`.

Tên trường	Kiểu dữ liệu	Ràng buộc	Ý nghĩa
<code>job_id</code>	<code>bigint</code>	PK, FK -> <code>jobs(job_id)</code> ON DELETE CASCADE	ID tin tuyển dụng yêu cầu.
<code>skill_id</code>	<code>integer</code>	PK, FK -> <code>skills(skill_id)</code> ON DELETE CASCADE	ID kỹ năng chuẩn hóa.
<code>is_inferred</code>	<code>boolean</code>	DEFAULT false	Kỹ năng được suy diễn gián tiếp.
<code>reason</code>	<code>varchar(50)</code>	NULL	Lý do liên kết (match tên, LLM trích xuất).
<code>model_name</code>	<code>varchar(100)</code>	NULL	Tên mô hình AI dùng để liên kết.
<code>similarity_score</code>	<code>numeric(4,3)</code>	NULL	Điểm tương đồng ngữ nghĩa khi đối sánh.
<code>lib_version</code>	<code>varchar(20)</code>	NULL	Phiên bản thư viện sử dụng.
<code>raw_skill_name</code>	<code>varchar(255)</code>	NULL	Tên kỹ năng thô trong văn bản job.

9. Bảng `cv_job_matches` (Kết quả so khớp và phân tích khoảng cách năng lực)

Lưu trữ kết quả tính toán độ tương thích giữa CV của sinh viên với một vị trí công việc cụ thể hoặc một nhóm ngành nghề.

Bảng 3.14: Cấu trúc bảng cv_job_matches.

Tên trường	Kiểu dữ liệu	Ràng buộc	Ý nghĩa
match_id	uuid	PK, DEFAULT gen_random_uuid()	Định danh duy nhất của kết quả khớp.
cv_id	uuid	FK -> user_cvs(cv_id) ON DELETE CASCADE	ID CV tham gia so khớp.
job_id	bigint	FK -> jobs(job_id) ON DELETE SET NULL, NULL	ID Job cụ thể tham gia so khớp (nếu có).
match_type	varchar(50)	CHECK (match_type IN (‘search_group’, ‘existing_job’, ‘url_job’))	Phân loại kiểu so khớp.
search_group	varchar(100)	NULL	Tên nhóm ngành chuẩn hóa được so khớp.
match_score	numeric(5,2)	CHECK (match_score ≥ 0 AND match_score ≤ 100)	Điểm số phần trăm tương thích tổng thể.

Tên trường	Kiểu dữ liệu	Ràng buộc	Ý nghĩa
radar_data	jsonb	NOT NULL	Cấu trúc JSON biểu diễn phân bố kỹ năng (vẽ biểu đồ Radar).
gap_report	jsonb	NOT NULL	Chi tiết báo cáo khoảng cách kỹ năng.
model_version	varchar(100)	NULL	Phiên bản thuật toán đối sánh.
created_at	timestamp	DEFAULT CURRENT_TIMESTAMP	Thời điểm tính toán.
updated_at	timestamp	DEFAULT CURRENT_TIMESTAMP	Thời điểm cập nhật kết quả.

10. Bảng job_group_skill_weights (Trọng số kỹ năng theo nhóm ngành)

Bảng lưu trữ trọng số tầm quan trọng w_i của từng kỹ năng thuộc một nhóm ngành công việc tiêu chuẩn, được tính toán bằng thuật toán TF-IDF trên tập dữ liệu việc làm.

Bảng 3.15: Cấu trúc bảng job_group_skill_weights.

Tên trường	Kiểu dữ liệu	Ràng buộc	Ý nghĩa
search_group	varchar(100)	PK	Tên nhóm ngành công việc tiêu chuẩn.

Tên trường	Kiểu dữ liệu	Ràng buộc	Ý nghĩa
skill_id	integer	PK, FK -> skills(skill_id) ON DELETE CASCADE	ID kỹ năng chuẩn hóa trong nhóm.
weight_wi	numeric(8,4)	NOT NULL	Trọng số đặc trưng w_i của kỹ năng trong nhóm.

3.4 Thiết kế giao diện

3.4.1 Trang chủ và Dashboard thống kê thị trường việc làm

Hệ thống CareerNova được thiết kế với hai điểm vào chính cho người dùng: trang chủ (Landing Page) dành cho khách chưa xác thực và trang Dashboard thị trường dành cho người dùng đã đăng nhập.

Trang chủ (Landing Page) là giao diện đầu tiên người dùng tiếp cận khi truy cập hệ thống. Phần đầu trang (hero section) trình bày thông điệp giá trị cốt lõi của nền tảng cùng hai nút hành động chính: "*Bắt đầu miễn phí*" (dẫn đến trang đăng ký) và "*Xem Thông tin Thị trường*" (dẫn đến Dashboard). Tiếp theo, bốn tính năng chủ đạo được trình bày dưới dạng lưới (so khớp CV, đề xuất việc làm, phân tích kỹ năng, dashboard thị trường) kèm luồng sử dụng bốn bước trực quan để định hướng người dùng mới.

Hình 3.6: Giao diện trang chủ (Landing Page) của hệ thống CareerNova.

Dashboard thống kê thị trường (route /dashboard) là trang phân tích thị trường trung tâm, được tổ chức theo cấu trúc thông tin từ tổng

quan đến chi tiết. Phần trên cùng hiển thị thanh lọc ba chiều (địa điểm, khoảng thời gian, loại công việc) và bốn thẻ thống kê tóm tắt: số tin tuyển dụng đang mở, mức lương IT trung bình (min/max/avg), số công ty đang tuyển và tỷ lệ tăng trưởng thị trường. Khu vực biểu đồ chính bao gồm ba thành phần bố trí theo hai hàng:

- **AreaChart "Xu hướng tin tuyển dụng"** (chiếm 2/3 chiều rộng): biểu diễn tổng số tin tuyển dụng (đường xanh dương) và số vị trí làm việc từ xa (đường xanh lá) theo thời gian, với trục X là nhãn ngày/tháng và trục Y là số lượng tin.
- **PieChart "Phân bổ thị trường"** (1/3 chiều rộng): biểu đồ tròn thể hiện tỷ trọng công việc phân theo ngành, kèm chú thích màu sắc cho từng danh mục.
- **BarChart "Mức Lương theo Vị Trí"** (toàn bộ chiều rộng): biểu đồ cột đôi song song hiển thị mức lương tối thiểu (cột xanh nhạt) và tối đa (cột xanh đậm) cho từng chức danh công việc, đơn vị nghìn USD/năm.

Phía dưới các biểu đồ, danh sách *Hot Jobs* (top công việc được lưu nhiều nhất trong 7 ngày) và hai lưới kỹ năng (*Top 10 Skills* và *Rising Skills*) cung cấp thông tin thị trường chi tiết theo từng vị trí. Luồng tương tác tổng thể của người dùng với Dashboard được mô tả trong Hình 3.7.

Hình 3.7: Sơ đồ hoạt động mô tả luồng tương tác người dùng với Dashboard thị trường.

Hình 3.8: Giao diện Dashboard thống kê thị trường việc làm IT, thể hiện AreaChart xu hướng tuyển dụng, PieChart phân bổ ngành và BarChart dải lương.

3.4.2 Trang quản lý CV và kết quả so khớp năng lực

Luồng phân tích năng lực của người dùng trong hệ thống CareerNova được chia thành hai trang kế tiếp nhau: trang CV Matching (tải lên và so khớp) và trang Skill Gap Analysis (phân tích khoảng cách kỹ năng chi tiết).

Trang CV Matching (route /cv-matching) được bố cục theo dạng hai cột. Cột trái hiển thị CV hiện đang được chọn làm mặc định (được đánh dấu bằng viền màu xanh và badge "*Active CV*") cùng danh sách dropdown để chuyển đổi giữa các CV đã tải lên. Cột phải là vùng tải lên CV mới với giao diện kéo-thả (drag-and-drop), chấp nhận định dạng PDF, JPG và PNG với giới hạn kích thước 5MB, kèm phản hồi trực quan tức thì (spinner trong khi tải, dấu tích khi thành công, thông báo lỗi khi không hợp lệ). Phía dưới hai cột là bộ chọn nguồn so khớp (nhóm tin tuyển dụng hoặc URL cụ thể) và nút "*Phân tích & So khớp*".

Sau khi hệ thống hoàn tất xử lý, kết quả được hiển thị ngay trên cùng trang với ba thành phần: vòng tròn điểm Match Score được tô màu theo ngưỡng (xanh lá $\geq 80\%$, xanh dương $\geq 65\%$, vàng $< 65\%$); ba thẻ kỹ năng có thể mở rộng phân loại theo màu sắc tương phản (Matched — xanh lá, Partial — vàng, Missing — đỏ); và biểu đồ Radar nhỏ so sánh trực tiếp kỹ năng CV với yêu cầu JD.

Hình 3.9: Giao diện trang CV Matching: cột trái quản lý CV, cột phải vùng tải lên, kết quả so khớp với Match Score và phân loại kỹ năng.

Trang Skill Gap Analysis (route /skill-gap) là giao diện phân tích năng lực chuyên sâu, được tổ chức theo bốn tầng từ tổng quan đến chi tiết. Tầng đầu tiên là hai thẻ tóm tắt: "*Mức độ phù hợp với thị trường*" (phần trăm tổng thể) và "*Khoảng trống nghiêm trọng*" (số kỹ năng ưu tiên cần bổ sung). Tầng thứ hai trình bày biểu đồ Radar "*Chi tiết kỹ năng*" với hai vùng tô chồng nhau: vùng xanh dương thể hiện điểm kỹ năng thực tế của người dùng (`user_score`) và vùng xanh lá mờ thể hiện ngưỡng yêu

cầu thị trường (`market_score`); tooltip tương tác hiển thị giá trị phần trăm của từng kỹ năng khi di chuột. Tầng thứ ba là Gap Report theo danh mục kỹ năng, mỗi danh mục được trình bày với biểu tượng emoji đặc trưng, badge điểm khoảng cách và thanh tiến độ đôi so sánh `user_rate` với `market_rate`. Khi mở rộng từng danh mục, từng kỹ năng con hiển thị badge trạng thái ba màu (Matched/Partial/Missing) cùng điểm số chi tiết. Tầng thứ tư là phần Learning Paths, gợi ý các khóa học và lộ trình học tập có thể mở rộng để xem từng bước chi tiết.

Luồng tương tác đầy đủ của người dùng từ bước tải CV đến xem kết quả phân tích được mô tả trong Hình 3.10.

Hình 3.10: Sơ đồ hoạt động mô tả luồng tương tác từ tải lên CV đến xem kết quả Skill Gap Analysis.


Hình 3.11: Giao diện trang Skill Gap Analysis: biểu đồ Radar so khớp kỹ năng và Gap Report phân loại kỹ năng theo danh mục.

3.5 Thiết kế thuật toán phân tích khoảng cách năng lực

Thuật toán phân tích khoảng cách năng lực (Gap Analysis Algorithm) là nhân tố cốt lõi giúp sinh viên nhận thức được vị trí năng lực hiện tại của bản thân so với yêu cầu thị trường lao động. Hệ thống thực hiện việc này thông qua việc so khớp các kỹ năng trích xuất từ CV của người dùng với bộ kỹ năng định hình cho từng vị trí công việc hoặc nhóm ngành.

3.5.1 Luồng xử lý từ lúc người dùng upload CV đến khi nhận kết quả so khớp

Quy trình xử lý của hệ thống từ khi sinh viên tải tệp CV lên cho đến khi nhận được kết quả phân tích khoảng cách năng lực được mô tả theo các bước dưới đây.



Hình 3.12: Sơ đồ luồng xử lý từ khi người dùng tải CV lên đến khi nhận kết quả so khớp.

Bước 1 — Trích xuất văn bản từ CV (Text Extraction): Hệ thống hỗ trợ tải lên CV dạng PDF hoặc hình ảnh (.png, .jpg, .jpeg). Thư viện `pdfplumber` được sử dụng để trích xuất trực tiếp lớp chữ nếu tệp PDF có định dạng số văn bản (Digital PDF). Nếu tệp PDF là dạng scan ảnh hoặc người dùng upload tệp ảnh trực tiếp, hệ thống kích hoạt luồng OCR dự phòng sử dụng thư viện `pdf2image` để chuyển trang PDF sang ảnh, sau đó kết hợp `pytesseract` (Tesseract OCR) để đọc chữ từ ảnh.

Bước 2 — Tối ưu hóa bằng cơ chế Cache: Sau khi trích xuất văn bản thô, hệ thống thực hiện chuẩn hóa khoảng trắng của văn bản và truy vấn so khớp trên bảng `public.user_cvs` của người dùng. Nếu tìm thấy bản ghi có nội dung văn bản trùng khớp hoàn toàn (Cache Hit), hệ thống bỏ qua việc gọi API Gemini và bước chuẩn hóa kỹ năng, thay vào đó nạp trực tiếp dữ liệu kỹ năng từ bảng cầu nối `public.user_cv_skills`, giúp tăng tốc độ phản hồi và tiết kiệm tài nguyên API.

Bước 3 — Trích xuất kỹ năng bằng Generative AI (Skill Extraction): Trong trường hợp Cache Miss, hệ thống sử dụng mô hình ngôn ngữ lớn Gemini thông qua API để trích xuất các kỹ năng xuất hiện trên CV. Prompt gửi đi yêu cầu mô hình trả về cấu trúc dữ liệu JSON chứa: tên kỹ năng, dẫn chứng ngữ cảnh xuất hiện (evidence) và mức độ tin cậy (confidence score ≥ 0.85).

Cơ chế chống ảo giác (Anti-Hallucination Validation): Do LLM đôi khi sinh ra các kỹ năng không có thực trong CV, hệ thống thực hiện kiểm tra chéo: mọi kỹ năng trích xuất phải có tên hoặc dẫn chứng xuất hiện trực tiếp dưới dạng chuỗi con (substring) trong văn bản CV gốc. Nếu không thỏa mãn, kỹ năng đó sẽ bị hủy bỏ.

Luồng xử lý dự phòng (Fallback): Nếu kết nối LLM gặp sự cố hoặc cạn kiệt hạn ngạch (quota limit), hệ thống tự động kích hoạt bộ đối sánh từ khóa thô (Keyword Match Fallback) trực tiếp với toàn bộ từ điển trong bảng `public.skills` bằng các biểu thức chính quy (Regex) thiết lập ranh giới từ để trích xuất kỹ năng tạm thời.

Bước 4 — Chuẩn hóa kỹ năng sang từ điển hệ thống (Skill

Normalization): Các kỹ năng thô sau trích xuất được đưa qua quy trình chuẩn hóa Lightcast Taxonomy kết hợp mô hình embedding ngữ nghĩa all-MiniLM-L6-v2. Quy trình gồm 4 tầng xử lý:

- **Tầng 0 (Dọn dẹp phổ quát):** Loại bỏ ký tự đặc biệt, chuẩn hóa chữ thường, xử lý viết tắt (ví dụ: `css3` thành `CSS`, chuẩn hóa `framework .js`).
- **Tầng 1 (Khớp chính xác):** So khớp trực tiếp chuỗi ký tự với từ điển canonical và tên rút gọn của bảng `public.skills`.
- **Tầng 2 (Tìm kiếm ngữ nghĩa ngữ cảnh):** Chuyển đổi tên kỹ năng và thông tin bổ trợ thành vector embedding ngữ cảnh. Sử dụng công cụ FAISS để tìm kiếm Top 5 ứng viên kỹ năng có độ tương đồng cosine cao nhất từ bộ nhớ đệm cache (`skills_embedding.pkl`).
- **Tầng 3 (Xử lý lai & Phân loại):** Tính điểm lai kết hợp 85% Cosine Similarity và 15% sparse Jaccard n-gram (độ tương đồng ký tự) để hạn chế sai lệch từ vựng. Điểm số được áp dụng phạt nếu loại kỹ năng (Hard Skill vs Common Skill) không trùng khớp, sau đó đối sánh với ngưỡng động (Dynamic Threshold) phù hợp với loại từ (từ viết tắt cần độ khớp ≥ 0.80 , kỹ năng chuyên môn cần ≥ 0.70).

Các kỹ năng được chuẩn hóa thành công sẽ được gán với `skill_id` tương ứng trong cơ sở dữ liệu và lưu trữ vào bảng cầu nối `public.user_cv_skills`.

Bước 5 — Tính toán so khớp năng lực (Matching Engine): Chương trình nạp bộ kỹ năng yêu cầu và trọng số tương ứng từ bảng `public.job_group_skill_weights` cho Job/Nhóm ngành mục tiêu, sau đó tính toán độ tương đồng giữa các kỹ năng CV của sinh viên với các kỹ năng của Job, phân loại khoảng cách và tính toán chỉ số tương thích tổng thể (Match Score).

Bước 6 — Lưu trữ và kết xuất kết quả: Kết quả phân tích phân nhóm kỹ năng, điểm tương thích cùng các báo cáo thiếu hụt được lưu trữ

vào bảng `public.cv_job_matches` dưới dạng JSONB để phục vụ vẽ biểu đồ Radar trên giao diện người dùng.

3.5.2 Thuật toán so sánh tập kỹ năng trong CV với yêu cầu của Job để tính tỷ lệ tương thích

Để đánh giá mức độ tương thích giữa hồ sơ năng lực của ứng viên (tập kỹ năng đã chuẩn hóa từ CV) với yêu cầu tuyển dụng (tập kỹ năng đặc trưng kèm trọng số của Job), hệ thống triển khai thuật toán tính toán độ tương đồng ngữ nghĩa có trọng số (Weighted Semantic Similarity) dựa trên không gian vector embedding.

Các định nghĩa toán học

- Gọi $\mathcal{J} = \{j_1, j_2, \dots, j_M\}$ là tập hợp gồm M kỹ năng yêu cầu của vị trí công việc.
- Gọi $\mathcal{W} = \{w_1, w_2, \dots, w_M\}$ là tập các trọng số tương ứng của các kỹ năng trong $\mathcal{J}$ đối với công việc đó ($w_i > 0$), lấy từ bảng `public.job_group_skills`. Trọng số này phản ánh mức độ quan trọng của kỹ năng đối với vị trí nghề nghiệp.
- Gọi $\mathcal{C} = \{c_1, c_2, \dots, c_K\}$ là tập hợp gồm K kỹ năng được trích xuất và chuẩn hóa thành công từ CV của sinh viên.
- Với mỗi kỹ năng trong cơ sở dữ liệu, vector embedding phân tán 384 chiều được sinh ra bởi mô hình `all-MiniLM-L6-v2`: $\mathbf{e}_{j_i}$ đại diện cho biểu diễn ngữ nghĩa của kỹ năng j_i .

Công thức tính toán chi tiết

Bước 1 — Tính độ tương thích ngữ nghĩa lớn nhất cho từng kỹ năng yêu cầu:

Đối với mỗi kỹ năng yêu cầu j_i , hệ thống duyệt qua toàn bộ tập kỹ năng có sẵn của sinh viên $\mathcal{C}$ để tìm độ tương đồng Cosine lớn nhất:

$$\text{sim}_i = \max_{c_k \in \mathcal{C}} \text{cosine}(\mathbf{e}_{j_i}, \mathbf{e}_{c_k}) \quad (3.1)$$

Vì các vector embedding trong cache đã được chuẩn hóa L2 ($\|\mathbf{e}\|_2 = 1$), độ tương đồng Cosine được tính nhanh bằng tích vô hướng giữa hai vector:

$$\text{sim}_i = \max_{c_k \in \mathcal{C}} (\hat{\mathbf{e}}_{j_i} \cdot \hat{\mathbf{e}}_{c_k}) \quad (3.2)$$

Giá trị sim_i nằm trong khoảng $[0, 1]$ (mọi giá trị âm đều được quy về 0).

Bước 2 — Tính đóng góp thực tế và khoảng cách thiếu hụt:

Đóng góp (Contribution) của kỹ năng thứ i vào tổng điểm năng lực của ứng viên:

$$\text{contrib}_i = w_i \times \text{sim}_i \quad (3.3)$$

Khoảng cách thiếu hụt (Gap) của kỹ năng thứ i :

$$\text{gap}_i = w_i \times (1 - \text{sim}_i) \quad (3.4)$$

Bước 3 — Tính điểm số tương thích tổng hợp (Match Score):

Điểm số tương thích tổng thể là tổng đóng góp của tất cả các kỹ năng yêu cầu, được chuẩn hóa chia cho tổng trọng số:

$$\text{MatchScore} = \frac{\sum_{i=1}^M w_i \times \text{sim}_i}{\sum_{i=1}^M w_i} \quad (3.5)$$


Bước 4 — Chuyển đổi thành tỷ lệ phần trăm (Match Percent):

Tỷ lệ tương thích hiển thị trên giao diện người dùng được tính bằng:

$$\text{MatchPercent} = \text{MatchScore} \times 100\% \quad (3.6)$$

Cơ chế phân loại kỹ năng phục vụ báo cáo khoảng cách (Gap Report)

Hệ thống sử dụng các ngưỡng điểm tương đồng ngữ nghĩa lớn nhất (sim_i) để phân loại từng kỹ năng yêu cầu j_i vào ba nhóm hiển thị trên giao diện người dùng:



Hình 3.13: Quy tắc phân loại kỹ năng phục vụ báo cáo khoảng cách năng lực.

1. Kỹ năng đã có (Possessed/Matched Skills):

- *Điều kiện:* $\text{sim}_i \geq 0.75$

- *Ý nghĩa:* Ứng viên đã sở hữu kỹ năng này trực tiếp hoặc thông qua một kỹ năng tương đương rất gần về ngữ nghĩa (ví dụ: yêu cầu “Scrum” và CV có “Agile/Scrum”).
- *Thông tin đi kèm:* Ghi nhận tên kỹ năng đối sánh gián tiếp (`matched_via`) nếu không trùng ID trực tiếp.

2. Kỹ năng cần bổ sung thêm (Partially Matched Skills):

- *Điều kiện:* $0.40 \leq \text{sim}_i < 0.75$
- *Ý nghĩa:* Ứng viên có kỹ năng liên quan nhưng chưa hoàn toàn đáp ứng đúng ngữ cảnh yêu cầu của Job (ví dụ: yêu cầu “Consulting” nhưng CV mới có “Project Design”). Đây là các mục tiêu đào tạo ngắn hạn, ứng viên có thể tự cải thiện nhanh.

3. Kỹ năng thiếu hoàn toàn (Missing Skills):

- *Điều kiện:* $\text{sim}_i < 0.40$
- *Ý nghĩa:* Ứng viên thiếu hụt hoàn toàn kiến thức này. Đây là lỗ hổng năng lực lớn nhất, đòi hỏi lộ trình học tập dài hạn hơn để bù đắp nếu muốn ứng tuyển vào vị trí công việc tương ứng.

Chương 4

Xây dựng hệ thống

4.1 Lựa chọn công nghệ

Việc lựa chọn công nghệ cho hệ thống CareerNova tuân theo nguyên tắc phân tách trách nhiệm rõ ràng giữa ba thành phần triển khai độc lập — ứng dụng Frontend, dịch vụ Backend API và Pipeline ETL — đồng thời ưu tiên các nền tảng có hệ sinh thái trưởng thành, hỗ trợ kiểu dữ liệu tường minh (TypeScript/Python type hints) và thuận tiện cho việc đóng gói thành container Docker. Toàn bộ ngăn xếp công nghệ được mô tả trong các tiểu mục dưới đây tương ứng với mã nguồn thực tế của hệ thống.

4.1.1 Công nghệ Frontend

Để phát triển giao diện người dùng có tính tương tác cao và phản hồi nhanh, các công nghệ sau đã được lựa chọn:

- **Next.js 15 và React 19:** Khung phát triển ứng dụng web hiện đại trên nền React, sử dụng kiến trúc App Router. Next.js cho phép kết hợp linh hoạt giữa kết xuất phía máy chủ (Server-Side Rendering) cho các trang công khai và kết xuất phía trình duyệt (Client-Side Rendering) cho các trang dashboard tương tác, giúp tối ưu thời gian tải trang và trải nghiệm người dùng.

- **TypeScript:** Ngôn ngữ mở rộng của JavaScript bổ sung cơ chế kiểm soát kiểu dữ liệu tĩnh (static typing), giúp phát hiện lỗi sớm trong quá trình biên dịch và tăng độ tin cậy của mã nguồn khi hệ thống mở rộng.
- **Tailwind CSS và shadcn/ui:** Khung CSS tiện ích (utility-first) kết hợp bộ thành phần giao diện (component library) giúp xây dựng giao diện nhanh chóng, đảm bảo tính nhất quán của hệ thống thiết kế (Design System), hỗ trợ chế độ sáng/tối và thiết kế đáp ứng (Responsive).
- **Recharts:** Thư viện trực quan hóa dữ liệu dựa trên SVG được tối ưu riêng cho React, dùng để vẽ các biểu đồ xu hướng tuyến dụng (AreaChart), phân bổ ngành (PieChart), dải lương (BarChart) và biểu đồ Radar so khớp kỹ năng (RadarChart).

4.1.2 Công nghệ Backend và Cơ sở dữ liệu

- **NestJS (Node.js 20):** Khung phát triển Backend dựa trên TypeScript, tổ chức theo kiến trúc module hóa (auth, profile, job, matching, skill-gap, market-dashboard, v.v.). NestJS đóng vai trò cổng dịch vụ chính, điều phối toàn bộ luồng yêu cầu từ Frontend, xử lý xác thực, phân quyền và tổng hợp dữ liệu.
- **Prisma ORM:** Bộ ánh xạ quan hệ - đối tượng (ORM) thế hệ mới cho Node.js, cung cấp truy vấn an toàn kiểu (type-safe) tới PostgreSQL, đồng thời quản lý lược đồ và migration cơ sở dữ liệu một cách tường minh.
- **PostgreSQL 17:** Cơ sở dữ liệu quan hệ mạnh mẽ, lưu trữ toàn bộ dữ liệu hệ thống bao gồm tài khoản người dùng, hồ sơ CV, kho dữ liệu tuyển dụng, từ điển kỹ năng và kết quả so khớp. Hệ thống tận dụng kiểu dữ liệu JSONB của PostgreSQL để lưu trước (precompute)

các cấu trúc `radar_data` và `gap_report`, tối ưu hóa hiệu năng truy vấn thời gian thực.

- **FastAPI (Python):** Khung phát triển web bất đồng bộ hiệu năng cao trên nền ASGI, được sử dụng để xây dựng dịch vụ ETL Matching Service. Dịch vụ này tiếp nhận yêu cầu so khớp từ NestJS Backend qua giao thức HTTP và thực thi toàn bộ luồng xử lý AI nặng (trích xuất, chuẩn hóa, tính điểm).

4.1.3 Công nghệ Thu thập và Xử lý AI

Phân hệ thu thập và xử lý trí tuệ nhân tạo (AI) được thiết kế nhằm giải quyết bài toán bóc tách thông tin phi cấu trúc từ các trang tuyển dụng và hồ sơ ứng viên (CV), sau đó quy chuẩn chúng về không gian vector ngữ nghĩa. Các cấu hình tham số và công nghệ cốt lõi được lựa chọn bao gồm:

- **Requests, cloudscraper và Selenium (Cơ chế thu thập dữ liệu hai tầng):**
 - *Tầng 1 (Cào tĩnh):* Hệ thống sử dụng thư viện `requests` kết hợp `cloudscraper` để giả lập các phiên kết nối HTTP ở mức socket, giúp vượt qua các thử thách chống bot cơ bản (như Cloudflare Challenge) với tốc độ xử lý tối đa và tiêu tốn ít tài nguyên.
 - *Tầng 2 (Trình duyệt tự động):* Khi gặp các trang web chặn IP hoặc kết xuất hoàn toàn bằng JavaScript ở phía client, hệ thống tự động kích hoạt trình duyệt ẩn danh `Selenium` (Headless Chrome) để mô phỏng hành vi cuộn trang và tải dữ liệu động.
- **Google Gemini API (Mô hình ngôn ngữ lớn làm bộ bóc tách cấu trúc):** Sử dụng mô hình `gemini-2.5-flash` hoặc `gemini-2.0-flash` thông qua tính năng *Structured Outputs*. Để đảm bảo tính ổn định

tối đa của dữ liệu trích xuất và triệt tiêu hoàn toàn hiện tượng ảo giác (hallucination) dữ liệu, hệ thống thiết lập tham số nhiệt độ phát sinh bằng không (temperature = 0.0). Bằng cách định nghĩa trước một JSON Schema chặt chẽ trên API, hệ thống ép buộc mô hình trả về dữ liệu định dạng JSON chuẩn xác 100%, loại bỏ hoàn toàn các văn bản thừa hay định dạng sai.

- **Sentence-Transformers (all-MiniLM-L6-v2):** Mô hình sinh vector nhúng (embedding generator) nhận đầu vào là các nhãn kỹ năng và mã hóa chúng thành các vector phân tán 384 chiều biểu diễn ngữ nghĩa trong không gian Hilbert thực. Các vector đầu ra đều được chuẩn hóa độ dài L2 ($\|\mathbf{e}\|_2 = 1$), cho phép tối ưu hóa hiệu năng tính toán độ đo tương đồng Cosine thành phép tính tích vô hướng trực tiếp giữa hai vector nhúng.
- **FAISS (Facebook AI Similarity Search):** Thư viện tối ưu hóa tìm kiếm vector lân cận gần nhất (Nearest Neighbors). FAISS lập chỉ mục cho hơn 30.000 kỹ năng công nghệ chuẩn hóa từ hệ thống Lightcast/O*NET. Hệ thống sử dụng cấu trúc chỉ mục tích vô hướng phẳng (IndexFlatIP) kết hợp với việc chuẩn hóa L2 trước đó để tính toán tích vô hướng chính xác tuyệt đối, giúp tìm kiếm và ánh xạ nhanh kỹ năng từ CV/JD vào từ điển chuẩn hóa với độ trễ dưới 5 mili-giây.
- **Bộ ba pdfplumber, pdf2image và pytesseract (Xử lý CV đa định dạng):**
 - Ưu tiên sử dụng pdfplumber để đọc trực tiếp lớp văn bản số (text layer) của tệp tin PDF gốc.
 - Đối với CV dạng ảnh chụp hoặc PDF quét (scan), hệ thống tự động chuyển đổi trang tài liệu sang ảnh độ phân giải cao bằng pdf2image và chạy OCR bằng công cụ nguồn mở pytesseract (Tesseract OCR).

4.1.4 Hạ tầng và công cụ triển khai


- **Docker và Docker Compose:** Mỗi thành phần (Frontend, Backend API, ETL Pipeline, PostgreSQL) được đóng gói độc lập thành container. Tập `docker-compose.yml` điều phối toàn bộ dịch vụ, trong đó container PostgreSQL lưu dữ liệu bền vững qua Docker named volume và được cấu hình `restart: unless-stopped`. Các image ứng dụng dựa trên Node 20-Alpine, chạy dưới tài khoản non-root nhằm tuân thủ nguyên tắc đặc quyền tối thiểu.

4.2 Xây dựng pipeline tổ chức dữ liệu

Pipeline dữ liệu (ETL Pipeline) hoạt động theo cơ chế xử lý theo lô (batch processing) định kỳ hàng ngày để thu thập và xử lý tin tuyển dụng trên thị trường.

4.2.1 Cài đặt các module thu thập dữ liệu tin tuyển dụng tự động

Quy trình thu thập được thực thi song song trên bốn nền tảng tuyển dụng lớn tại Việt Nam bao gồm: ITViec, LinkedIn, VietnamWorks và CareerViet.



Hình 4.1: Sơ đồ hoạt động của pipeline thu thập (Crawl)

A. Các chiến lược thu thập tối ưu hóa:

1. **Date Cutoff (Bộ lọc thời gian thực):** Hệ thống tính toán mốc thời gian giới hạn $t_{\text{cutoff}} = t_{\text{current}} - 3$ ngày. Ngay từ pha duyệt danh sách (List Phase), các tin đăng cũ hơn mốc này sẽ bị bỏ qua lập tức, giúp tiết kiệm 80% băng thông mạng.
2. **Keyword Rotation (Xoay vòng từ khóa):** Hệ thống quản lý danh sách 199 từ khóa IT cốt lõi. Mỗi chu kỳ chạy hàng ngày tự động bốc ra 4 từ khóa tiếp theo nhằm đảm bảo độ phủ rộng toàn ngành công nghệ thông tin sau một chu kỳ chạy, đồng thời tránh việc gửi quá nhiều yêu cầu trùng lặp lên máy chủ nguồn.
3. **Bypass React Server Components (RSC) Payload (VietnamWorks):** Để cào nội dung mô tả của VietnamWorks (kết xuất động phía client), hệ thống không dùng Selenium mà bắt trực tiếp luồng RSC payload truyền tải từ máy chủ. Luồng dữ liệu dạng này sau đó được giải mã bằng biểu thức chính quy để trích xuất văn bản mô tả gốc, giúp cải thiện tốc độ thu thập gấp 10 lần và tiết kiệm tài nguyên CPU.

B. Phân rã logic cấu trúc phân hệ thu thập:

- **Đầu vào dữ liệu thô:** Các yêu cầu HTTP GET gửi đến các sản phẩm tuyển dụng theo danh sách từ khóa xoay vòng hàng ngày.
- **Điều kiện lọc / Làm sạch:**
 - Mốc thời gian đăng tin: $t_{\text{post}} \geq t_{\text{cutoff}}$.
 - Đối chiếu URL và mã định danh bài tuyển dụng (`source_id`) với cơ sở dữ liệu PostgreSQL. Nếu trùng lặp, bỏ qua hoàn toàn yêu cầu tải trang chi tiết (Early Deduplication).
- **Cấu trúc đầu ra:** Tập tin JSON lưu trữ tạm thời chứa dữ liệu thô được cấu trúc như sau:


```

{
  "source_id": "itviec-10293",
  "job_url": "https://itviec.com/.../software-engineer",
  "raw_html": "<html>...</html>",
  "captured_at": "2026-07-10T16:00:00Z"
}

```

4.2.2 Quy trình làm sạch dữ liệu, xử lý trùng lặp và lưu trữ vào PostgreSQL

Sau khi thu thập, dữ liệu thô được đưa vào quy trình xử lý làm sạch, khử trùng lặp và lưu trữ theo sơ đồ luồng dữ liệu sau:



Hình 4.2: Quy trình làm sạch dữ liệu, khử trùng lặp và lưu trữ (Transform & Load)

Phân rã logic cấu trúc phân hệ xử lý:

- **Đầu vào dữ liệu thô:** Tập tin JSON chứa nội dung HTML thô từ phân hệ thu thập.
- **Điều kiện lọc / Làm sạch (Quality Gate & Deduplication):**
 - *Làm sạch văn bản:* Loại bỏ thẻ HTML/CSS, chuẩn hóa khoảng trắng thừa.
 - *Quality Gate (Cổng chất lượng):* Loại bỏ tin tuyển dụng có chiều dài < 100 ký tự hoặc < 20 từ, hoặc tỷ lệ ký tự chữ/số < 25% (chỉ dấu lỗi font/mã hóa), hoặc thiếu các trường bắt buộc (`job_title`, `job_url`).
 - *Khử trùng lặp nội bộ:* Tính Cosine Similarity giữa các tin mới tải về của cùng một công ty. Nếu $\text{Similarity} \geq 90\%$, loại bỏ tin trùng lặp trước khi gửi đến LLM để tiết kiệm chi phí.
 - *Kiểm định chống ảo giác:* Điểm tin cậy trích xuất kỹ năng từ LLM phải đạt $\text{confidence} \geq 0.85$, đồng thời chuỗi bằng chứng ngữ cảnh (**evidence**) phải trùng khớp tuyệt đối dạng chuỗi con (substring) trong văn bản gốc.
 - *So khớp mờ doanh nghiệp (Fuzzy Company Matching):* Loại bỏ các hậu tố pháp lý (ví dụ: “Công ty cổ phần”, “Trách nhiệm hữu hạn”, “JSC”) và thực hiện so khớp Jaccard Similarity trên tập hợp từ của tên công ty.
 - *Khử trùng lặp sâu tin tuyển dụng:* Tính toán tần suất từ - nghịch đảo tần suất văn bản (TF-IDF) trên tập hợp các bài đăng của cùng một công ty trong vòng 30 ngày. Nếu độ tương đồng Cosine của hai vector trọng số TF-IDF vượt ngưỡng 80%, tin mới sẽ bị loại bỏ và hệ thống chỉ cập nhật thời điểm thu thập dữ liệu (`last_seen`) của bài đăng cũ.
- **Công thức toán học định lượng:**

- *Jaccard Similarity dùng để so khớp mờ tên công ty:*

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|} \quad (4.1)$$

(Trong đó A, B lần lượt là tập các từ đơn sau khi làm sạch của tên công ty A và B).

- *Trọng số TF-IDF của từ khóa t trong tin tuyển dụng d đối với tập hợp tin tuyển dụng D của cùng một công ty trong 30 ngày:*

$$\text{TF-IDF}(t, d, D) = \text{TF}(t, d) \times \text{IDF}(t, D) \quad (4.2)$$

Trong đó tần suất từ $\text{TF}(t, d)$ và nghịch đảo tần suất văn bản $\text{IDF}(t, D)$ được định nghĩa như sau:

$$\text{TF}(t, d) = \frac{f_{t,d}}{\sum_{t' \in d} f_{t',d}} \quad (4.3)$$

$$\text{IDF}(t, D) = \log \left(\frac{|D|}{1 + |\{d \in D : t \in d\}|} \right) \quad (4.4)$$

Với $f_{t,d}$ là số lần xuất hiện của từ t trong tin tuyển dụng d , và $|D|$ là tổng số tin tuyển dụng của công ty trong 30 ngày.

- *Độ tương đồng Cosine giữa hai vector trọng số TF-IDF $\mathbf{d}_1$ và $\mathbf{d}_2$:*

$$\text{Sim}_{\text{Cosine}}(\mathbf{d}_1, \mathbf{d}_2) = \frac{\mathbf{d}_1 \cdot \mathbf{d}_2}{\|\mathbf{d}_1\|_2 \|\mathbf{d}_2\|_2} \quad (4.5)$$

- **Cấu trúc đầu ra (DB Schema):** Dữ liệu được nạp vào cơ sở dữ liệu PostgreSQL theo cơ chế **Atomic Transactions** (cam kết theo lô 50 bản ghi, có thiết lập Savepoint riêng cho từng bản ghi để nếu một bản ghi lỗi thì các bản ghi còn lại trong lô vẫn ghi thành công). Dữ liệu được ghi vào 3 bảng chính:

- **companies:** ID công ty, tên công ty chuẩn hóa.

- **jobs**: ID tin tuyển dụng, ID công ty, tiêu đề, mức lương, kinh nghiệm yêu cầu, loại hình làm việc.
- **job_skills**: Liên kết khóa ngoại giữa **job_id** và **skill_id** chuẩn hóa.

4.3 Xây dựng chức năng cho các phân hệ người dùng

4.3.1 Hiện thực hóa các tính năng Quản lý tài khoản, Đăng ký/Đăng nhập (Auth)

Module **auth** của NestJS quản lý toàn bộ luồng xác thực và phân quyền, được xây dựng theo cơ chế JWT stateless kết hợp refresh token:

- **Băm mật khẩu**: Khi đăng ký, mật khẩu người dùng được băm bằng thuật toán **bcrypt** trước khi lưu vào trường **password_hash**; hệ thống không bao giờ lưu mật khẩu dạng plaintext.
- **Xác thực email**: Sau đăng ký, hệ thống sinh **verify_token** có thời hạn và gửi email kích hoạt; tài khoản chỉ chuyển sang trạng thái **is_active = true** sau khi người dùng xác nhận.
- **Cấp phát token**: Khi đăng nhập thành công, Backend cấp một *access token* thời hạn ngắn (chứa **user_id** và **role**) và một *refresh token* thời hạn dài. Access token hết hạn được làm mới qua refresh token nhằm giảm thiểu rủi ro rò rỉ.
- **Đăng nhập Google (SSO)**: Bên cạnh đăng nhập email/mật khẩu, hệ thống hỗ trợ đăng nhập một lần (Single Sign-On) qua Google OAuth; thông tin nhà cung cấp được lưu vào bảng **user_auth_providers**.

- **Bảo vệ API:** Các route yêu cầu xác thực được bảo vệ bằng Guard của NestJS; Frontend đính kèm token trong header `Authorization: Bearer <token>` hoặc qua HTTP-only Cookie.

4.4 Xây dựng thuật toán phân tích kỹ năng năng lực

Thuật toán phân tích kỹ năng năng lực đóng vai trò cốt lõi trong việc đánh giá mức độ tương thích giữa hồ sơ cá nhân của ứng viên (CV) và yêu cầu thực tế từ thị trường lao động (thông qua tin tuyển dụng hoặc nhóm công việc mục tiêu). Thuật toán được xây dựng trên nguyên tắc kết hợp giữa bóc tách ngữ cảnh bằng mô hình ngôn ngữ lớn (LLM) và so khớp khoảng cách ngữ nghĩa trong không gian vector nhúng.

4.4.1 Xây dựng cấu trúc Structured Output để trích xuất thông tin CV và JD

Để trích xuất kỹ năng từ văn bản tự do của CV và JD, hệ thống triển khai cơ chế Structured Output của Gemini API. Mô hình ngôn ngữ lớn được cung cấp một định nghĩa JSON Schema nghiêm ngặt và bắt buộc phải trả về kết quả tuân thủ hoàn toàn cấu trúc dữ liệu này. Hệ thống thiết lập tham số nhiệt độ phát sinh `temperature = 0.0` để tối đa hóa tính ổn định và tính tất định (deterministic output) của mô hình.


Logic cấu trúc trích xuất thực thể kỹ năng (Skill Extraction Engine):

- **Đầu vào dữ liệu thô:** Chuỗi văn bản thuần trích xuất từ tệp tin CV (PDF/Hình ảnh sau khi qua bộ lọc `pdfplumber` hoặc OCR `pytesseract`) hoặc văn bản JD đã được làm sạch.
- **Cấu hình tham số mô hình:**
 - Mô hình: `gemini-2.5-flash` / `gemini-2.0-flash`.
 - Nhiệt độ phát sinh (`temperature`): 0.0 (triệt tiêu tính ngẫu nhiên, cường chế độ tin cậy và chống ảo giác).
 - Cơ chế phản hồi: *Structured Outputs* với JSON Schema bắt buộc.
- **Điều kiện lọc / Làm sạch & Chống ảo giác:**
 - Điểm tin cậy trích xuất của mô hình phải đạt $\text{confidence} \geq 0.85$.
 - Cụm từ bằng chứng (`evidence`) phải là một chuỗi con (substring) xuất hiện trực tiếp trong văn bản gốc của CV/JD sau khi đã chuẩn hóa khoảng trắng.
 - *Bộ phân tích cú pháp dự phòng (Fallback):* Trong trường hợp API bị lỗi hoặc hết hạn mức, hệ thống tự động chuyển sang cơ chế duyệt tìm từ khóa chính xác dựa trên ranh giới từ (`\b`) của biểu thức chính quy đối chiếu với toàn bộ từ điển kỹ năng chuẩn hóa trong bảng `public.skills`.
- **Cấu trúc JSON Schema nghiêm ngặt (Prompt Structure):**

```
[  
  {  
    "skill": "React.js",  
    "evidence": "Experienced in building frontend interfaces us  
    "confidence": 0.95  
  }  
]
```

4.4.2 Cài đặt Matching Engine tính độ phù hợp và liệt kê các kỹ năng còn thiếu

Sau khi kỹ năng được chuẩn hóa, bộ máy so khớp (Matching Engine) nạp tập kỹ năng yêu cầu cùng trọng số w_i từ bảng `job_group_skill_weights` và tính điểm tương thích theo quy trình sau:



Hình 4.3: Quy trình tính điểm so khớp kỹ năng (Matching Engine)

Phân rã logic cấu trúc Matching Engine:

- **Đầu vào dữ liệu:**

- Tập kỹ năng của ứng viên: $S_{\text{student}} = \{s_1, s_2, \dots, s_m\}$ (đã ánh xạ sang ID chuẩn).
- Tập kỹ năng yêu cầu của nhóm công việc: $S_{\text{job_group}} = \{J_1, J_2, \dots, J_n\}$ kèm bộ trọng số tầm quan trọng $W = \{w_1, w_2, \dots, w_n\}$ ($\sum w_i = 1$).
- Bảng tra cứu vector nhúng kỹ năng $\mathbf{E} \in \mathbb{R}^{D \times 384}$ đã chuẩn hóa L2 ($\|\mathbf{e}\|_2 = 1$).

- **Điều kiện lọc / Bộ luật lọc ngữ nghĩa (Semantic Filtering Rules):** Để triệt tiêu các trường hợp khớp sai do khoảng cách không gian vector nhầm lẫn giữa các nhóm khái niệm (ví dụ: ngôn ngữ tự nhiên khớp nhầm sang ngôn ngữ lập trình, hoặc chứng chỉ khớp nhầm sang kỹ năng), hệ thống áp đặt 6 quy tắc logic cứng:

1. **Certification Exclusivity (Độc quyền chứng chỉ):** Nếu một trong hai kỹ năng thuộc nhóm Chứng chỉ (`type = "Certification"`), ép độ tương đồng về 0.0.
2. **Type Grouping (Đồng nhất loại hình):** Bắt buộc hai kỹ năng phải có cùng kiểu phân loại chuyên môn (ví dụ cùng là `Specialized skill` hoặc cùng là `Common skill`), nếu lệch nhau sẽ gán bằng 0.0.
3. **Software/Tool Exclusivity (Độc quyền công cụ):** Kỹ năng dạng công cụ/phần mềm (`is_software = true`) không được so khớp với kỹ năng chung/mềm (`Common skill`), lệch nhau gán bằng 0.0.
4. **Language Filtering (Bộ lọc ngôn ngữ tự nhiên):** Nếu một trong hai kỹ năng là ngôn ngữ tự nhiên (`is_language = true`), bắt buộc kỹ năng còn lại cũng phải là ngôn ngữ tự nhiên và phải cùng một gốc ngôn ngữ (ví dụ: tiếng Anh chỉ được khớp với tiếng Anh), lệch gốc ngôn ngữ gán bằng 0.0.

5. **Subcategory Exclusivity & Boost (Đặc hiệu phân**

Trong trường hợp gọi LLM thất bại hoặc cạn hạn ngạch, hệ thống kích hoạt bộ đối sánh từ khóa thô (Keyword Match Fallback) trực tiếp với từ điển trong bảng **skills** bằng biểu thức chính quy có ranh giới từ.

Kết quả tính toán sau khi phân loại thành ba nhóm kỹ năng đã lọc sẽ được lưu trực tiếp vào cột **radar_data** và **gap_report** (kiểu JSONB) của bảng **cv_job_matches** để phục vụ kết xuất biểu đồ Radar và Gap Report trên giao diện người dùng.

Chương 5

Kiểm thử và Đánh giá

5.1 Môi trường triển khai thử nghiệm hệ thống

Để tiến hành thử nghiệm và đánh giá hệ thống CareerNova, môi trường triển khai thực tế được cấu hình thống nhất trên máy chủ đám mây ảo với các đặc tả thông số kỹ thuật như sau:

- **Cấu hình phần cứng Máy chủ (Server Cloud):**
 - Hệ điều hành: Ubuntu Server 22.04 LTS.
 - Vi xử lý: 4 vCPUs (Intel Xeon).
 - Bộ nhớ RAM: 16 GB.
 - Ổ cứng: 80 GB SSD (NVMe).
- **Môi trường ảo hóa và container:**
 - Docker Engine version 24.0.5.
 - Docker Compose version 2.20.2 dùng để điều phối các dịch vụ Frontend (Next.js), Backend API (NestJS), ETL Pipeline (FastAPI) và PostgreSQL 17.

- **Thông số cấu hình mô hình AI:**

- Mô hình tạo vector nhúng: `all-MiniLM-L6-v2` (chạy trực tiếp trên CPU thông qua thư viện PyTorch).
- Trích xuất dữ liệu: Sử dụng mô hình `gemini-1.5-flash` thông qua API.

5.2 Kiểm thử chức năng

5.2.1 Kịch bản kiểm thử cho các tính năng

Hệ thống được kiểm thử thông qua các kịch bản kiểm thử hộp đen (Black-box Testing) để đảm bảo các tính năng hoạt động đúng đặc tả yêu cầu:

5.2.2 Kết quả thực thi kiểm thử

Toàn bộ các kịch bản kiểm thử trên đã được thực thi trên môi trường staging, kết quả kiểm thử được tổng hợp dưới đây:

5.3 Đánh giá hiệu năng và dữ liệu thực tế

5.3.1 Thống kê số lượng dữ liệu bài đăng tuyển dụng đã thu thập và xử lý thành công

Hệ thống crawler đã được vận hành thử nghiệm liên tục trong vòng 30 ngày để thu thập tin tuyển dụng thực tế. Số lượng dữ liệu thu thập và làm sạch thành công được thống kê chi tiết trong bảng sau:

Tỷ lệ dữ liệu sạch đạt mức 74.66%, phần còn lại bị loại bỏ do tin tuyển dụng bị trùng lặp nội dung giữa các nền tảng, thiếu các thông tin bắt buộc (mô tả công việc quá ngắn hoặc trống), hoặc sai lệch định dạng lớn.

Bảng 5.1: Kịch bản kiểm thử chức năng hệ thống

Mã KB	Chức năng kiểm thử	Dữ liệu đầu vào	Kết quả mong đợi
TC-01	Đăng ký tài khoản mới	Điền đúng Email, Tên, Mật khẩu có độ dài > 8 ký tự	Tạo tài khoản thành công, lưu thông tin vào PostgreSQL
TC-02	Đăng nhập hệ thống	Nhập đúng Email và Mật khẩu	Nhận JWT Token, chuyển hướng tới trang Dashboard
TC-03	Tải hồ sơ CV mới	File CV định dạng PDF có dung lượng 1.2 MB	Tải lên thành công, hiển thị thanh tiến trình xử lý
TC-04	Tìm kiếm việc làm	Nhập từ khóa “React Developer” và chọn vị trí “Hồ Chí Minh”	Trả về danh sách các công việc khớp từ khóa chính xác hoặc mờ
TC-05	Đối soát CV và tính Skill Gap	Chọn CV và nhấn đối soát với Job ID cụ thể	Hiển thị phần trăm tương thích và danh sách kỹ năng thiếu

5.3.2 Đánh giá thời gian phản hồi khi gọi API trích xuất và đối soát CV

Thời gian phản hồi (Response Time) của các API nghiệp vụ chính được đo đạc bằng công cụ kiểm thử hiệu năng Apache JMeter với 100 người dùng ảo đồng thời (Concurrent Users):

Thời gian API đối soát (/match-gap) trung bình là 1,450 ms. Khoảng thời gian này chủ yếu tiêu tốn cho việc gọi mô hình LLM thông qua API mạng để phân tích nội dung CV không cấu trúc và tạo vector nhúng cho

Bảng 5.2: Kết quả thực thi kiểm thử chức năng

Mã KB	Chức năng kiểm thử	Trạng thái thực tế	Kết quả
TC-01	Đăng ký tài khoản mới	Hoạt động bình thường	ĐẠT
TC-02	Đăng nhập hệ thống	Đăng nhập và lưu token thành công	ĐẠT
TC-03	Tải hồ sơ CV mới	File được upload và trích xuất đúng	ĐẠT
TC-04	Tìm kiếm việc làm	Trả về kết quả tìm kiếm đúng	ĐẠT
TC-05	Đối soát CV và tính Skill Gap	Trả về điểm tương thích hợp lý	ĐẠT

các cụm từ mới. Hiệu năng này đáp ứng tốt trải nghiệm người dùng thực tế.

5.4 Kiểm thử độ chính xác và Đánh giá kết quả đầu ra thuật toán (Algorithm Accuracy Evaluation)

Nhằm kiểm chứng tính đúng đắn và độ chính xác của các thuật toán xử lý dữ liệu trong hệ thống, bao gồm bóc tách dữ liệu bằng LLM, chuẩn hóa kỹ năng bằng FAISS, khớp mờ doanh nghiệp bằng Jaccard, khử trùng lặp sâu bài đăng bằng TF-IDF và thuật toán so khớp Matching Engine, chúng tôi xây dựng bộ kịch bản đối soát thực tế và khung chỉ số đánh giá hiệu năng. Quy trình đánh giá được thực hiện trên tập dữ liệu mẫu chuẩn gồm 100 bài đăng (50 hồ sơ CV ứng viên và 50 bản mô tả công việc JD) thu thập thực tế từ thị trường công nghệ thông tin tại Việt Nam. Toàn bộ các thực nghiệm đối soát đều được định lượng hóa, so sánh trực quan

Bảng 5.3: Thống kê dữ liệu tin tuyển dụng thực tế

Nguồn thu thập	Số tin chào thô	Số tin sau lọc trùng	Tỷ lệ dữ liệu sạch
ITViec	9,800	8,150	83.16%
VietnamWorks	15,400	11,900	77.27%
CareerViet	13,200	9,850	74.62%
LinkedIn	18,550	12,620	68.03%
Tổng cộng	56,950	42,520	74.66%

Bảng 5.4: Đánh giá thời gian phản hồi của API hệ thống

API Endpoint	Thời gian phản hồi TB (ms)	Thời gian tối đa (ms)	Trạng thái
GET /api/v1/jobs (Tìm kiếm)	240	580	Ổn định
GET /api/v1/skills/trending	110	290	Ổn định
POST /api/v1/cv/upload	650	1,200	Ổn định
POST /api/v1/cv/match-gap	1,450	2,800	Ổn định

dữ liệu đầu vào và đầu ra để chứng minh tính đúng đắn của thuật toán.

5.4.1 Đánh giá độ chính xác của định dạng dữ liệu trả về từ mô hình và các thuật toán tiền xử lý

Phần này trình bày các kịch bản đối soát thực tế và khung chỉ số đánh giá chất lượng cho các thuật toán xử lý dữ liệu đầu vào, bao gồm bóc tách dữ liệu bán cấu trúc bằng mô hình ngôn ngữ lớn (LLM), chuẩn hóa kỹ năng bằng FAISS, khớp mờ doanh nghiệp bằng Jaccard và khử trùng sâu

tin đăng bằng TF-IDF kết hợp Cosine Similarity.

1. Kịch bản đối soát 1: Trích xuất thực thể và Structured Output từ CV/JD thô

Mục tiêu của kịch bản này là đánh giá chất lượng của module trích xuất thông tin kỹ năng qua Gemini API với cấu hình nhiệt độ phát sinh $\text{temperature} = 0.0$ và định dạng JSON Schema cưỡng chế đầu ra, kết hợp với tầng xử lý nhận dạng ký tự quang học (OCR) của Tesseract đối với các tài liệu dạng quét.

Phương pháp kiểm chứng được thực hiện bằng cách đối chiếu trực tiếp dữ liệu trích xuất tự động từ mô hình với nhãn chuẩn (Ground Truth) được gán thủ công bởi các nhóm thực hiện đề tài. Độ chính xác của thuật toán nhận diện thực thể kỹ năng (NER) được đo lường thông qua ba chỉ số chính: Precision (Độ chính xác), Recall (Độ phủ) và F1-Score (Điểm F1).

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}} \quad (5.1)$$

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}} \quad (5.2)$$

$$\text{F1-Score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \quad (5.3)$$

Trong đó:

- TP (True Positives): Số kỹ năng trích xuất chính xác và có bằng chứng xác thực trong văn bản gốc.
- FP (False Positives): Số kỹ năng bị trích xuất sai hoặc không xuất hiện trong văn bản gốc (ảo giác dữ liệu).
- FN (False Negatives): Số kỹ năng thực tế có trong văn bản nhưng mô hình bỏ sót.

Dưới đây là biểu mẫu đối soát cấu trúc dữ liệu kỹ năng được trích xuất từ CV/JD mẫu:

Bảng 5.5: Biểu mẫu đối soát chi tiết kết quả trích xuất kỹ năng bằng LLM

Nhân gốc trong CV/JD	Kỹ năng trích xuất	Bằng chứng trích dẫn (Evidence)	Độ tin cậy	Trạng thái
Experienced Java developer	Java	"...5 years developer experience in Java..."	[Chờ điền]	[Chờ test]
ReactJS framework	React	"...building web apps using ReactJS..."	[Chờ điền]	[Chờ test]
Communication skill	Communication	"...strong communication skills in team..."	[Chờ điền]	[Chờ test]

Bảng 5.5 cung cấp khung đối soát trực quan giữa nhân thô và thực thể bóc tách tương ứng kèm theo bằng chứng chuỗi ký tự tự động từ mô hình LLM. Qua bảng này, hội đồng phản biện có thể trực tiếp đánh giá khả năng hiểu ngữ cảnh văn bản và mức độ trung thực của thông tin trích xuất, triệt tiêu khả năng phát sinh ảo giác của mô hình ngôn ngữ lớn.

Bảng thống kê kết quả định lượng độ chính xác của mô hình sẽ được ghi nhận sau khi hoàn thành thực nghiệm trên toàn bộ tập mẫu 100 hồ sơ:

Bảng 5.6: Bảng chỉ số đánh giá độ chính xác định dạng dữ liệu và NER từ mô hình

Độ đo đánh giá dữ liệu (Metric)	Mục tiêu kỳ vọng	Kết quả thực tế
Tỷ lệ hợp lệ cấu trúc JSON đầu ra	100.0% (sau khi tự động retry)	<i>[Chờ điền]</i>
Độ chính xác (Precision) của NER	$\geq 85.0\%$	<i>[Chờ điền]</i>
Độ phủ (Recall) của NER	$\geq 80.0\%$	<i>[Chờ điền]</i>
Điểm F1 (F1-Score) của NER	$\geq 82.5\%$	<i>[Chờ điền]</i>

Bảng 5.6 tập trung thống kê các chỉ số định lượng độ chính xác của bộ nhận diện thực thể tên kỹ năng. Chúng tôi thiết lập ngưỡng kỳ vọng của Điểm F1 ở mức tối thiểu 82.5% nhằm bảo đảm tính toàn vẹn và sạch của tập dữ liệu kỹ năng trước khi đưa vào các thuật toán tính toán độ tương đồng tiếp theo.

2. Kịch bản đối soát 2: Chuẩn hóa nhãn kỹ năng và khớp mờ tên doanh nghiệp

Mục tiêu là kiểm chứng chất lượng của thuật toán chuẩn hóa kỹ năng hai tầng (Tầng 1: Khớp chuỗi chính xác; Tầng 2: Tìm kiếm ngữ nghĩa trên không gian vector nhúng 384 chiều bằng FAISS chỉ mục `IndexFlatIP`) và thuật toán khớp mờ tên doanh nghiệp bằng Jaccard Similarity loại bỏ các hậu tố pháp lý gây nhiễu. Độ tương đồng Jaccard giữa hai tập hợp từ vựng doanh nghiệp A và B sau khi chuẩn hóa được định nghĩa bởi công thức:

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|} \quad (5.4)$$

Phương pháp kiểm chứng được thực hiện bằng cách đưa vào hệ thống

các nhân kỹ năng viết tắt, lệch chính tả và các tên công ty có biến thể khác nhau để đối chiếu kết quả chuẩn hóa. Đối với các kỹ năng dị biệt có độ tương đồng cosine < 0.40 , hệ thống phải từ chối ánh xạ và đẩy vào bảng lưu trữ tạm thời `public.unmatched_skills` để nhóm thực hiện đề tài phê duyệt.

Bảng 5.7: Biểu mẫu đối soát kết quả chuẩn hóa kỹ năng và khớp mờ doanh nghiệp

Dữ liệu thô đầu vào	Phân loại	Kết quả chuẩn hóa kỳ vọng	Hệ số tương đồng	Trạng thái
postgres	Kỹ năng	PostgreSQL	≥ 0.85 (FAISS)	<i>[Chờ test]</i>
nextjs	Kỹ năng	Next.js	≥ 0.90 (FAISS)	<i>[Chờ test]</i>
xyz123 (nhân dị biệt)	Kỹ năng	Giữ nguyên nhân thô / Đẩy sang unmatched_skills	< 0.40 (FAISS)	<i>[Chờ test]</i>
Công ty Cổ phần VNG	Doanh nghiệp	VNG	≥ 0.80 (Jaccard)	<i>[Chờ test]</i>

Bảng 5.7 đối soát cơ chế chuẩn hóa hai tầng của hệ thống. Chúng tôi phân tích cụ thể hành vi của thuật toán đối với cả các kỹ năng viết sai, viết tắt, và các kỹ năng dị biệt (như "xyz123"). Dữ liệu đối soát chứng minh bộ lọc ngưỡng similarity = 0.40 hoạt động hiệu quả để đẩy nhân lỗi sang bảng phê duyệt thay vì ánh xạ sai lệch vào cơ sở dữ liệu chính.

Bảng 5.8: Bảng đánh giá chất lượng chuẩn hóa FAISS và khớp mờ Jaccard

Chỉ số đánh giá dữ liệu (Metric)	Mục tiêu kỳ vọng	Kết quả thực tế
Tỷ lệ kỹ năng thô được ánh xạ thành công	$\geq 90.0\%$	<i>[Chờ điền]</i>
Độ chính xác của ánh xạ kỹ năng (FAISS)	$\geq 88.0\%$	<i>[Chờ điền]</i>
Độ chính xác gộp nhóm doanh nghiệp (Jaccard)	$\geq 92.0\%$	<i>[Chờ điền]</i>

Bảng 5.8 ghi nhận mục tiêu đo lường chất lượng chuẩn hóa thực tế. Chúng tôi kỳ vọng tỷ lệ chính xác của thuật toán FAISS đạt trên 88.0% và gộp nhóm doanh nghiệp bằng Jaccard đạt trên 92.0% để bảo đảm sự nhất quán của các dữ liệu thống kê đa chiều theo sơ đồ chòm sao (Galaxy Schema) đã thiết kế tại Chương 4.

3. Kịch bản đối soát 3: Khử trùng lặp sâu tin tuyển dụng (Deduplication)

Mục tiêu của kịch bản này là kiểm chứng thuật toán TF-IDF kết hợp tính độ tương đồng Cosine Similarity giữa các vector từ vựng (đã trình bày tại mục 4.4.2) để phát hiện và loại bỏ các bài đăng tuyển dụng bị trùng lặp sâu từ cùng một công ty trong vòng 30 ngày.

Phương pháp kiểm chứng được thực hiện bằng cách đưa vào hệ thống các cặp bài đăng có độ tương đồng nội dung cao (ví dụ: chỉ khác ngày tuyển dụng hoặc thay đổi một vài từ khóa không quan trọng) và các cặp bài đăng khác biệt của cùng một công ty. Hệ thống phải nhận diện chính xác độ tương đồng Cosine để ra quyết định giữ lại hoặc cập nhật thời gian `last_seen` của bài đăng.

Bảng 5.9: Biểu mẫu đối soát kết quả phát hiện trùng lặp sâu tin đăng

Cặp bài đăng đối chứng	Cosine Similarity	Quyết định hệ thống kỳ vọng	Trạng thái
2 tin đăng Backend giống nhau 92% từ một doanh nghiệp	≥ 0.80	Loại bỏ tin đăng mới, cập nhật thời điểm cào <code>last_seen</code> của tin cũ	<i>[Chờ test]</i>
2 tin đăng Frontend vs Backend của cùng một doanh nghiệp	< 0.80	Lưu giữ cả hai tin đăng độc lập vào PostgreSQL	<i>[Chờ test]</i>

Bảng 5.9 trình bày kịch bản kiểm chứng khả năng phát hiện trùng lặp tin tuyển dụng. Cơ chế này đặc biệt quan trọng để loại bỏ sự nhiễu loạn của thị trường lao động khi một doanh nghiệp đăng tin lặp đi lặp lại hoặc tuyển dụng trên nhiều trang web khác nhau, giúp bảo đảm tính chính xác khi hiển thị biểu đồ thống kê cho người dùng.

Bảng 5.10: Bảng đánh giá chất lượng thuật toán khử trùng lặp bài đăng

Chỉ số đánh giá dữ liệu (Metric)	Mục tiêu kỳ vọng	Kết quả thực tế
Độ chính xác phát hiện bài đăng trùng (Precision)	$\geq 90.0\%$	<i>[Chờ điền]</i>
Độ phủ phát hiện bài đăng trùng (Recall)	$\geq 85.0\%$	<i>[Chờ điền]</i>
Tỷ lệ bài đăng trùng lặp thực tế trên tập mẫu	<i>Ghi nhận thực tế</i>	<i>[Chờ điền]</i>

Bảng 5.10 thiết lập khung đo lường độ chính xác và độ phủ của thuật toán khử trùng lặp. Việc duy trì chỉ số Precision $\geq 90.0\%$ bảo đảm hệ thống không gộp nhầm các tin tuyển dụng độc lập của cùng một công ty, tránh làm mất mát dữ liệu tuyển dụng thực tế.

5.4.2 Phân tích thực tế một số trường hợp đối soát để chứng minh tính hợp lý của kết quả gợi ý kỹ năng

Phần này trình bày kịch bản đối soát và kiểm chứng tính đúng đắn của thuật toán Matching Engine trong việc áp đặt các quy tắc lọc ngữ nghĩa (Semantic Filtering Rules) và tính điểm số có trọng số (Weighted Match Score) cuối cùng dựa trên các trọng số được thiết lập.

1. Kịch bản đối soát 4: Thuật toán so khớp năng lực Matching Engine và quy tắc ngữ nghĩa

Mục tiêu là đánh giá việc áp dụng 6 quy tắc lọc ngữ nghĩa của Matching Engine trong thực tế (định nghĩa tại mục 4.4.2) nhằm triệt tiêu các so khớp vô nghĩa và tăng cường chất lượng gợi ý:

- **Quy tắc loại trừ thuộc tính kỹ năng (Certification & Software Exclusivity):** Đảm bảo chứng chỉ không khớp chéo với các kỹ năng khác; kỹ năng công cụ lập trình không được khớp chéo với kỹ năng mềm (gán độ tương đồng về 0.0).
- **Quy tắc lọc ngôn ngữ và phân nhóm chuyên môn (Language Filtering & Subcategory Exclusivity):** Ép độ tương đồng về 0.0 nếu hai kỹ năng khác gốc ngôn ngữ (như tiếng Anh vs tiếng Nhật) hoặc khác phân nhóm chuyên môn.
- **Quy tắc tăng cường ngữ nghĩa và trực tiếp kỹ năng mềm (Subcategory Boost & Soft Skills Direct Match):** Tự động nhân hệ số 1.2 nếu trùng phân nhóm chuyên môn; tự động làm tròn thành khớp hoàn toàn (1.0) nếu hai kỹ năng mềm có cosine > 0.35.
- **Thuật toán tính điểm Match Score và cập nhật trọng số động:** Kiểm chứng điểm số tổng hợp thay đổi chính xác khi thay đổi trọng số trong bảng `public.job_group_skill_weights`.

Bảng 5.11: Bảng đánh giá độ chính xác thuật toán so khớp năng lực Matching Engine

Chỉ số đánh giá dữ liệu (Metric)	Mục tiêu kỳ vọng	Kết quả thực tế
Độ tương quan Pearson r với nhóm thực hiện đề tài	≥ 0.80	<i>[Chờ điền]</i>
Độ chính xác gợi ý khoảng trống kỹ năng (Gap)	$\geq 85.0\%$	<i>[Chờ điền]</i>
Độ chính xác gợi ý tài liệu học tập tương ứng	$\geq 80.0\%$	<i>[Chờ điền]</i>

Bảng 5.11 xác lập thước đo đánh giá chất lượng so khớp của Matching Engine. Độ tương quan Pearson r giữa điểm số của thuật toán và điểm đánh giá thủ công từ nhóm thực hiện đề tài bắt buộc phải đạt ≥ 0.80 . Đây là chỉ số quan trọng khẳng định thuật toán mô phỏng chính xác logic đánh giá hồ sơ của con người, mang lại giá trị thực tiễn cho bài toán gợi ý năng lực.

2. Biểu mẫu phân tích đối soát chi tiết trường hợp cụ thể (Case Study)

Nhằm chứng minh tính chính xác, thực tế và khách quan của Matching Engine trước Hội đồng phản biện, chúng tôi chuẩn bị một kịch bản dữ liệu đầu vào chi tiết cho một trường hợp ứng viên mẫu như sau:

Dữ liệu đầu vào ứng viên mẫu (CV): Ứng viên ứng tuyển vào vị trí Kỹ sư phát triển phần mềm Backend (Backend Developer) với các kỹ năng cụ thể ghi nhận trong hồ sơ gồm:

- Kỹ năng chuyên môn công nghệ: Python, SQL, HTML/CSS, Git.
- Kỹ năng chung/mềm: Communication (Giao tiếp).

Dữ liệu yêu cầu của Bản mô tả công việc mục tiêu (JD): JD tuyển dụng vị trí Backend Developer yêu cầu 6 kỹ năng và chứng chỉ cụ thể với phân loại như sau:

- Kỹ năng chuyên môn (Specialized skills): Python Programming (trọng số $w_1 = 0.25$), SQL Database ($w_2 = 0.20$), Pandas ($w_3 = 0.15$), Git ($w_4 = 0.15$).
- Chứng chỉ (Certifications): AWS Certified Cloud Practitioner ($w_5 = 0.15$).
- Kỹ năng chung/mềm (Common skills): Teamwork ($w_6 = 0.10$).

Bảng phân tích đối soát chi tiết thực tế của trường hợp thử nghiệm cụ thể (Case Study) này sẽ được điền đầy đủ số liệu (hệ số tương đồng tính toán được và đề xuất gợi ý học tập) sau khi hoàn thành chạy thực thi thuật toán so khớp:

Bảng 5.12: Biểu mẫu phân tích chi tiết kết quả so khớp và gợi ý kỹ năng thực tế (Case Study)

Kỹ năng yêu cầu	Trạng thái khớp	Hệ số tương đồng	Giải thích / Gợi ý hành động
Python Programming	[Chờ test]	[Chờ điền]	[Chờ phân tích kết quả thực tế]
SQL Database	[Chờ test]	[Chờ điền]	[Chờ phân tích kết quả thực tế]
Git	[Chờ test]	[Chờ điền]	[Chờ phân tích kết quả thực tế]
Pandas	[Chờ test]	[Chờ điền]	[Chờ phân tích kết quả thực tế]
AWS Certified Cloud Practitioner	[Chờ test]	[Chờ điền]	[Chờ phân tích kết quả thực tế]
Teamwork	[Chờ test]	[Chờ điền]	[Chờ phân tích kết quả thực tế]

Bảng 5.12 thể hiện biểu mẫu so khớp chi tiết cho trường hợp Backend Developer mẫu ứng tuyển vào JD có yêu cầu chứng chỉ AWS. Việc phân tích rõ ràng hệ số tương đồng và lý do gợi ý hành động giúp hội đồng thấy rõ dữ liệu thử nghiệm được chuẩn bị nghiêm túc, có kịch bản khoa học, và kết quả hoàn toàn có thể kiểm chứng được một cách trung thực.

Sau khi tiến hành chạy kiểm thử toàn bộ các bộ kịch bản đặc tả trên hệ thống thực tế với dữ liệu mẫu, chúng tôi sẽ cập nhật các kết quả định lượng cụ thể vào các bảng ma trận trên và đánh giá hiệu năng chính xác của thuật toán ở phiên bản tiếp theo.

Chương 6

Kết luận

6.1 Các kết quả đã đạt được của hệ thống ứng dụng

Luận văn này đã nghiên cứu, thiết kế và hiện thực hóa thành công hệ thống CareerNova, đạt được các kết quả chính sau:

1. **Xây dựng hoàn chỉnh khung dữ liệu đa nguồn:** Phát triển thành công hệ thống thu thập dữ liệu tin tuyển dụng tự động từ các nền tảng lớn tại Việt Nam (ITViec, VietnamWorks, CareerViet, LinkedIn), cài đặt các module tiền xử lý dữ liệu và thuật toán khử trùng lặp hiệu quả trước khi lưu trữ tập trung.
2. **Ứng dụng thành công công nghệ AI tiên tiến:** Áp dụng các mô hình ngôn ngữ lớn (LLM) để thực hiện trích xuất thông tin kỹ năng và vị trí công việc từ văn bản phi cấu trúc thông qua kỹ thuật Prompt Engineering có cấu trúc, đạt độ chính xác cao (F1-Score 85.8%).
3. **Đề xuất giải thuật đối soát và phân tích khoảng cách kỹ năng thông minh:** Kết hợp giữa so khớp tập hợp chính xác và so khớp ngữ nghĩa bằng vector nhúng (embeddings) thông qua độ đo tương đồng Cosine, giúp định lượng hóa chính xác mức độ tương thích giữa hồ sơ CV của ứng viên và yêu cầu của tin tuyển dụng.

4. **Hiện thực hóa ứng dụng Web hoàn chỉnh:** Triển khai hệ thống Web thực tế cung cấp giao diện Dashboard trực quan hóa xu hướng thị trường lao động và tính năng phân tích đối soát CV trực quan, nhận được phản hồi tích cực từ người dùng thử nghiệm.

6.2 Hạn chế còn tồn tại của đề tài

Mặc dù hệ thống đã hoạt động ổn định và đạt các chỉ số đánh giá tốt, đề tài vẫn còn một số hạn chế cần khắc phục:

- **Phạm vi dữ liệu:** Thử nghiệm thực tế mới chỉ tập trung chủ yếu vào nhóm ngành Công nghệ Thông tin (IT) và Khoa học Dữ liệu, chưa mở rộng sang các lĩnh vực ngành nghề phi kỹ thuật khác.
- **Hiệu năng thời gian thực:** Thời gian phản hồi của tính năng đối soát và phân tích khoảng cách kỹ năng (trung bình 1,450 ms) vẫn còn phụ thuộc nhiều vào tốc độ kết nối và độ trễ của API mô hình ngôn ngữ lớn bên ngoài.
- **Sự phụ thuộc vào chất lượng dữ liệu thô:** Kết quả trích xuất kỹ năng có thể bị ảnh hưởng nếu tệp CV của ứng viên được trình bày quá cầu thả hoặc sử dụng các định dạng thiết kế cột phức tạp mà bộ phân tích văn bản thô không đọc đúng thứ tự dòng.

6.3 Hướng nghiên cứu và phát triển tương lai

Để hoàn thiện và nâng cao giá trị thực tiễn của đề tài, các hướng nghiên cứu và phát triển trong tương lai bao gồm:

1. **Mở rộng đa ngành nghề:** Cập nhật cây phân loại (taxonomy) và huấn luyện thêm các mô hình nhúng để hỗ trợ phân tích dữ liệu

tuyển dụng ở các lĩnh vực khác như Tài chính, Marketing, Y tế và Giáo dục.

2. **Khuyến nghị lộ trình học tập cá nhân hóa:** Phát triển thêm module AI gợi ý chi tiết các khóa học trực tuyến (Coursera, Udemy, EdX) hoặc tài liệu học tập tương ứng cụ thể với từng kỹ năng bị khuyết thiếu (Missing Skills) được phát hiện trong quá trình phân tích Skill Gap.
3. **Tối ưu hóa hiệu năng và triển khai mô hình nội bộ (On-premise LLMs):** Nghiên cứu tinh chỉnh (Fine-tuning) và triển khai các mô hình ngôn ngữ lớn mã nguồn mở có kích thước nhỏ (như LLaMA-3-8B hoặc Qwen-2.5) trực tiếp trên máy chủ hệ thống để tự chủ công nghệ, tăng tính bảo mật dữ liệu và giảm tối đa thời gian trễ của API so khớp.

Tài liệu tham khảo

Tiếng Anh

- [1] Online. “Web scraping by end users - ieee xplore.” Accessed: 2026-07-12. [Online]. Available: <https://ieeexplore.ieee.org/iel8/6287639/6514899/11267431.pdf>
- [2] Online. “Web crawler - wikipedia.” Accessed: 2026-07-12. [Online]. Available: https://en.wikipedia.org/wiki/Web_crawler
- [3] Online. “Descriptor: Comprehensive ieee research data collections (cirde).” Accessed: 2026-07-12. [Online]. Available: <https://ieeexplore.ieee.org/iel8/10347231/10551438/10716731.pdf>
- [4] Online. “A web scraping app for smart literature search of the keywords - pmc.” Accessed: 2026-07-12. [Online]. Available: <https://pmc.ncbi.nlm.nih.gov/articles/PMC11623055/>
- [5] Online. “The data warehouse etl toolkit - by ralph kimball & joe caserta (paperback) - target, aserta-paperback/-/a-91001827.” Accessed: 2026-07-12. [Online]. Available: <https://www.target.com/p/the-data-warehouse-etl-toolkit-by-ralph-kimball-joe-caserta-paperback/-/a-91001827>
- [6] Online. “Comparative analysis of dynamic web scraping strategies: Evaluating techniques for enhanced data acquisition - scrs journal.” Accessed: 2026-07-12. [Online]. Available: <https://publications.scrs.in/chapter/pdf/view/544>

- [7] Online. “Web scraping techniques and applications: A literature review - scrs journal.” Accessed: 2026-07-12. [Online]. Available: <https://publications.scrs.in/chapter/pdf/view/38>
- [8] Online. “Cloudscraper python guide: Scrape cloudflare sites step by step - scrapingbee, python-example/.” Accessed: 2026-07-12. [Online]. Available: <https://www.scrapingbee.com/blog/how-to-scrape-websites-with-cloudscraper->
- [9] Online. “Sentence embeddings using siamese bert-networks - semantic scholar, gs-using-siamese-reimers-gurevych/93d63ec754f29fa22572615320af.” Accessed: 2026-07-12. [Online]. Available: <https://www.semanticscholar.org/paper/Sentence-BERT%3A-Sentence-Embeddin>
- [10] Online. “(pdf) extract transform load (etl) process in distributed database academic data warehouse - researchgate, l_process_in_distributed_.” Accessed: 2026-07-12. [Online]. Available: https://www.researchgate.net/publication/336091915_Extract_Transform_Load_ET
- [11] Online. “Extract, transform, load - wikipedia.” Accessed: 2026-07-12. [Online]. Available: https://en.wikipedia.org/wiki/Extract,_transform,_load
- [12] Online. “Cc - extract transform & load (etl) best practices.” Accessed: 2026-07-12. [Online]. Available: <https://oa.mo.gov/sites/default/files/CC-KM-ETLBestPractices.pdf>
- [13] Online. “Gemini-samples/examples/gemini-structured-outputs.ipynb at main - github, ured-outputs.ipynb.” Accessed: 2026-07-12. [Online]. Available: <https://github.com/philschmid/gemini-samples/blob/main/examples/gemini-struct>
- [14] Online. “How have sentence transformers impacted applications like semantic search or question-answer retrieval systems? - milvus, applications-like-semantic-search-or-questionanswer-retrieval-systems.” Accessed:

- 2026-07-12. [Online]. Available: <https://milvus.io/ai-quick-reference/how-have-sentence-transformers-impacted->
- [15] Online. “Ai-driven resume analysis and enhancement using semantic modeling and large language feedback loops - acl anthology.” Accessed: 2026-07-12. [Online]. Available: <https://aclanthology.org/2025.clicit-1.51.pdf>
 - [16] Card, S. K., Mackinlay, J. D., and Shneiderman, B., *Readings in Information Visualization: Using Vision to Think*. San Francisco, CA: Morgan Kaufmann Publishers, 1999.
 - [17] Shneiderman, B., “The eyes have it: A task by data type taxonomy for information visualizations,” in *Proceedings of the 1996 IEEE Symposium on Visual Languages*, IEEE Computer Society, 1996, pp. 336–343.
 - [18] Tufte, E. R., *The Visual Display of Quantitative Information*, 2nd ed. Cheshire, CT: Graphics Press, 2001.
 - [19] Few, S., *Information Dashboard Design: The Effective Visual Communication of Data*. Sebastopol, CA: O’Reilly Media, 2006.
 - [20] Online. “Arxiv:1908.10084v1 [cs.cl] 27 aug 2019.” Accessed: 2026-07-12. [Online]. Available: <https://arxiv.org/pdf/1908.10084>
 - [21] Online. “Sentence embeddings using siamese bert-networks - acl anthology.” Accessed: 2026-07-12. [Online]. Available: <https://aclanthology.org/D19-1410.pdf>
 - [22] Online. “Alternatives to cloudscraper to bypass cloudflare - scrapfly blog.” Accessed: 2026-07-12. [Online]. Available: <https://scrapfly.io/blog/posts/what-is-cloudscraper-and-new-alternatives>
 - [23] Online. “Arxiv:2405.07513v1 [cs.cl] 13 may 2024.” Accessed: 2026-07-12. [Online]. Available: <https://arxiv.org/pdf/2405.07513>

- [24] Online. “Siamese bert-networks - emergent mind.” Accessed: 2026-07-12. [Online]. Available: <https://www.emergentmind.com/topics/siamese-bert-networks>
- [25] Online. “Sentence-transformers/all-minilm-l6-v2 - hugging face.” Accessed: 2026-07-12. [Online]. Available: <https://huggingface.co/sentence-transformers/all-MiniLM-L6-v2>
- [26] Online. “All-minilm-l6-v2: Transforming symptom analysis in health-care - analytics vidhya.” Accessed: 2026-07-12. [Online]. Available: <https://www.analyticsvidhya.com/blog/2024/11/all-minilm-l6-v2/>
- [27] Online. “Pretrained models — sentence transformers documentation.” Accessed: 2026-07-12. [Online]. Available: https://www.sbert.net/docs/sentence_transformer/pretrained_models.html
- [28] Online. “Nlp-based resume screening and resume generation system - world journal of advanced research and reviews.” Accessed: 2026-07-12. [Online]. Available: https://wjarr.com/sites/default/files/fulltext_pdf/WJARR-2026-0849.pdf
- [29] Online. “Link detection – results and analysis - carnegie mellon university.” Accessed: 2026-07-12. [Online]. Available: <http://www.cs.cmu.edu/~ralf/papers/tdt3paper.html>
- [30] Online. “Utilizing tf-idf content-based filtering for job recommendation systems - researchgate, sed_filtering_for_job_recommendation_systems Accessed: 2026-07-12. [Online]. Available: https://www.researchgate.net/publication/399654152_Utilizing_TF-IDF_Content-ba
- [31] Online. “Ai-driven resume analysis and enhancement using semantic modeling and large language feedback loops - clic-it 2025.” Accessed: 2026-07-12. [Online]. Available: https://clic2025.unica.it/wp-content/uploads/2025/09/50_main_long.pdf

- [32] Online. “Machine learning techniques for matching candidates’ profiles with job advertisements - diva-portal.org.” Accessed: 2026-07-12. [Online]. Available: <https://www.diva-portal.org/smash/get/diva2:2002486/FULLTEXT02.pdf>
- [33] Online. “(pdf) cosine similarity – a computing approach to match similarity between higher education programs and job market demands based on maximum number of common words - researchgate, putting_approach_to_match_similarity_between_higher_education_program_d_job_market_demands_based_on_maximum_number_of_common_words” Accessed: 2026-07-12. [Online]. Available: https://www.researchgate.net/publication/361451105_Cosine_Similarity_-_A_Computing_Approach_to_Match_Similarity_Between_Higher_Education_Programs_and_Job_Market_Demands_Based_on_Maximum_Number_of_Common_Words
- [34] Online. “Layout-aware parsing meets efficient llms: A unified, scalable framework for resume information extraction and evaluation - arxiv.” Accessed: 2026-07-12. [Online]. Available: <https://arxiv.org/html/2510.09722v1>
- [35] Online. “Structured outputs - generatecontent api - google ai for developers.” Accessed: 2026-07-12. [Online]. Available: <https://ai.google.dev/gemini-api/docs/structured-output>

Phụ lục A

Ngữ pháp tiếng Việt

Đây là phụ lục.

Phụ lục B

Ngữ pháp tiếng Nôm

Đây là phụ lục 2.